

ABD-Net: 具有注意力但多样化的行人重识别

陈天龙¹, 丁少进^{1*}, 谢静怡^{2*}, 袁野¹, 陈舞阳¹, 杨阳³, 任周⁴, 王张阳¹

1 德克萨斯 A&M 大学, 2 中国科学技术大学, 3 沃尔玛科技, 4Wormpex 人工智能研究院

{@tamueduhsfzxy@mail.ustc.edu.cn yang2@walmart.com zhou.ren@bianlifeng.com}

q.com

<https://github.com/TAMU-VITA/ABD-Net>

摘要

注意力机制已被证实对行人重识别 (Re-ID) 有效。然而, 学到的“注意力”特征通常并非自然不相关或“多样化”, 这会影响基于欧氏距离的检索性能。我们提出一种注意力但多样化网络 (ABD-Net), 主张在行人重识别中结合注意力和多样性的互补优势。ABD-Net 将注意力模块和多样性正则化无缝集成到整个网络中, 以学习具有代表性、鲁棒性且更具判别力的特征。具体而言, 我们引入一对互补的注意力模块, 分别专注于通道聚合和位置感知。然后, 我们加入一种新颖的正交性约束, 有效地在隐藏激活和权重上增强多样性。通过大量的消融研究, 我们证实注意力项和多样性项均有助于提升 ABD-Net 的性能。在三个主流的行人重识别基准测试中, 它始终优于现有的最先进方法。

引言

行人重识别 (Re-ID) 旨在跨不同时间和地点关联个体身份。它在智能视频监控中有着诸多应用。给定一张查询图像和大量的图库图像, 行人重识别会用特征嵌入来表示每张图像, 然后根据特征嵌入与查询图像的相似度对图库图像进行排序。尽管近年来取得了令人欣喜的进展, 但在实际的无约束场景中, 行人重识别仍然极具挑战性。常见的挑战包括身体错位、遮挡、背景干扰、视角变化、姿态等。



图 1. 注意力图的可视化。(i) 原始图像; (ii) 注意力特征图; (iii) 具有注意力但多样化的特征图。总体而言, 多样性会使注意力“更广泛”, 并减少注意力对局部区域 (如衣物纹理) 的 (不正确的) 过拟合。(L: 大值; S: 小值)

以及其许多图表中的身体和噪声干扰 [11]

人们已经投入了大量精力来应对这些各种挑战。其中, 纳入身体部位信息 [2, 3, 4, 5, 6] 已被经验证明能有效增强特征在应对身体错位、部位不完整和遮挡问题时的鲁棒性。受这些观察结果的启发, 注意力机制 [7] 被引入, 以促使特征主要捕捉人体 (或特定身体部位) 的具有辨别性的外观。从那以后, 基于注意力的模型 [8, 9, 10, 11, 12] 极大地提升了行人重识别性能。

另需说明的是, 特征嵌入用于计算图像之间的相似度, 通常基于欧氏距离来返回最接近的匹配项。Sun 等人 [13] 指出, 特征嵌入之间的相关性会显著降低匹配性能。然而, 基于注意力的模型并不能自然保证低特征相关性这一特性。我们观察到, 那些基于注意力的模型往往更容易出现较高的特征相关性, 因为直观来看, 注意力机制倾向于让特征聚焦于一个更紧凑的子空间 (例如前景而非

*同等贡献。

鉴于上述情况,我们认为,对于行人重识别 (person Re-ID) 而言,更理想的特征嵌入应当兼具注意力性和多样性:前者旨在纠正错位、消除背景干扰,并聚焦于人体外观中具有判别性的局部区域;后者旨在降低特征之间的相关性,从而实现更好的匹配,并有可能使特征空间更加全面。我们提出了一种兼具注意力性与多样性的网络 (ABD-Net),该网络致力于整合注意力模块和多样性正则化,并在整个网络中贯彻实施。ABD-Net 的主要贡献如下:

- 我们在 ABD-Net 中融入了一种复合注意力机制,该机制由通道注意力模块 (CAM) 和位置注意力模块 (PAM) 组成。CAM 有助于实现通道层面、特征级别的信息聚合,而 PAM 则能捕捉身体及身体部位的空间感知。研究发现,这两种模块具有互补性,共同对行人重识别 (Re-ID) 起到促进作用。
- 我们提出了一种名为谱值差异正交性 (SVDO) 的新型正则化项,它能直接约束权重格拉姆矩阵的条件数。SVDO 实现高效,可应用于激活值和权重,并且被证明能有效减少学习到的特征相关性。
- 我们在 Market-1501 [14]、DukeMTMC-Re-ID [15] 和 MSMT17 [1] 上进行了大量实验。ABD-Net 显著优于现有方法,在这三个常用基准测试中均达到了新的最先进水平。通过严格的消融研究和可视化,我们还验证了具有注意力的多样化术语各自都有助于性能提升。

相关工作

2.1. 行人重识别: 简要概述

行人重识别有两个关键步骤: 获取特征嵌入以及在某种距离度量下进行匹配 [16,17,18]。我们主要回顾前者,其中手工特征 [18,19,20,21] 和学习特征 [22,23,4,24,25] 都得到了研究。近年来,卷积神经网络 (CNNs) 在计算机视觉领域的广泛成功也让行人重识别不例外。由于存在许多特定问题带来的挑战,如遮挡/错位、身体部位不完整以及背景干扰/视角变化,简单地应用 CNN 骨干网络进行特征提取可能无法获得理想的重识别性能。从图像层面提取的特征和从身体部位提取的局部特征都被证明能增强鲁棒性。许多基于部位的方法已经取得了优异的性能 [2,3,26,27,28,4,5,29,6,30,31,8,32]。更全面的综述可参考 [33]。

2.2. 行人重识别中的注意力机制

多项研究提出将注意力机制融入深度模型,以解决行人重识别 (person Re-ID) 中的错位问题。Zhao 等人 [8] 提出了一种基于部位图检测器的部位对齐表示方法,用于每个预定义的身体部位。Yao 等人 [9] 提出了一种部位损失网络 (Part Loss Network),该网络为每个平均池化的身体部位定义了一个损失,并联合优化这些损失的总和。Si 等人 [10] 提出了一种双注意力匹配网络,该网络基于类间和类内注意力模块,用于捕捉行人重识别 (person Re-ID) 视频序列的上下文信息。Li 等人 [12] 提出了一种多任务学习模型,该模型联合学习硬区域级和软像素级注意力,以生成更具判别性的特征表示。Xu 等人 [11] 利用姿态信息来学习刚性和非刚性部位的注意力掩码,然后将全局特征和部位特征结合起来作为最终的特征嵌入。

我们提出的注意力机制在多个方面与以往方法不同。首先,以往的方法 [8,9,11] 仅使用注意力机制从人物图像中提取基于部分的空间模式,这些模式通常集中在前景。相比之下,ABD-Net 结合了空间和通道线索;此外,我们添加的多样性约束将避免注意力特征过度相关和冗余。其次,我们的注意力掩码直接从数据和上下文学习而来,不依赖于手动定义的部分、部分区域提议或姿态估计 [8,9,11]。我们的两个注意力模块嵌入在单个主干网络中,这使得我们的模型比多任务学习替代方案 [11,12] 更轻量。

2.3. 基于正交性的多样性

在深度学习中,正交性已被广泛研究,旨在促进对具有信息性和多样性特征的学习。在卷积神经网络 (CNNs) 中,多项研究 [34, 35, 36, 37] 采用“硬正交约束”进行正则化,这通常依赖于奇异值分解 (SVD),将其解严格约束在斯蒂费尔流形上。[13] 首次将类似思路应用于行人重识别 (person Re-ID),作者对最后一层的权重矩阵进行奇异值分解,以减少特征相关性。尽管这种方法有效,但基于奇异值分解的硬正交约束计算成本高昂,且有时会限制学习的灵活性。

最近的研究还通过在弗罗贝尼乌斯范数 [38] 或谱范数 [39] 下,强制每个权重矩阵的格拉姆矩阵接近单位矩阵,来研究“更柔和的”正交性正则化。我们提出了一种新颖的谱值差异正交性 (SVDO) 正则化方法,该方法直接约束格拉姆矩阵的条件数。此外,与仅将正交性应用于 CNN 权重的 [13, 38] 不同,我们对隐藏激活和权重都实施了这种新的正则化。




图 2. 通道注意力模块 (CAM)




图 3. 位置注意力模块 (PAM)

专注且多样的网络

在本节中，我们首先介绍两个注意力模块，接着介绍新的多样性（正交性）正则化方法。然后，我们将对这些内容进行整合，并描述 ABD-Net 的整体架构。

3.1. 注意力：通道维度与位置维度

在行人重识别中，注意力机制的目标是聚焦于与行人相关的特征，同时排除无关的背景。受分割领域成功理念的启发 [40]，我们整合了两种互补的注意力机制：通道注意力模块（CAM）和位置注意力模块（PAM）。CAM 和 PAM 的完整配置可在补充材料中找到。

3.1.1 通道注意力模块

在训练好的 CNN 分类器中，高层卷积通道众所周知与语义相关，且通常具有类别选择性。在行人重识别（Re-ID）场景中，我们假设高层通道也是“成组的”，即某些通道共享相似的语义语境（如前景行人、遮挡物或背景），并且彼此之间的相关性更强。CAM 旨在对这些语义相似的通道进行分组和聚合。

CAM 的完整结构如图 2 所示。给定输入特征图 $A \in \mathbb{R}^{C \times H \times W}$ ，其中 C 是通道总数， $H \times W$ 是特征图大小，我们计算通道亲和矩阵 $X \in \mathbb{R}^{C \times C}$ ，如下所示：

$$x_{ij} = \frac{\exp(A_i \cdot A_j)}{\sum_{k=1}^C \exp(A_i \cdot A_k)}, i, j \in \{1, \dots, C\} \quad (1)$$

其中 x_{ij} 表示通道 i 对通道 j 的影响。最终输出特征图 E 通过公式 (2) 计算：

$$E_i = \gamma \sum_{j=1}^C (x_{ij} A_j) + A_i, i \in \{1, \dots, C\} \quad (2)$$

γ 是用于调整 CAM 影响的超参数。

3.1.2 位置注意力模块

与 CAM 不同，位置注意力模块（PAM）旨在捕获和聚合空间域中那些语义相关的像素。我们在图 3 中展示了 PAM 的结构。输入特征图 $A \in \mathbb{R}^{C \times H \times W}$ 首先被送入带有批归一化和 ReLU 激活函数的卷积层，以生成特征图 $B, C, D \in \mathbb{R}^{C' \times H' \times W'}$ 。然后我们计算像素亲和矩阵

$S \in \mathbb{R}^{N \times N}$ 位于 $N = H' \times W'$ 处。注意， S 和 X 的维度不同，因为前者计算的是全部 N 个像素之间的相关性，而非通道之间的相关性。我们生成最终的输出特征图 E 时，采用的计算方式与 3.1.1 节中的 CAM 类似。

3.2. 多样性：正交正则化

遵循文献 [13]，我们通过正交性来增强多样性，同时推导出一个新的正交正则化项。它适用于卷积层和全连接层的隐藏特征及权重。特征空间上的正交正则化项（以下简称 O.F.）旨在减少特征相关性，这能直接有利于匹配。权重上的正交正则化项（O.W.）则促进滤波器多样性 [39] 并增强学习能力。

接下来，我们展示特征上正交性项的详细推导过程，而权重正交性可以通过类似的方式推导得出*。对于特征图 $M \in \mathbb{R}^{C \times H \times W}$ ，其中 C, H, W 分别是通道数、高度和宽度的特征

真实地图的高度和宽度，我们首先会将 M 重塑为矩阵形式 $F \in \mathbb{R}^{C \times N}$ ，其中 $N = H \times W$ 。

许多正交性方法 [34, 35, 36, 37]，包括之前关于行人重识别（Re-ID）的研究 [13]，都对权重的正交性施加了严格约束，其计算依赖于奇异值分解（SVD）。然而，在高维矩阵上计算奇异值分解的成本很高，这促使了软正交性正则化项的发展。许多现有的软正则化项 [38, 41] 限制特征矩阵 F 的格拉姆矩阵在弗罗贝尼乌斯范数下接近单位矩阵，这样可以避免奇异值分解步骤，同时具有可微性。但是，

对于卷积层中的权重张量 $W_{\text{conv}} \in \mathbb{R}^{S \times H \times C \times M}$ ，其中 S, H, C, M 分别是滤波器的宽度、高度、输入通道数和输出通道数，我们遵循 [38, 39] 中的惯例，将 W_{conv} 重塑为矩阵形式 $F^ \in \mathbb{R}^{C^* \times M}$ ，其中 $C^* = S \times H \times C$ 。



图 4. ABD-Net 的架构：在所有 ResNet 层上应用了 O.W.。在注意力分支中，在 res conv 2 的 CAM 之后和 res conv 5 的 CAM 之后应用了 O.F.。来自注意力分支和全局分支的特征向量被拼接起来，作为最终的特征输入。

对于过完备的 F ，其格拉姆矩阵由于秩亏缺无法达到单位矩阵，这使得这些正则化项存在偏差。[39] 因此引入了基于谱范数的正则化项，有效缓解了这种偏差。我们提出了一种新的方法，通过直接正则化 FF^T 的条件数来强制正交性：

$$\beta \|k(F) - 1\|_2^2, \quad (3)$$

其中 β 是系数， $k(F)$ 表示 F 的条件数，定义为 F 的最大奇异值与最小奇异值之比。直接求解 $k(F)$ 需要一次完整的奇异值分解 (SVD)。为了提高计算的可行性，我们将式 (3) 转换为谱值差异正交性 (SVDO)[†] 正则化：

$$\beta \|\lambda_1(FF^T) - \lambda_2(FF^T)\|_2^2,$$

我们使用自动微分来获取 SVDO 的梯度，然而，这种计算仍然包含昂贵的特征值分解 (EVD)。为了绕过 EVD，我们参考幂迭代法来近似特征值。我们从随机初始化的 q 开始，然后迭代执行公式 (5)（默认两次）：

$$p \leftarrow Xq, q \leftarrow Xp, \lambda(X) \leftarrow \frac{\|q\|_2}{\|p\|_2}.$$

其中，公式 (5) 中的 x 在计算 $\lambda_1(FF^T)$ 时为 FF^T ，在计算 $\lambda_2(FF^T)$ 时为 $FF^T - \lambda_1 I$ 。通过这种方式，SVDO 的计算变

[†]我们选择惩罚 $\lambda_1(FF^T)$ 与 $\lambda_2(FF^T)$ 之间的差值而非它们的比值，是为了避免因除以极小的 $\lambda_2(FF^T)$ 而导致的数值不稳定性，这在我们的实验中经常出

3.3. 网络架构概述

所提出的 ABD-Net 的整体架构如图 4 所示。ABD-Net 与大多数常见的特征提取主干网络兼容，例如 ResNet [42]、InceptionNet [43] 和 Densenet [44]。除非另有说明，由于 ResNet-50 在行人重识别 (Re-ID) 中应用广泛 [45, 46, 47]，我们在残差卷积 2 模块的输出上添加了一个 CAM 和 O.F.。经过正则化的特征图被用作残差卷积 3 的输入。接下来，在残差卷积 4 模块之后，网络并行拆分为全局分支和注意力分支。我们在 ResNet-50 骨干网络的所有卷积层上应用 O.W.，即从残差卷积 1 到残差卷积 4，以及两个分支中的两个残差卷积 5。两个分支的输出被拼接起来，作为最终的特征输入。注意力分支使用与 ResNet-50 中相同的 res conv 5 层。然后，输出特征图被送入一个缩减层[‡]，并应用 O.F.，得到一个更小的特征图 T_n 。我们将 T_n 同时送入 CAM 和 PAM，两者都带有 O.F. 约束。两个注意力模块的输出与输入 T_n 进行拼接，然后一起经过全局平均池化层，最终得到一个 k_n 维的特征向量。在全局分支中，经过 res conv 5^{''} 处理后，特征图 T_n 被输入到全局平均池化层，随后是一个缩减层，得到一个 k_n 维的特征向量。全局分支除了关注分支特征外，还旨在保留全局上下

[‡]我们选择 ABD-Net 在损失函数上下进行训练。

缩减层由线性层、批归一化、ReLU 和丢弃层组成。参见：
<https://github.com/KaiyangZhou/deep-person-reid>

对于两个分支中的两个残差卷积 5 层，我们都移除了下采样层，以获得更大的特征图。

由交叉熵损失、硬挖掘三元组损失以及对特征 (O.F.) 和权重 (O.W.) 的正交约束惩罚项组成:

$$L = L_{\text{cross}} + \beta_{tr} L_{\text{triple}} + \beta_{OF} L_{OF} + \beta_{OW} L_{OW} \quad (6)$$

其中, L_{OF} 和 L_{OW} 分别代表应用于隐藏特征和权重的 SVDO 惩罚项。 β_{tr} 、 β_{OF} 和 β_{OW} 是超参数。

实验

为了评估 ABD-Net, 我们在三个大规模行人重识别数据集上进行了实验: Market1501 [14]、DukeMTMC-Re-ID [15] 和 MSMT17 [1]。首先, 我们报告了一组消融研究 (主要在 Market1501 和 DukeMTMC-Re-ID 上进行), 以验证每个组件的有效性。其次, 我们在所有三个数据集上将 ABD-Net 的性能与现有的最先进方法进行了比较。最后, 我们提供了更多的可视化结果和分析, 以说明 ABD-Net 是如何实现其有效性的。

4.1. 数据集

Market-1501 [14] 包含由 6 个摄像头拍摄的 1501 个身份的 32668 张带标签图像。按照文献 [14] 的划分, 751 个身份的 12936 张图像用于训练, 其余图像用于测试。在测试数据集中, 测试探针集包含 750 个身份的 3368 张图像。测试图库集还包括 2793 个额外的干扰项。

DukeMTMC-Re-ID [15] 包含 1812 个身份的 36411 张图像。这些图像由 8 个摄像头拍摄, 其中 1404 个身份出现在两个以上的摄像头中, 408 个身份 (干扰项) 仅出现在一个摄像头中。1404 个身份被随机划分, 702 个身份用于训练, 其余用于测试。在测试集中, 每个摄像头下每个身份选取一张查询图像组成探针集, 而包括干扰项在内的所有剩余图像则组成画廊集。

MSMT17 [1] 是目前最大的公开可用行人重识别数据集。它包含由 15 个摄像头网络 (12 个户外摄像头、3 个室内摄像头) 拍摄的 4101 个身份的 126441 张图像。我们遵循 [1] 中的训练 - 测试划分方式。该视频是在不同天气条件下的三个时间段 (早上、中午、下午) 收集的。所有标注信息均可用, 包括摄像头 ID、天气和时间段。由于规模庞大、场景更复杂且动态性更强, MSMT17 比另外两个数据集更具挑战性。此外, 由于该数据集是近期发布的, 在其上进行报告的方法数量有限。

4.2. 实现细节与评估

训练过程中, 输入图像被调整为 384×128 的尺寸, 然后通过随机水平翻转、标准化和随机擦除 [52] 进行增强。测试图像则

调整大小为 384×128 , 且仅通过归一化进行增强。在我们的实验中, 特征图 T_n 和 T_s 的尺寸分别为 $1024 \times 24 \times 8$ 和

$2048 \times 24 \times 8$ 。我们将全局平均池化后的特征 $((k_n, k_s))$ 维度均设置为 1024, 从而得到用于匹配的 2048 维最终特征嵌入。

使用经 ImageNet 预训练的 ResNet-50 骨干网络, 我们采用两步迁移学习算法 [53] 对模型进行微调。首先, 冻结骨干网络权重, 仅训练缩减层、分类器和所有注意力模块, 训练 10 个 epoch, 仅应用交叉熵损失和三元组损失。其次, 释放所有层进行再 60 个 epoch 的训练, 并应用完整损失 (6)。我们设置了 $\beta_{tr} = 10^{-1}$ 、 $\beta_{OF} = 10^{-6}$ 和 $\beta_{OW} = 10^{-3}$, 以及三元组损失的边际参数 $\alpha = 1.2$ 。

我们的网络使用 2 块 Tesla P100 GPU 进行训练, 批大小为 64。每个批次包含 16 个身份, 每个身份有 4 个实例。我们使用 Adam 优化器, 初始基础学习率设为 3×10^{-4} , 然后在 30 个、40 个 epoch 后分别衰减至 3×10^{-5} 、 3×10^{-6} 。在 Market-1501 数据集上的训练大约需要 4 小时。

我们采用标准的行人重识别指标: top-1 准确率和平均精度均值 (mAP)。我们认为 mAP 是衡量行人重识别性能更可靠的指标。

4.3. ABD-Net 的消融研究

为了验证 ABD-Net 中注意力模块和正交正则化的效果, 我们在 Market-1501 和 DukeMTMC-Re-ID 上对每个模块进行了增量评估。我们选择 ResNet-50 并结合交叉熵损失 (XE) 作为基线。在此基线之上构建了九个变体: a) 基线 (XE) + PAM; b) 基线 (XE) + CAM; c) 基线 (XE) + PAM + CAM; d) 基线 (XE) + O.F.; e) 基线 (XE) + O.W.; f) 基线 (XE) + O.F. + O.W.; g) 基线 + SVD 层 (类似于 SVD-Net [13]); h) ABD-Net (XE), 在式 (6) 中设置 $\beta_{tr} = 0$; 以及

i) ABD-Net 结合完整损失 (6)。

表 1 展示了消融研究的结果, 从中可以得出以下几点观察结论:

- 使用 PAM 或 CAM 均能在两个数据集上提升基线性能。将这两种不同的注意力机制结合起来可进一步提升性能, 这表明它们在单独使用时具有互补作用。
- 使用 O.F. 或 O.W. 在两个数据集上始终优于基线, 它们的组合带来了进一步的收益, 验证了

为保证消融研究的公平性, 我们使用两个重复的分支, 均采用与 ABD-Net 中相同的 res conv 5 结构, 如图 4 所示。同时应用了数据增强和 dropout 技术。

注意: (1) CAM 在 ABD-Net 中用于两个地方; (2) ABD-Net 采用 O.F. + O.W. + PAM + CAM。

表 1. ABD-Net 在 Market-1501 上的消融研究。O.F. 和 O.W.: 特征和权重的正交正则化; PAM 和 CAM: 位置注意力模块和通道注意力模块。

Method	Market-1501		DukeMTMC	
	top1	mAP	top1	mAP
baseline (XE)	91.50	77.40	82.80	66.40
baseline (XE) + PAM	92.10	78.10	83.80	67.00
baseline (XE) + CAM	91.80	78.00	84.30	67.60
baseline (XE) + PAM + CAM	92.70	78.50	84.40	67.90
baseline (XE) + O.F.	92.90	82.10	84.90	71.30
baseline (XE) + O.W.	92.50	78.50	83.70	67.40
baseline (XE) + O.F. + O.W.	93.20	82.30	85.30	72.20
baseline + SVD layer	90.80	76.90	79.40	62.50
ABD-Net (XE)	94.90	85.90	87.30	76.00
ABD-Net	95.60	88.28	89.00	78.59

我们的正交性正则化。我们还观察到，所提出的基于 SVD 的 O.W. 在实验中表现优于 SVD 层，这可能是由于 SVD 层起到了“硬约束”的作用，从而限制了 ResNet-50 骨干网络的学习能力。

- 通过结合“注意力”和“多样性”，ABD-Net (XE) 的性能得到了进一步提升。例如，在 Market1501 数据集上，ABD-Net (XE) 的表现超过了“无注意力”的对应模型（基线 (XE) + O.F. + O.W.），top-1 准确率提升了 1.50%，平均精度均值 (mAP) 提升了 3.60%；同时，它也超过了“无多样性”的对应模型（基线 (XE) + O.F. + O.W.），top-1 准确率提升了 2.20%，平均精度均值 (mAP) 提升了 7.40%。此外，当我们在注意力机制中强化多样性时，性能会得到进一步改善。最后，完整的 ABD-Net 通过添加三元组损失获得了更多收益。

4.4. 与最先进方法的比较

我们在 Market-1501、DukeMTMC-Re-ID 和 MSMT17 这三个数据集上，将 ABD-Net 与最先进的方法进行了对比，结果分别如表 2、表 3 和表 4 所示。为了保证对比的公平性，我们的方法没有使用重排序 [54] 或多查询融合 [55] 等后处理手段。

ABD-Net 在所有数据集上显然都取得了整体最先进的性能。具体来说，在 DukeMTMC-ReID 上，ABD-Net 的 top-1 准确率为 89.00%，平均精度均值 (mAP) 为 78.59%，显著优于所有现有方法。在 MSMT17 上，ABD-Net 也表现出明显的优势。在 Market-1501 上，其 top-1 准确率 (95.60%) 略低于 Local CNN [48] (95.90%) 和 MGN [47] (95.70%)；然而，ABD-Net 在平均精度均值 (mAP) 方面明显超过所有现有方法 (88.28%，以 0.88% 的较大优势超过最接近的竞争方法 [48])。

具体而言，我们着重比较了 ABD-Net 与现有的基于注意力的方法（在表 2 和表 3 中以*标记）。如表 2 和表 3 所示，在 Market-1501 数据集上，与最接近的基于注意力的先前工作 C^3A^3Net [51] 相比，ABD-Net 的 top-1 准确率至少提高了 2.40%，mAP 至少提高了 5.98%。在 DukeMTMC 数据集上，两者之间的差距

表 2. 与 Market-1501 上最先进方法的对比。红色表示我们的性能，蓝色表示现有方法报告的最佳性能：下同。

Method	Market-1501	
	top1	mAP
BOW [55] (2015 ICCV)	44.42	20.76
Re-Rank [54] (2017 CVPR)	77.11	63.63
SSM [56] (2017 CVPR)	82.21	68.80
SVDNet(RE) [52] (2017 CVPR)	87.08	71.31
AWTL [57] (2018 CVPR)	84.20	68.03
DSR [58] (2018 CVPR)	83.68	64.25
MLFN [59] (2018 CVPR)	90.00	74.30
Deep CRF [60] (2018 CVPR)	93.50	81.60
Deep KPM [61] (2018 CVPR)	90.10	75.30
HAP2S [62] (2018 ECCV)	84.20	69.76
SGGNN [63] (2018 ECCV)	92.30	82.08
Part-aligned [31] (2018 ECCV)	91.70	79.60
PCB [64] (2018 ECCV)	93.80	81.60
SNL [45] (2018 ACM MM)	88.27	73.43
HDLF [46] (2018 ACM MM)	93.30	79.10
‡ MGN [47] (2018 ACM MM)	95.70	86.90
‡ Local CNN [48] (2018 ACM MM)	95.90	87.40
* MGCAM [49] (2018 CVPR)	83.79	74.33
* AACN [11] (2018 CVPR)	85.90	66.87
* HA-CNN [50] (2018 CVPR)	91.20	75.70
* C^3A^3Net [51] (2018 CVPR)	93.20	80.00
* Mancs [65] (2018 ECCV)	93.10	82.30
* A^3M [66] (2018 ACM MM)	86.54	68.97
• SPRID [67] (2018 CVPR)	93.68	83.36
* ◊ DuATM [68] (2018 CVPR)	91.42	76.62
ABD-Net	95.60	88.28

*这也利用了注意力机制。· 这采用 ResNet-152 骨干网络。◊这采用 DenseNet-121 骨干网络。‡ 官方代码未发布。我们报告的是原始论文中的数据，这些数据优于我们的重新实现结果。

top-1 准确率为 3.40%，mAP 为 6.40%。我们还考虑了 SVDNet [13] 和 HA-CNN [50]，这两种方法也提出了生成多样化且不相关的特征嵌入。ABD-Net 在 top-1 准确率和 mAP 上均显著优于这两种方法。总体而言，我们的观察结果证实了 ABD-Net 通过结合“注意力”和“多样性”所具备的优越性。

4.5. 可视化

注意力模式可视化：我们对基线 (XE)、基线 (XE) + PAM + CAM 以及 ABDNet (XE) 的最终输出特征图进行了一系列注意力可视化 **，如图 5 所示。我们注意到，来自基线的特征图几乎没有表现出注意力。PAM +

Grad-CAM 可视化方法 [73]: <https://github.com/utkuozbulak/pytorch-cnn-visualizations>; 用于测试图像的 RAM 可视化方法 [74]。更多结果可参见补充材料。

表 3. 与 DukeMTMC 上最先进方法的比较。

Method	DukeMTMC-Re-ID	
	top1	mAP
BOW [55] (2015 ICCV)	25.13	12.17
SVDNet [13] (2017 ICCV)	76.70	56.80
SVDNet(RE) [52] (2017 CVPR)	79.31	62.44
FMN [69] (2017 CVPR)	74.51	56.88
PAN [70] (2018 TCSVT)	71.59	51.51
AWTL(2-stream) [57] (2018 CVPR)	79.80	63.40
Deep-person [71] (2018 CVPR)	80.90	64.80
MLFN [59] (2018 CVPR)	81.20	62.80
GP-Re-ID [72] (2018 CVPR)	85.20	72.80
PCB [64] (2018 ECCV)	83.30	69.20
Part-aligned [31] (2018 ECCV)	84.40	69.30
‡ MGN [47] (2018 ACM MM)	88.70	78.40
‡ Local CNN [48] (2018 ACM MM)	82.23	66.04
* AACN [11] (2018 CVPR)	76.84	59.25
* HA-CNN [50] (2018 CVPR)	80.50	63.80
* CA ³ Net [51] (2018 CVPR)	84.60	70.20
* Mancs [65] (2018 ECCV)	84.90	71.80
• SPreID [67] (2018 CVPR)	85.95	73.34
* ◊ DuATM [68] (2018 CVPR)	78.74	62.26
ABD-Net	89.00	78.59

这也利用了注意力机制。它使用 ResNet-152 作为骨干网络。它使用 DenseNet-121 作为骨干网络。‡官方代码未发布。我们报告的是原始论文中的数据，这些数据优于我们的重新实现结果。

表 4. 与 MSMT17 上最先进方法的比较。

Method	MSMT17		
	top1	top5	mAP
PDC [5] (2017 ICCV)	58.00	73.60	29.70
GLAD [29] (2017 ACM MM)	61.40	76.80	34.00
ABD-Net	82.30	90.60	60.80




图 5. 基线模型、基线 + PAM+CAM 模型以及 ABD-Net (XE) 的注意力图可视化。如第四列和第八列所示，ABD-Net 产生的多样化注意力图几乎覆盖了整个人体，而非过拟合于某些局部区域。




图 6. 基线模型、基线 + PAM+CAM 模型和 ABD-Net (XE) 的通道间相关矩阵可视化。颜色越亮表示相关性越大。从左上角图像开始按顺时针顺序来看，注意力机制使特征嵌入具有较高的相关性，而多样性则减少了冗余，进一步提高了判别性。

CAM 促使网络更多地关注人物区域，但注意力区域有时会过度强调某些局部区域（例如衣物），这意味着存在过拟合与人物无关的干扰信息的风险。大多数通道聚焦于相似区域还可能导致特征嵌入具有较高相关性。相比之下，ABD-Net (XE) 的注意力能够达到更好的平衡：它更多地关注人物身体的局部部位，同时仍能人物从背景中分离出来。现在，不同人物的注意力模式差异更大，特征嵌入也变得更加去相关和多样化。

特征去相关：我们研究了基线模型（Baseline）和基础模型（Base）产生的通道输出之间的相关矩阵。line + PAM + CAM 以及 ABD-Net (XE) ‡。该特征

全局平均池化前的嵌入被重塑为 $F \in \mathbb{R}^{C \times N}$ ，其中 $N = H \times W$ 。然后，我们在图 6 中可视化了 F 的相关系数矩阵（记为 $Corr \in \mathbb{R}^{C \times C}$ ），并计算了每种设置下所有相关系数的平均值。基线特征嵌入显示非对角线元素的相关性较低（平均为 0.049）。应用 PAM 和 CAM 后，特征相关性变得大得多（平均为 0.368）

‡此处我们以一张随机测试图像为例，更多结果详见补充材料。

‡我们取相关系数的绝对值。




图 7. 基线模型、基线 + PAM+CAM 模型和 ABD-Net (XE) 的相关性直方图。分布越倾斜，表明特征嵌入的去相关性越好。(b) 是 (a) 中红框区域的放大图。




图 8. 基线模型、基线 + PAM+CAM 模型以及 ABD-Net (XE) 的特征分布 t-SNE 可视化结果。从 Market-1501 中随机选取了 10 个身份，其 ID 列于图的右侧。圆圈 A 和 B 分别包含 ID 为 521、94 和 156 的特征。

这支持了我们的假设，即注意力机制倾向于促成更“集中”且因此具有高度相关性的特征。然而，在我们的正交正则化作用下，与仅使用注意力机制的情况相比，ABD-Net (XE) 中的特征相关性得到了成功抑制（平均值为 0.214）。图 7 中的特征直方图也证实了这一观察结果。

特征嵌入分布：图 8 展示了使用 t-SNE 对基线模型、基线 + PAM+CAM 模型以及 ABD-Net (XE) 的特征分布进行的 tSNE 可视化结果。与基线模型相比，尽管基线 + PAM+CAM 模型的注意力特征使周期 B 中的 ID 94 和 ID 156 能被略微区分开，但 ABD-Net 增大了周期 A 中 ID 521 的类内距离。这使得 ID 94 和 ID 156 的特征更具判别性，同时 ID 521 的特征也处于一个紧凑的区域内。



图 9. ABD-Net (XE)、Baseline + PAM + CAM 以及 Baseline 在 Market-1501 上的 6 个重识别示例。左图：查询图像。右图：i) ABD-Net (XE) 的前 5 名结果。ii) Baseline + PAM + CAM 的前 5 名结果。iii) Baseline 的前 5 名结果。红色框中的图像为错误结果。具有注意力多样化的特征嵌入提升了检索性能。

再识别定性视觉结果：图 9 展示了 ABD-Net (XE)、Baseline + PAM + CAM 以及 Baseline 在 Market-1501 上的再识别视觉示例。结果表明，即使图像中的人物存在明显的视角变化和外观差异，ABD-Net 也能比 Baseline + PAM + CAM 模型找到更多的真阳性样本。

结论

本文提出了一种新颖的注意力多样化网络 (ABD-Net)，旨在为行人重识别学习更具代表性、鲁棒性和判别性的特征嵌入。通过大量实验，ABD-Net 展现出了最先进的性能，其中消融实验和可视化结果表明，所添加的每个组件都对其最终性能有显著贡献。未来，我们将把 ABD-Net 的设计理念推广到其他计算机视觉任务中。

参考文献

- [1] 魏龙辉、张世亮、高文和田奇。用于弥合行人重识别领域差距的行人迁移生成对抗网络

- 识别。发表于《IEEE 计算机视觉与模式识别会议论文集》(CVPR)，2018年6月。1、2、5
- [2] 道格拉斯·格雷和海涛。利用局部特征集成进行视点不变的行人识别。见《欧洲计算机视觉会议》，第262-275页。施普林格出版社，2008年。1、2
- [3] 布莱恩·詹姆斯·普罗瑟、郑伟诗、龚绍刚、项涛和Q·玛丽。基于支持向量排序的行人重识别。见《英国机器视觉会议论文集》，第2卷，第6页，2010年。1、2
- [4] 程德、龚怡宏、周三明、王金军、郑南宁。基于多通道部件CNN和改进三元组损失函数的行人重识别。《IEEE 计算机视觉与模式识别会议论文集》，第1335-1344页，2016年。1、2
- [5] 苏驰、李建宁、张世亮、邢俊亮、高文和田奇。用于行人重识别的姿态驱动深度卷积模型。见《计算机视觉 (ICCV)》，2017年IEEE国际会议，第3980-3989页。IEEE，2017年。1、2、7
- [6] 梁正、黄雨佳、卢湖川和杨毅。用于深度行人重识别的姿态不变嵌入。arXiv预印本 arXiv:1701.07732，2017。1、2
- [7] 阿希什·瓦斯瓦尼、诺阿姆·沙泽尔、尼基·帕尔马、雅各布·乌兹科雷特、利昂·琼斯、艾丹·N·戈麦斯、卢卡斯·凯泽和伊利亚·波洛苏欣。《注意力就是一切》。收录于《神经信息处理系统讲稿》，第5998-6008页。2017年。1
- [8] 赵明，李曦，庄越挺，王敬东。用于行人重识别的深度学习部分对齐表示。见《国际计算机视觉大会论文集》，第3239-3248页，2017年。1、2
- [9] 姚涵涛、张世良、张永东、李金涛和齐天。用于行人重识别的带部分损失的深度表示学习。arXiv预印本 arXiv:1707.00798，2017。1、2
- [10] 司建楼、张洪刚、李春广、Jason Kuen、孔祥飞、Alex C Kot、王刚。用于基于上下文感知特征序列的行人重识别的双注意力匹配网络。arXiv预印本 arXiv:1803.09937，2018。1、2
- [11] 徐静、赵睿、朱峰、王华明和欧阳万里。用于行人重识别的注意力感知组合网络。arXiv预印本 arXiv:1805.03344，2018。1、2、4、6、7
- [12] 李伟、朱夏天、龚少刚。用于行人重识别的和谐注意力网络。收录于《CVPR》，第1卷，第2页，2018年。1、2
- [13] 孙一帆、梁政、邓伟建、王盛金。用于行人检索的Svdnet。2017年IEEE国际计算机视觉会议 (ICCV)，2017年10月。1、2、3、5、6、7
- [14] 郑亮、沈礼悦、田璐、王盛金、王京东、田奇。《可扩展的行人重识别：一个基准》。发表于《IEEE 国际计算机视觉会议 (ICCV)》，2015年12月。2、5
- [15] Ergys Ristani, Francesco Solera, Roger Zou, Rita Cucchiara 和 Carlo Tomasi。多目标、多摄像机跟踪的性能指标和数据集。发表于《欧洲计算机视觉会议 (ECCV)》，2016年9月。2、5
- [16] 基利安·Q·魏因伯格、约翰·布利策和劳伦斯·K·索尔。用于大间隔最近邻分类的距离度量学习。见《神经信息处理系统进展》，第1473-1480页，2006年。2
- [17] 李振、常世宇、梁峰、托马斯·S·黄、曹亮亮和约翰·R·史密斯。《学习用于人物验证的局部自适应决策函数》。收录于《IEEE 计算机视觉与模式识别会议论文集》，第3610-3617页，2013年。2
- [18] 萨梅赫·哈米斯、郭正豪、维韦克·K·辛格、维奈·D·谢特和拉里·S·戴维斯。用于属性一致的行人重识别的联合学习。见《欧洲计算机视觉会议》，第134-146页。施普林格出版社，2014年。2
- [19] 马丁·科斯特 inger、马丁·希尔策、保罗·沃尔哈特、彼得·M·罗斯和霍斯特·比肖夫。基于等价约束的大规模度量学习。见《计算机视觉与模式识别 (CVPR)》，2012年IEEE会议，第2288-2295页。IEEE，2012年。2
- [20] 李伟和王晓刚。跨视图的局部对齐特征变换。见《IEEE 计算机视觉与模式识别会议论文集》，第3594-3601页，2013年。2
- [21] 马兵鹏、苏宇和弗雷德里克·朱里。Bicov：一种用于行人重识别和人脸验证的新型图像表示方法。发表于《英国机器视觉会议》，第11-页，2012年。2
- [22] 李伟、赵瑞、肖彤和王晓刚。Deepreid：用于行人重识别的深度滤波器配对神经网络。见《IEEE 计算机视觉与模式识别会议论文集》，第152-159页，2014年。2
- [23] 赵锐、欧阳万里、王晓刚。《学习用于行人重识别的中层滤波器》。发表于《IEEE 计算机视觉与模式识别会议论文集》，第144-151页，2014年。2
- [24] 亚历山大·赫尔曼斯、卢卡斯·拜尔和巴斯蒂安·莱贝。为行人重识别中的三元组损失辩护。arXiv预印本 arXiv:1703.07737，2017。2
- [25] 廖文通、杨映 (Michael Ying Yang)、詹妮 (Ni Zhan) 和博多·罗森哈恩 (Bodo Rosenhahn)。基于三元组的深度相似性学习在行人重识别中的应用。《2017年IEEE国际计算机视觉研讨会论文集》(ICCVW)，第385-393页，2017年。2
- [26] 廖胜才、胡杨、朱翔宇、Stan Z Li。基于局部最大出现表示和度量学习的行人重识别。《IEEE 计算机视觉与模式识别会议论文集》，第2197-2206页，2015年。2

[27] Andy J Ma, Pong C Yuen 和 Jiawei Li. 无需目标相机标签信息的跨域迁移支持向量排序在行人重识别中的应用。见《IEEE 国际计算机视觉会议论文集》，第 3567-3574 页，2013 年。2

[28] 郑伟诗、龚绍刚、项涛。基于相对距离比较的重识别。《IEEE 模式分析与机器智能汇刊》，35 (3): 653-668, 2013。2

[29] 魏龙辉、张世亮、姚汉涛、高文、田奇。Glad: 用于行人检索的全局 - 局部对齐描述符。《2017 年 ACM 多媒体会议论文集》，第 420-428 页。ACM, 2017 年。2、7

[30] 朱福清、孔祥伟、郑亮、傅海燕和齐天。用于大规模行人重识别的基于部件的深度哈希方法。《IEEE 图像处理汇刊》，26 (10): 4806-4817, 2017。2

[31] 苏裕民、王京东、唐思宇、梅涛和李灵茂。用于行人重识别的部分对齐双线性表示。arXiv 预印本 arXiv:1804.07094, 2018。2、6、7

[32] 赵海宇、田茂庆、孙树阳、邵景、闫俊杰、易帅、王晓刚和汤晓鸥。Spindle 网络: 基于人体区域引导的特征分解与融合的行人重识别。《IEEE 计算机视觉与模式识别会议论文集》，第 1077-1085 页，2017 年。2

[33] 梁政、易阳、亚历山大·G·豪普特曼。行人重识别: 过去、现在与未来。arXiv 预印本 arXiv:1610.02984, 2016。2

[34] 斯特凡·范德沃尔特、S. 克里斯·科尔伯特和盖尔·瓦罗夸克斯。NumPy 数组: 一种高效数值计算结构。CoRR, abs/1102.1523, 2011。2、3

[35] 梅赫塔什·哈兰迪和巴苏拉·费尔南多。广义反向传播, 案例研究: 正交性。arXiv 预印本 arXiv:1611.05927, 2016。2、3

[36] 梅特·奥扎伊和高谷冈谷。卷积神经网络中卷积核子流形的优化, 2016 年。2、3

[37] 黄磊、刘翔龙、郎波、余亚当·魏、王永亮、李波。正交权重归一化: 深度神经网络中多个相关斯蒂费尔流形的优化解决方案, 2017。2、3

[38] 谢迪、熊江和蒲世亮。训练极深卷积神经网络的更佳解决方案: 正交性与调制的探索, 远不止良好的初始化。2017 年 IEEE 计算机视觉与模式识别会议 (CVPR), 2017 年 7 月。2、3

[39] 尼廷·班萨尔、陈晓寒和王章阳。我们能从深度网络训练中的正交正则化中获得更多吗?《神经信息处理系统进展》，第 4266-4276 页, 2018 年。2、3、4

[40] 付军、刘静、田海杰、方志伟和卢汉清。用于场景分割的双注意力网络。arXiv 预印本 arXiv:1809.02983, 2018。3

[41] 徐宏宇、王张扬、杨海川、刘丁和刘吉。利用稀疏支持恢复学习简单的阈值特征。《IEEE 电路与系统汇刊 (视频技术)》，2019 年。3

[42] 何凯明、张祥雨、任少卿和孙剑。用于图像识别的深度残差学习。《IEEE 计算机视觉与模式识别会议论文集》，第 770-778 页, 2016 年。4

[43] 克里斯蒂安·斯泽杰迪、谢尔盖·约菲、文森特·范霍克和亚历山大·A·阿莱米。《Inception-v4、Inception-ResNet 以及残差连接对学习的影响》。发表于《第三十一届 AAAI 人工智能大会》，2017 年。4

[44] 高黄、庄刘、劳伦斯·范德马腾和基利安·Q·魏因贝格。密集连接卷积网络。《IEEE 计算机视觉与模式识别会议论文集》，第 4700-4708 页, 2017 年。4

[45] 李凯、丁正明、李鲲鹏、张宇伦和傅云。用于行人重识别的支持邻域损失。见《2018 年 ACM 多媒体会议论文集》，第 1492-1500 页。ACM, 2018 年。4、6

[46] 曾明勇、田畅、吴泽敏。基于分层深度学习特征和高效 XQDA 度量的行人重识别。见《2018 年 ACM 多媒体会议论文集》，第 1838-1846 页。ACM, 2018 年。4、6

[47] 王冠硕、袁玉峰、陈雄、李继伟、周曦。用于行人重识别的多粒度判别特征学习。见《2018 年 ACM 多媒体会议论文集》，第 274-282 页。ACM, 2018 年。4、6、7

[48] 杨继伟、沈旭、田新梅、李厚强、黄建强、华先胜。用于行人重识别的局部卷积神经网络。见《2018 年 ACM 多媒体会议论文集》，第 1074-1082 页。ACM, 2018 年。4、6、7

[49] 宋春风、黄燕、欧阳万里和王亮。用于行人重识别的掩码引导对比注意力模型。《IEEE 计算机视觉与模式识别会议论文集》，第 1179-1188 页, 2018 年。4、6

[50] 李伟、朱夏天和龚绍刚。用于行人重识别的和谐注意力网络。2018 年 IEEE/CVF 计算机视觉与模式识别会议, 2018 年 6 月。4、6、7

[51] 刘佳伟、查正军、谢宏涛、熊志伟、张永东。Ca3net。2018 年 ACM 多媒体会议——MM 18, 2018。4、6、7

[52] 钟准、梁政、康国良、李少子和杨亦。随机擦除数据增强。arXiv 预印本 arXiv:1708.04896, 2017。5、6、7

[53] 耿梦月、王耀伟、项涛和田永红。用于行人重识别的深度迁移学习。arXiv 预印本 arXiv:1611.05244, 2016。5

[54] 钟准、郑亮、曹东林和李少子。基于 k - 互反编码的行人重识别重排序。

发表于《IEEE 计算机视觉与模式识别会议论文集》，第 1318-1327 页，2017 年。6

[55] 梁正、沈立月、田露、王盛金、王京东和齐天。《可扩展的行人重识别：一个基准》。发表于《计算机视觉，IEEE 国际会议》，2015 年。6、7

[56] 宋柏、向柏、齐天。基于监督平滑流形的可扩展行人重识别。《IEEE 计算机视觉与模式识别会议论文集》，第 2530-2539 页，2017 年。6

[57] 埃尔吉斯·里斯塔尼和卡洛·托马西。用于多目标多摄像机跟踪和重识别的特征。《IEEE 计算机视觉与模式识别会议论文集》，第 6036-6046 页，2018 年。6、7

[58] 何凌霄、梁健、李海清、孙振楠。用于部分行人重识别的深度空间特征重建：无对齐方法。《IEEE 计算机视觉与模式识别会议论文集》，第 7073-7082 页，2018 年。6

[59] 常晓斌、蒂莫西·M·霍斯佩代尔斯、陶翔。用于行人重识别的多级分解网络。《IEEE 计算机视觉与模式识别会议论文集》，第 2109-2118 页，2018 年。6、7

[60] 陈大鹏、徐丹、李洪生、尼库·塞贝、王晓刚。基于深度条件随机场的群体一致性相似性学习在行人重识别中的应用。《IEEE 计算机视觉与模式识别会议论文集》，第 8649-8658 页，2018 年。6

[61] 沈艳涛、肖桐、李洪生、易帅和王晓刚。用于行人重识别的端到端深度克罗内克积匹配。《IEEE 计算机视觉与模式识别会议论文集》，第 6886-6895 页，2018 年。6

[62] 于睿、窦志勇、白松、张兆祥、徐永超和白翔。用于行人重识别的硬感知点到集深度度量。《欧洲计算机视觉会议论文集》(ECCV)，第 188-204 页，2018 年。6

[63] 沈艳涛、李洪生、易帅、陈大鹏和王晓刚。基于深度相似性引导图神经网络的行人重识别。《欧洲计算机视觉会议论文集》(ECCV)，第 486-504 页，2018 年。6

[64] 孙一凡、梁铮、杨毅、田奇、王生进。超越部件模型：基于精细化部件池化的行人重识别（及一个强大的卷积基线）。《欧洲计算机视觉会议论文集》(ECCV)，第 480-496 页，2018 年。6、7

[65] 王成、张倩、黄畅、刘文宇和王兴刚。Manacs：一种用于行人重识别的带课程采样的多任务注意力网络。《欧洲计算机视觉会议论文集》(ECCV)，第 365-381 页，2018 年。6、7

[66] 韩凯、郭建远、张超、朱明建。用于细粒度表示学习的属性感知注意力模型。见《2018 年 ACM 多媒体会议论文集》，第 2040-2048 页。ACM，2018 年。6

[67] 马赫迪·M·卡拉耶、埃姆拉·巴萨兰、穆希廷·格克门、穆斯塔法·E·卡马萨克和穆巴拉克·沙阿。用于行人重识别的人体语义解析。《IEEE 计算机视觉与模式识别会议论文集》，第 1062-1071 页，2018 年。6、7

[68] 司建楼、张洪刚、李春广、Jason Kuen、孔祥飞、Alex C. Kot、王刚。用于基于上下文感知特征序列的行人重识别的双注意力匹配网络。2018 年 IEEE/CVF 计算机视觉与模式识别会议，2018 年 6 月。6、7

[69] 丁国栋、萨尔曼·汗、唐振民和法蒂赫·波里克利。《让特征自己做决定：用于行人重识别的特征掩码网络》，2017 年。7

[70] 郑哲东、郑亮、杨毅。用于大规模行人重识别的行人对齐网络，2017.7

[71] 白翔、杨明坤、黄腾腾、窦志勇、于睿和徐永超。Deep-person：学习用于行人重识别的判别性深度特征，2017.7

[72] 乔恩·阿尔马赞、博亚娜·加伊奇、奈拉·默里和黛安·拉卢斯。《正确的重识别：迈向行人重识别的良好实践》，2018 年。7

[73] 兰普拉萨思·R. 塞尔瓦拉朱、迈克尔·科格斯韦尔、阿比舍克·达斯、拉马克里希纳·韦丹塔姆、德维·帕里赫和德鲁夫·巴特拉。Grad-CAM：基于梯度定位的深度网络视觉解释。2017 年 IEEE 国际计算机视觉会议 (ICCV)，2017 年 10 月。6

[74] 杨文杰、黄厚景、张章、陈晓棠、黄凯奇、张舒。面向行人重识别的类激活图增强丰富特征发现。发表于《IEEE 计算机视觉与模式识别会议论文集》(CVPR)，2019 年 6 月。6