

先对齐再融合：基于动量蒸馏的视觉与语言表征学习

李俊楠、兰普拉萨思·R·塞尔瓦拉朱、阿基莱什·D·戈特马
雷、沙菲克·乔蒂、熊彩明、史蒂文·C·H·许

{junnan.li, rselvaraju, akhilesh.gomar, siotv.shoi}@salesforce.com

摘要

大规模视觉与语言表示学习在各种视觉 - 语言任务上展现出了令人瞩目的进步。大多数现有方法采用基于 Transformer 的多模态编码器，对视觉标记（基于区域的图像特征）和文字标记进行联合建模。由于视觉标记和文字标记未对齐，多模态编码器学习图像 - 文本交互面临挑战。在本文中，我们引入一种对比损失，在通过跨模态注意力融合图像和文本表示之前对其进行对齐（ALBEF），这使得视觉与语言表示学习能更贴合实际。与大多数现有方法不同，我们的方法不需要边界框标注，也不需要高分辨率图像。为了改进从嘈杂网络数据中的学习效果，我们提出了动量蒸馏——一种从动量模型生成的伪目标中学习的自训练方法。我们从互信息最大化的角度对 ALBEF 进行了理论分析，结果表明，不同的训练任务可以解释为图像 - 文本对生成视图的不同方式。ALBEF 在多个下游视觉 - 语言任务上取得了最先进的性能。在图像 - 文本检索任务上，ALBEF 的表现优于那些在规模大几个数量级的数据集上预训练的方法。在 VQA 和 NLVR2 任务上，与最先进的方法相比，ALBEF 分别实现了 2.37% 和 3.84% 的绝对提升，同时推理速度更快。代码和模型可在 <https://github.com/salesforce/ALBEF> 获取。

1 引言

视觉 - 语言预训练（VLP）旨在从大规模图像 - 文本对中学习多模态表示，以改进下游的视觉 - 语言（V+L）任务。大多数现有的 VLP 方法（例如 LXMERT [1]、UNITER [2]、OSCAR [3]）依赖预训练的目标检测器来提取基于区域的图像特征，并采用多模态编码器将图像特征与词元融合。多模态编码器通过训练来解决需要联合理解图像和文本的任务，例如掩码语言建模（MLM）和图像 - 文本匹配（ITM）。

尽管该视觉语言预训练框架是有效的，但它存在几个关键局限性：（1）图像特征和词元嵌入处于各自的空间中，这使得多模态编码器难以学习对它们的交互进行建模；（2）目标检测器既耗费标注资源又耗费计算资源，因为它在预训练期间需要边界框标注，在推理期间需要高分辨率（例如 600×1000 ）图像；（3）广泛使用的图像 - 文本数据集 [4, 5] 是从网络上收集的，本身就存在噪声，而现有的预训练目标（如掩码语言模型）可能会过拟合于带噪声的文本，从而降低模型的泛化性能。

我们提出了 ALign BEfore Fuse（ALBEF），这是一种新的视觉语言预训练（VLP）框架，旨在解决这些局限性。我们首先使用无检测器的图像编码器和文本编码器分别对图像和文本进行编码。然后，我们使用多模态编码器通过跨模态注意力将图像特征与文本特征融合。我们在单模态编码器的表征上引入了一种中间的图像 - 文本对比（ITC）损失，它有三个目的：（1）对齐图像特征和文本特征，使多模态编码器更容易进行跨模态学习；（2）它

改进单模态编码器，以更好地理解图像和文本的语义；（3）学习一个共同的低维空间来嵌入图像和文本，这使得图文匹配目标能够通过我们的对比性难负样本挖掘找到更多信息丰富的样本。

为了在嘈杂监督下改进学习效果，我们提出了动量蒸馏（MoD）这一简单方法，该方法能让模型利用更大规模的未整理网络数据集。在训练过程中，我们通过对模型参数取移动平均值来保留模型的动量版本，并使用该动量模型生成伪目标作为额外的监督信息。借助 MoD，模型不会因产生与网络标注不同但合理的其他输出而受到惩罚。我们发现，MoD 不仅能改进预训练效果，还能提升带有清晰标注的下游任务表现。

我们从互信息最大化的角度为 ALBEF 提供了理论依据。具体而言，我们证明了 ITC 和 MLM 最大化了图像 - 文本对不同视图之间互信息的下界，其中这些视图是通过从每个图像 - 文本对中提取部分信息生成的。从这个角度来看，我们的动量蒸馏可以解释为利用语义相似的样本生成新的视图。因此，ALBEF 学习到的视觉 - 语言表示对保留语义的变换具有不变性。

我们在多种下游视觉 - 语言任务上证明了 ALBEF 的有效性，这些任务包括图文检索、视觉问答、视觉推理、视觉蕴含以及弱监督视觉定位。ALBEF 相较于现有的最先进方法取得了显著提升。在图文检索任务上，它的性能超过了那些在规模大几个数量级的数据集上预训练的方法（CLIP [6] 和 ALIGN [7]）。在 VQA 和 $NTVR^2$ 任务上，与最先进的方法 VILLA [8] 相比，它分别实现了 2.37% 和 3.84% 的绝对提升，同时推理速度快得多。我们还使用 Grad-CAM [9] 对 ALBEF 进行了定量和定性分析，结果表明它能够隐式地实现准确的对象、属性和关系定位。

2 相关工作

2.1 视觉 - 语言表征学习

大多数现有的视觉 - 语言表征学习研究可分为两类。第一类侧重于利用基于 Transformer 的多模态编码器对图像和文本特征之间的交互进行建模 [10, 11, 12, 13, 1, 14, 15, 2, 3, 16, 8, 17, 18]。这类方法在需要对图像和文本进行复杂推理的下游视觉 - 语言任务（例如 $NTVR^2$ [19]、视觉问答（VQA）[20]）上表现优异，但其中大多数需要高分辨率输入图像和预训练的目标检测器。最近的一种方法 [21] 通过移除目标检测器提高了推理速度，却导致性能下降。第二类侧重于为图像和文本分别学习单模态编码器 [22, 23, 6, 7]。最近的 CLIP [6] 和 ALIGN [7] 利用对比损失在大规模嘈杂网络数据上进行预训练，对比损失是表征学习中最有效的损失函数之一 [24, 25, 26, 27]。它们在图像 - 文本检索任务上取得了显著性能，但在其他视觉 - 语言任务中缺乏对图像和文本之间更复杂交互的建模能力 [21]。

ALBEF 将这两类方法统一起来，形成了强大的单模态和多模态表示，在检索和推理任务上均表现出优异性能。此外，ALBEF 不需要目标检测器，而目标检测器是许多现有方法的主要计算瓶颈 [1, 2, 3, 8, 17]。

2.2 知识蒸馏

知识蒸馏 [28] 旨在通过从教师模型中提取知识来提升学生模型的性能，通常是通过使学生模型的预测与教师模型的预测相匹配来实现。大多数方法侧重于从预训练的教师模型中提取知识 [28, 29, 30, 31, 32]，而在线蒸馏 [33, 34] 则同时训练多个模型，并将它们的集成用作教师模型。我们提出的动量蒸馏可以理解作为一种在线自蒸馏形式，其中学生模型的时间集成被用作教师模型。类似的思路在半监督学习 [35]、标签噪声学习 [36] 以及最近的对比学习 [37] 中都有探索。与现有研究不同的是，我们从理论和实验上证明，动量蒸馏是一种通用的学习算法，能够在许多视觉 - 语言任务上提升模型的性能。

3 ALBEF 预训练

在本节中，我们首先介绍模型架构（第 3.1 节）。然后阐述预训练目标（第 3.2 节），接着介绍所提出的动量蒸馏（第 3.3 节）。最后，我们描述预训练数据集（第 3.4 节）和实现细节（第 3.5 节）。




图 1: ALBEF 示意图。它由图像编码器、文本编码器和多模态编码器组成。我们提出了一种图像 - 文本对比损失，用于在融合前对齐图像 - 文本对的单模态表示。我们应用了图像 - 文本匹配损失（使用通过对比相似度挖掘的批内难负样本）和掩码语言建模损失，以学习图像和文本之间的多模态交互。为了改进含噪声数据的学习效果，我们在训练过程中使用动量模型（基础模型的移动平均版本）生成伪目标，作为额外的监督信息。

3.1 模型架构

如图 1 所示，ALBEF 包含一个图像编码器、一个文本编码器和一个多模态编码器。我们使用 12 层视觉 Transformer 模型 ViT-B/16 [38] 作为图像编码器，并使用在 ImageNet-1k 上预训练的权重 [31] 对其进行初始化。输入图像 I 被编码为一系列嵌入向量： $e_1, e_2, \dots, e_n$ ，其中 e_1 是 [CLS] 标记的嵌入向量。文本编码器和多模态编码器均使用 6 层 Transformer 模型 [39]。文本编码器使用 `DEPTN` 模型 [40] 的前 6 层进行初始化，多模态编码器使用 `DEPTN` 的后 6 层进行初始化。文本编码器将输入文本 T 转换为一系列嵌入向量 $t_1, t_2, \dots, t_m$ ，并将其输入到多模态编码器中。图像特征通过多模态编码器各层的交叉注意力与文本特征进行融合。

3.2 预训练目标

我们使用三个目标对 ALBEF 进行预训练：单模态编码器上的图像 - 文本对比学习（ITC）、多模态编码器上的掩码语言建模（MLM）和图像 - 文本匹配（ITM）。我们通过在对比难负样本挖掘来改进 ITM。

图文对比学习旨在融合前学习更好的单模态表示。它学习一种相似性函数

$s = \alpha_{\text{img}}(v_{\text{img}})^\top \alpha_{\text{txt}}(v_{\text{txt}})$ ，使得并行的图文对具有更高的相似性分数。 α_{img} 和 α_{txt} 是将 [CLS] 嵌入映射到标准化低维（256 维）表示的线性变换。受 MoCo [24] 的启发，我们维护两个队列来存储来自动量单模态编码器的最新 M 个图文表示。来自动量编码器的标准化特征表示为 $\alpha'_{\text{img}}(v'_{\text{img}})$ 和 $\alpha'_{\text{txt}}(v'_{\text{txt}})$ 。我们定义 $s(I, T) = \alpha_{\text{img}}(v_{\text{img}})^\top \alpha'_{\text{img}}(v'_{\text{img}})$ 和 $s(T, I) = \alpha_{\text{txt}}(v_{\text{txt}})^\top \alpha'_{\text{txt}}(v'_{\text{txt}})$ 。

对于每个图像和文本，我们计算经过 softmax 归一化的图像到文本以及文本到图像的相似度，公式如下：

$$p_m^{i2t}(I) = \frac{\exp(s(I, T_m)/\tau)}{\sum_{T \in \mathcal{T}} \exp(s(I, T)/\tau)}, p_m^{t2i}(T) = \frac{\exp(s(T, I_m)/\tau)}{\sum_{I \in \mathcal{I}} \exp(s(T, I)/\tau)}$$

其中 τ 是一个可学习的温度参数。令 $p_m^{i2t}(I)$ 和 $p_m^{t2i}(T)$ 表示真实的独热相似度，其中负对的概率为 0，正对的概率为 1。图像 - 文本对比损失定义为 p 和 y 之间的交叉熵 H ：

$$\mathcal{L}_{\text{itc}} = \frac{1}{2} \mathbb{E}_{(I, T) \sim D} [H(p_m^{i2t}(I), p_m^{i2t}(I)) + H(p_m^{t2i}(T), p_m^{t2i}(T))]$$



图 2: MLM (第一行) 和 ITC (第二行) 的伪目标示例。这些伪目标能够捕捉到真实文本中未描述的视觉概念（例如“美丽的瀑布”“年轻女性”）。

掩码语言建模利用图像和上下文文本来预测被掩码的单词。我们以 15% 的概率随机掩码输入标记，并将其替换为特殊标记 $[MASK]$ ¹。令 $\hat{T}$ 表示被掩码的文本， $p^{msk}(I, \hat{T})$ 表示模型对被掩码标记的预测概率。掩码语言建模最小化交叉熵损失：

$$\mathcal{L}_{mlm} = \mathbb{E}_{(I, \hat{T}) \sim D} H(p^{msk}, p^{msk}(I, \hat{T}))$$

其中， p^{msk} 是一种独热词汇分布，其中真实标记的概率为 1。

图文匹配用于预测一对图像和文本是正向的（匹配的）还是负向的（不匹配的）。我们将 $[CLS]$ 标记的多模态编码器输出嵌入作为图像 - 文本对的联合表示，并附加一个全连接（FC）层，随后通过 softmax 来预测二分类概率 p^{itm} 。图文匹配损失为：

$$\mathcal{L}_{itm} = \mathbb{E}_{(I, T) \sim D} H(p^{itm}, p^{itm}(I, T))$$

其中， p^{itm} 是一个二维的独热向量，用于表示真实标签。

我们提出了一种为图像 - 文本匹配（ITM）任务采样难负样本的策略，且该策略无需额外计算开销。如果一个负图像 - 文本对具有相似的语义但在细粒度细节上存在差异，那么它就是难负样本。我们利用公式 1 中的对比相似度来寻找批次内的难负样本。对于迷你批次中的每个图像，我们根据对比相似度分布从同一批次中采样一个负文本，与该图像相似度越高的文本被采样的概率越大。同样，我们也为每个文本采样一个难负图像。

ALBEF 的完整预训练目标是：

$$\mathcal{L} = \mathcal{L}_{itm} + \mathcal{L}_{mlm} + \mathcal{L}_{itc} \quad (5)$$

3.3 动量蒸馏

用于预训练的图文对大多从网络上收集而来，且往往存在噪声。正样本对通常关联性较弱：文本可能包含与图像无关的词汇，或者图像可能包含文本中未描述的实体。对于图文对比学习（ITC），一张图像的负文本也可能与该图像的内容相匹配。对于掩码语言模型（MLM），可能存在其他与标注不同的词汇，同样能很好（甚至更好地）描述图像。然而，图文对比学习和掩码语言模型的独热标签会对所有负预测进行惩罚，无论这些预测是否正确。

为解决这一问题，我们建议从动量模型生成的伪目标中学习。动量模型是一个不断进化的教师模型，由单模态编码器和多模态编码器的指数移动平均版本组成。在训练过程中，我们对基础模型进行训练，使其预测结果与动量模型的预测结果相匹配。具体而言，对于 ITC，我们首先使用来自动量单模态编码器的特征计算图像 - 文本相似度，如 1

$s'(I, T) = s'(e^I, e^T) = e^{I^T e^T}$ 和 $s'(T, I) = s'(e^T, e^I) = e^{T^T e^I}$ 所示。然后，我们通过公式 1 中将 s 替换为 s' 来计算软伪目标 σ^{i2t} 和 σ^{t2i} 。ITC_{mod} 损失定义为：

$$\mathcal{L}_{mod} = (1 - \alpha) \mathcal{L}_{itm} + \alpha \mathbb{E}_{(I, T) \sim D} [K_L(\sigma^{i2t}(I) \| \sigma^{i2t}(I)) + K_L(\sigma^{t2i}(T) \| \sigma^{t2i}(T))] \quad (6)$$

在 BERT 之后，替换方式为 10% 的随机 token、10% 保持不变以及 80% 的 $[MASK]$

类似地，对于 MLM，令 $q^{msk}(I, \hat{T})$ 表示动量模型对掩码 token 的预测概率， MLM_{MoD} 损失为：

$$\mathcal{L}_{mlm}^{mod} = (1 - \alpha)\mathcal{L}_{mlm} + \alpha \mathbb{E}_{(I, \hat{T}) \sim D} KL(q^{msk}(I, \hat{T}) \| p^{msk}(I, \hat{T}))$$

在图 2 中，我们展示了伪目标中排名前五的候选示例，这些示例有效地捕捉了图像的相关词语 / 文本。更多示例可参见附录。

我们还将 MoD 应用于下游任务。每个任务的最终损失是原始任务损失与模型预测和伪目标之间的 KL 散度的加权组合。为简单起见，我们为所有预训练和下游任务 2 设置权重 $\alpha = 0.4$ 。

3.4 预训练数据集

遵循 UNITER [2]，我们使用两个网络数据集（Conceptual Captions [4]、SBU Captions [5]）和两个领域内数据集（COCO [41]、Visual Genome [42]）构建预训练数据。独特图像的总数为 400 万张，图像 - 文本对的数量为 510 万对。为了证明我们的方法在更大规模的网络数据集上具有可扩展性，我们还纳入了噪声大得多的 Conceptual

1200 万数据集 [43]，将图像总数增加到 1410 万 [4.1M]³。详情见附录。

3.5 实现细节

我们的模型由一个参数为 123.7M 的 *bert-base* 和一个参数为 85.8M 的 ViT-B/16 组成。我们在 8 块 NVIDIA A100 GPU 上，以 512 的批次大小对模型进行了 30 个 epoch 的预训练。我们使用 AdamW [44] 优化器，权重衰减设为 0.02。学习率在前 1000 次迭代中预热至 10^{-4} ，之后按照余弦调度衰减至 10^{-5} 。预训练期间，我们采用分辨率为 256×256 的随机图像裁剪作为输入，并应用 RandAugment4 [45]。微调时，我们将图像分辨率提高到 384×384 ，并按照 [38] 中的方法对图像块的位置编码进行插值。用于更新动量模型的动量参数设为 0.995，用于图像 - 文本对比学习的队列大小设为 65,536。我们在第一个 epoch 内将蒸馏权重 α 从 0 线性提升至 0.4。

4 互信息最大化视角

在本节中，我们提供了 ALBEF 的另一种视角，并表明它最大化了图像 - 文本对不同“视图”之间互信息（MI）的下界。ITC、MLM 和 MoD 可以被解释为生成这些视图的不同方式。

形式上，我们将两个随机变量 a 和 b 定义为数据点的两种不同视图。在自监督学习中 [24, 25, 46]， a 和 b 是同一图像的两种增强形式。在视觉 - 语言表示学习中，我们将 a 和 b 视为捕获图像 - 文本对语义的不同变体。我们的目标是学习对视图变化具有不变性的表示。这可以通过最大化 a 和 b 之间的互信息（MI）来实现。在实践中，我们通过最小化 InfoNCE 损失 [47] 来最大化 $MI(a, b)$ 的下界，该损失定义为：

$$\mathcal{L}_{NCE} = -\mathbb{E}_{(a, b)} \left[\log \frac{\exp(s(a, b))}{\sum_{(a', b') \in \hat{R}} \exp(s(a', b'))} \right]$$

其中， $s(a, b)$ 是一个评分函数（例如，两个表示之间的点积）， $\hat{R}$ 包含正样本 b 和从提议分布中抽取的 $|\hat{R}| - 1$ 个负样本。

我们使用独热标签的 ITC 损失（公式 2）可以重写为：

$$\mathcal{L}_{itc} = -\frac{1}{2} \mathbb{E}_{(I, T)} \left[\log \frac{\exp(s(I, T)/\tau)}{\sum_{(I', T') \in \hat{R}} \exp(s(I', T')/\tau)} + \log \frac{\exp(s(T, I)/\tau)}{\sum_{(T', I') \in \hat{R}} \exp(s(T', I')/\tau)} \right] \quad (9)$$

最小化 $\mathcal{L}_{itc}$ 可以被视为最大化 InfoNCE 的对称版本。因此，ITC 将两种单独的模态（即图像和文本）视为图像 - 文本对的两个视图，并训练单模态编码器以最大化正样本对的图像视图和文本视图之间的互信息（MI）。

³ 我们的实验表明， $\alpha = 0.3$ 到 0.5 产生了相似的性能，其中 $\alpha = 0.4$ 略好一些。

网络数据集中提供的一些 URL 已失效。

我们从 RandAugment 中移除了颜色变化操作，因为文本中通常包含颜色信息。

如 [48] 所示, 我们也可以将 MLM 解释为最大化被掩码词元与其掩码上下文 (即图像 + 被掩码文本) 之间的互信息 (MI)。具体来说, 我们可以用独热标签重写 MLM 损失 (公式 3), 如下所示:

$$\mathcal{L}_{mlm} = -\mathbb{E}_{p(I, \hat{T})} \left[\log \frac{\exp(\psi(y^{msk})^\top f(I, \hat{T}))}{\sum_{v \in V} \exp(\psi(v)^\top f(I, \hat{T}))} \right]$$

其中, $\psi(v): V \rightarrow \mathbb{R}^d$ 是多模态编码器输出层中的一个查找函数, 它将词元 y 映射为一个向量, v 是完整词汇集, 而 $f(I, \hat{T})$ 是一个函数, 返回与掩码上下文对应的多模态编码器的最终隐藏状态。因此, MLM 将图像 - 文本对的两种视图视为: (1) 随机选择的词元, 以及 (2) 图像 + 该词被掩码后的上下文文本。

ITC 和 MLM 都是通过从图文对中提取部分信息 (要么通过模态分离, 要么通过单词掩码) 来生成视图。我们的动量蒸馏可以看作是从整个提议分布中生成替代视图。以公式 6 中的 $ITCM_{\tau}$ 为例, 最小化 $KL(p^{i2t}(I) \| q^{i2t}(I))$ 等同于最小化以下目标:

$$-\sum_m q_m^{i2t}(I) \log p_m^{i2t}(I) = -\sum_m \frac{\exp(s(I, T_m)/\tau)}{\sum_{m'} \exp(s(I, T_{m'})/\tau)} \log \frac{\exp(s(I, T_m)/\tau)}{\sum_{m'} \exp(s(I, T_{m'})/\tau)} \quad (11)$$

它会针对与图像 I 具有相似语义的文本最大化 $MI(I \| T_m)$, 因为这些文本具有更大的 $q_m^{i2t}(I)$ 。同样, $ITCM_{\tau}$ 也会针对与 T 相似的图像最大化 $MI(I_m \| T)$ 。我们可以采用相同的方法来证明机器学习 $ITCM_{\tau}$ 会为被掩码词元 msk 生成替代视图 $v' \in V$, 并最大化 v' 与 $(I, \hat{T})$ 之间的互信息 (MI)。因此, 我们的动量蒸馏可以被视为对原始视图进行数据增强。动量模型会生成原始图像 - 文本对中所没有的多样化视图集合, 并促使基础模型学习能够捕捉视图不变语义信息的表示。

5 下游视觉 + 语言任务

我们将预训练模型适配到五个下游视觉 - 语言任务中。下面介绍每个任务以及我们的微调策略。数据集和微调超参数的详细信息见附录。

图文检索包含两个子任务: 图像到文本检索 (TR) 和文本到图像检索 (IR)。我们在 Flickr30K [49] 和 COCO 基准数据集上对 ALBEF 进行评估, 并使用每个数据集的训练样本对预训练模型进行微调。对于 Flickr30K 上的零样本检索, 我们使用在 COCO 上微调过的模型进行评估。在微调过程中, 我们联合优化 ITC 损失 (公式 2) 和 ITM 损失 (公式 4)。ITC 基于单模态特征的相似性学习图像 - 文本评分函数, 而 ITM 则对图像和文本之间的细粒度交互进行建模以预测匹配分数。由于下游数据集的每张图像都对应多个文本, 我们修改了 ITC 的真实标签, 以在队列中考虑多个正样本, 其中每个正样本的真实概率为 $1/\#$ 个正样本。在推理阶段, 我们首先计算所有图像 - 文本对的特征相似性分数 $\dots$ 。然后, 我们选取前 k 个候选对, 并计算它们的 ITM 分数 $\dots$ 用于排序。由于 k 可以设置得非常小, 我们的推理速度比需要计算所有图像 - 文本对的 ITM 分数的方法 [2, 3, 8] 快得多。

视觉蕴含 (SNLI-VF⁵ [51]) 是一项细粒度的视觉推理任务, 用于预测图像和文本之间的关系是蕴含、中立还是矛盾。我们遵循 UNITER [2], 将视觉蕴含视为一个三分类问题, 并使用多层感知器 (MLP) 基于多模态编码器对 [CLS] 标记的表示来预测类别概率。

视觉问答 (VQA [52]) 要求模型在给定图像和问题的情况下预测答案。与将 VQA 表述为多答案分类问题的现有方法 [53, 2] 不同, 我们将 VQA 视为答案生成问题, 这与 [54] 类似。具体而言, 我们使用一个 6 层的 Transformer 解码器来生成答案。如图 3a 所示, 自回归答案解码器通过交叉注意力接收多模态嵌入, 并且序列起始标记 ([CLS]) 被用作解码器的初始输入标记。同样, 序列结束标记 ([SEP]) 被附加到解码器输出的末尾, 以指示生成完成。

⁵关于 SNLI-VF 的 5 个结果应谨慎解读, 因为据报道称其测试数据存在噪声 [50]




图 3: VQA 和 $NLVR^2$ 的模型架构。对于 VQA, 我们添加了一个自回归解码器, 以根据图像 - 问题嵌入生成答案。对于 $NLVR^2$, 我们在多模态编码器的每一层内复制了 transformer 块, 以实现对于两张图像的推理。

答案解码器使用多模态编码器的预训练权重进行初始化, 并通过条件语言建模损失进行微调。为了与现有方法进行公平比较, 我们在推理过程中限制解码器只能从 3192 个候选答案中生成结果 [55]。

视觉推理自然语言 ($NLVR^2$ [19]) 要求模型预测一段文本是否描述了一对图像。我们扩展了多模态编码器, 使其能够对两张图像进行推理。如图 3b 所示, 多模态编码器的每一层都被复制为两个连续的 Transformer 块, 每个块包含一个自注意力层、一个交叉注意力层和一个前馈层 (见图 1)。每层中的两个块使用相同的预训练权重进行初始化, 且两个交叉注意力层共享相同的键和值的线性投影权重。在训练过程中, 这两个块接收图像对的两组图像嵌入。我们在多模态编码器的 [CLS] 表示上附加了一个 MLP 分类器用于预测。

对于 NLVR2, 我们执行了一个额外的预训练步骤, 为编码图像对准备新的多模态编码器。我们设计了一个文本分配 (TA) 任务, 具体如下: 给定一对图像和一段文本, 模型需要将该文本分配给第一张图像、第二张图像, 或者两者都不分配。我们将其视为一个三分类问题, 并在 [CLS] 表示上使用全连接层来预测分配结果。我们使用 400 万张图像 (第 3.4 节) 仅对 TA 任务进行了 1 个 epoch 的预训练。

视觉定位旨在定位图像中与特定文本描述相对应的区域。我们研究了弱监督设置, 其中没有可用的边界框标注。我们在 RefCOCO+[56] 数据集上进行了实验, 并遵循与图像 - 文本检索相同的策略, 仅使用图像 - 文本监督来微调模型。在推理过程中, 我们扩展了 Grad-CAM [9] 以获取热图, 并使用这些热图对 [53] 提供的检测提案进行排序。

6 实验

6.1 所提方法的评估

首先, 我们评估了所提出方法 (即图像 - 文本对比学习、对比难负样本挖掘和动量蒸馏) 的有效性。表 1 展示了不同变体方法在下游任务中的性能。与基线预训练任务 (MLM+ITM) 相比, 添加 ITC 显著提升了预训练模型在各个方面的性能。

#Pre-train Images	Training tasks	TR (flickr test)	IR	SNLI-VE (test)	NLVR ² (test-P)	VQA (test-dev)
4M	MLM + ITM	93.96	88.55	77.06	77.51	71.40
	ITC + MLM + ITM	96.55	91.69	79.15	79.88	73.29
	ITC + MLM + ITM _{hard}	97.01	92.16	79.77	80.35	73.81
	ITC _{MoD} + MLM + ITM _{hard}	97.33	92.43	79.99	80.34	74.06
	Full (ITC _{MoD} + MLM _{MoD} + ITM _{hard})	97.47	92.58	80.12	80.44	74.42
	ALBEF (Full + MoD _{Downstream})	97.83	92.65	80.30	80.50	74.54
14M	ALBEF	98.70	94.07	80.91	83.14	75.84

表 1: 所提方法在四个下游视觉 + 语言任务上的评估。对于文本检索 (TR) 和图像检索 (IR), 我们报告了 R@1、R@5 和 R@10 的平均值。ITC: 图像 - 文本对比学习。MLM: 掩码语言建模。ITM_{hard}: 带有对比性难负样本挖掘的图像 - 文本匹配。MoD: 动量蒸馏。MoD_{Downstream}: 下游任务上的动量蒸馏。

Method	# Pre-train Images	Flickr30K (1K test set)						MSCOCO (5K test set)					
		TR			IR			TR			IR		
		R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10
UNITER	4M	87.3	98.0	99.2	75.6	94.1	96.8	65.7	88.6	93.8	52.9	79.9	88.0
VILLA	4M	87.9	97.5	98.8	76.3	94.2	96.8	-	-	-	-	-	-
OSCAR	4M	-	-	-	-	-	-	70.0	91.1	95.5	54.0	80.8	88.5
ALIGN	1.2B	95.3	99.8	100.0	84.9	97.4	98.6	77.0	93.5	96.9	59.9	83.3	89.8
ALBEF	4M	94.3	99.4	99.8	82.8	96.7	98.4	73.1	91.4	96.0	56.8	81.5	89.2
ALBEF	14M	95.9	99.8	100.0	85.6	97.5	98.9	77.6	94.3	97.2	60.7	84.3	90.5

表 2: 在 Flickr30K 和 COCO 数据集上的微调图文检索结果。

Method	# Pre-train Images	Flickr30K (1K test set)					
		TR			IR		
		R@1	R@5	R@10	R@1	R@5	R@10
UNITER [2]	4M	83.6	95.7	97.7	68.7	89.2	93.9
CLIP [6]	400M	88.0	98.7	99.4	68.7	90.6	95.2
ALIGN [7]	1.2B	88.6	98.7	99.7	75.7	93.8	96.8
ALBEF	4M	90.5	98.8	99.7	76.8	93.7	96.7
ALBEF	14M	94.1	99.5	99.7	82.8	96.3	98.1

表 3: Flickr30K 上的零样本图文检索结果。

Method	VQA		NLVR ²		SNLI-VE	
	test-dev	test-std	dev	test-P	val	test
VisualBERT [13]	70.80	71.00	67.40	67.00	-	-
VL-BERT [10]	71.16	-	-	-	-	-
LXMERT [1]	72.42	72.54	74.90	74.50	-	-
12-in-1 [12]	73.15	-	-	78.87	-	76.95
UNITER [2]	72.70	72.91	77.18	77.85	78.59	78.28
VL-BART/T5 [54]	-	71.3	-	73.6	-	-
ViLT [21]	70.94	-	75.24	76.21	-	-
OSCAR [3]	73.16	73.44	78.07	78.36	-	-
VILLA [8]	73.59	73.67	78.39	79.30	79.47	79.03
ALBEF (4M)	74.54	74.70	80.24	80.50	80.14	80.30
ALBEF (14M)	75.84	76.04	82.55	83.14	80.80	80.91

表 4: 在下游视觉 - 语言任务上与最先进方法的比较。

所有任务。所提出的难负样本挖掘通过找到更多信息量丰富的训练样本来改进 ITM。此外，添加动量蒸馏改进了 ITC（第 4 行）、MLM（第 5 行）以及所有下游任务（第 6 行）的学习效果。在最后一行中，我们展示了 ALBEF 能够有效利用更多含噪网络数据来提升预训练性能。

6.2 图像 - 文本检索评估

表 2 和表 3 分别报告了微调及零样本图文检索的结果。我们的 ALBEF 实现了最先进的性能，优于 CLIP [6] 和 ALIGN [7]，后两者是在规模大几个数量级的数据集上训练的。鉴于当训练图像数量从 400 万增加到 1400 万时，ALBEF 有显著的性能提升，我们推测，通过在更大规模的网络图文对上进行训练，它还有进一步提升的潜力。

6.3 对 VQA、NLVR 和 VE 的评估

表 4 报告了在其他视觉 + 语言理解任务上与现有方法的比较。使用 400 万张预训练图像时，ALBEF 已达到最先进的性能。使用 1400 万张预训练图像时，ALBEF 大幅优于现有方法，包括那些额外使用对象标签 [3] 或对抗性数据增强 [8] 的方法。与 VILLA [8] 相比，ALBEF 在 VQA test-std 上实现了 2.37% 的绝对提升，在 $NLVR^2$ test-P 上实现了 3.84% 的提升，在 SNLI-VE 测试上实现了 1.88% 的提升。由于 ALBEF 无需检测器且需要的图像分辨率更低，与大多数现有方法相比，它还拥有更快的推理速度（在 $NLVR^2$ 上比 VILLA 快 < 10 倍）。

6.4 弱监督视觉定位

表 5 展示了在 RefCOCO + 上的结果，其中 ALBEF 显著优于现有方法 [57, 58]（这些方法使用较弱的文本嵌入）。ALBEF 变体计算 Grad-CAM。

Method	Val	TestA	TestB
ARN [57]	32.78	34.35	32.13
CCL [58]	34.29	36.91	33.56
ALBEF _{itc}	51.58	60.09	40.19
ALBEF _{itm}	58.46	65.89	46.25

表 5: 在 RefCOCO+ [56] 数据集上的弱监督视觉定位。



图 4: 多模态编码器第三层交叉注意力图上的 Grad-CAM 可视化。




图 5: VQA 模型多模态编码器交叉注意力图的 Grad-CAM 可视化。“一个小女孩抱着一只小猫，旁边是蓝色的栅栏”



图 6: 对应单个词语的交叉注意力图上的 Grad-CAM 可视化结果。

图像编码器最后一层自注意力图的可视化，其中梯度是通过最大化图像 - 文本相似度 ϕ_{itc} 获得的。ALBEF_{itm} 变体在多模态编码器第三层（这是一个专门用于接地的层）的交叉注意力图上计算 Grad-CAM，其中梯度是通过最大化图像 - 文本匹配分数 ϕ_{itm} 获得的。图 4 提供了一些可视化结果。更多分析见附录。

我们在图 5 中提供了 VQA 的 Grad-CAM 可视化结果。如附录所示，ALBEF 的 Grad-CAM 可视化结果与人类做决策时的关注点高度相关。在图 6 中，我们展示了 COCO 的逐词可视化结果。可以注意到，我们的模型不仅能定位物体，还能定位物体的属性和关系。

6.5 消融研究

表 6 研究了各种设计选择对图文检索的影响。由于我们在推理过程

	w/ hard negs	w/o hard negs
	$k = 256$	$k = 128$
	98.57	98.22 (-0.35)
	93.95	93.68 (-0.31)

中使用 s_{itc} 来筛选前 k 个候选对象，因此我们改变 k 的值并报告其

影响。总体而言，通过 s_{itm} 获得的召回率。我们使用 s_{itc} 来筛选前 k 个候选，并计算它们的 s_{itm} 分数以进行排序。他们还在最后一列验证了难负样本挖掘的效果。

表 7 研究了文本分配 (TA) 预训练和参数共享对 $NLVR^2$ 的影响。我们考察了三种策略：

(1) 两个多模态块共享所有参数；(2) 仅共享交叉注意力 (CA) 层；(3) 不共享。在没有 TA 的情况下，共享整个块的性能更好。使用 TA 对图像块模型进行预训练时，共享 CA 会带来最佳性能。

表 7: 关于 $NLVR^2$ 的消融研究：

7 结论与社会影响

本文提出了 ALBEF，一个用于视觉 - 语言表征学习的新框架。ALBEF 首先将单模态图像表征和文本表征进行对齐，然后通过多模态编码器对它们进行融合。我们从理论和实验上验证了所提出方法的有效性。

图文对比学习和动量蒸馏。与现有方法相比, ALBEF 在多个下游视觉 - 语言任务上表现更优, 推理速度更快。

虽然我们的论文在视觉 - 语言表征学习方面展示了令人期待的结果, 但在实际部署之前, 还需要对数据和模型进行额外分析, 因为网络数据可能包含非预期的私人信息、不合适的图像或有害文本, 而且仅优化准确性可能会产生不良的社会影响。

参考文献

- [1] 谭浩、M. 班萨尔。LXMERT: 从 Transformer 学习跨模态编码器表示。收录于 K. 乾、J. 江、V. 吴、X. 万编著的《EMNLP》, 第 5099 - 5110 页, 2019 年。
- [2] 陈宇、李莉、余亮等。UNITER: 通用图像 - 文本表示学习。见《欧洲计算机视觉会议论文集》, 卷 12375, 第 104-120 页, 2020 年。
- [3] 李雪、尹晓、李聪等。Oscar: 面向视觉 - 语言任务的对象 - 语义对齐预训练。见《欧洲计算机视觉会议论文集》, 第 121-137 页, 2020 年。
- [4] Sharma, P., N. Ding, S. Goodman, 等。概念性标题: 一个用于自动图像标题生成的经过清理、包含上位词的图像替代文本数据集。见 I. Gurevych、Y. Miyao 编, 《计算语言学协会会刊》, 第 2556 - 2565 页, 2018 年。
- [5] 奥尔多涅斯、V.、库尔卡尼、G.、伯格、T. L.。《Im2text: 使用 100 万张带字幕的照片描述图像》。收录于肖韦 - 泰勒、J.、泽梅尔、R. S.、巴特利特、P. L.、佩雷拉、F. C. N.、温伯格、K. O. 编著的《神经信息处理系统进展》, 第 1143-1151 页, 2011 年。
- [6] 拉德福德 (A. Radford)、金 (J. W. Kim)、哈拉西 (C. Hallacy) 等。《从自然语言监督中学习可迁移的视觉模型》。arXiv 预印本 arXiv:2103.00020, 2021。
- [7] 贾聪、杨宇、夏宇等。利用带噪声的文本监督扩展视觉和视觉 - 语言表示学习。arXiv 预印本 arXiv:2102.05918, 2021。
- [8] 甘卓, 陈阳, 李亮等。用于视觉 - 语言表征学习的大规模对抗训练。见: 拉罗谢尔 H, 兰扎托 M, 哈德塞尔 R, 巴尔坎 M, 林 H (编), 《神经信息处理系统进展》。2020。
- [9] Selvaraju, R. R., M. Cogswell, A. Das, 等。Grad-cam: 基于梯度定位的深度网络视觉解释。见: ICCV, 第 618-626 页, 2017。
- [10] 苏伟、朱晓、曹阳等。Vl-bert: 通用视觉 - 语言表征的预训练。见《国际学习表征会议论文集》, 2020 年。
- [11] 卢静、D. 巴特拉、D. 帕里希等。《Vilbert: 为视觉与语言任务预训练与任务无关的视觉语言表征》。收录于 H. M. 沃拉赫、H. 拉罗谢尔、A. 贝格尔齐默、F. 达尔谢 - 布克、E. B. 福克斯、R. 加内特编。《神经信息处理系统进展》, 第 13-23 页, 2019 年。
- [12] 卢 (Lu)、戈斯瓦米 (V. Goswami)、罗尔巴赫 (M. Rohrbach) 等人。《十二合一: 多任务视觉与语言表征学习》。发表于《计算机视觉与模式识别会议论文集》(CVPR), 第 10434 - 10443 页, 2020 年。
- [13] 李, L. H., M. 亚茨卡尔, D. 尹等。VisualBERT: 视觉与语言的简单高效基准模型。arXiv 预印本 arXiv:1908.03557, abs/1908.03557, 2019。
- [14] 齐栋、苏乐、宋佳等。Imagebert: 基于大规模弱监督图像 - 文本数据的跨模态预训练。arXiv 预印本 arXiv:2001.07966, 2020。
- [15] 李戈、段宁、方宇等。Unicoder-vl: 通过跨模态预训练实现的通用视觉与语言编码器。发表于《AAAI》, 第 11336-11344 页, 2020 年。
- [16] 余飞、唐杰、尹文生等。Ernie-vil: 通过场景图增强的知识视觉 - 语言表征。arXiv 预印本 arXiv:2006.16934, 2020。
- [17] 张鹏、李鑫、胡晓等。Vinvl: 让视觉表征在视觉 - 语言模型中发挥作用。arXiv 预印本 arXiv:2101.00529, 2021。
- [18] 黄卓、曾卓、黄毅等。跳出框框看: 用于视觉 - 语言表示学习的端到端预训练。arXiv 预印本 arXiv:2104.03135, 2021。
- [19] 苏尔 (A. Suhr)、周 (S. Zhou)、张 (A. Zhang) 等人。一个基于照片的自然语言推理语料库。收录于科尔霍宁 (A. Korhonen)、特劳姆 (D. R. Traum)、马克斯 (L. Márquez) 主编的《计算语言学期刊》, 第 6418-6428 页, 2019 年。

- [20] Antol, S., A. Agrawal, J. Lu, et al. VQA: visual question answering. In *ICCV*, pages 2425–2433. 2015.
- [21] Kim, W., B. Son, I. Kim. Vilt: Vision-and-language transformer without convolution or region supervision. *arXiv preprint arXiv:2102.03334*, 2021.
- [22] Faghri, F., D. J. Fleet, J. R. Kiros, et al. VSE++: improving visual-semantic embeddings with hard negatives. In *BMVC*, page 12. 2018.
- [23] Li, K., Y. Zhang, K. Li, et al. Visual semantic reasoning for image-text matching. In *ICCV*, pages 4653–4661. 2019.
- [24] He, K., H. Fan, Y. Wu, et al. Momentum contrast for unsupervised visual representation learning. In *CVPR*. 2020.
- [25] Chen, T., S. Kornblith, M. Norouzi, et al. A simple framework for contrastive learning of visual representations. In *ICML*. 2020.
- [26] Li, J., P. Zhou, C. Xiong, et al. Prototypical contrastive learning of unsupervised representations. In *ICLR*. 2021.
- [27] Li, J., C. Xiong, S. C. Hoi. Mopro: Webly supervised learning with momentum prototypes. In *ICLR*. 2021.
- [28] Hinton, G., O. Vinyals, J. Dean. Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*, 2015.
- [29] Zagoruyko, S., N. Komodakis. Paying more attention to attention: Improving the performance of convolutional neural networks via attention transfer. In *ICLR*. 2017.
- [30] Furlanello, T., Z. C. Lipton, M. Tschannen, et al. Born-again neural networks. In J. G. Dy, A. Krause, eds., *ICML*, pages 1602–1611. 2018.
- [31] Touvron, H., M. Cord, M. Douze, et al. Training data-efficient image transformers & distillation through attention. *arXiv preprint arXiv:2012.12877*, 2020.
- [32] Sanh, V., L. Debut, J. Chaumond, et al. Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter. *arXiv preprint arXiv:1910.01108*, 2019.
- [33] Zhang, Y., T. Xiang, T. M. Hospedales, et al. Deep mutual learning. In *CVPR*, pages 4320–4328. 2018.
- [34] Anil, R., G. Pereyra, A. Passos, et al. Large scale distributed neural network training through online distillation. In *ICLR*. 2018.
- [35] Tarvainen, A., H. Valpola. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results. In *NIPS*, pages 1195–1204. 2017.
- [36] Li, J., R. Socher, S. C. Hoi. Dividemix: Learning with noisy labels as semi-supervised learning. In *ICLR*. 2020.
- [37] Cheng, R., B. Wu, P. Zhang, et al. Data-efficient language-supervised zero-shot learning with self-distillation. *arXiv preprint arXiv:2104.08945*, 2021.
- [38] Dosovitskiy, A., L. Beyer, A. Kolesnikov, et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *ICLR*. 2021.
- [39] Vaswani, A., N. Shazeer, N. Parmar, et al. Attention is all you need. In I. Guyon, U. von Luxburg, S. Bengio, H. M. Wallach, R. Fergus, S. V. N. Vishwanathan, R. Garnett, eds., *NIPS*, pages 5998–6008. 2017.
- [40] Devlin, J., M. Chang, K. Lee, et al. BERT: pre-training of deep bidirectional transformers for language understanding. In J. Burstein, C. Doran, T. Solorio, eds., *NAACL*, pages 4171–4186. 2019.
- [41] Lin, T., M. Maire, S. J. Belongie, et al. Microsoft COCO: common objects in context. In D. J. Fleet, T. Pajdla, B. Schiele, T. Tuytelaars, eds., *ECCV*, vol. 8693, pages 740–755. 2014.
- [42] Krishna, R., Y. Zhu, O. Groth, et al. Visual genome: Connecting language and vision using crowdsourced dense image annotations. *IJCV*, 123(1):32–73, 2017.
- [43] Changpinyo, S., P. Sharma, N. Ding, et al. Conceptual 12M: Pushing web-scale image-text pre-training to recognize long-tail visual concepts. In *CVPR*. 2021.

- [44] Loshchilov, I., F. Hutter. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017.
- [45] Cubuk, E. D., B. Zoph, J. Shlens, et al. Randaugment: Practical automated data augmentation with a reduced search space. In *CVPR Workshops*, pages 702–703. 2020.
- [46] Tian, Y., C. Sun, B. Poole, et al. What makes for good views for contrastive learning? In H. Larochelle, M. Ranzato, R. Hadsell, M. Balcan, H. Lin, eds., *NeurIPS*. 2020.
- [47] Oord, A. v. d., Y. Li, O. Vinyals. Representation learning with contrastive predictive coding. *arXiv preprint arXiv:1807.03748*, 2018.
- [48] Kong, L., C. de Masson d’Autume, L. Yu, et al. A mutual information maximization perspective of language representation learning. In *ICLR*. OpenReview.net, 2020.
- [49] Plummer, B. A., L. Wang, C. M. Cervantes, et al. Flickr30k entities: Collecting region-to-phrase correspondences for richer image-to-sentence models. In *ICCV*, pages 2641–2649. 2015.
- [50] Do, V., O.-M. Camburu, Z. Akata, et al. e-snli-ve: Corrected visual-textual entailment with natural language explanations. *arXiv preprint arXiv:2004.03744*, 2020.
- [51] Xie, N., F. Lai, D. Doran, et al. Visual entailment: A novel task for fine-grained image understanding. *arXiv preprint arXiv:1901.06706*, 2019.
- [52] Goyal, Y., T. Khot, D. Summers-Stay, et al. Making the V in VQA matter: Elevating the role of image understanding in visual question answering. In *CVPR*, pages 6325–6334. 2017.
- [53] Yu, L., Z. Lin, X. Shen, et al. Mattnet: Modular attention network for referring expression comprehension. In *CVPR*, pages 1307–1315. 2018.
- [54] Cho, J., J. Lei, H. Tan, et al. Unifying vision-and-language tasks via text generation. *arXiv preprint arXiv:2102.02779*, 2021.
- [55] Kim, J., J. Jun, B. Zhang. Bilinear attention networks. In S. Bengio, H. M. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, R. Garnett, eds., *NIPS*, pages 1571–1581. 2018.
- [56] Yu, L., P. Poirson, S. Yang, et al. Modeling context in referring expressions. In B. Leibe, J. Matas, N. Sebe, M. Welling, eds., *ECCV*, pages 69–85. 2016.
- [57] Liu, X., L. Li, S. Wang, et al. Adaptive reconstruction network for weakly supervised referring expression grounding. In *ICCV*, pages 2611–2620. 2019.
- [58] Zhang, Z., Z. Zhao, Z. Lin, et al. Counterfactual contrastive learning fo weakly-supervised vision-language grounding. In H. Larochelle, M. Ranzato, R. Hadsell, M. Balcan, H. Lin, eds., *NeurIPS*. 2020.
- [59] Karpathy, A., F. Li. Deep visual-semantic alignments for generating image descriptions. In *CVPR*, pages 3128–3137. 2015.
- [60] Bowman, S. R., G. Angeli, C. Potts, et al. A large annotated corpus for learning natural language inference. In L. Màrquez, C. Callison-Burch, J. Su, D. Pighin, Y. Marton, eds., *EMNLP*, pages 632–642. 2015.
- [61] Yu, Z., J. Yu, Y. Cui, et al. Deep modular co-attention networks for visual question answering. In *CVPR*, pages 6281–6290. 2019.
- [62] Kazemzadeh, S., V. Ordonez, M. Matten, et al. Referitgame: Referring to objects in photographs of natural scenes. In A. Moschitti, B. Pang, W. Daelemans, eds., *EMNLP*. 2014.
- [63] Das, A., H. Agrawal, C. L. Zitnick, et al. Human Attention in Visual Question Answering: Do Humans and Deep Networks Look at the Same Regions? 2016.

A 下游任务详情

在此我们描述预训练模型微调的实现细节。对于所有下游任务，我们使用与预训练期间相同的 RandAugment、AdamW 优化器、余弦学习率衰减、权重衰减和蒸馏权重。所有下游任务接收的输入图像分辨率为 384×384 。在推理过程中，我们对图像进行缩放，不进行任何裁剪。

图文检索。我们为这项任务考虑了两个数据集：COCO 和 Flickr30K。我们对这两个数据集都采用了广泛使用的 Karpathy 分割 [59]。COCO 的训练 / 验证 / 测试集包含 113/5k/5k。Flickr30K 的训练 / 验证 / 测试集包含 29k/1k/1k 张图像。我们微调了 10 个 epoch。批大小为 256，初始学习率为 $1e^{-5}$ 。

视觉蕴含。我们在 SNLI-VE 数据集 [51] 上进行评估，该数据集是利用斯坦福自然语言推理 (SNLI) [60] 和 Flickr30K 数据集构建的。我们遵循原始的数据集划分，其中 29.8k 张图像用于训练，1k 张用于评估，1k 张用于测试。我们对预训练模型进行了 5 个 epoch 的微调。批处理大小为 256，初始学习率为 $2e^{-5}$ 。

VQA。我们在 VQA2.0 数据集 [52] 上进行了实验，该数据集是利用 COCO 中的图像构建的。它包含 83k 张训练图像、41k 张验证图像和 81k 张测试图像。我们在 test-dev 和 test-std 拆分上报告性能。遵循大多数现有研究 [1, 2, 61]，我们同时使用训练集和验证集进行训练，并纳入来自 Visual Genome 的额外问答对。由于 VQA 数据集中的许多问题有多个答案，我们根据每个答案在所有答案中的出现比例来对其损失进行加权。我们对模型进行了 8 个 epoch 的微调，使用的批处理大小为 256，初始学习率为 $2e^{-5}$ 。

NLVR² 我们按照文献 [19] 中最初的训练 / 验证 / 测试划分进行实验。我们微调了使用 128 的批次大小和 $2e^{-5}$ 的初始学习率，对模型进行 10 个轮次的训练。因为 NLVR

接收两张输入图像时，我们会执行一个额外的文本分配 (TA) 预训练步骤，为模型对两张图像进行推理做准备。TA 预训练使用尺寸为 256×256 的图像。我们在 4M 数据集上预训练 1 个轮次，使用的批处理大小为 256，学习率为 $2e^{-5}$ 。

视觉定位。我们在 RefCOCO + 数据集 [56] 上进行了实验，该数据集是通过双人 ReferitGame [62] 收集的。它包含来自 COCO 训练集的 19,992 张图像的 141,564 个表达式。严格来说，我们的模型不允许看到 RefCOCO + 的验证 / 测试图像，但在预训练期间已经接触过这些图像。我们假设这几乎没有影响，因为这些图像在整个 1400 万张预训练图像中只占很小的一部分，我们将数据净化工作留待未来进行。在弱监督微调期间，我们采用与图像 - 文本检索相同的策略，只是不进行随机裁剪，并对模型进行 5 个 epoch 的训练。

在推理过程中，我们使用 e_{itn} 或 e_{itm} 来计算每个 16×16 图像块的重要性分数。对于 ITC，我们在视觉编码器最后一层中针对 [CLS] 标记的自注意力图上计算 Grad-CAM 可视化，并对所有注意力头的热力图进行平均。对于 ITM，我们在多模态编码器第三层的交叉注意力图上计算 Grad-CAM，并对所有注意力头和所有输入文本标记的分数进行平均。ITC 和 ITM 之间的定量比较如表 5 所示。图 7 展示了定性比较。由于多模态编码器能够更好地建模图像 - 文本交互，因此它生成的热力图更好，能够捕捉更精细的细节。在图 8 中，我们报告了每个交叉注意力层以及性能最佳层中每个单独注意力头的定位准确率。




图 7：多模态编码器生成的 Grad-CAM 捕捉到了更精细的细节，例如“更大”和“卷曲”。




图 8: RefCOCO + 验证集上的定位准确率。(a) 改变交叉注意力层，其中每层使用所有注意力头。(b) 在性能最佳的（第 3 个）层中改变交叉注意力头。



图 9: 对应单个词语的交叉注意力图上的 Grad-CAM 可视化。

B 额外的逐词可视化

在图 9 中，我们展示了更多单词级 Grad-CAM 的可视化结果，以证明我们的模型具备对物体、动作、属性和关系进行视觉定位的能力。




图 10：人类注意力与 ALBEF 的 Grad-CAM 在视觉问答（VQA）上的定性比较。

C 与人类注意力的比较

Das 等人 [63] 为 VQA 数据集 [20] 的一个子集收集了人类注意力图。在 Amazon Mechanical Turk 平台上，研究人员向参与者展示一个问题和一张经过模糊处理的图像，要求他们交互式地对图像区域进行去模糊处理，直到能够自信地回答该问题。在本研究中，我们将人类注意力图与 ALBEF VQA 模型的 Grad-CAM 可视化结果进行了比较。这些 Grad-CAM 可视化结果是在第 3 个多模态交叉注意力层上，针对 1374 个验证集问题 - 图像对计算得出的，采用的是 [63] 中使用的秩相关评估协议。我们发现，针对真实答案计算出的 Grad-CAM 和人类注意力图具有 0.205 的高相关性。这表明，尽管 ALBEF 没有在带标注的图像 - 文本对上进行训练，但在做决策时它会关注合适的区域。图 10 中提供了与人类注意力图进行比较的定性示例。

D 伪目标的其他示例



图 11：动量模型为 ITC 选择的前 5 个最相似文本示例。



图 12: 动量模型为 MLM 生成的排名前五的单词示例。

E 预训练数据集详情

表 8 展示了预训练数据集的图像和文本的统计数据。

	COCO (Karpathy-train)	VG	CC	SBU	CC12M
# image	113K	100K	2.95M	860K	10.06M
# text	567K	769K	2.95M	860K	10.06M

表 8: 预训练数据集的统计信息。