

BLIP-2: 使用冻结图像编码器和大型语言模型进行语言 - 图像预训练的引导

李俊楠 李在旭 西尔维奥·赫瓦雷斯 中基立·汪

<https://github.com/salesforce/BLIP/tree/main/projects/blip2>

由于大规模模型的端到端训练，视觉 - 语言预训练的成本变得越来越高昂。本文提出了 BLIP-2，这是一种通用且高效的预训练策略，它利用现成的冻结预训练图像编码器和冻结大型语言模型来启动视觉 - 语言预训练。BLIP-2 通过一个轻量级的查询 Transformer 来弥合模态差距，该 Transformer 分两个阶段进行预训练。第一阶段利用冻结的图像编码器启动视觉 - 语言表示学习。第二阶段利用冻结的语言模型启动视觉到语言的生成式学习。尽管 BLIP-2 的可训练参数明显少于现有方法，但它在各种视觉 - 语言任务上都达到了最先进的性能。例如，我们的模型在零样本 VQAv2 上比 Flamingo80B 高出 8.7%，而可训练参数却少了 54 倍。我们还展示了该模型在零样本图像

视觉 - 语言预训练 (VLP) 研究在过去几年中取得了快速进展，其中，规模不断扩大的预训练模型被开发出来，持续刷新各种下游任务的最先进水平 (Radford 等人, 2021 年; Li 等人, 2021 年、2022 年; Wang 等人, 2022a; Alayrac 等人, 2022 年; Wang 等人, 2022b)。然而，由于使用大规模模型和数据集进行端视觉 - 语言研究处于视觉和语言的交叉领域，因此，人们自然期望视觉 - 语言模型能够从视觉和自然语言领域中现成的单模态模型中汲取养分。在本文中，我

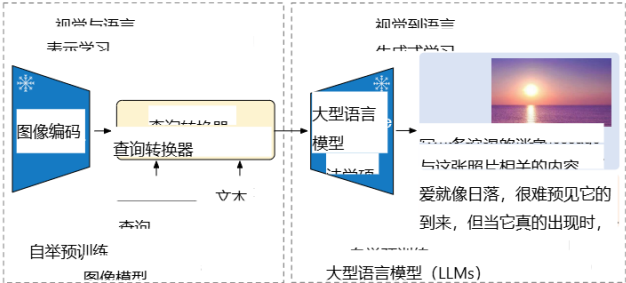


图 1. BLIP-2 框架概述。我们采用两阶段策略对轻量级查询 Transformer 进行预训练，以弥合模态差距。第一阶段从冻结的图像编码器中引导视觉 - 语言表示学习。第二阶段从冻结的大型语言模型 (LLM) 中引导视觉到语言的生成式学习，这使但零样本图像到文本生成成为可能 (更多示例见图

一种计算高效的视觉语言预训练 (VLP) 方法，通过利用现成的预训练视觉模型和语言模型进行引导。预训练视觉模型提供高质量的视觉表征。预训练语言模型，特别是大型语言模型 (LLMs)，具有强大的语言生成能力和零样本迁移能力。为了降低计算成本并解

为了将预训练的单模态模型应用于视觉语言预训练 (VLP)，促进跨模态对齐是关键。然而，由于大型语言模型 (LLMs) 在单模态预训练过程中并未接触过图像，冻结它们会使视觉 - 语言对齐变得尤其具有挑战性。在这方面，现有方法 (例如 Frozen (Tsimpoukelli

为了利用冻结的单模态模型实现有效的视觉 - 语言对齐，我们提出了一种查询转换器 (QFormer)，并采用了新的两阶段预训练策略对其进行预训练。如图 1 所示，Q-Former 是一种轻量级转换器，它使用一组可学习的查询向量从冻结的图像编码器中提取视觉特

供大语言模型输出所需文本的视觉特征。在第一个预训练阶段，我们进行视觉 - 语言表征学习，促使 Q-Former 学习与文本最相关的视觉表征。在第二个预训练阶段，我们通过将 Q-Former 的输出与冻结的大语言模型相连来进行视觉到语言的生成式学习，并训练 Q-Former，使其输出的视觉表征能被大语言模型解读。

我们将我们的视觉语言预训练框架命名为 BLIP-2：利用冻结的单模态模型进行语言 - 图像预训练的引导。BLIP-2 的主要优势包括：

- BLIP-2 有效地利用了冻结的预训练图像模型和语言模型。我们通过分两阶段预训练的 Q-Former 来弥合模态差距：表征学习阶段和生成学习阶段。BLIP-2 在各种视觉 - 语言任务上取得了最先进的性能，包括视觉问答、图像描述和图像 - 文本检索。
- 由大语言模型（例如 OPT (Zhang 等人, 2022)、FlanT5 (Chung 等人, 2022)）提供支持，BLIP-2 可以通过提示词执行零样本图文生成任务，遵循自然语言指令，这使其具备了视觉知识推理、视觉对话等新兴能力（示例见图 4）。
- 由于使用了冻结的单模态模型和轻量级的 Q-Former，BLIP-2 比现有的最先进模型在计算效率上更高。例如，在零样本 VQAv2 任务上，BLIP-2 的性能比 Flamingo (Alayrac 等人, 2022) 高出 8.7%，同时使用的可训练参数少了 54 倍。此外，我们的结果表明，BLIP-2 是一种通用方法，能够利用更先进的单模态模型来提升视觉语言处理 (VLP) 性能。

相关工作

2.1. 端到端视觉 - 语言预训练

视觉 - 语言预训练旨在学习多模态基础模型，以提高其在各种视觉和语言任务上的性能。根据下游任务的不同，研究者们提出了不同的模型架构，包括双编码器架构 (Radford 等人, 2021; Jia 等人, 2021)、融合编码器架构 (Tan 和 Bansal, 2019; Li 等人, 2021)、编码器 - 解码器架构 (Cho 等人, 2021; Wang 等人, 2021b; Chen 等人, 2022b)，以及最近提出的统一 Transformer 架构 (Li 等人, 2022; Wang 等人, 2022b)。多年来，人们还提出了各种预训练目标，这些目标逐渐集中到几个经过时间检验的目标上：图像 - 文本对比学习 (Radford 等人, 2021; Yao 等人, 2022; Li 等人, 2021; 2022)、图像 - 文本匹配 (Li 等人, 2021; 2022; Wang 等人, 2021a) 以及 (掩码) 语言建模 (Li 等人, 2021; 2022; Yu 等人, 2022; Wang 等人, 2022b)。

大多数视觉语言预训练 (VLP) 方法利用大规模图像 - 文本数据集进行端到端预训练。随着模型规模的不断增大，预训练会产生极高的计算成本。此外，端到端预训练模型在利用现成的单模态预训练模型（如大型语言模型 (LLMs) (Brown 等人, 2020; Zhang 等人, 2022; Chung 等人, 2022)）时缺乏灵活性。

2.2. 模块化视觉 - 语言预训练

与我们更相似的是那些利用现成预训练模型并在视觉语言预训练 (VLP) 期间保持其冻结状态的方法。一些方法冻结图像编码器，包括早期采用冻结目标检测器提取视觉特征的研究 (Chen 等人, 2020; Li 等人, 2020; Zhang 等人, 2021)，以及最近的 LiT (Zhai 等人, 2022)，该方法使用冻结的预训练图像编码器进行 CLIP (Radford 等人, 2021) 预训练。还有一些方法冻结语言模型，以利用大型语言模型 (LLMs) 中的知识来完成视觉到语言的生成任务 (Tsimpoukelli 等人, 2021; Alayrac 等人, 2022; Chen 等人, 2022a; Ma'nas 等人, 2023; Tiong 等人, 2022; Guo 等人, 2022)。使用冻结的大型语言模型的关键挑战在于将视觉特征与文本空间对齐。为实现这一点，Frozen (Tsimpoukelli 等人, 2021) 对图像编码器进行微调，其输出直接用作大型语言模型的软提示。Flamingo (Alayrac 等人, 2022) 在大型语言模型中插入新的交叉注意力层以注入视觉特征，并在数十亿图像 - 文本对上预训练这些新层。这两种方法都采用语言建模损失，即语言模型在图像的条件下生成文本。

与现有方法不同，BLIP-2 能够高效且有效地利用冻结的图像编码器和冻结的大型语言模型 (LLMs) 来完成各种视觉 - 语言任务，以更低的计算成本实现了更优的性能。

方法

我们提出了 BLIP-2，这是一种新的视觉 - 语言预训练方法，它基于冻结的预训练单模态模型进行开发。为了弥合模态差距，我们提出了一种分两阶段预训练的查询 Transformer (Q-Former)：(1) 使用冻结图像编码器的视觉 - 语言表示学习阶段；(2) 使用冻结大语言模型 (LLM) 的视觉到语言生成学习阶段。本节首先介绍 Q-Former 的模型架构，然后详细阐述两阶段预训练过程。

3.1. 模型架构

我们提出 Q-Former 作为可训练模块，以弥合冻结图像编码器和冻结大型语言模型 (LLM) 之间的差距。它从图像编码器中提取固定数量的输出特征，与输入图像分辨率无关。如图 2 所示，Q-Former 由两个共享相同自注意力层的 Transformer 子模块组成：(1) 一个与冻结图像编码器交互的图像 Transformer。




图 2. (左) Q-Former 的模型架构以及 BLIP-2 第一阶段的视觉 - 语言表征学习目标。我们联合优化三个目标，这些目标促使查询（一组可学习的嵌入）提取与文本最相关的视觉表征。（右）用于每个目标的自注意力掩码策略，以控制查询 - 文本交互。

用于视觉特征提取；(2) 一个既可以作为文本编码器又可以作为文本解码器的文本转换器。我们创建一定数量的可学习查询嵌入作为图像转换器的输入。查询通过自注意力层相互作用，并通过交叉注意力层（每隔一个转换器块插入）与冻结的图像特征相互作用。查询还可以通过相同的自注意力层与文本进行交互。根据预训练任务，我们应用不同的自注意力掩码来控制查询 - 文本交互。我们使用 $BERT_{\text{base}}$ (Devlin 等人, 2019) 的预训练权重初始化 QFormer，而交叉注意力层则是随机初始化的。Q-Former 总共有 1.88 亿个参数。请注意，查询被视为模型参数。

在我们的实验中，我们使用 32 个查询，每个查询的维度为 768（与 Q-Former 的隐藏维度相同）。我们用 Z 表示输出的查询表示。 Z 的大小 (32×768) 远小于冻结图像特征的大小（例如，ViT-L/14 的特征大小为 257×1024 ）。这种瓶颈架构与我们的预训练目标协同作用，迫使查询提取与文本最相关的视觉信息。

3.2. 基于冻结图像编码器的自举视觉 - 语言表示学习

在表示学习阶段，我们将 Q-Former 与冻结的图像编码器相连，并使用图文对进行预训练。我们的目标是训练 Q-Former，使查询能够学习提取对文本最具信息量的视觉表示。受 BLIP (Li 等人, 2022) 的启发，我们联合优化三个预训练目标，这些目标共享相同的输入格式和模型参数。每个目标在查询和文本之间采用不同的注意力掩码策略来控制它们的交互（见图 2）。

图文对比学习 (ITC) 旨在对齐图像表征和文本表征，以最大化它们之间的互信息。其通过将正样本对的图文相似度与负样本对的图文相似度进行对比来实现这一目标。我们将图像 Transformer 的输出查询表征 Z 与文本表征进行对齐。

t 来自文本转换器，其中 t 是 [CLS] 标记的输出嵌入。由于 Z 包含多个输出嵌入（每个查询一个），我们首先计算每个查询输出与 t 之间的成对相似度，然后选择最高的一个作为图像 - 文本相似度。为避免信息泄露，我们采用单模态自注意力掩码，其中查询和文本不允许相互查看。由于使用了冻结的图像编码器，与端到端方法相比，我们每个 GPU 可以容纳更多样本。因此，我们使用批内负样本，而不是 BLIP 中的动量队列。

图像接地文本生成 (ITG) 损失训练 Q-Former 以输入图像为条件生成文本。由于 Q-Former 的架构不允许冻结的图像编码器和文本标记之间直接交互，生成文本所需的信息必须首先由查询提取，然后通过自注意力层传递给文本标记。因此，查询被迫提取能够捕捉文本所有信息的视觉特征。我们采用多模态因果自注意力掩码来控制查询 - 文本交互，类似于 UniLM (Dong 等人, 2019) 中使用的掩码。查询可以相互关注，但不能关注文本标记。每个文本标记可以关注所有查询及其之前的文本标记。我们还将 [CLS] 标记替换为新的 [DEC] 标记作为第一个文本标记，以表示解码任务。

图文匹配 (ITM) 旨在学习图像和文本表示之间的细粒度对齐。这是一个二分类任务，要求模型预测图像 - 文本对是正样本（匹配）还是负样本（不匹配）。我们使用双向自注意力掩码，使所有查询和文本能够相互关注。因此，输出的查询嵌入 Z 捕获了多模态信息。我们将每个输出的查询嵌入输入到一个二分类线性分类器中以获得对数几率，并对所有查询的对数几率取平均值作为输出匹配分数。我们采用了 Li 等人 (2021; 2022) 的难负样本挖掘策略来创建具有信息性的负样本对。




图 3. BLIP-2 的第二阶段视觉到语言生成式预训练，该训练从冻结的大型语言模型（LLM）进行引导。（上）引导基于解码器的 LLM（例如 OPT）。（下）引导基于编码器 - 解码器的 LLM（例如 FlanT5）。全连接层将 Q-Former 的输出维度适配到所选 LLM 的输入维度。

3.3. 基于冻结大语言模型的视觉到语言生成式学习引导

在生成预训练阶段，我们将 QFormer（附带冻结的图像编码器）与冻结的大语言模型（LLM）相连，以获取 LLM 的生成语言能力。如图 3 所示，我们使用全连接（FC）层将输出的查询嵌入 Z 线性投影到与 LLM 的文本嵌入相同的维度。然后，将投影后的查询嵌入前置到输入文本嵌入中。它们充当软视觉提示，使 LLM 以 Q-Former 提取的视觉表示为条件。由于 Q-Former 已通过预训练来提取具有语言信息的视觉表示，它有效地充当了信息瓶颈，向 LLM 提供最有用的信息，同时去除不相关的视觉信息。这减轻了 LLM 学习视觉 - 语言对齐的负担，从而缓解了灾难性遗忘问题。

我们对两种类型的大语言模型（LLMs）进行了实验：基于解码器的大语言模型和基于编码器 - 解码器的大语言模型。对于基于解码器的大语言模型，我们使用语言建模损失进行预训练，其中冻结的大语言模型的任务是根据来自 Q-Former 的视觉表征生成文本。对于基于编码器 - 解码器的大语言模型，我们使用前缀语言建模损失进行预训练，在此过程中，我们将文本分为两部分。前缀文本与视觉表征拼接后作为大语言模型编码器的输入。后缀文本则作为大语言模型解码器的生成目标。

3.4. 模型预训练

预训练数据。我们使用与 BLIP 相同的预训练数据集，总共包含 1.29 亿张图像，其中包括 COCO (Lin 等人, 2014)、Visual Genome (Krishna 等人, 2017)、CC3M (Sharma 等人, 2018)、CC12M (Changpinyo 等人, 2021)、SBU (Ordonez 等人, 2011) 以及来自 LAION400M 数据集 (Schuhmann 等人, 2021) 的 1.15 亿张图像。我们采用 CapFilt 方法 (Li 等人, 2022) 为网络图像生成合成标题。具体来说，我们生成 10

使用 *BLIP_{FlanT5}* 字幕模型生成字幕，并根据 CLIP ViT-L/14 模型产生的图文相似度，将合成字幕与原始网页字幕进行排序。我们为每张图片保留排名前两位的字幕作为训练数据，并在每个预训练步骤中随机抽取一个。

预训练图像编码器和大型语言模型（LLM）。对于冻结的图像编码器，我们研究了两种最先进的预训练视觉 Transformer 模型：（1）来自 CLIP 的 ViT-L/14

(Radford 等人, 2021) 和（2）来自 EVA-CLIP 的 ViT-g/14 (Fang 等人, 2022)。我们移除了 ViT 的最后一层，并使用倒数第二层的输出特征，这带来了稍好的性能。对于冻结的语言模型，针对基于解码器的大语言模型，我们研究了无监督训练的 OPT 模型系列 (Zhang 等人, 2022)；针对基于编码器 - 解码器的大语言模型，我们研究了指令训练的 FlanT5 模型系列 (Chung 等人, 2022)。

预训练设置。我们在第一阶段预训练 25 万步，第二阶段预训练 8 万步。第一阶段中，ViT-L/ViT-g 的批处理大小为 2320/1680；第二阶段中，OPT/FlanT5 的批处理大小为 1920/1520。预训练期间，我们将冻结的 ViT、*LLM* 以及大型语言模型（LLM）的参数转换为 FP16，不过 FlanT5 除外，其使用的是 BFloat16。我们发现，与使用 32 位模型相比，性能并未下降。由于使用了冻结模型，我们的预训练在计算方面比现有的大规模视觉语言预训练（VLP）方法更具优势。例如，使用单台 16-A100 (40G) 机器，我们最大的模型（配备 ViT-g 和 FlanT5-XXL）在第一阶段需要不到 6 天，第二阶段需要不到 3 天。

所有模型均使用相同的预训练超参数。我们使用 AdamW (Loshchilov 和 Hutter, 2017) 优化器，参数为 $\beta_1 = 0.9$ 、 $\beta_2 = 0.98$ ，权重衰减为 0.05。学习率采用余弦衰减方式，峰值学习率为 $1e-4$ ，线性预热步数为 2k。第二阶段的最小学习率为 $5e-5$ 。我们使用尺寸为 224×224 的图像，并通过随机 resize 裁剪和水平翻转进行数据增强。


 解释 的保持 这个产品。 奥迪 e-tron quattro 概念车是一款 纯电动的豪华SUV，由奥迪 公司在（时间）从 0 英里 / 小时加速至 60 只需 4 秒。	 告诉我一些关于 这个地方的历史 中国的长城建于 公元前 7 世纪，最初是为了 保护帝国免受北方入侵者的侵扰。	 写下你所知道的事实 了解兰花 它是一种开花植物的属，属于 兰科。原产于东亚和东南亚。它是一种多年生开 花植物，可长到 1 米高。
 这张照片不寻常吗？ 是的，这是一座看起来像是颠倒过来的房子。 倒置的。 一个人怎么能在土 怎么从房子里出来？ 它的侧面有一个滑梯 房子。	 照片里有什么？ 一个男人和一只鸡。 这个人感觉如何 以及为什么？ 他害怕那只鸡 因为它正朝他飞来。	 我需要哪些原料？ 我需要制作这个的食材是什么？ 意大利香肠、马苏里拉奶酪、洋葱、 酱汁、橄榄油、盐、胡椒、罗勒。 第一步是什么？ 将披萨面团放在烤盘上， 撒上盐、胡椒和罗勒。
 这是哪个城市？ 新加坡。 你为什么这么认为？ 这座城市有一座鱼尾狮雕像。	 最后发生了什么 这部电影的？ 泰坦尼克号沉没了。 莱昂纳多·迪卡普里奥的 角色活下来了吗？ 不，他淹死了。	 照片里有什么？ 一个看起来像猫的披萨。 鼻子是由什么构成的？ 一片意大利辣香肠。
 它多温暖的自由 与这张照片相配的浪漫讯息。 孤独/寂寞、孤独 很难预见它的到来，但当它真的来临时，却是如此美 太美了。	 告诉我们你拍的这张照片的情况 为达伦和本德所花费的 达伦和本德是一对夫妇，他们 对马有着浓厚的热情，所以我们 决定在他们的沙漠中与一匹马一起为他 们拍一张照片。 婚礼当天。	 写一段对话 在这两种动物之间。 猫：嘿，狗，我能骑在你背上吗？ 狗：当然，为什么不呢？ 猫：我厌倦在雪地里走路了。

图 4. 使用配备 ViT-g 和 *FlanT5XXL* 的 BLIP-2 模型进行指令式零样本图像到文本生成的精选示例，展示了该模型的多种能力，包括视觉对话、视觉知识推理、视觉常识推理、故事讲述、个性化图像到文本生成等。

表 1. BLIP-2 在各种零样本视觉 - 语言任务上的结果概述。与之前的最先进模型相比，BLIP-2 在零样本性能上达到最高，同时在视觉 - 语言预训练期间所需的可训练参数数量最小

表 2. 与最先进方法在零样本视觉问答上的比较。

表 1 概述了 BLIP-2 在各种零样本视觉 - 语言任务上的性能。与之前的最先进模型相比，BLIP-2 在视觉 - 语言预训练期间所需的可训练参数数量大幅减少的同

4.1. 指令式零样本图像到文本生成

BLIP-2 能有效地让大语言模型 (LLM) 理解图像，同时保留其遵循文本提示的能力，这使我们能够通过指令控制图像到文本的生成。我们只需将文本提示附加在视觉提示之后，作为大语言模型的输入。图 4 展示了多个示例，以体现其广泛的零样本图像到文本能力，包括视觉知识推理、视觉常识推理、视觉对话、零样本视觉问答。我们在零样本视觉问答任务上进行了定量评估。对于 OPT 模型，我们使用提示 “问题: {} 答案: ”。对于 FlanT5 模型，我们使用提示 “问题: {} 简短答案: ”。在生成过程中，我们使用束宽为 5 的束搜索。我们将以流式方式生成文本，并每 10 个 token 生成一次 token。

如表 2 所示，BLIP-2 在 VQAv2 (Goyal 等人, 2017) 和 GQA (Hudson 与 Manning, 2019) 数据集上取得了最先进的结果。尽管其可训练参数少了 54 倍，但在 VQAv2 上，它的性能比 Flamingo80B 高出 8.7%。在 OK-VQA (Marino 等人, 2019) 数据集上，BLIP-2 的表现仅次于 Flamingo80B。我们推测，这是因为 OK-VQA 更侧重于开放世界知识而非视觉理解。我们

我们从表 2 中得出一个很有前景的发现：更强的图像编码器或更强的大语言模型 (LLM) 都能带来更好的性能。这一发现得到了以下几个事实的支持：(1) 在 OPT 和 FlanT5 中，ViT-g 的表现都优于 ViT-L。(2) 在同一 LLM 系列中，更大的模型表现优于更小的模型。(3) 经过指令微调的 LLM——FlanT5，在视觉问答 (VQA) 任务上的表现优于未经监督训练的 OPT。这证明了视觉 - 语言表征学习的效果。第一阶段的表征学习对 QFormer 进行预训练，以学习与文本相关的视觉特征，这减轻了大语言模型学习视觉 - 语言对齐的负担。在第二阶段，我们使用 QFormer 生成文本，并每 10 个 token 生成一次 token。

Models	#Trainable Params	NoCaps Zero-shot (validation set)								COCO Fine-tuned Karpathy test	
		in-domain		near-domain		out-domain		overall		B@4	C
		C	S	C	S	C	S	C	S		
OSCAR (Li et al., 2020)	345M	-	-	-	-	-	-	80.9	11.3	37.4	127.8
VinVL (Zhang et al., 2021)	345M	103.1	14.2	96.1	13.8	88.3	12.1	95.5	13.5	38.2	129.3
BLIP (Li et al., 2022)	446M	114.9	15.2	112.1	14.9	115.3	14.4	113.2	14.8	40.4	136.7
OFA (Wang et al., 2022a)	930M	-	-	-	-	-	-	-	-	43.9	<u>145.3</u>
Flamingo (Alayrac et al., 2022)	10.6B	-	-	-	-	-	-	-	-	-	138.1
SimVLM (Wang et al., 2021b)	~1.4B	113.7	-	110.9	-	115.2	-	112.2	-	40.6	143.3
BLIP-2 ViT-g OPT _{2.7B}	1.1B	<u>123.0</u>	<u>15.8</u>	117.8	<u>15.4</u>	123.4	15.1	119.7	<u>15.4</u>	43.7	145.8
BLIP-2 ViT-g OPT _{6.7B}	1.1B	123.7	<u>15.8</u>	<u>119.2</u>	15.3	<u>124.4</u>	14.8	<u>121.0</u>	15.3	43.5	145.2
BLIP-2 ViT-g FlanT5 _{XL}	1.1B	123.7	16.3	120.2	15.9	124.8	15.1	121.6	15.8	42.4	144.5

表 3. 在 NoCaps 和 COCO Caption 上与最先进的图像 captioning 方法的比较。所有方法在微调期间都优化交叉熵损失。C: CIDEr, S: SPICE, B@4: BLEU@4。




图 5. 视觉 - 语言表征学习对视觉到语言生成式学习的影响。若没有表征学习，Q-Former 无法弥合模态差距，导致在零样本视觉问答 (VQA) 上的性能显著下降。

前者仅依靠视觉到语言的生成式学习来弥合模态差距，这与 Flamingo 中的 Perceiver Resampler 类似。图 5 展示了表征学习对生成式学习的影响。没有表征学习时，两种大型语言模型在零样本视觉问答上的性能都显著下降。特别是 OPT 存在灾难性遗忘问题，其性能随着训练的进程急剧下降。

4.2. 图像 captioning 生成

我们对 BLIP-2 模型进行微调以用于图像 captioning 任务，该任务要求模型为图像的视觉内容生成文本描述。我们使用提示词 “a photo of” 作为大语言模型的初始输入，并通过语言建模损失来训练模型生成 caption。在微调过程中，我们保持大语言模型冻结，同时更新 Q-Former 和图像编码器的参数。我们使用 ViT-g 和各种大语言模型进行了实验。详细的超参数可在附录中找到。我们在 COCO 数据集上进行微调，并在 COCO 测试集和零样本迁移到 NoCaps (Agrawal 等人, 2019) 验证集上进行评估。结果如表 3 所示。BLIP-2 达到了当前最优

Models	#Trainable Params	VQAv2 test-dev test-std	
<i>Open-ended generation models</i>			
ALBEF (Li et al., 2021)	314M	75.84	76.04
BLIP (Li et al., 2022)	385M	78.25	78.32
OFA (Wang et al., 2022a)	930M	82.00	82.00
Flamingo80B (Alayrac et al., 2022)	10.6B	82.00	82.10
BLIP-2 ViT-g FlanT5 _{XL}	1.2B	81.55	81.66
BLIP-2 ViT-g OPT _{2.7B}	1.2B	81.59	81.74
BLIP-2 ViT-g OPT _{6.7B}	1.2B	82.19	82.30
<i>Closed-ended classification models</i>			
VinVL	345M	76.52	76.60
SimVLM (Wang et al., 2021b)	~1.4B	80.03	80.34
CoCa (Yu et al., 2022)	2.1B	82.30	82.30
BEIT-3 (Wang et al., 2022b)	1.9B	84.19	84.03

表 4. 与为视觉问答任务微调的最先进模型的比较。

在 NoCaps 上的性能达到了最先进水平，相比现有方法有显著提升，展现出对域外图像强大的泛化能力。

4.3. 视觉问答

给定带注释的 VQA 数据，我们在冻结 LLM 的同时微调 Q-Former 和图像编码器的参数。我们使用开放式答案生成损失进行微调，其中 LLM 接收 Q-Former 的输出和问题作为输入，并被要求生成答案。为了提取与问题更相关的图像特征，我们额外将 Q-Former 以问题为条件。具体来说，问题标记被作为输入提供给 Q-Former，并通过自注意力层与查询进行交互，这可以引导 Q-Former 的交叉注意力层关注信息更丰富的图像区域。

继 BLIP 之后，我们的 VQA 数据包括 VQAv2 的训练集和验证集，以及来自 Visual Genome 的训练样本。表 4 展示了 BLIP-2 在开放式生成模型中的最先进水平。

Model	#Trainable Params	Flickr30K Zero-shot (1K test set)						COCO Fine-tuned (5K test set)					
		Image → Text			Text → Image			Image → Text			Text → Image		
		R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10
<i>Dual-encoder models</i>													
CLIP (Radford et al., 2021)	428M	88.0	98.7	99.4	68.7	90.6	95.2	-	-	-	-	-	-
ALIGN (Jia et al., 2021)	820M	88.6	98.7	99.7	75.7	93.8	96.8	77.0	93.5	96.9	59.9	83.3	89.8
FILIP (Yao et al., 2022)	417M	89.8	99.2	99.8	75.0	93.4	96.3	78.9	94.4	97.4	61.2	84.3	90.6
Florence (Yuan et al., 2021)	893M	90.9	99.1	-	76.7	93.6	-	81.8	95.2	-	63.2	85.7	-
BEIT-3(Wang et al., 2022b)	1.9B	94.9	99.9	100.0	81.5	95.6	97.8	<u>84.8</u>	<u>96.5</u>	<u>98.3</u>	<u>67.2</u>	87.7	92.8
<i>Fusion-encoder models</i>													
UNITER (Chen et al., 2020)	303M	83.6	95.7	97.7	68.7	89.2	93.9	65.7	88.6	93.8	52.9	79.9	88.0
OSCAR (Li et al., 2020)	345M	-	-	-	-	-	-	70.0	91.1	95.5	54.0	80.8	88.5
VinVL (Zhang et al., 2021)	345M	-	-	-	-	-	-	75.4	92.9	96.2	58.8	83.5	90.3
<i>Dual encoder + Fusion encoder reranking</i>													
ALBEF (Li et al., 2021)	233M	94.1	99.5	99.7	82.8	96.3	98.1	77.6	94.3	97.2	60.7	84.3	90.5
BLIP (Li et al., 2022)	446M	96.7	100.0	100.0	86.7	97.3	98.7	82.4	95.4	97.9	65.1	86.3	91.8
BLIP-2 ViT-L	474M	<u>96.9</u>	100.0	100.0	<u>88.6</u>	<u>97.6</u>	98.9	83.5	96.0	98.0	66.3	86.5	91.8
BLIP-2 ViT-g	1.2B	97.6	100.0	100.0	89.7	98.1	98.9	85.4	97.0	98.5	68.3	87.7	<u>92.6</u>

表 5. 与最先进的图文检索方法的对比。在 COCO 上进行微调并零样本迁移至 Flickr30K。

COCO finetuning objectives	Image → Text		Text → Image	
	R@1	R@5	R@1	R@5
ITC + ITM	84.5	96.2	67.2	87.1
ITC + ITM + ITG	85.4	97.0	68.3	87.7

表 6. 图像锚定文本生成 (ITG) 损失通过促使查询提取与语言相关的视觉特征，提高了图像 - 文本检索性能。

4.4. 图文检索

由于图文检索不涉及语言生成，我们直接微调不包含 LLM 的第一阶段预训练模型。具体而言，我们在 COCO 数据集上对图像编码器和 Q-Former 进行微调，使用与预训练相同的目标（即 ITC、ITM 和 ITG）。然后，我们在 COCO 和 Flickr30K (Plummer 等人, 2015) 数据集上评估该模型的图到文检索和文到图检索性能。在推理过程中，我们遵循 Li 等人 (2021; 2022) 的方法，首先基于图文特征相似度选择 $k = 128$ 个候选对象，然后基于成对的 ITM 分数进行重排序。我们分别以 ViT-L 和 ViT-g 作为图像编码器进行了实验。详细的超参数可在附录中找到。

结果如表 5 所示。BLIP-2 在零样本图文检索任务上取得了最先进的性能，与现有方法相比有显著提升。

ITC 和 ITM 损失对于图文检索至关重要，因为它们直接学习图文相似度。在表 6 中，我们展示了 ITG（基于图像的文本生成）损失对图文检索也有帮助。这一结果印证了我们在设计表征学习目标时的直觉：ITG 损失不仅迫使模型学习文本表征，而且迫使模型学习视觉表征，从而对齐视觉和语言表征。

局限性

最近的大语言模型 (LLMs) 在给定少量示例的情况下能够进行上下文学习。然而，我们在 BLIP-2 上的实验发现，向大语言模型提供上下文视觉问答 (VQA) 示例时，其视觉问答性能并未得到提升。我们将这种上下文学习能力的缺失归因于我们的预训练数据集，该数据集每个样本仅包含一个图像 - 文本对。大语言模型无法从中学习到单个序列中多个图像 - 文本对之间的关联。Flamingo 的论文中也有相同的观察结果，该论文使用了一个闭源的交错图像和文本数据集 (M3W)，其中每个序列包含多个图像 - 文本对。我们计划在未来的工作中创建一个类似的数据集。

BLIP-2 的图文生成可能会因多种原因导致结果不尽如人意，包括大语言模型的知识不准确、激活了错误的推理路径，或者缺乏关于新图像内容的最新信息（见图 7）。此外，由于使用了冻结模型，BLIP-2 继承了大语言模型的风险，例如输出冒犯性语言、传播社会偏见或泄露隐私信息。补救方法包括使用指令来引导模型生成，或在移除了有害内容的过滤数据集上进行训练。

结论

我们提出了 BLIP-2，这是一种通用且计算高效的视觉 - 语言预训练方法，它利用了冻结的预训练图像编码器和大型语言模型 (LLMs)。BLIP-2 在各种视觉 - 语言任务上实现了最先进的性能，同时在预训练期间只有少量可训练参数。BLIP-2 还展示了在零样本指令式图像到文本生成方面的新兴能力。我们认为 BLIP-2 是构建多模态对话式人工智能智能体的重要一步。

参考文献

- Agrawal, H., Anderson, P., Desai, K., Wang, Y., Chen, X., Jain, R., Johnson, M., Batra, D., Parikh, D. 和 Lee, S. nocaps: 大规模新型目标 captioning. 发表于《ICCV》, 第 8947–8956 页, 2019 年。
- Alayrac, J., Donahue, J., Luc, P., Miech, A., Barr, I., Hasson, Y., Lenc, K., Mensch, A., Millican, K., Reynolds, M., Ring, R., Rutherford, E., Cabi, S., Han, T., Gong, Z., Samangooei, S., Monteiro, M., Menick, J., Borgeaud, S., Brock, A., Nematzadeh, A., Sharifzadeh, S., Binkowski, M., Barreira, R., Vinyals, O., Zisserman, A., 以及 Simonyan, K. Flamingo: 一种用于少样本学习的视觉语言模型。arXiv 预印本 arXiv:2204.14198, 2022。
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., 和 Amodei, D. 语言模型是少样本学习者。收录于 Larochelle, H., Ranzato, M., Hadsell, R., Balcan, M., 和 Lin, H. (编), 《神经信息处理系统进展》, 2020 年。
- Changpinyo, S., Sharma, P., Ding, N. 和 Soricut, R. Conceptual 12M: 推动网络规模图文预训练以识别长尾视觉概念。发表于《CVPR》, 2021 年。
- 陈, J., 郭, H., 易, K., 李, B., 和 Elhoseiny, M. VisualGPT: 用于图像 captioning 的预训练语言模型的数据高效适配。发表于《CVPR》, 第 18009–18019 页, 2022a。
- 陈, X., 王, X., 昌皮约, S., 皮尔乔瓦尼, A. J., 帕德莱夫斯基, P., 萨尔茨, D., 古德曼, S., 格里克纳, A., 穆斯塔法, B., 拜尔, L., 科列斯尼科夫, A., 普伊格塞尔韦尔, J., 丁, N., 荣, K., 阿克巴里, H., 米什拉, G., 薛, L., 塔普利亚尔, A., 布拉德伯里, J., 郭, W., 赛义德侯赛尼, M., 贾, C., 艾扬, B. K., 里克尔梅, C., 施泰纳, A., 安杰洛娃, A., 翟, X., 霍尔斯基, N., 和索里库特, R. Pali: 一个联合缩放的多语言语言 - 图像模型。arXiv 预印本 arXiv:2209.06794, 2022b。
- 陈宇、李磊、余亮、A. E. Kholy, F. Ahmed、甘臻、程勇、刘静。UNITER: 通用图像 - 文本表示学习。《欧洲计算机视觉会议论文集》, 卷 12375, 第 104–120 页, 2020 年。
- Cho, J., Lei, J., Tan, H. 和 Bansal, M. 通过文本生成统一视觉和语言任务。arXiv 预印本 arXiv:2102.02779, 2021。
- 钟浩伟、侯亮、龙普雷、佐夫、郑叶音、费德斯、李干鑫、德赫加尼、布拉马、Webson, A., Gu, S. S., Dai, Z., Suzgun, M., Chen, X., Chowdhery, A., Narang, S., Mishra, G., Yu, A., Zhao, V. Y., Huang, Y., Dai, A. M., Yu, H., Petrov, S., Chi, E. H., Dean, J., Devlin, J., Roberts, A., Zhou, D., Le, Q. V. 和 Wei, J. 缩放指令微调语言模型。arXiv 预印本 arXiv:2210.11416, 2022。
- 戴伟、侯亮、尚立、蒋鑫、刘琦、冯鹏。通过视觉 - 语言知识蒸馏在 CLIP 上实现多模态生成。见穆雷桑、纳科夫、比利亚维森西奥 (编), 《ACL 发现》, 第 2383–2395 页, 2022 年。
- 德夫林 (J.)、张 (M.)、李 (K.) 和托图诺娃 (K.)。《BERT: 用于语言理解的深度双向 Transformer 预训练》。收录于伯斯坦 (J.)、多兰 (C.) 和索洛里奥 (T.) (编), 《北美计算语言学协会年会论文集》, 第 4171–4186 页, 2019 年。
- 董磊、杨楠、王伟、魏峰、刘鑫、王艳、高军、周明、韩宏 (2019)。用于自然语言理解与生成的统一语言模型预训练。收录于瓦拉赫、拉罗谢尔、贝耶热兹默、达尔谢 - 巴克、福克斯、加内特 (编), 《神经信息处理系统进展》, 第 13042–13054 页。
- 方宇、王薇、谢波、孙强、吴磊、王旭、黄涛、王旭和曹阳。Eva: 大规模探索掩码视觉表征学习的极限。arXiv 预印本 arXiv:2211.07636, 2022 年。
- Goyal, Y., Khot, T., Summers-Stay, D., Batra, D. 和 Parikh, D. 让 VQA 中的 V 变得重要: 提升图像理解在视觉问答中的作用。发表于《CVPR》, 第 6325–6334 页, 2017 年。
- 郭佳、李佳、李丹、A. M. H. Tiong、李博、陶栋、S. C. H. Hoi. 《从图像到文本提示: 基于冻结大型语言模型的零样本视觉问答》。发表于《计算机视觉与模式识别会议》, 2022 年。
- 霍夫曼 (J.)、博若 (S.)、门施 (A.)、布恰茨卡娅 (E.)、蔡 (T.)、拉瑟福德 (E.)、德洛斯卡萨斯 (D.)、亨德里克斯 (L. A.)、韦布尔 (J.)、克拉克 (A.)、亨尼根 (T.)、诺兰 (E.)、米利肯 (K.)、范德里舍 (G.)、达莫克 (B.)、盖伊 (A.)、奥辛德罗 (S.)、西蒙扬 (K.)、埃尔森 (E.)、雷 (J. W.)、文尼亚斯 (O.) 和西弗雷 (L.)。训练计算最优的大型语言模型。arXiv 预印本 arXiv:2203.15556, 2022 年。
- Hudson, D. A. 和 Manning, C. D. GQA: 一个用于现实世界视觉推理和组合式问答的新数据集。发表于《CVPR》, 第 6700–6709 页, 2019 年。
- 贾晨、杨阳、夏阳、陈永泰、帕雷克 (Z. Parekh)、范黄 (H. Pham)、勒·奎恩 (Q. V. Le)、宋 (Y. Sung)、李子 (Z. Li) 和杜里格 (T. Duerig)。《利用含噪文本监督扩大视觉及视觉 - 语言表征学习规模》。arXiv 预印本 arXiv:2102.05918, 2021 年。

金伟、程宇、沈洋、陈伟和任晓。一个好的提示词价值百万参数：面向视觉 - 语言模型的低资源提示词学习。见穆雷桑、纳科夫和比利亚维森西奥 (编)，《计算语言学期刊》，第 2763-2775 页，2022 年。

Krishna, R., Zhu, Y., Groth, O., Johnson, J., Hata, K., Kravitz, J., Chen, S., Kalantidis, Y., Li, L., Shamma, D. A., Bernstein, M. S. 和 Fei-Fei, L. 视觉基因组：利用众包密集图像标注连接语言与视觉。《国际计算机视觉杂志》(IJCV)，123 (1): 32-73, 2017。

李, J., 塞尔瓦拉朱, R. R., 戈特马尔, A. D., 乔蒂, S., 熊, C. 和霍伊, S. 在融合前对齐：基于动量蒸馏的视觉与语言表征学习。发表于《神经信息处理系统进展》，2021 年。

李, J., 李, D., 熊, C. 和许, S. C. H. BLIP: 用于统一视觉语言理解与生成的自举语言 - 图像预训练。见《国际机器学习会议论文集》，第 12888-12900 页，2022 年。

李 X., 尹 X., 李 C., 张 P., 胡 X., 张 L., 王 L., 胡 H., 董 L., 魏 F., 崔 Y. 和高 J. Oscar: 面向视觉 - 语言任务的对象 - 语义对齐预训练。发表于《欧洲计算机视觉会议论文集》，第 121-137 页，2020 年。

林 (T.)、迈尔 (M.)、贝隆吉 (S. J.)、海斯 (J.)、佩罗纳 (P.)、拉马南 (D.)、多拉 (P.) 和齐特尼克 (C. L.)。《微软 COCO: 上下文中的常见物体》。收录于弗利特 (D. J.)、帕德拉 (T.)、席勒 (B.) 和图伊特拉尔斯 (T.) (编)，《欧洲计算机视觉会议论文集》，第 8693 卷，第 740-755 页，2014 年。

Loshchilov, I. 和 Hutter, F. 解耦权重衰减正则化。arXiv 预印本 arXiv:1711.05101，2017。

Mañnas, O., Rodriguez, P., Ahmadi, S., Nematzadeh, A., Goyal, Y. 和 Agrawal, A. MAPL: 用于视觉语言少样本提示的单模态预训练模型的参数高效适配。发表于《EACL》，2023 年。

Marino, K., Rastegari, M., Farhadi, A. 和 Mottaghi, R. Okvqa: 一个需要外部知识的视觉问答基准。发表于《CVPR》，2019 年。

Ordonez, V., Kulkarni, G. 和 Berg, T. L. Im2text: 使用 100 万张带字幕的照片描述图像。收录于 Shawe-Taylor, J., Zemel, R. S., Bartlett, P. L., Pereira, F. C. N. 和 Weinberger, K. Q. (编)，《神经信息处理系统进展》(NIPS)，第 1143-1151 页，2011 年。

Plummer, B. A., Wang, L., Cervantes, C. M., Caicedo, J. C., Hockenmaier, J. 以及 Lazebnik, S. 《Flickr30k 实体：为更丰富的图像到句子模型收集区域到短语的对应关系》。发表于《国际计算机视觉大会》，第 2641-2649 页，2015 年。

拉德福德 (A.)、金 (J. W.)、哈拉西 (C.)、拉梅什 (A.)、吴 (G.)、阿加瓦尔 (S.)、萨斯特里 (G.)、阿斯科尔 (A.)、米什金 (P.)、克拉克 (J.) 等。从自然语言监督中学习可迁移的视觉模型。arXiv 预印本 arXiv:2103.00020, 2021。

舒曼 (C.)、文库 (R.)、博蒙特 (R.)、卡奇马尔奇克 (R.)、马利斯 (C.)、卡塔 (A.)、库姆斯 (T.)、吉采夫 (J.) 和小松崎 (A.)。Laion-400m: 4 亿个经 CLIP 过滤的图像 - 文本对开放数据集。arXiv 预印本 arXiv:2111.02114, 2021。

Sharma, P., Ding, N., Goodman, S. 和 Soricut, R. 所著的《Conceptual captions: 用于自动图像 captioning 的经过清理、带有上位词的图像替代文本数据集》，收录于 Gurevych, I. 和 Miyao, Y. 编著的《ACL》，第 2556-2565 页，2018 年。

Tan, H. 和 Bansal, M.。《LXMERT: 从 Transformer 中学习跨模态编码器表示》。收录于 Inui, K., Jiang, J., Ng, V. 和 Wan, X. (编)，《EMNLP》，第 5099-5110 页，2019 年。

Tiong, A. M. H., Li, J., Li, B., Savarese, S., 以及 Hoi, S. C. H. 即插即用型视觉问答：通过结合大型预训练模型实现零训练的零样本视觉问答。收录于《EMNLP 发现》，2022 年。

Tsimpoukelli, M., Menick, J., Cabi, S., Eslami, S. M. A., Vinyals, O. 和 Hill, F. 基于冻结语言模型的多模态少样本学习。收录于 Ranzato, M., Beygelzimer, A., Dauphin, Y. N., Liang, P. 和 Vaughan, J. W. (编)，《神经信息处理系统进展》，第 200-212 页，2021 年。

王鹏、杨安、门瑞、林静、白松、李子、马军、周聪、周杰、杨浩。《OFA: 通过简单的序列到序列学习框架统一架构、任务和模态》。收录于 Chaudhuri, K., Jegelka, S., Song, L., Szepesvári, C., Niu, G., Sabato, S. (编)，《国际机器学习会议论文集》，第 23318-23340 页，2022a。

王, W., 包, H., 董, L., 和魏, F. VLMo: 使用模态混合专家的统一视觉 - 语言预训练。arXiv 预印本 arXiv:2111.02358，2021a。

王巍、包晗、董力、约翰·比约克、彭志、刘琦、卡尔·阿加瓦尔、奥马尔·K·穆罕默德、萨米尔·辛哈尔、萨米特·索姆、魏峰。《图像作为一门外语：BEiT 预训练适用于所有视觉及视觉 - 语言任务》。arXiv 预印本 arXiv:2208.10442, 2022b。

王泽、于佳、余艾文、戴卓、叶夫根尼·茨维特科夫、曹越。SimVLM: 基于弱监督的简单视觉语言模型预训练。arXiv 预印本 arXiv:2108.10904, 2021b。

姚磊、黄榕、侯磊、陆罡、牛萌、徐航、梁晓、李子、蒋鑫、徐超。FILIP: 细粒度交互式语言 - 图像预训练。发表于《国际学习表征会议》，2022 年。

余佳、王梓、瓦苏德万 (V.)、杨立、赛义德侯赛尼 (M.) 和吴雨: 《Coca: 对比性字幕生成器是图像文本基础模型》, arXiv 预印本 arXiv:2205.01917, 2022 年

袁磊、陈丹、陈宇、科德拉·N、戴旭、高杰、胡华、黄旭、李波、李成、刘畅、刘明、刘志、陆洋、石云、王丽、王军、肖兵、肖志、杨军、曾敏、周亮、张鹏。Florence: 一种新的计算机视觉基础模型。arXiv 预印本 arXiv:2111.11432, 2021。

翟晓、王晓、穆斯塔法·B、施泰纳·A、凯瑟斯·D、科列斯尼科夫·A 和拜尔·L。《Lit: 基于锁定图像文本微调的零样本迁移》。发表于《计算机视觉与模式识别会议论文集》, 第 18102–18112 页, 2022 年。

张鹏、李晓、胡晓、杨静、张丽、王丽、崔怡和高军。Vinvl: 让视觉表征在视觉 - 语言模型中发挥作用。arXiv 预印本 arXiv:2101.00529, 2021。

张思 (音译)、罗勒 (音译)、戈亚尔 (音译)、阿尔特克塞 (音译)、陈 (音译)、陈 (音译)、德万 (音译)、迪亚布 (音译)、李 (音译)、林 (音译)、米哈伊洛夫 (音译)、奥特 (音译)、施莱弗 (音译)、舒斯特 (音译)、西米格 (音译)、库拉 (音译)、斯里达尔 (音译)、王 (音译) 和泽特尔莫耶 (音译)。OPT: 开放预训练 Transformer 语言模型。arXiv 预印本 arXiv:2205.01068, 2022 年。

LLM	FlanT5 _{XL}	OPT _{2.7B}	OPT _{6.7B}
Fine-tuning epochs		5	
Warmup steps		1000	
Learning rate		1e-5	
Batch size		256	
AdamW β		(0.9,0.999)	
Weight decay		0.05	
Drop path		0	
Image resolution		364	
Prompt		"a photo of"	
Inference beam size		5	
Layer-wise learning rate decay for ViT	1	1	0.95

表 7. 使用 ViT-q 在 COCO 图像描述任务上微调 BLIP-2 的超参数。

LLM	FlanT5 _{XL}	OPT _{2.7B}	OPT _{6.7B}
Fine-tuning epochs		5	
Warmup steps		1000	
Learning rate		1e-5	
Batch size		128	
AdamW β		(0.9,0.999)	
Weight decay		0.05	
Drop path		0	
Image resolution		490	
Prompt		"Question: {} Answer:"	
Inference beam size		5	
Layer-wise learning rate decay for ViT	0.95	0.95	0.9

表 8. 使用 ViT-q 在 VQA 上微调 BLIP-2 的超参数。

Image Encoder	ViT-L/14	ViT-g/14
Fine-tuning epochs		5
Warmup steps		1000
Learning rate	5e-6	1e-5
Batch size		224
AdamW β	(0.9,0.98)	(0.9,0.999)
Weight decay		0.05
Drop path		0
Image resolution		364
Layer-wise learning rate decay for ViT	1	0.95

表 9. 在 COCO 图像 - 文本检索任务上微调 BLIP-2 的超参数。

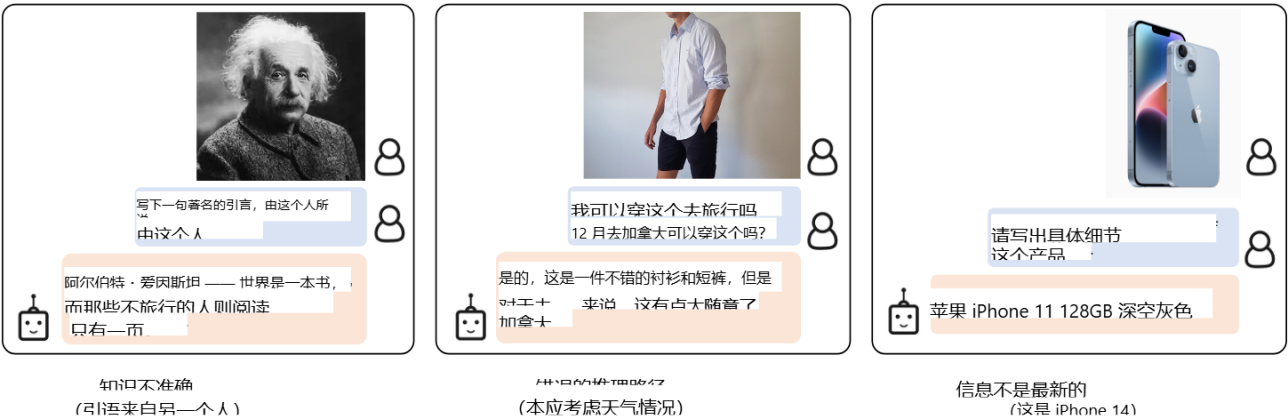


图 6. 使用带有 ViT-q 和 FlanT5XXL 的 BLIP-2 模型进行指令式零样本图像到文本生成的错误输出示例。




图 7. VQA 微调的模型架构，其中大语言模型接收 Q-Former 的输出和问题作为输入，然后预测答案。我们还将问题作为条件提供给 Q-Former，以便提取的图像特征与问题更相关。