

arXiv:2304.08485v2 [cs.CV] 2023年12月11日

视觉指令微调

刘昊天^{1*}, 李春元^{2*}, 吴青阳³, 李勇宰¹

¹ 威斯康星大学麦迪逊分校 ² 微软研究院

³ 哥伦比亚大学

<https://llava-vl.github.io>

摘要

研究表明, 使用机器生成的指令遵循数据对大型语言模型 (LLMs) 进行指令微调, 能够提升模型在新任务上的零样本能力, 但这一理念在多模态领域的探索较少。我们首次尝试使用纯语言模型 GPT-4 来生成多模态的语言 - 图像指令遵循数据。通过在这类生成数据上进行指令微调, 我们提出了 LLaVA: 大型语言与视觉助手, 这是一个端到端训练的大型多模态模型, 它将视觉编码器与大型语言模型相连, 以实现通用的视觉和语言理解。为了推动未来在视觉指令遵循方面的研究, 我们构建了两个评估基准, 包含多样化且具有挑战性的面向应用的任务。我们的实验表明, LLaVA 展现出令人印象深刻的多模态对话能力, 有时在未见过的图像 / 指令上会表现出多模态 GPT-4 的行为, 在合成的多模态指令遵循数据集上, 其相对得分达到 GPT-4 的 85.1%。在 Science QA 上进行微调时, LLaVA 与 GPT-4 的协同作用达到了 92.53% 的最新准确率。我们公开了 GPT-4 生成的视觉指令微调数据、我们的模型及代码。

1 引言

人类通过视觉、语言等多种渠道与世界互动, 因为每个单独的渠道在表示和传达特定概念方面都具有独特优势, 从而有助于更好地理解世界。人工智能的核心目标之一是开发一种通用助手, 它能够有效地遵循多模态视觉 - 语言指令, 与人类意图保持一致, 以完成现实世界中的各种任务 [4, 27, 26]。

为此, 研究界对开发语言增强型基础视觉模型的兴趣日益浓厚 [27, 16], 这类模型在开放世界视觉理解方面具备强大能力, 例如分类 [40, 21, 57, 54, 39]、检测 [29, 62, 33]、分割 [25, 63, 58] 和字幕生成 [50, 28], 以及视觉生成与编辑 [42, 43, 56, 15, 44, 30]。读者可参考《野外计算机视觉》阅读清单, 获取更最新的文献汇编 [12]。在这一系列研究工作中, 每个任务都由单个大型视觉模型独立解决, 任务指令在模型设计中被隐含考虑。此外, 语言仅被用于描述图像内容。虽然这使得语言在将视觉信号映射到语言语义 (人类交流的通用渠道) 方面发挥重要作用, 但也导致模型通常具有固定的接口, 在与用户指令的交互性和适应性方面存在局限。

另一方面, 大型语言模型 (LLM) 表明, 语言可以发挥更广泛的作用: 它是通用助手的通用接口, 在这个接口中, 各种任务指令可以用语言明确表示, 并引导经过端到端训练的神经助手切换到目标任务以解决问题。例如, ChatGPT [35] 和 GPT-4 [36] 最近的成功证明了对齐的大型语言模型在遵循人类指令方面的能力, 并激发了人们对开发开源大型语言模型的极大兴趣。其中, LLaMA [49] 是一款开源大型语言模型, 其性能与 GPT-3 相当。Alpaca [48]、Vicuna [9]、GPT-4-11M [38]

利用各种机器生成的高质量指令遵循样本，以提高大语言模型的对齐能力，其报告的性能优于专有大语言模型。重要的是，这类研究仅涉及文本。

在本文中，我们提出了视觉指令微调，这是首次尝试将指令微调扩展到语言 - 图像多模态领域，旨在为构建通用视觉助手铺平道路。具体而言，本文有以下贡献：

- 多模态指令遵循数据。一个关键挑战是缺乏视觉 - 语言指令遵循数据。我们提出了一种数据重构视角和流程，利用 ChatGPT/GPT-4 将图像 - 文本对转换为合适的指令遵循格式。大型多模态模型。我们通过将 CLIP [40] 的开放集视觉编码器与语言解码器 Vicuna [9] 相连，并在我们生成的指导性视觉 - 语言数据上进行端到端微调，开发了一个大型多模态模型 (LMM)。我们的实证研究验证了使用生成的数据进行 LMM 指令微调的有效性，并为构建通用的指令遵循视觉智能体提供了实用建议。当与 GPT-4 集成时，我们的方法在 Science QA [34] 多模态推理数据集上达到了当前最佳水平。
- 多模态指令遵循基准。我们提出了 LLaVA-Bench，它包含两个具有挑战性的基准，其中精选了大量配对的图像 - 文本和详细注释。
- 开源。我们向公众发布以下资源：生成的多模态指令数据、代码库、模型检查点以及一个可视化聊天演示。

2 相关工作

多模态指令跟随智能体。在计算机视觉领域，现有的构建指令跟随智能体的研究可大致分为两类：(i) 端到端训练模型，这类模型针对每个特定研究主题分别进行探索。例如，视觉 - 语言导航任务 [3, 19] 和 Habitat [47] 要求具身 AI 智能体遵循自然语言指令，并执行一系列动作以在视觉环境中完成目标。在图像编辑领域，给定输入图像和告知智能体应执行操作的书面指令，InstructPix2Pix [6] 通过遵循人类指令来编辑图像。(ii) 通过 LangChain [1]/ 大语言模型 [35] 协调各种模型的系统，如 Visual ChatGPT [53]、X-GPT [63]、MM-REACT [55]、VisProg [18] 和 ViperGPT [46]。尽管在构建指令跟随智能体方面目标一致，但我们专注于为多项任务开发端到端训练的语言 - 视觉多模态模型。

指令微调。在自然语言处理 (NLP) 领域，为了让 GPT-3 [7]、T5 [41]、PaLM [10] 和 OPT [60] 等大语言模型 (LLMs) 能够遵循自然语言指令并完成现实世界任务，研究人员探索了大语言模型的指令微调方法 [37, 52, 51]，由此分别产生了 InstructGPT [37]/ChatGPT [35]、FLAN-T5 [11]、FLAN-PaLM [11] 和 OPT-IML [22] 等经过指令微调的模型。事实证明，这种简单的方法能有效提升大语言模型的零样本和少样本泛化能力。因此，将 NLP 领域的这一理念借鉴到计算机视觉领域是很自然的事。更广泛地说，基于基础模型的师生蒸馏理念已在图像分类等其他领域得到研究 [14]。Flamingo [2] 因其在零样本任务迁移和上下文学习方面的出色表现，可被视为多模态领域的 GPT-3 时刻。其他基于图像 - 文本对训练的多模态大模型 (LMMs) 包括 BLIP-2 [28]、FROMAGE [24] 和 KOSMOS-1 [20]。PaLM-E [13] 是一款用于具身人工智能的多模态大模型。基于最新的“最佳”开源大语言模型 LLaMA，OpenFlamingo [5] 和 LLaMA-Adapter [59] 等开源成果让 LLaMA 能够处理图像输入，为构建开源多模态大语言模型奠定了基础。尽管这些模型在任务迁移泛化性能方面表现前景良好，但它们并未明确使用视觉 - 语言指令数据进行微调，而且在多模态任务中的表现通常不如纯语言任务。本文旨在填补这一空白，并研究其有效性。最后需要注意的是，视觉指令微调与视觉提示微调 [23] 不同：前者旨在提升模型遵循指令的能力，而后者旨在提高模型话配时的参数效率。

3 GPT 辅助的视觉指令数据生成

社区见证了公共多模态数据（如图文对）数量的激增，从 CC [8] 到 LAION [45] 均是如此。然而，在涉及多模态指令时


提示类别 1. 字幕 一群人站在一辆黑色车辆外，身边放着各式各样的行李 一辆车在地下停车场被行李包围着 人们试图把所有行李都装进一辆 SUV 里 这辆运动型多用途车在左边并排左边的 正在被装行李准备出行。 一些人带着行李站在一辆正在运输行李的货车旁。 提示类别 2. 详细描述 人，「0 681 0 242 0 774 0 694」，背包，「0 384 0 696 0 485 0 914」，行李箱， < 省略 >	
响应类别 1. 对话 问题：图片中显示的是哪种类型的车辆？ 答案：这张图片中有一辆黑色的运动型多用途汽车（SUV）……<省略> 响应类别 2. 详细描述 这张图片展示的是一个地下停车场，里面停着一辆黑色的运动型多功能车（SUV）。场景中有三个人，一个人站在靠近车辆左侧的位置，另一个人在中间，第三个人在右侧。他们正一起把行李装进 SUV，准备出行。……<省略> 响应类别 3. 有挑战 问题：这些人面临着什么挑战？ 答案：图片中，一群人站在停车场的一辆黑色 SUV 外面，周围放着各种行李，包括行李箱和背包。他们正面临着要把所有行李都装进这辆黑色 SUV 的挑战。有多个行李箱和背包需要打包，这表明这群人有不少随身物品……<省略>	

表 1：一个说明指令遵循数据的示例。上方区块展示了用于提示 GPT 的语境，如说明文字和框注，下方区块展示了三种类型的回应。请注意，视觉图像并未用于提示 GPT，我们在此仅将其作为参考展示。

以下数据中，可用量有限，部分原因是考虑到人工搜寻时，创建此类数据的过程耗时且定义不够明确。受近期 GPT 模型在文本标注任务中取得成功的启发 [17]，我们提议基于广泛存在的图像对数据，利用 ChatGPT/GPT-4 来收集多模态指令遵循数据。

对于图像 x_i 及其相关说明文字 w_i ，生成一组问题 q_i 以指导助手描述图像内容是很自然的做法。我们提示 GPT-4 来精心设计这样的问题列表（详见附录）。因此，将图像 - 文本对扩展为其遵循指令版本的一种简单方式是“人类： $x_i \ x_w$ <STOP>助手： y_i < STOP >”。尽管这种构建方式成本较低，但这个简单的扩展版本在指令和响应中都缺乏多样性和深度推理。

为了缓解这一问题，我们利用纯语言的 GPT-4 或 ChatGPT 作为强大的教师模型（两者都只接受文本作为输入），来创建涉及视觉内容的指令遵循数据。具体而言，为了将图像编码为其视觉特征以提示纯文本的 GPT，我们使用两种类型的符号表示：（i）标题通常从不同角度描述视觉场景；（ii）边界框通常用于定位场景中的对象，每个框都编码了对象概念及其空间位置。表 14 的顶部区块展示了一个示例。

这种符号表示使我们能够将图像编码为大语言模型可识别的序列。我们使用 COCO 图像 [31] 并生成三种类型的指令遵循数据。每种类型的一个示例显示在表 14 的底部区块中。对于每种类型，我们首先手动设计一些示例。这些是我们在数据收集过程中仅有的人工标注，并在上下文学习中被用作种子示例来查询 GPT-4。

- 对话。我们设计了一段助手与询问者关于这张照片的对话。助手的回答语气要像是在亲眼看着图片进行回应。对话中包含一系列关于图片视觉内容的问题，涉及物体类型、物体数量、物体动作、物体位置以及物体间的相对位置。只考虑有明确答案的问题。详细提示请参见附录。
- 详细描述。为了给一张图片添加丰富且全面的描述，我们创建了一系列具有此意图的问题。我们提示 GPT-4，然后对该列表进行整理（详见详细提示）

以及附录中的筛选过程）。对于每张图片，我们从列表中随机抽取一个问题，让 GPT-4 生成详细回答。

- 复杂推理。上述两种类型侧重于视觉内容本身，在此基础上，我们进一步设计了深度推理问题。答案通常需要遵循严谨的逻辑，通过逐步推理过程得出。

我们总共收集了 158K 个独特的语言 - 图像指令遵循样本，其中包括 58K 个对话样本、23K 个详细描述样本和 77K 个复杂推理样本。我们在早期实验中移除了 ChatGPT 和 GPT-4 的使用，发现 GPT-4 始终能提供更高质量的指令遵循数据，例如空间推理方面的数据。

4 视觉指令微调

4.1 架构

主要目标是有效利用预训练大语言模型和视觉模型的能力。网络架构如图 1 所示。我们选择 Vicuna [9] 作为我们的大语言模型，其参数为 ϕ ，因为在公开可用的检查点中，它在语言任务中具有最佳的指令遵循能力 [48, 9, 38]。




图 1: LLaVA 网络架构。

对于输入图像 x_v ，我们考虑预训练的 CLIP 视觉编码器 ViT-L/14 [40]，它提供视觉特征 $z_v = \alpha(x_v)$ 。在我们的实验中，会考虑最后一个 Transformer 层前后的网格特征。我们采用一个简单的线性层将图像特征连接到词嵌入空间中。具体来说，我们应用一个可训练的投影矩阵 W ，将 z_v 转换为语言嵌入标记 h_v ，其维度与语言模型中的词嵌入空间相同：

$$h_v = W \cdot z_v \text{ with } z_v = \alpha(x_v) \quad (1)$$

因此，我们得到了一系列视觉标记 h_v 。请注意，我们的简单投影方案是轻量级的，这使我们能够快速迭代以数据为中心的实验。也可以考虑更复杂的方案来连接图像和语言表示，例如 Flamingo [2] 中的门控交叉注意力和 BLIP-2 [28] 中的 Q-former。我们将探索可能更有效、更复杂的 LLaVA 架构设计留作未来的工作。

4.2 训练

对于每个图像 x_v ，我们生成多轮对话数据 $(x^1_v, x^1_q, \dots, x^T_v, x^T_q)$ ，其中 T 是总轮数。我们将它们组织成一个序列，将所有回答视为助手的回应，第 t 轮的指令 x^t_q 定义为：

$x_{\text{instruct}}^t = \left[\begin{array}{l} \text{随机选择 } \left[x_q^1, x_v \right] \text{ 或 } \\ \left[x_v, x_q^1 \right], \& \text{ 第一轮 } t=1 \setminus \setminus \{ x_q^t \}, \& \text{ 其余轮次 } t>1 \end{array} \right]$

这就形成了表 2 所示的多模态指令遵循序列的统一格式。我们使用大语言模型原始的自回归训练目标，对其在预测标记上进行指令微调。

具体来说，对于长度为 L 的序列，我们通过以下方式计算目标答案 x_a 的概率：

$$p(x_a | x_v, x_{\text{instruct}}) = \prod_{i=1}^L p\theta(x_i | x_v, x_{\text{instruct}_{<i}}, x_{a_{<i}}),$$

```

Xsystem-message <STOP>
Human : Xinstruct1 <STOP> Assistant: Xa1 <STOP>
Human : Xinstruct2 <STOP> Assistant: Xa2 <STOP> ...

```

表 2: 用于训练模型的输入序列。这里仅展示了两个对话轮次; 实际上, 轮次数量会根据遵循指令的数据而变化。在我们当前的实现中, 我们遵循 Vicuna-v0 [9] 来设置系统消息 $X_{\text{system-message}}$, 并设置 $\langle \text{STOP} \rangle = \backslash \#\#\backslash \#$ 。模型经过训练以预测助手的回答以及何时停止, 因此在自回归模型中, 仅使用绿色序列 / 标记来计算损失。

其中 θ 是可训练参数, $\mathbf{Y}_{\text{instruct}}^{1:n}$ 和 $\mathbf{Y}_{\text{a}}^{1:n}$ 分别是当前预测 token τ_n 之前所有轮次中的指令和答案 token。关于预测 token 的说明请参见表 2。对于 (3) 中的条件, 我们明确添加了 $\mathbf{Y}_{\text{a}}$, 以强调图像是所有答案的基础这一事实, 并且为了提高可读性, 我们省略了 system-message 和所有之前的 $\langle \text{STOP} \rangle$ 。在 LLaVA 模型训练中, 我们采用了两阶段的指令微调流程。

阶段 1: 用于特征对齐的预训练。为了在概念覆盖范围和训练效率之间取得平衡, 我们将 CC3M 筛选为 595K 个图像 - 文本对。有关筛选过程的详细信息, 请参见附录。这些对通过第 3 节中描述的简单扩展方法转换为遵循指令的数据。每个样本都可以视为单轮对话。为了构建 (2) 中的输入 $\mathbf{X}_{\text{instruct}}$, 对于图像 τ_{img} , 随机采样一个问题 τ_{q} , 这是一个要求助手简要描述图像的语言指令。真实的预测答案 τ_{a} 是原始标题。在训练中, 我们冻结视觉编码器和 LLM 的权重, 仅使用可训练参数 $\theta = \mathbf{W}$ (投影矩阵) 来最大化 (3) 的可能性。通过这种方式, 图像特征 $\mathbf{h}_{\text{img}}$ 可以与预训练的 LLM 词嵌入对齐。这个阶段可以理解为为冻结的 LLM 训练一个兼容的视觉分词器。

第二阶段: 端到端微调。我们始终冻结视觉编码器的权重, 并继续更新 LLaVA 中投影层和大语言模型 (LLM) 的预训练权重; 即, 可训练参数为 (3) 中的 $\theta = \mathbf{W}, \phi$ 。我们考虑了两个具体的用例场景:

- 多模态聊天机器人。我们通过在第 3 节的 158K 语言 - 图像指令遵循数据上进行微调来开发聊天机器人。在三种响应类型中, 对话是多轮的, 而另外两种是单轮的。它们在训练中被均匀采样。Science QA。我们在 ScienceQA 基准 [34] 上研究我们的方法, 这是第一个大规模多模态科学问题数据集, 它用详细的讲解和解释对答案进行标注。每个问题都以自然语言或图像的形式提供一个上下文。助手用自然语言提供推理过程, 并在多个选项中选择答案。对于 (2) 中的训练, 我们将数据组织为单轮对话, 问题 & 上下文为 $\mathbf{X}_{\text{instruct}}$, 推理 & 答案为 τ_{a} 。

5 实验

我们分别在两种主要实验设置 (多模态聊天机器人和 ScienceQA 数据集) 下评估 LLaVA 在指令遵循和视觉推理能力方面的性能。我们使用 8×A100 训练所有模型, 并遵循 Vicuna 的超参数 [9]。我们在经过筛选的 CC-595K 子集上对模型进行预训练, 训练 1 个 epoch, 学习率为 2e-3, 批次大小为 128; 然后在我们提出的 LLaVA-Instruct-158K 数据集上进行微调, 训练 3 个 epoch, 学习率为 2e-5, 批次大小为 32。更多训练细节请参见附录。

5.1 多模态聊天机器人

我们开发了一个聊天机器人演示, 以展示 LLaVA 的图像理解和对话能力, 并研究 LLaVA 在处理视觉输入和展现遵循指令能力方面的表现。我们首先使用了原始 GPT-4 论文 [36] 中的示例 (如表 3 所示, 更多示例见附录), 这些示例需要深入的图像理解能力。为了进行比较, 我们引用了该论文中多模态 GPT-4 的提示词和响应, 并查询了 BLIP-2 和 OpenFlamingo 的模型检查点以获取它们的响应。



来源: <https://www.barnorama.com/wp-content/uploads/2016/12/03-ConfusingPictures.jpg>

用户

这张图片有什么不寻常之处？

LLaVA

这张图片的不同寻常之处在于，一名男子在一辆小型货车或面包车的车尾熨烫衣服。这并非进行这项活动的典型场所，因为人们通常会在更固定且安全的地方熨衣服，比如家里，使用常规的熨衣板。图片中描绘的场景很奇特，因为它涉及在车辆上临时搭建的熨烫装置，这既不安全也不合常规。此外，目前尚不清楚这名男子是如何在如此不稳定的环境中保持平衡和稳定来熨烫衣服的。

用户

「开始新对话，并清除历史记录」

LLaVA

这张图片描绘了一个男人站在繁忙城市街道上的一辆黄色 SUV 车顶。他拿着一个便携式梯子，似乎站在车顶上熨衣服。场景周围有其他车辆、一个红绿灯和一个消防栓。此外，附近还有另外两个人，一个靠近车上的男人，另一个则离得较远。站在梯子上的男人似乎因为选择在行驶的车顶上熨衣服这种非常规行为而引人注目。他周围的城市街道十分热闹，更凸显了这一场景的独特性。

用户

请提供需要翻译的内容
(前三个引号)

这张图片有什么不寻常之处？

这张图片的特别之处在于，一个男人正在安装在行驶中的出租车车顶的熨衣板上熨衣服。

这张图片的
不寻常之处

这张图片有什么不寻常之处？

RLIP-2

一个男人正坐在一辆黄色出租车的后座上。

这张图片的
不寻常之处

这张图片有什么不寻常之处？

OpenFlamingo

那个男人正在他的汽车引擎盖上熨衣服。

表 3: 来自 GPT-4 论文 [36] 的示例提示词，用于比较视觉推理和聊天能力。与 BLIP-2 [28] 和 OpenFlamingo [5] 相比，LLaVA 能准确遵循用户指令，而非简单描述场景。LLaVA 提供的响应比 GPT-4 更全面。即便只是被要求描述图像，LLaVA 也能识别出图像中不典型的方面。

令人惊讶的是，尽管 LLaVA 是用一个小型多模态指令遵循数据集（约 80K 张独特图像）训练的，但在这些示例上，它展示出的推理结果与多模态 GPT-4 颇为相似。需要注意的是，虽然这些图像对 LLaVA 而言属于域外数据，但 LLaVA 仍然能够理解场景并遵循问题指令，从而提供合理的回应。相比之下，BLIP-2 和 OpenFlamingo 更侧重于描述图像，而非遵循用户指令以恰当的方式进行回答。

定量评估。为了系统地了解 LLaVA 的性能，我们提出了一种定量指标来衡量该模型在多模态数据上的指令遵循能力。受 [9] 的启发，我们利用 GPT-4 来评估生成回复的质量。具体而言，我们创建了由图像、真实文本描述和问题组成的三元组。候选模型（如 LLaVA）根据问题和图像进行答案预测。为了提供一个近似的理论上限，我们基于问题和真实文本描述，使用纯文本的 GPT-4 生成参考预测。在获得两个模型的回复后，我们将问题、视觉信息（以文本描述的形式）以及两个助手生成的回复输入给评判者（即纯文本的 GPT-4）。评判者会评估助手回复的有用性、相关性、准确性和详细程度，并给出 1 到 10 分的总体评分，分数越高表示总体性能越好。我们还要求评判者提供全面的评估解释，以便我们更好地理解。

	Conversation	Detail description	Complex reasoning	All
Full data	83.1	75.3	96.5	85.1
Detail + Complex	81.5 (-1.6)	73.3 (-2.0)	90.8 (-5.7)	81.9 (-3.2)
Conv + 5% Detail + 10% Complex	81.0 (-2.1)	68.4 (-7.1)	91.5 (-5.0)	80.5 (-4.4)
Conversation	76.5 (-6.6)	59.8 (-16.2)	84.9 (-12.4)	73.8 (-11.3)
No Instruction Tuning	22.0 (-61.1)	24.0 (-51.3)	18.5 (-78.0)	21.5 (-63.6)

表 4：使用不同训练数据在 LLaVA-Bench (COCO) 上的消融实验。我们报告了相对于仅文本 GPT-4 模型的分数，该模型使用真实图像标题和边界框作为视觉输入。我们向 GPT-4 提供我们模型输出的答案以及 GPT-4（仅文本）的答案，让它对这两个响应进行比较，并给出评分和解释。

	Conversation	Detail description	Complex reasoning	All
OpenFlamingo [5]	19.3 ± 0.5	19.0 ± 0.5	19.1 ± 0.7	19.1 ± 0.4
BLIP-2 [28]	54.6 ± 1.4	29.1 ± 1.2	32.9 ± 0.7	38.1 ± 1.0
LLaVA	57.3 ± 1.9	52.5 ± 6.3	81.7 ± 1.8	67.3 ± 2.0
LLaVA [†]	58.8 ± 0.6	49.2 ± 0.8	81.4 ± 0.3	66.7 ± 0.3

表 5：使用 LLaVA-Bench (In-theWild) 上的相对分数进行的指令遵循能力比较。结果以均值 ± 标准差的形式报告。对于前三行，我们报告了三次推理运行。LLaVA 的表现明显优于其他模型。† 对于一组给定的 LLaVA 解码序列，我们通过三次查询 GPT-4 进行评估；GPT-4 给出了一致的评价。

模型。我们报告了相对于纯文本 GPT-4 模型的相对分数，该模型使用文本真实描述作为视觉输入。我们创建了两个基准来评估模型的性能。

LLaVA 基准测试 (COCO)。我们从 COCO-Val-2014 中随机选取 30 张图像，对于每张图像，使用第 3 节中提出的数据生成流程生成三种类型的问题（对话、详细描述、复杂推理），总共 90 个问题。该基准测试研究模型在一致视觉输入下的对齐行为和能力。我们通过改变训练数据集来研究不同类型指令遵循数据的有效性，并在表 4 中展示结果。首先，通过指令微调，模型遵循用户指令的能力显著提升，超过 50 分。其次，添加少量详细描述和复杂推理问题，使模型的整体能力有了相当大的提升，提高了 7 分。此外，这也改善了模型在对话问题上的表现，表明推理能力的提升对对话能力有补充作用。最后，我们发现包含所有三种类型的数据时，模型性能最佳，达到 85.1%。

LLaVA 基准测试（真实场景）。为了评估模型在更具挑战性的任务中的能力以及对新领域的泛化性，我们收集了 24 张多样化的图像，共包含 60 个问题，涵盖室内外场景、表情包、绘画、素描等，并为每张图像配上了详细的人工整理描述和精心挑选的问题。我们在表 5 中对 LLaVA、BLIP 和 OpenFlamingo 进行了比较。得益于视觉指令微调，LLaVA 的性能显著优于 BLIP-2（高出 29%）和 OpenFlamingo（高出 48%）。与可获取真实标签的纯文本 GPT-4 相比，LLaVA 在复杂推理问题上的表现达到了令人印象深刻的 81.7%，总分则为 67.3%。

局限性。此 LLaVA 基准（真实场景）旨在具有挑战性，以揭示模型的弱点。我们在表 6 中提供了两个带有相关说明和问题的示例。对于拉面示例（左侧），要正确回答餐厅名称，需要模型具备广泛的知识覆盖范围和多语言理解能力；要正确描述配菜，模型可能需要从互联网检索相关的多模态信息。对于冰箱示例（右侧），要识别出酸奶的正确品牌，需要模型能够处理高分辨率图像并拥有广泛的知识覆盖。我们还观察到 LLaVA 的一个有趣缺陷：当被问及是否有草莓味酸奶时，它会回答“有”，尽管冰箱里只有酸奶和草莓。这表明，LLaVA 有时会将图像视为“补丁包”，无法理解图像中复杂的语义。我们希望 LLaVA 能成为这些基准测试中的坚实基线，我们的研究发现能为未来开发更强大的大语言模型提供启发。

LLaVA-Bench（自然场景）中的挑战性示例：

	
ICHIRAN Ramen [source]	Filled fridge [source]
Annotation A close-up photo of a meal at ICHI-RAN. The chashu ramen bowl with a spoon is placed in the center. The ramen is seasoned with chili sauce, chopped scallions, and served with two pieces of chashu. Chopsticks are placed to the right of the bowl, still in their paper wrap, not yet opened. The ramen is also served with nori on the left. On top, from left to right, the following sides are served: a bowl of orange spice (possibly garlic sauce), a plate of smoke-flavored stewed pork with chopped scallions, and a cup of matcha green tea.	An open refrigerator filled with a variety of food items. In the left part of the compartment, towards the front, there is a plastic box of strawberries with a small bag of baby carrots on top. Towards the back, there is a stack of sauce containers. In the middle part of the compartment, towards the front, there is a green plastic box, and there is an unidentified plastic bag placed on it. Towards the back, there is a carton of milk. In the right part of the compartment, towards the front, there is a box of blueberries with three yogurts stacked on top. The large bottle of yogurt is Fage non-fat yogurt, and one of the smaller cups is Fage blueberry yogurt. The brand and flavor of the other smaller cup are unknown. Towards the back, there is a container with an unknown content.
Question 1 What's the name of the restaurant?	What is the brand of the blueberry-flavored yogurt?
Question 2 Describe this photo in detail.	Is there strawberry-flavored yogurt in the fridge?

表 6：来自 LLaVA-Bench（真实场景）的具有挑战性的示例，我们为每张图像提供了极其详细的注释，以便进行准确评估。有些问题要求模型从高分辨率图像中提取细节，并具备广泛的知识覆盖范围。

5.2 科学问答

ScienceQA [34] 包含 21000 道多模态选择题，涵盖 3 个学科、26 个主题、127 个类别和 379 项技能，领域多样性丰富。该基准数据集分为训练集、验证集和测试集，分别包含 12726、4241 和 4241 个样本。我们考虑了两种代表性方法，包括带思维链（CoT）和不带思维链的 GPT-3.5 模型（text-davinci-002）、LLaMA-Adapter [59]，以及多模态思维链（MM-CoT）[61]，后者是该数据集上当前的最先进方法。更多基线数据请参见 [34]。

结果如表 7 所示。对于 LLaVA，我们使用最后一层之前的视觉特征，让模型先预测原因再预测答案，并对其进行 12 个 epochs 的训练。其准确率达到 90.92%，非常接近当前最优的 91.68%。为了探索大型语言模型的极限，我们还使用 2 样本上下文学习提示 GPT-4，取得了 82.69% 的准确率，相较于 GPT-3.5 的 75.17%，绝对提升了 7.52%。我们注意到，对于相当多的问题，GPT-4 之所以失败，仅仅是因为它反馈说缺乏图像或图表等足够的上下文信息。我们考虑了两种方案来结合我们的模型和 GPT-4 的结果。（i）GPT-4 补充方案。当 GPT-4 无法提供答案时，我们使用我们方法的预测结果。该方案的准确率为 90.97%，几乎与单独使用我们的方法相同。（ii）GPT-4 作为判断者方案。当 GPT-4 和 LLaVA 得出不同答案时，我们再次提示 GPT-4，要求它根据问题和这两个结果给出自己的最终答案。其核心思想与思维链（CoT）类似，但融入了来自另一个模型的外部知识。令人惊讶的是，该方案在所有问题类别上都能带来持续的提升，并达到了 92.53% 这一新的当前最优准确率。有趣的是，无法处理图像的纯文本 GPT-4，竟然提高了模型在以图像为上下文的问题上的整体表现。这是因为其中一些问题实际上并不需要图像上下文就能得出正确答案。GPT-4 判断者能够识别出这类情况，并纠正 LLaVA 所犯的一些错误。详见附录中的示例。据我们所知，

Method	Subject			Context Modality			Grade		Average
	NAT	SOC	LAN	TXT	IMG	NO	G1-6	G7-12	
<i>Representative & SoTA methods with numbers reported in the literature</i>									
Human [34]	90.23	84.97	87.48	89.60	87.50	88.10	91.59	82.42	88.40
GPT-3.5 [34]	74.64	69.74	76.00	74.44	67.28	77.42	76.80	68.89	73.97
GPT-3.5 w/ CoT [34]	75.44	70.87	78.09	74.68	67.43	79.93	78.23	69.68	75.17
LLaMA-Adapter [59]	84.37	88.30	84.36	83.72	80.32	86.90	85.83	84.05	85.19
MM-CoT _{Base} [61]	87.52	77.17	85.82	87.88	82.90	86.83	84.65	85.37	84.91
MM-CoT _{Large} [61]	95.91	82.00	90.82	95.26	88.80	92.89	92.44	90.31	91.68
<i>Results with our own experiment runs</i>									
GPT-4 [†]	84.06	73.45	87.36	81.87	70.75	90.73	84.69	79.10	82.69
LLaVA	90.36	95.95	88.00	89.49	88.00	90.66	90.93	90.90	90.92
LLaVA+GPT-4 [†] (complement)	90.36	95.50	88.55	89.05	87.80	91.08	92.22	88.73	90.97
LLaVA+GPT-4 [†] (judge)	91.56	96.74	91.09	90.62	88.99	93.52	92.73	92.16	92.53

表 7: Science QA 数据集上的准确率 (%)。问题类别: NAT = 自然科学, SOC = 社会科学, LAN = 语言科学, TXT = 文本语境, IMG = 图像语境, NO = 无语境, G1-6=1-6 年级, G7-12=7-12 年级。[†] 仅文本的 GPT-4, 我们的评估。我们将新模型与仅文本的 GPT-4 进行集成, 在所有类别下均持续提升模型性能, 创下了新的当前最佳性能 (SoTA)。

这是 GPT-4 首次被用于模型集成。我们希望这一发现能鼓励未来的研究探索更有效的方法, 以利用大型语言模型进行模型集成。

消融实验。我们在表 8 中对 ScienceQA 的几个设计选择进行了消融实验。(i) 视觉特征。我们尝试使用 CLIP 视觉编码器的最后一层特征, 其准确率为 89.96%, 比倒数第二层的特征低 0.96%。我们推测, 这是因为与倒数第二层相比, CLIP 的最后一层特征可能更关注图像的全局和抽象属性, 而倒数第二层则更能关注有助于理解特定图像细节的局部属性。

(ii) 思维链。为了确定模型预测中答案和推理的差异用红色文本标注。表 8: 设计选择消融实验 (%)。与最佳变体案优先的方式在 12 个 epoch 时达到了 89.77% 的准确率, 但随着训练的继续进行, 准确率没有进一步提升。训练模型 24 个 epoch 也没有提高性能。我们得出结论, 类似思维链的推理优先策略可以在很大程度上加快收敛速度, 但对最终性能的贡献相对较小。(iii) 预训练。我们跳过预训练, 直接在 ScienceQA 上从头开始训练——性能降至 85.81% 的准确率。5.11% 的绝对下降表明, 我们的预训练阶段在对齐多模态特征的同时保留大量预训练知识方面具有重要意义。(iv) 模型大小。我们保持所有配置与最佳的 13B 模型相同, 并训练了一个 7B 模型。其准确率为 89.84%, 比 13B 模型的 90.92% 低 1.08%, 这表明了模型规模的重要性。

6 结论

本文展示了视觉指令微调的有效性。我们提出了一个自动流程来创建语言 - 图像指令遵循数据, 基于此我们训练了 LLaVA——一个能够遵循人类意图完成视觉任务的多模态模型。在 ScienceQA 上进行微调后, 它达到了新的当前最优准确率; 在多模态对话数据上进行微调后, 它具备了出色的视觉对话能力。此外, 我们还提出了首个用于研究多模态指令遵循能力的基准。本文是视觉指令微调领域的初步探索, 主要聚焦于现实生活中的任务。关于 LLaVA 在学术基准上的更多定量结果, 请参考经过视觉指令微调的改进基线 [32]。我们希望我们的工作能为未来构建更强大的多模态模型的研究提供启发。

致谢。我们感谢彭宝林和卢潘分别就指令微调语言模型和 Science QA 进行的有益讨论。感谢 LLaMA 团队给予我们使用权限。

以及开源项目, 包括 Alpaca 和 Vicuna。本研究部分得到了美国国家科学基金会职业发展奖 IIS2150012, 以及韩国政府(科学和信息通信技术部)资助的信息与通信技术规划与评估研究所(IITP) grants(编号: 2022-0-00871, 人工智能智能体协作的自主性与知识增强技术研发)和(编号: RS-2022-00187238, 高效预训练的大型韩语语言模型技术研发)的支持。

参考文献

- [1] Langchain. <https://github.com/hwchase17/langchain>. 2022. 2
- [2] 让 - 巴蒂斯特·阿莱拉克、杰夫·多纳休、波林·吕克、安托万·米什、伊恩·巴尔、亚娜·哈森、卡雷尔·伦茨、阿瑟·门施、凯蒂·米利肯、马尔科姆·雷诺兹等人。火烈鸟: 一种用于少样本学习的视觉语言模型。arXiv 预印本 arXiv:2204.14198, 2022 年。2、4
- [3] 彼得·安德森、吴琦、达米安·特尼、杰克·布鲁斯、马克·约翰逊、尼科·松德豪夫、伊恩·里德、斯蒂芬·古尔德和安东·范登亨格尔。视觉与语言导航: 在真实环境中解读基于视觉的导航指令。《IEEE 计算机视觉与模式识别会议论文集》, 2018 年。2
- [4] 阿曼达·阿斯科尔、白云涛、陈安娜、道恩·德雷因、迪普·甘古利、汤姆·亨尼根、安迪·琼斯、尼古拉斯·约瑟夫、本·曼、诺娃·达斯萨尔马等。作为对齐实验室的通用语言助手。arXiv 预印本 arXiv:2112.00861, 2021. 1
- [5] 阿纳斯·阿瓦达拉、艾琳娜·高、约书亚·加德纳、杰克·赫塞尔、优素福·哈纳菲、朱婉蓉、卡莉娅妮·马拉特、约纳坦·比顿、萨米尔·加德雷、耶尼亚·吉采夫、西蒙·科恩布利特、许邦伟、加布里埃尔·伊尔哈科、米切尔·沃茨曼和路德维希·施密特。《Openflamingo》, 2023 年 3 月。2、6、7
- [6] 蒂姆·布鲁克斯、亚历山大·霍林斯基和阿列克谢·A·埃弗罗斯。Instruct pix2pix: 学习遵循图像编辑指令。arXiv 预印本 arXiv:2211.09800. 2022. 2
- [7] 汤姆·布朗、本杰明·曼、尼克·赖德、梅勒妮·萨比亚、贾里德·D·卡普兰、普拉富拉·达里瓦尔、阿尔温德·尼拉坎坦、普拉纳夫·希亚姆、吉里什·萨斯特里、阿曼达·阿斯科尔等人。语言模型是少样本学习者。《神经信息处理系统进展》。33:1877–1901. 2020. 2
- [8] 索拉维特·昌皮尼奥、皮尤什·夏尔马、南丁和拉杜·索里库特。Conceptual 12m: 推动网络规模图文预训练以识别长尾视觉概念。发表于《CVPR》, 2021 年。2
- [9] 蒋伟林、李卓瀚、林子、盛英、吴张浩、张浩、郑联敏、庄思源、庄永浩、约瑟夫·E·冈萨雷斯、伊恩·斯托伊卡、埃里克·P·邢。Vicuna: 一个开源聊天机器人, 以 90% 的 ChatGPT 质量给 GPT-4 留下深刻印象。2023 年 3 月。1、2、4、5、6
- [10] 阿卡安莎·乔杜里、沙兰·纳兰、雅各布·德夫林、马腾·博斯马、高拉夫·米什拉、亚当·罗伯茨、保罗·巴勒姆、郑亨元、查尔斯·萨顿、塞巴斯蒂安·格尔曼等人。Palm: 通过路径缩放语言建模。arXiv 预印本 arXiv:2204.02311, 2022. 2
- [11] 郑亨元、侯乐、谢恩·朗普雷、巴雷特·佐夫、伊·泰、威廉·费达斯、埃里克·李、王学志、穆斯塔法·德赫加尼、悉达多·布拉马等。《缩放指令微调语言模型》。arXiv 预印本 arXiv:2210.11416. 2022 年. 2
- [12] CVinW. 野外计算机视觉。https://github.com/Computer-Vision-in-the-Wild/CVinW_Readings. 2022. 1
- [13] 丹尼·德里斯、费霞、迈赫迪·SM·萨贾迪、科里·林奇、阿卡安莎·乔杜里、布莱恩·伊希特、艾扎安·瓦希德、乔纳森·汤普森、全旺、余天和等人。PaLM-E: 一种具身多模态语言模型。arXiv 预印本 arXiv:2303.03378. 2023. 2
- [14] 法尔塔什·法格里、哈迪·普兰萨里、萨钦·梅塔、迈赫达德·法拉杰塔巴尔、阿里·法拉哈迪、穆罕默德·拉斯泰加里和翁塞林·图泽尔。强化数据, 倍增影响: 通过数据集聚强化提高模型准确性和鲁棒性。arXiv 预印本 arXiv:2303.08983. 2023 年. 2
- [15] 奥兰·加夫尼、亚当·波利亚克、奥伦·阿舒阿尔、雪莉·谢宁、德维·帕里赫和亚尼夫·泰格曼。《场景生成: 基于场景的带有人为先验的文本到图像生成》。预印本平台, 编号 abs/2203.13131. 2022 年。1

- [16] 甘哲、李琳杰、李春元、王丽娟、刘子成、高剑锋等。视觉语言预训练：基础、最新进展与未来趋势。《计算机图形与视觉基础与趋势》，2022 年。1
- [17] 法布里齐奥·吉拉尔迪、梅萨姆·阿里扎德和马埃尔·库布利。ChatGPT 在文本标注任务上的表现优于众包工作者。arXiv 预印本 arXiv:2303.15056, 2023. 3
- [18] 坦梅伊·古普塔和阿尼尔鲁达·肯巴维。《视觉编程：无需训练的组合式视觉推理》。arXiv 预印本 arXiv:2211.11559. 2022 年。2
- [19] 郝维拓、李春元、李秀军、劳伦斯·卡林和高建峰。通过预训练学习通用的视觉 - 语言导航智能体。发表于《CVDP》。2020 年。2
- [20] 黄少涵、李东、王文辉、郝雅茹、萨克沙姆·辛哈尔、马树铭、吕腾超、崔磊、Owais Khan Mohammed、刘强等人。语言并非万能：让感知与语言模型对齐。arXiv 预印本 arXiv:2302.14045, 2023. 2
- [21] 加布里埃尔·伊尔哈科、米切尔·沃茨曼、罗斯·怀特曼、凯德·戈登、尼古拉斯·卡林尼、罗汉·陶里、阿查尔·戴夫、瓦伊沙尔·尚卡尔、南公洪锡、约翰·米勒、汉纳内·哈吉希尔齐、阿里·法哈迪和路德维希·施密特。Openclip。2021 年 7 月。如果您使用本软件，请按以下方式引用。1
- [22] 斯里尼瓦桑·艾耶尔、席维多利亚·林、拉马坎斯·帕苏努鲁、托多尔·米哈伊洛夫、丹尼尔·西米格、余平、库尔特·舒斯特、王天路、刘青、普尼特·辛格·库拉等。Opt-impl：通过泛化视角扩展语言模型指令元学习。arXiv 预印本 arXiv:2212.12017, 2022. 2
- [23] 贾梦琳、唐路明、陈博春、克莱尔·卡迪、塞尔日·贝隆吉、巴拉特·哈里哈兰、瑟尔 - 南·林。视觉提示微调。发表于《欧洲计算机视觉会议》，2022 年。2
- [24] 许静宇 (Jing Yu Koh)、鲁斯兰·萨拉胡丁诺夫 (Ruslan Salakhutdinov) 和丹尼尔·弗里德 (Daniel Fried)。为多模态生成将语言模型与图像关联。arXiv 预印本 arXiv:2301.13823, 2023. 2
- [25] 李博艺、基利安·Q·魏因伯格、塞尔日·贝隆吉、弗拉德伦·科尔顿和勒内·兰夫特尔。语言驱动的语义分割。国际学习表征会议 (ICLR)。2022 年。1
- [26] 李春元、甘哲、杨正元、杨建伟、李琳杰、王丽娟、高剑锋。多模态基础模型：从专家到通用助手。arXiv 预印本 arXiv:2309.10020, 2023. 1
- [27] 李春元、刘昊天、李刘年·哈罗德、张鹏川、乔蒂·阿内亚、杨建伟、金平、胡厚东、刘子成、李勇宰和高剑锋。ELEVATER：评估语言增强视觉模型的基准和工具包。见《神经信息处理系统大会数据集与基准轨道》，2022 年。1
- [28] 李俊楠、李东旭、西尔维奥·萨瓦雷塞和史蒂文·霍伊。Blip-2：利用冻结图像编码器和大型语言模型引导语言 - 图像预训练。arXiv 预印本 arXiv:2301.12597, 2023. 1, 2, 4, 6, 7
- [29] 刘年·哈罗德·李、彭传章、张昊天、杨建伟、李春元、钟义武、王丽娟、袁璐、张磊、黄仁能等。基于接地的语言 - 图像预训练。发表于《计算机视觉与模式识别会议》，2022 年。1
- [30] 李宇恒、刘昊天、吴庆阳、穆方舟、杨建伟、高剑锋、李春元、李勇宰。Gligen：开放集有锚定文本到图像生成。arXiv 预印本 arXiv:2301.07093, 2023. 1
- [31] 林宗毅 (Tsung-Yi Lin)、迈克尔·迈尔 (Michael Maire)、塞尔日·贝隆吉 (Serge Belongie)、詹姆斯·海斯 (James Hays)、彼得罗·佩罗那 (Pietro Perona)、德瓦·拉马南 (Deva Ramanan)、彼得·多拉尔 (Piotr Dollár) 和 C·劳伦斯·齐特尼克 (C Lawrence Zitnick)。《微软 COCO：场景中的常见物体》。发表于《欧洲计算机视觉会议论文集》(ECCV)，2014 年。3
- [32] 刘昊天、李春元、李宇航和李勇宰。通过视觉指令微调改进基线，2023 年。9, 14

- [33] 石龙·刘、朝阳·曾、天和·任、冯·李、浩·张、杰·杨、春园·李、建伟·杨、杭·苏、君·朱等。Grounding DINO: 将 DINO 与基础预训练相结合用于开放集目标检测。arXiv 预印本 arXiv:2303.05499, 2023. 1
- [34] 潘璐、斯瓦鲁普·米什拉、夏棠林、邱亮、张凯伟、朱松纯、奥伊文德·塔夫约德、彼得·克拉克、阿什温·卡利安。《学会解释：通过思维链进行科学问答的多模态推理》。《神经信息处理系统讲展》，2022 年。2、5、8、9
- [35] OpenAI. ChatGPT. <https://openai.com/blog/chatgpt/>, 2023. 1, 2
- [36] OpenAI. Gpt-4 技术报告, 2023. 1. 5. 6. 15
- [37] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray 等。利用人类反馈训练语言模型遵循指令。《神经信息处理系统进展》，35:27730–27744, 2022. 2
- [38] 彭宝林、李春园、何鹏程、米歇尔·加利和高剑锋。使用 GPT-4 进行指令微调。arXiv 预印本 arXiv:2304.03277, 2023. 1. 4
- [39] 范辉、戴子航、戈尔纳兹·吉亚西、川口健二、刘瀚霄、余亚当·魏、余家辉、陈奕廷、梁明仓、吴永辉等。用于开放词汇图像分类的联合缩放。arXiv 预印本 arXiv:2111.10050, 2021. 1
- [40] 亚历克·拉德福德、钟旭（音译）、克里斯·哈拉西、阿迪蒂亚·拉梅什、加布里埃尔·吴（音译）、桑迪尼·阿加瓦尔、吉里什·萨斯特里、阿曼达·阿斯科尔、帕梅拉·米什金、杰克·克拉古等。从自然语言监督中学习可迁移视觉模型。arXiv 预印本 arXiv:2103.00020, 2021. 1, 2, 4
- [41] 科林·拉菲尔、诺阿姆·沙泽尔、亚当·罗伯茨、凯瑟琳·李、沙兰·纳兰、迈克尔·马泰纳、周彦琦、李伟和彼得·J·刘。利用统一的文本到文本转换器探索迁移学习的极限。《机器学习研究期刊》，2020 年。2
- [42] 阿迪蒂亚·拉梅什、普拉富拉·达里瓦尔、亚历克斯·尼科尔、凯西·朱和马克·陈。基于 CLIP 潜在变量的分层文本条件图像生成。arXiv, 编号 abs/2204.06125, 2022 年。1
- [43] 罗宾·隆巴赫、A. 布拉特曼、多米尼克·洛伦茨、帕特里克·埃塞尔和比约恩·奥默。基于潜在扩散模型的高分辨率图像合成。《计算机视觉与模式识别会议论文集》，第 10674–10685 页, 2022 年。1
- [44] 奇特万·萨哈里亚、威廉·陈、Saurabh Saxena、拉拉·李、杰·王、艾米丽·L·丹顿、赛义德·卡迈勒、赛义德·加塞米普尔、布尔库·卡拉戈尔·阿扬、赛义德·萨拉·马赫达维、拉斐尔·贡蒂约·洛佩斯、蒂姆·萨利曼斯、乔纳森·何、大卫·J·弗利特、穆罕默德·诺鲁兹。具有深度语言理解能力的逼真文本到图像扩散模型。ArXiv, 编号 abs/2205.11487, 2022 年。1
- [45] 克里斯托夫·舒曼、罗曼·博蒙特、理查德·文库、凯德·戈登、罗斯·怀特曼、迈赫迪·谢尔蒂、西奥·库姆斯、阿鲁什·卡塔、克莱顿·马利斯、米切尔·沃茨曼等人。Laion5b: 用于训练下一代图文模型的开放式大规模数据集。arXiv 预印本 arXiv:2210.08402, 2022. 2
- [46] 迪达克·苏里斯、萨奇特·梅农和卡尔·冯德里克。Vipergpt: 通过 Python 执行进行推理的视觉推断。arXiv 预印本 arXiv:2303.08128, 2023. 2
- [47] 安德鲁·索特、亚历克斯·克莱格、埃里克·昂德桑德、埃里克·维杰曼斯、赵一力、约翰·特纳、诺亚·梅斯特雷、穆斯塔法·穆卡达姆、德文德拉·查普洛特、奥列克桑德尔·马克西梅茨、艾伦·戈卡斯兰、弗拉基米尔·冯德鲁斯、萨米尔·达鲁尔、弗兰齐斯卡·迈尔、沃伊切赫·加卢巴、安吉尔·张、佐尔特·基拉、弗拉德伦·科尔顿、吉滕德拉·马利克、马诺利斯·萨瓦、德鲁夫·巴特拉。Habitat 2.0: 训练家庭助手重新布置其居住环境。《神经信息处理系统讲展》(NeurIPS), 2021 年。2
- [48] 罗汉·陶里、伊尚·古拉贾尼、张天翼、扬·杜波依斯、李学晨、卡洛斯·格斯特林、珀西·梁和桥本达规。斯坦福羊驼: 一个遵循指令的 LLaMA 模型。https://github.com/tatsu-lab/stanford_alpaca, 2023. 1, 4

- [49] 雨果·图夫龙、蒂博·拉夫里尔、戈蒂埃·伊扎卡尔、泽维尔·马蒂内、玛丽 - 安妮·拉乔、蒂莫泰·拉克鲁瓦、巴蒂斯特·罗齐埃、纳曼·戈亚尔、埃里克·汉布罗、费萨尔·阿扎尔等。Llama: 开放且高效的基础语言模型。arXiv 预印本 arXiv:2302.13971, 2023. 1
- [50] 王剑峰、杨正远、胡晓伟、李琳杰、凯文·林、甘哲、刘子成、刘策和王丽娟。Git: 用于视觉与语言的生成式图像到文本转换器。arXiv 预印本 arXiv:2205.14100, 2022. 1
- [51] 王一中、叶加内·科尔迪、斯瓦鲁普·米什拉、艾丽莎·刘、诺亚·A·史密斯、丹尼尔·哈沙比和汉纳内·哈吉希尔齐。自我指令: 通过自生成指令对齐语言模型。arXiv 预印本 arXiv:2212.10560, 2022. 2
- [52] 王一中、斯瓦鲁普·米什拉、佩加·阿里普尔莫拉巴希、叶加内·科尔迪、阿米雷扎·米尔扎伊、安贾娜·阿伦库马尔、阿尔俊·阿肖克、阿鲁特·塞尔万·达纳塞卡兰、阿塔尔瓦·奈克、大卫·斯塔普等。通过 1600 多项语言任务的上下文指令对泛化能力进行基准测试。arXiv 预印本 arXiv:2204.07705, 2022. 2
- [53] 吴晨飞、尹圣明、祁伟珍、王晓东、唐泽成和段楠。Visual ChatGPT: 借助视觉基础模型进行对话、绘图与编辑。arXiv 预印本 arXiv:2303.04671, 2023. 2
- [54] 杨建伟、李春园、张鹏川、肖斌、袁璐、刘策和高剑锋。图像 - 文本 - 标签空间中的统一对比学习。CVPR, 2022 年。1
- [55] 杨正元、李琳杰、王建峰、凯文·林、埃哈桑·阿扎尔纳萨卜、费萨尔·艾哈迈德、刘子成、刘策、迈克尔·曾和王丽娟。《Mm-react: 提示 ChatGPT 进行多模态推理与行动》。arXiv 预印本 arXiv:2303.11381, 2023. 2
- [56] 余家辉、徐元忠、许景瑜·Koh、唐·梁、冈扬·拜德、王 zirui、维贾伊·瓦苏德万、亚历山大·库、杨银飞、布尔库·卡拉戈尔·阿扬、本顿·C. 哈钦森、魏瀚、扎拉纳·帕雷克、李鑫、张涵、杰森·鲍德里奇和吴永辉。用于内容丰富的文本到图像生成的自回归模型缩放。ArXiv, abs/2206.10789, 2022. 1
- [57] 陆远、陈东冬、陈怡玲、诺埃尔·科德拉、戴西洋、高剑锋、胡厚冬、黄学东、李博鑫、李春元等。Florence: 一种新的计算机视觉基础模型。arXiv 预印本 arXiv:2111.11432, 2021. 1
- [58] 张浩、李锋、邹雪燕、刘世龙、李春园、高剑锋、杨建伟和张磊。开放词汇分割与检测的简单框架。arXiv 预印本 arXiv:2303.08131, 2023. 1
- [59] 张仁瑞、韩佳明、周奥钧、胡祥飞、闫世林、卢潘、李宏生、高鹏和乔宇。Llama-adapter: 基于零初始化注意力的语言模型高效微调。arXiv 预印本 arXiv:2303.16199, 2023. 2, 8, 9
- [60] 苏珊·张、斯蒂芬·罗勒、纳曼·戈亚尔、米克尔·阿特克塞、莫亚·陈、陈硕辉、克里斯托弗·德万、莫娜·迪亚布、李显、林熙维多利亚等。OPT: 开源预训练 Transformer 语言模型。arXiv 预印本 arXiv:2205.01068, 2022. 2
- [61] 张卓生、阿斯顿·张、李沐、赵海、乔治·卡利皮斯、亚历克斯·斯莫拉。语言模型中的多模态思维链推理。arXiv 预印本 arXiv:2302.00923, 2023. 8, 9
- [62] 钟义乌、杨建伟、张鹏川、李春元、诺埃尔·科德拉、李刘年·哈罗德、周洛维、戴西洋、袁璐、李茵等。RegionCLIP: 基于区域的语言 - 图像预训练。《IEEE/CVF 计算机视觉与模式识别会议论文集》, 第 16793-16803 页, 2022 年。1
- [63] 邹雪燕、窦子毅、杨建伟、甘哲、李琳杰、李春元、戴西洋、哈基拉特·贝尔、王建峰、袁露等。像素、图像和语言的广义解码。arXiv 预印本 arXiv:2212.11270, 2022. 1, 2

更广泛的影响

LLaVA 作为一款通用视觉助手，其更广泛的影响与其部署和发布相关的潜在收益和风险并存。由于其视觉特性，一些考量因素是 LLaVA 所独有的，而其他因素则与现有的指令遵循型大语言模型（如 Alpaca、Vicuna 等）存在相似之处。由于 LLaVA 是基于 LLaMA、Vicuna 和 CLIP 构建的，它继承了大语言模型和视觉编码器的一些相关问题。下文将概述该模型发布所面临的风险以及已采取的缓解策略。

恶意输入。为了最大限度地减少潜在的滥用和有害后果，我们为 LLaVA 采取了两项预防措施：（1）使用 OpenAI 过滤 API 处理用户输入文本，防止有害或不当的文本指令被模型处理；（2）对用户上传的图像使用 NSFW 过滤器，以检测并拦截不适合工作场景（NSFW）的内容或任何其他具有潜在危害的图像输入。

幻觉。与大语言模型类似，LLaVA 可能会生成并非基于事实或输入数据的输出。这引发了人们对所做推断的担忧，尤其是在关键应用中（例如医疗领域）。

偏见。偏见可能会从基础模型转移到 LLaVA，既可能来自视觉编码器（CLIP），也可能来自语言解码器（LLaMA/Vicuna）。这可能会导致有偏见的结果，或者对多样化内容的不公平呈现。

能耗。尽管由于预训练数据集较小（详见附录 C），能耗并非 LLaVA 的主要关注点，但在扩大预训练数据集规模或增大模型尺寸时（例如，采用更大的 LLaMA 版本如 65B 模型），这可能会成为一个问题。

评估的复杂性。评估 LLaVA 的性能具有挑战性，因为它涉及语言和视觉任务。我们的评估基准涵盖多个方面，包括准确性、概念覆盖度、推理能力和创造力。然而，还需要考虑其他方面，例如视觉内容幻觉的程度以及对视觉内容的细粒度理解。在我们的研究中，基于纯文本 GPT-4 的多模态评估是一致且准确的，但其在不同情况下的稳健性以及评估其他未探索方面的能力有待未来研究。

尽管存在这些风险，我们认为向研究界发布 LLaVA 的益处超过了潜在危害。这使得对该模型的持续研究和改进成为可能，并能让研究界参与到更好的缓解策略的开发中，以解决这些问题。此外，LLaVA 的发布可推动新应用和研究方向的发展，最终为视觉 - 语言任务中基础模型的进步和负责任部署做出贡献。

查看更多结果

我们展示了更多 LLaVA 的定性结果，以分析其涌现行为和观察到的弱点。有关 LLaVA 在学术基准上的更多定量结果，请参考经过视觉指令微调的改进基线 [32]。在表 9 中，LLaVA 在其论文的另一个示例中表现出与 GPT-4 相似的行为。与 OpenAI 的 GPT-4 实时演示类似，LLaVA 能够根据图 2 中简化的用户输入草图生成交互式笑话网站的 HTML/JS/CSS 代码，尽管存在一个小错误。如图 3 所示，LLaVA 能够以对话风格遵循用户的指令，并提供详细的回答或富有创意的文字内容。此外，正如在图 4 和图 5 中所展示的，LLaVA 能够将视觉内容与预训练大语言模型中的文本知识相关联。

LLaVA 一个有趣的涌现行为是，它能够理解训练中未涵盖的视觉内容。例如，在图 6 中，它能够识别出埃隆·马斯克的头像以及他打扮成狗狗币形象的幽默表情包，尽管在视觉特征对齐或视觉指令微调阶段的训练数据中，埃隆·马斯克从未出现过。

LLaVA。如表 9 和图 2 所示，LLaVA 还展现出令人印象深刻的 OCR（光学字符识别）能力，而这在我们的训练数据中很少涉及。

我们希望这些额外的结果和观察能展示 LLaVA 在各种应用领域的潜力。在未来的工作中，深入研究这些涌现行为并理解使 LLaVA 展现出这种泛化能力的潜在机制至关重要。这将为构建更好的大语言模型（LMMs）铺平道路，包括增强鲁棒性、减少偏见，以及改进所学视觉 - 语言表征的对齐性和范围。

视觉输入示例：鸡块地图。	
Sometimes I just look at pictures of the earth from space and I marvel at how beautiful it all is.	
User	Can you explain this meme in detail?
LLaVA	The meme in the image is a creative and humorous take on food, with a focus on chicken nuggets, as the center of the universe. The meme begins with the phrase "Sometimes I just look at pictures of the Earth from space and I marvel at how beautiful it all is..." The main image features a tray of cooked chicken nuggets, with the chicken pieces positioned to resemble the continents and islands on a world map. The meme playfully suggests that the chicken nuggets represent the Earth, and the various locations depicted in the photo are actually chicken nugget versions of different places. The punchline of the meme appears in smaller text at the bottom, reading "I mean, it's not the real Earth, but how beautiful it is all is." This lighthearted and entertaining meme combines food and humor, using the image of chicken nuggets to create a funny and imaginative representation of the world.
User	Can you explain this meme?
GPT-4 [36]	This meme is a joke that combines two unrelated things: pictures of the earth from space and chicken nuggets. The text of the meme suggests that the image below is a beautiful picture of the earth from space. However, the image is actually of chicken nuggets arranged to vaguely resemble a map of the world. The humor in this meme comes from the unexpected juxtaposition of the text and the image. The text sets up an expectation of a majestic image of the earth, but the image is actually something mundane and silly.
User	Can you explain this meme in detail?
BLIP-2	sometimes i just look at pictures of the earth from space and marvel how beautiful it is
User	Can you explain this meme in detail?
OpenFlamingo	It's a picture of a chicken nugget on the International Space Station.

表 9：比较 LLaVA、GPT-4、BLIP-2 和 OpenFlamingo 在理解幽默方面的视觉推理能力的示例提示。BLIP-2 和 OpenFlamingo 未能遵循用户的指示。LLaVA 和 GPT-4 都对这个表情包及其幽默之处进行了解释，而 GPT-4 给出的答案更简洁。



图 2: LLaVA 根据用户的草图输入生成交互式网站的 HTML/JS 代码。在修复生成输出中的一个小错误（红色标注）后，该交互式界面即可正常运行。LLaVA 的输出还有改进空间，例如将笑话和妙语拆分为两行，并且仅在点击按钮时才显示妙语，以更好地反映用户的意图。



图 3: LLaVA 能够按照用户的意图识别视觉内容，无需直接提示进行视觉识别。当收到后续请求提示时，它还能提供详细的回应，且生成的回应与所提供的视觉内容密切相关。






图 5: LLaVA 识别出了列奥纳多·达·芬奇的著名艺术品《蒙娜丽莎》。当我们开启新对话时，它还会解释网络上模仿《蒙娜丽莎》创作的幽默艺术品。



图 6: LLaVA 一个有趣的突发行为是，它能够识别出埃隆·马斯克的头像，以及他打扮成“狗狗币”形象的幽默表情包。这意味着预训练的 CLIP 视觉编码器可能见过埃隆·马斯克的图像。不过，这仍然令人惊讶，因为在 LLaVA 的视觉特征对齐或视觉指令微调阶段的训练数据中，从未出现过埃隆·马斯克，这表明基础语言模型能够泛化到未见过的视觉概念。

问题。	
这把摇椅是由什么材料制成的？	
选项：(A) 木材 (B) 丝绸	
LLaVA 的答案。	
这应该是一种材料制成的。	
木材、玻璃、金属和塑料是常见的材料。	
有此物体仅由一种材料制成	
一些物体是由多种材料制成的	
其他物体由不止一种材料制成。	
这描述了一个由多种材料制成的	
解决方案：看这张摇椅的图片。这把摇椅由两种不同的材料制成。椅腿是木制的，椅背和座椅则是丝绸的。	
答案是 B	
GPT-4 (纯文本) 答案。	
答案是 A。原因如下：摇椅通常由坚固的材料制成，这些材料能够支撑人的重量并承受摇晃动作。木材因其强度、耐用性和自然外观，是制作摇椅的常用材料。	
GPT-4 (纯文本) 评判者。	
由于没有可参考的上下文或图像，我无法独立分析所提及的摇椅。不过，我可以尝试分析助手们给出的推理	
声称见过该图像的助手 1 提到，摇椅的腿是木制的，椅背和座椅则是丝绸材质，这意味着它是两种材料的结合体。然而，这种说法似乎不太合理，因为丝绸由于在稳定性和耐用性方面存在问题，并非制作摇椅的常用材料。通常情况下，人们会认为摇椅的框架、椅腿以及座椅或椅背是木制的，而坐垫和衬垫则由棉布或聚酯纤维等面料制成。	
助手 2 认为，摇椅通常由坚固的材料制成，而木材因其强度、耐用性和自然外观，是制作摇椅的常用材料。这一推理是正确的，且基于常识。	
根据现有信息，最合理的答案是如助手 1 所建议的，这把摇椅是木制的。答案是 A。	

表 10: 纯文本 GPT-4 作为评判者，整合 LLaVA 和纯文本 GPT-4 的预测并给出正确最终答案的一个示例。

C 训练细节

我们在经过筛选的 CC-595K 子集上对模型进行预训练，训练 1 个 epoch，学习率为 $2e-3$ ，批大小为 128；然后在提出的 LLaVA-Instruct-158K 数据集上进行微调，训练 3 个 epoch，学习率为 $2e-5$ ，批大小为 32。遵循 Vicuna 的做法，我们使用 Adam 优化器（无权重衰减）和余弦学习率，预热比例为 3%。微调过程中，使用 FSDP（全分片数据并行）和梯度检查点来节省 GPU 内存，不使用卸载技术。启用 BF16 和 TF32 以在速度和精度之间取得平衡。

我们使用 8×A100 训练所有模型。在 CC-595K 上的预训练在 4 小时内完成。在 Instruct-158K 上的微调在 10 小时内完成。在 ScienceQA 上的微调在 4 小时内完成。

D 资源

我们的源代码、生成的指令微调数据以及提出的基准已上传至匿名 GitHub 仓库：LLaVA-Anonymous/LLaVA。

源代码：链接

自述文件：链接

启动演示的说明：链接

用于查询 GPT-4 的所有提示词和少样本示例：链接

LLaVA-Instruct-158K：链接

LLaVA 基准测试：COCO、自然场景

模型检查点。压缩后的模型检查点大小为 25GB，超过了 GitHub LFS（大文件存储）5GB 的限制。我们将向公众发布该检查点，或者应本次投稿评审人员的要求提供。

E 数据

图像简要描述说明。用于简要描述图像内容的说明列表如表 11 所示。这些说明表述的含义相同，但存在自然语言上的差异。

表 11：图像简要描述说明列表。

• “简要描述该图像。”

图像简要描述说明。用于简要描述图像内容的说明列表如表 11 所示。这些说明含义相同，但存在自然语言上的差异。

• “简洁地描述这张图片。”
• “对给定的图像进行简要描述。”
• “对所呈现的图片给出简洁的解释。”
• “总结图像的视觉内容。”
• “对后续图片给出简短清晰的解释。”
• “对所提供的图像给出简短清晰的解释。”
• “对照片的关键特征进行简洁描述。”
• “简要、清晰地描述所示图片。”
• “对照片进行清晰简洁的总结。”
• “为这幅图片撰写一段简洁但内容丰富的总结。”
• “创作一个简洁的叙述来呈现所给图像。”

表 11：简短图像描述指令列表。

详细图像描述说明。用于详细描述图像内容的说明列表如表 12 所示。这些说明含义相同，但存在自然语言上的差异。

CC3M。我们使用 Spacy 对整个 CC3M 数据集的每个标题提取名词短语，并统计每个独特名词短语的出现频率。我们会跳过频率低于 3 的名词短语，因为它们通常是罕见的概念和属性组合，且这些内容已经被涵盖。

• “详细描述以下图像”
• “提供对给定图像的详细描述”
• “对所看到的图像进行详细解释”
• “公开所呈现图像的全面了解”
• “对图像进行全面分析”
• “解释你所见图像的各个方面”
• “详细阐明所显示图像的内容”
• “用详尽的描述来刻画这幅图像”
• “详细分解图像的各个元素”
• “详细梳理图像的重要细节”
• “用丰富、生动的叙述描绘这幅图像”
• “精准叙述图像内容”
• “全面且详细地分析该图像”
• “通过描述性解释来说明图像”
• “仔细检查图像并公开其细节”
• “对给定图像进行详尽描述”

表 12：详细图像描述指令列表。

由其他标题完成。然后，我们从剩余频率最低的名词短语开始，将包含该名词短语的标题添加到候选池中。如果该名词短语的频率超过 100，我们会从其所有标题中随机选择 100 个组成子集。这会产生大约 59.5 万对图像 - 文本对。

图 7 展示了过滤 CC3M 前后名词短语统计数据的对比。过滤后的数据集对频率高于 3 的概念有较好的覆盖，但图文对的数量较少。




图 7：CC3M 过滤前后名词短语统计对比。图例中报告了独特名词短语的总数。

F 提示词

用于从 ChatGPT/GPT-4 生成基于图像的对话的提示词如表 13 所示。

```
messages = [ {"role": "system", "content": f""" 你是一名 AI 视觉助手，正在查看一张图片。你所看到的内容由五个句子提供，这些句子描述的是你正在查看的同一张图片。请像你正在看这张图片一样回答所有问题。
"""
```

设计一段你与询问这张照片的人之间的对话。回答的语气应符合视觉 AI 助手正在查看图片并进行解答的情境。要提出各种不同的问题，并给出相应的回答。

包含询问图像视觉内容的问题，包括物体类型、物体计数、物体动作、物体位置、物体之间的相对位置等。只包含有明确答案的问题：

(1) 人们能够看到图像中问题所询问的内容，并且能够自信地绘出答案。

(2) 人们可以从图像中确切判断出它不在该图像中。不要提出任何无法确切回答的问题。

还要包含与图像内容相关的复杂问题，例如询问图像中物体的背景知识、要求讨论图像中正在发生的事件等。同样，不要询问不确定的细节。在回答复杂问题时，要提供详细的答案。例如，给出详细的例子或推理步骤，使内容更具说服力且条理清晰。必要时可以分多个段落。

```
for sample in fewshot_samples:
    messages.append({"role": "user", "content": sample['context']})
    messages.append({"role": "assistant", "content": sample['response']})
messages.append({"role": "user", "content": '\n'.join(query)})
```

表 13: 对于每个查询，我们展示了使用 ChatGPT/GPT-4 从查询的“上下文”中获取查询的“响应”时的提示构建过程，该过程采用小样本上下文学习，其中示例来自小样本数据集，每个示例包括输入样本的“上下文”和输出样本的“响应”。请注意，消息是最终的提示。在本示例中，我们提供了用于生成对话响应的提示，其上下文学习示例的详细内容另见表 15 和表 16。我们建议读者查看代码库，以获取用于生成其他两种类型响应（包括详细描述和复杂推理）的提示。


上下文类别 1. 字幕 一群人站在一辆黑色车辆外面，身边放着各式各样的行李。 地下停车场内，车辆周围放满了行李。 人们试图把所有行李都塞进一辆运动型多用途汽车（SUV）里。 这辆运动型多功能车停在公共车库里，正在为旅行装车。一些人带着行李在一辆运送它的货车旁边。 视觉类别 1. 分析 人: [0.681, 0.242, 0.774, 0.694], 人: [0.63, 0.222, 0.686, 0.516], 人: [0.444, 0.233, 0.487, 0.34], 背包: [0.384, 0.696, 0.485, 0.914], 背包: [0.755, 0.413, 0.846, 0.692], 手提箱: [0.758, 0.413, 0.845, 0.69], 手提箱: [0.1, 0.497, 0.173, 0.579], 自行车: [0.282, 0.363, 0.327, 0.442], 汽车: [0.786, 0.25, 0.848, 0.322], 汽车: [0.783, 0.27, 0.827, 0.335], 汽车: [0.86, 0.254, 0.891, 0.3], 汽车: [0.261, 0.101, 0.787, 0.626]	
响应类别 1. 对话 问题：图片中显示的是哪种类型的车辆？ 答案：这张图片中有一辆黑色的运动型多用途汽车（SUV）。 问题：车辆停在哪儿？ 答案：这辆车停在地下停车区域，可能是在公共车库里。 问题：图片中的人们在做什么？ 答案：人们正试图把所有行李都装进这辆运动型多用途汽车（SUV）里，他们可能在为旅行做准备。 回答：人们正试图将他们所有的行李装进一辆 SUV 里，他 这张图片展示的是一个地下停车场，里面停着一辆黑色的运动型多用途汽车（SUV）。场景中有三个人，一个人站在车辆左侧较近的位置，另一个人在中间，第三个人在右侧。他们正一起把行李装进 SUV，准备出行。 在停车场区域，车辆周围散落着各种行李物品。有两个背包，一个在左后轮附近，另一个离车辆右侧较近。此外，还有两个行李箱，一个在汽车右侧，另一个在更远的停车场中央附近。车辆左侧还能看到一辆自行车。 主 SUV 周围还停着其他车辆，一辆车停在它后方稍偏左的位置，另一辆停在后方稍偏右的位置，第三辆车则停在左侧更靠后的地方。 响应类别 2. 行为指南 问题：这些人面临着什么挑战？ 答案：图片中，一群人正站在停车场的一辆黑色 SUV 外面，周围放着各种行李，包括行李箱和背包。他们正面临着将所有行李塞进这辆黑色 SUV 的挑战。需要打包的行李箱和背包数量不少，这表明这群人有相当多的物品要装。他们可能需要制定策略，高效地摆放行李，以确保所有东西都能妥善放进车里。此外，他们还需要考虑乘客的舒适度和驾驶时的视野，因此行李的放置不能遮挡司机的视线，也不能让乘客在旅途中感到不适。	

表 14：一个说明指令遵循数据的示例。上方区块展示了用于提示 GPT 的上下文（如标题和文本框），下方区块展示了三种类型的回应。请注意，视觉图像并未用于提示 GPT，我们在此仅将其作为参考展示。

字幕	有一家电影院在门的上方显示放映时间。 一个红色的消防栓深陷在雪中。 消防栓位于雪中。靠近一条刚清扫过的人行道。 这座城市经历了一个大雪纷飞的严冬。 及大雪掩埋的一家宠物店。
对话	问题：_____： 图片中的消防栓是什么颜色的？ ==== 答案：图片中的消防栓是红色的。 ==== 问题：_____： 消防栓是被雪完全覆盖了，还是部分可见？ ==== 答案：_____： 消防栓部分可见，其大部分被厚厚的积雪覆盖。 ==== 问题：_____： 消防栓附近的人行道状况如何？ ==== 答案：消防栓附近的人行道最近已被清理过积雪，因此与周边区域相比，这里的积雪相对较少。=== _____ 问题：这张图片表明了这座城市的冬季是什么样的？ _____ 答案：_____： 这张图片表明，这座城市的冬季相当严酷且充满挑战。图中明显的积雪表明该城市经历了强降雪，这可能会给居民带来各种困难和不便。 _____ 例如，覆盖在消防栓上的厚厚的积雪可能会在紧急情况下阻碍其正常使用，这引发了安全隐患。最近清理过的人行道表明，该市的维护人员一直在积极工作，以确保人行道畅通无阻，保障行人安全，但如此大的降雪量可能会使持续的除雪工作难以跟上进度。 _____ 此外，这种极端的冬季天气状况会对交通造成影响，导致交通问题、公共交通延误，以及因路面湿滑而增加的事故风险。它还会给企业和学校带来麻烦，因为人们可能在通勤上班或上课途中遇到困难。此外，大雪会给屋顶和电线等基础设施带来额外压力，增加结构损坏或停电的可能性。 _____ 总之，雪中深处的红色消防栓以及新近清扫过的人行道这一景象表明，这座城市经历了一个尤为寒冷的冬季，大量的降雪可能给居民生活和基础设施带来了各种挑战与干扰。

表 15. 用于上下文学习构建视觉对话数据的一个示例。

观察 一个人正在山顶的和平山路上滑雪。 一名滑雪者正在走滑雪中。 一名滑雪者站在一个路线指示牌旁，眺望着群山。 一个人在有很多灌木丛的区域附近滑雪。	
对话 问题：那个滑雪者在做什么？ 答案：滑雪者正在被积雪覆盖的小山中滑雪，在雪地里穿行，欣赏着美丽的山景。他们还站在一个路线指示牌附近，指示牌标明了他们在山上的位置。 问题：图片中能看到其他的人或滑雪者吗？ 答案：不，图片中只有一个人在滑雪，且这个人周围有很多灌木丛。 问题：这个人正在进行哪种滑雪？越野滑雪还是高山滑雪？ 答案：根据我从照片中看到的情况，无法确切判断这位滑雪者从事的是越野滑雪还是高山滑雪。不过，考虑到有 trail 标志，而且他们是在山麓地带滑雪，这位滑雪者更有可能在进行越野滑雪。高山滑雪通常在坡度更陡的斜坡上进行，并且会用到滑雪缆车，而越野滑雪则常发生在地形相对平坦、设有标记赛道的地方。 问题：你能再详细解释一下越野滑雪和高山滑雪吗？ 越野滑雪和高山滑雪是两种不同的滑雪类型，每种都有其独特的技巧、装备和地形偏好。 越野滑雪： 越野滑雪也被称为北欧滑雪，它是一项使用滑雪板和滑雪杖在相对平坦的地形或缓坡上滑行的运动。这是一项广受欢迎的休闲和竞技运动，注重耐力、平衡能力和有氧体能。越野滑雪者依靠自身的移动来在积雪覆盖的地形上前进，而非依赖滑雪缆车或其他形式的辅助工具。 There are two main techniques in cross-country skiing: 经典式：这种技术包括在平行轨迹上滑雪，保持双板平行的同时做前后滑行动作。滑雪者使用雪杖推动自己前进。 自由式滑雪：这种技术类似于滑冰，滑雪者以一定角度蹬离一只雪板，同时在另一只雪板上滑行。它需要平坦、经过整理的雪面，通常比传统技术速度更快。 越野滑雪装备包括轻型滑雪板、滑雪靴、固定器和滑雪杖。这种滑雪靴比 downhill 滑雪所用的更柔韧，能提供更好的脚踝活动度和控制力。 高山滑雪： 也被称为高山滑雪，downhill skiing 是指使用滑雪板和滑雪杖保持平衡与控制，从斜坡上高速滑下。这项运动更注重速度、技巧以及在具有挑战性的地形中穿行，包括陡坡、雪包甚至跳跃。 高山滑雪可进一步分为多个项目，如回转、大回转、超级大回转和滑降。每个项目都有其自身的规则、赛道和滑雪装备。高山滑雪装备包括比越野滑雪所用装备更重、更硬的滑雪板、滑雪靴、固定器和滑雪杖。滑雪靴更为坚硬，以便在高速下滑和急转弯时提供更好的支撑和控制。 总之，越野滑雪是一项以耐力为基础的运动，需要在平坦或缓坡地形上滑行；而高山滑雪则侧重于速度和技巧，滑雪者要在更陡峭的斜坡和具有挑战性的地形中穿梭。这两项运动都需要专门的装备和技巧，但它们为参与者带来了不同的体验和挑战。	

表 16. 用于上下文学习构建视觉对话数据的一个示例。