

语言模型是无监督多任务学习者

亚历克·拉德福德 * 1 杰弗里·吴 * 1 雷翁·蔡尔德 1 戴维·卢安 1 达里奥·阿莫迪 ** 1 伊利亚·萨茨克韦弗 ** 1

摘要

自然语言处理任务，如问答、机器翻译、阅读理解和文本摘要，通常是通过在特定任务数据集上进行有监督学习来实现的。我们发现，当在一个名为 WebText 的包含数百万网页的新数据集上进行训练时，语言模型无需任何显式监督就能开始学习这些任务。当以一篇文档加问题作为条件时，该语言模型生成的答案在 CoQA 数据集上达到了 55 的 F1 分数——在不使用 127,000 多个训练样本的情况下，其性能与 4 个基线系统中的 3 个相当或超过它们。语言模型的容量对于零样本任务迁移的成功至关重要，并且增加容量能以对数线性方式提升跨任务的性能。我们最大的模型 GPT-2 是一个拥有 15 亿参数的 Transformer，它在 8 个测试的语言建模数据集中，有 7 个在零样本设置下取得了最先进的结果，但仍对 WebText 存在欠拟合。该模型生成的样本体现了这些改进，其中包含连贯的文本段落。这些发现为构建能够从自然出现的示例中学习执行任务的语言处理系统指明了一条充满前景的道路。

引言

如今，机器学习系统通过结合大型数据集、高容量模型和监督学习，在其训练的任务上表现出色（从预期来看）（Krizhevsky 等人，2012）（Sutskever 等人，2014）（Amodi 等人，2016）。然而，这些系统较为脆弱，对数据分布的细微变化（Recht 等人，2018）和任务说明的细微调整（Kirkpatrick 等人，2017）都很敏感。当前的系统更适合被描述为狭隘的专家，而非

能干的通才。我们希望朝着更通用的系统发展，这类系统能够执行多种任务——最终无需为每个任务手动创建和标记训练数据集。

创建机器学习系统的主流方法是收集一组展示特定任务正确行为的训练示例数据集，训练系统模仿这些行为，然后在独立同分布（IID）的预留示例上测试其性能。这在培养专精于特定领域的专家模型方面效果显著。但图像描述模型（Lake 等人，2017）、阅读理解系统（Jia 和 Liang，2017）以及图像分类器

（Alcorn 等人，2018）在面对各种可能的输入时，其行为往往不稳定，这凸显了这种方法的一些缺陷。

我们推测，在单一领域数据集上进行单一任务训练的普遍做法，是导致当前系统泛化能力不足的主要原因。要利用现有架构开发出稳健的系统，可能需要在广泛的领域和任务上进行训练并衡量性能。最近，已有多项基准被提出，例如 GLUE（Wang 等人，2018）和 decaNLP（McCann 等人，2018），以开始对此进行研究。

多任务学习（Caruana，1997）是一种有望提升整体性能的框架。然而，自然语言处理（NLP）中的多任务训练仍处于初级阶段。近期研究显示其性能提升较为有限（Yogatama 等人，2019），而迄今为止两项最具雄心的研究分别在 10 组和 17 组（数据集、目标）对上进行了训练（McCann 等人，2018；Bowman 等人，2018）。从元学习的角度来看，每个（数据集、目标）对都是从数据集和目标的分布中抽取的单个训练样本。当前的机器学习系统需要数百到数千个样本才能归纳出具有良好泛化能力的函数。这表明，利用现有方法实现多任务训练的潜力，可能需要同样多的有效训练对。依靠现有技术，通过 brute force 方式将数据集的创建和目标的设计扩展到所需程度，将是非常困难的。这促使人们探索更多进行多任务学习的设置。

当前在语言任务上表现最佳的系统

同等贡献 100001 美国加利福尼亚州旧金山

通信作者：Alec Radford alec@openai.com。




图 1. WebText 语言模型在多个自然语言处理任务上的零样本任务表现与模型规模的关系。阅读理解结果基于 CoQA (Reddy 等人, 2018), 翻译结果基于 WMT-14 法英语料库 (Artetxe 等人, 2017), 摘要结果基于 CNN 和《每日邮报》(See 等人, 2017), 问答结果基于自然问题数据集 (Kwiatkowski 等人, 2019)。第 3 节包含每个结果的详细描述。

采用预训练和有监督微调相结合的方法。这种方法有着悠久的历史, 并且呈现出向更灵活的迁移形式发展的趋势。首先, 词向量被学习并用作特定任务架构的输入 (Mikolov 等人, 2013) (Collobert 等人, 2011), 然后循环网络的上下文表示被迁移 (Dai 和 Le, 2015) (Peters 等人, 2018), 而最近的研究表明, 特定任务架构已不再必要, 迁移多个自注意力块就足够了 (Radford 等人, 2018) (Devlin 等人, 2018)。

这些方法仍然需要有监督训练才能执行任务。当只有极少的有监督数据或完全没有有监督数据时, 另一类研究已经证明了语言模型在执行特定任务 (如常识推理 (Schwartz 等人, 2017) 和情感分析 (Radford 等人, 2017)) 方面的潜力。

在本文中, 我们将这两条研究路线联系起来, 并延续更通用的迁移方法这一趋势。我们证明, 语言模型能够在零样本设置下执行下游任务——无需任何参数或架构修改。我们通过强调语言模型在零样本设置下执行多种任务的能力, 表明这种方法具有潜力。根据不同任务, 我们取得了有前景、有竞争力且最先进的结果。

方法

我们方法的核心是语言建模。语言建模通常被定义为从一组示例 ($x_1, x_2, \dots, x_n$) 中进行无监督分布估计, 每个示例都由可变长度的符号序列 $1 (e_1, e_2, \dots, e_n)$ 组成。由于语言具有自然的顺序性, 因此对联合概率进行分解是很常见的

符号作为条件概率的产物 (Jelinek 和 Mercer, 1980)

(Bengio 等人, 2003):

$$p(x) = \prod_{i=1}^n p(s_i | s_1, \dots, s_{i-1})$$

这种方法允许对 $p(s_i | s_1, \dots, s_{i-1})$ 以及任何形式的条件句进行易处理的采样和估计。

$p(s_{n-k}, \dots, s_n | s_1, \dots, s_{n-k-1})$ 。近年来, 已经有

在能够计算这些条件概率的模型的表达能力方面, 已经有了显著的改进, 例如像 Transformer (Vaswani 等人, 2017 年) 这样的自注意力架构。

学习执行单个任务可以在概率框架中表示为估计条件分布 $p(\text{输出} | \text{输入})$ 。由于一个通用系统应该能够执行许多不同的任务, 即使对于相同的输入, 它不仅要以输入为条件, 还要以要执行的任务为条件。也就是说, 它应该对 $p(\text{输出} | \text{输入}, \text{任务})$ 进行建模。这在多任务和元学习场景中有着不同的形式化表述。任务条件设定通常在架构层面实现, 例如 (Kaiser 等人, 2017) 中的特定任务编码器和解码器, 或者在算法层面实现, 例如 MAML (Finn 等人, 2017) 的内外循环优化框架。但正如 McCann 等人 (2018) 所举例说明的, 语言提供了一种灵活的方式, 可以将任务、输入和输出都指定为符号序列。例如, 一个翻译训练示例可以写成这样的序列 (翻译成法语, 英语文本, 法语文本)。同样, 一个阅读理解训练示例可以写成 (回答问题, 文档, 问题, 答案)。McCann 等人 (2018) 证明, 训练单个模型——MQAN 是可行的。

在具有此类格式的示例上进行推断并执行许多不同的任务。

原则上，语言建模也能够学习 McCann 等人（2018）提出的任务，且无需对哪些符号是需要预测的输出进行明确监督。由于有监督目标与无监督目标相同，只是仅在序列的一个子集上进行评估，因此无监督目标的全局最小值也是有监督目标的全局最小值。在这个略显理想化的设定中，Sutskever 等人（2015）所讨论的、将密度估计作为一种有原则的训练目标的相关担忧得到了规避。相反，问题变成了在实践中我们是否能够将无监督目标优化至收敛。初步实验证实，足够大的语言模型能够在这种略带理想化的设置中进行多任务学习，但学习速度比显式有监督方法慢得多。

虽然从上述描述的良好设定到“真实世界中的语言”的复杂性还有很大差距，但 Weston（2016）在对话语境中主张，需要开发能够直接从自然语言中学习的系统，并展示了一个概念验证——通过对教师输出的正向预测，在没有奖励信号的情况下学习问答任务。对话虽然是一种很有吸引力的方法，但我们担心它过于受限。互联网包含大量被动可用的信息，无需互动交流。我们推测，具有足够能力的语言模型将开始学习推断并执行自然语言序列中展示的任务，以便更好地预测它们，无论这些任务的获取方式如何。如果语言模型能够做到这一点，那么实际上它就是在执行无监督多任务学习。我们通过分析语言模型在多种任务的零样本设置下的表现，来检验是否存在这种情况。

2.1. 训练数据集

大多数先前的研究都在单一文本领域训练语言模型，例如新闻文章（Jozefowicz 等人，2016）、维基百科（Merity 等人，2016）或虚构书籍（Kiros 等人，2015）。我们的方法旨在构建尽可能庞大且多样化的数据集，以便在尽可能多的不同领域和语境中收集自然语言的任务演示。

一个具有前景的、包含多样且近乎无限文本的来源是网络爬取数据，例如 Common Crawl。尽管这些档案库比当前的语言建模数据集大很多个数量级，但它们存在严重的数据质量问题。Trinh 和 Le（2018）在其关于常识推理的研究中使用了 Common Crawl，但指出其中有大量文档“其内容大多难以理解”。我们在初步实验中也观察到了类似的数据问题，这些实验涉及

“我不是世界上最聪明的人，但就像法国人说的那样：
Je ne suis pas un imbécile（我不是傻瓜）”

在 8 月 16 日一篇现已删除的帖子中，乔利埃特选区的保守党候选人索海耳·Eid 用法语写道：“Mentez mentez, il en restera toujours quelque chose”，这句话的意思是“不断撒谎，总会留下些什么”。

“我讨厌 ‘perfume’ 这个词，” 伯尔说。“用法语说稍微好一点，‘parfium’。”

如果仔细听 29 分 55 秒处，可以听到两个男人用法语交谈：“-Comment on fait pour aller de l’ autre cot’e? -Quel autre cot’e?”，意思是“- 怎么去另一边? - 哪一边?”。

如果这听起来有点牵强，不妨想想法语中的这个问题：“As-tu aller au cinéma?”，也就是“你去看电影了吗?”，它的字面意思是“你有去电影院 / 剧院吗?”。

“Brevet Sans Garantie Du Gouvernement”，翻译成苗立县，“未经政府担保的专利”

表 1. WebText 训练集中发现的自然出现的英法互译示例。

Common Crawl。Trinh 和 Le（2018）使用 Common Crawl 的一个小子样本取得了最佳结果，该子样本只包含与他们的目标数据集——Winograd 模式挑战最相似的文档。虽然这是一种提高特定任务性能的实用方法，但我们希望避免提前对要执行的任务做出假设。

相反，我们创建了一个新的网页抓取工具，它着重强调文档质量。为实现这一点，我们只抓取那些经过人工整理 / 筛选的网页。对完整的网页抓取结果进行人工筛选的成本会异常高昂，因此，作为起点，我们抓取了社交媒体平台 Reddit 上所有获得至少 3 个赞的外向链接。这可以被视为一个启发式指标，用于判断其他用户是否觉得该链接有趣、有教育意义或只是好笑。

由此产生的数据集 WebText 包含这 4500 万个链接中的文本子集。为了从 HTML 响应中提取文本，我们结合使用了 Dragnet (Peters & Lecocq, 2013) 和 Newspaper1 内容提取器。本文中呈现的所有结果均使用 WebText 的初步版本，该版本不包含 2017 年 12 月之后创建的链接，经过去重和一些基于启发式的清理后，包含略多于 800 万份文档，文本总量达 40GB。我们从 WebText 中移除了所有维基百科文档，因为它是其他数据集的常见数据源，可能会因过度（引用）而使分析变得复杂。

<https://github.com/codelucas/newspaper>

将训练数据与测试评估任务重叠。

2.2. 输入表示

一个通用语言模型 (LM) 应该能够计算 (并且生成) 任何字符串的概率。当前的大规模语言模型包含预处理步骤, 例如小写转换、分词和处理未登录词, 这些步骤限制了模型可处理的字符串范围。正如 Gillick 等人 (2015) 的研究所示, 将 Unicode 字符串作为 UTF-8 字节序列进行处理可以巧妙地满足这一要求, 但在诸如 “十亿词基准” (Al-Rfou 等人, 2018) 这样的大规模数据集上, 当前的字节级语言模型并不如词级语言模型表现出色。在我们尝试在 WebText 上训练标准的字节级语言模型时, 也观察到了类似的性能差距。

字节对编码 (BPE) (Sennrich 等人, 2015) 是字符级和词级语言建模之间的一种实用折中方案, 它能有效地在高频符号序列的词级输入和低频符号序列的字符级输入之间进行插值。尽管名称如此, 标准的 BPE 实现通常操作的是 Unicode 码点, 而非字节序列。这些实现需要包含全部的 Unicode 符号空间, 才能对所有 Unicode 字符串进行建模。这会导致在添加任何多符号令牌之前, 基础词汇量就超过 130,000。与 BPE 常用的 32,000 到 64,000 的令牌词汇量相比, 这一数量过于庞大, 难以处理。相比之下, 字节级的 BPE 版本只需要一个大小为 256 的基础词汇表。然而, 由于 BPE 在构建令牌词汇表时采用基于频率的贪婪启发式算法, 直接将 BPE 应用于字节序列会导致非最优的合并。我们观察到, BPE 会包含 “dog” 等常见词的许多版本, 因为它们以多种变体形式出现, 例如 dog、dog!、dog?。这导致有限的词汇槽位和模型容量得不到最优分配。为避免这种情况, 我们阻止 BPE 在任何字节序列的字符类别之间进行合并。我们对空格做了例外处理, 这显著提高了压缩效率, 同时仅使单词在多个词汇令牌上的碎片化程度降至最低。

这种输入表示使我们能够将词级语言模型的实证优势与字节级方法的通用性相结合。由于我们的方法可以为任何 Unicode 字符串分配概率, 这使我们能够在任何数据集上评估我们的语言模型, 而不受预处理、分词或词汇量的限制。

2.3. 模型

我们的语言模型采用基于 Transformer (Vaswani 等人, 2017) 的架构。该模型在很大程度上遵循了 OpenAI GPT 模型 (Radford 等人, 2018) 的细节, 具有

Parameters	Layers	d_{model}
117M	12	768
345M	24	1024
762M	36	1280
1542M	48	1600

表 2.4 种模型规模的架构超参数。

仅做了少量修改。层归一化 (Ba 等人, 2016 年) 被移至每个子块的输入端, 类似于预激活残差网络 (He 等人, 2016 年), 并且在最终的自注意力块之后增加了一个额外的层归一化。采用了一种经过修改的初始化方法, 该方法考虑了残差路径上随模型深度的累积效应。我们在初始化时将残差层的权重按 $1/\sqrt{N}$ 的因子进行缩放, 其中 N 是残差层的数量。词汇表扩展到 50257 个。我们还将上下文长度从 512 个标记增加到 1024 个标记, 并使用了更大的批次大小 512。

实验

我们训练并测试了四个语言模型 (LM), 它们的规模大致呈对数均匀分布。这些模型的架构总结在表 2 中。最小的模型与原始 GPT 相当, 第二小的模型与 BERT 中最大的模型 (Devlin 等人, 2018) 相当。我们最大的模型名为 GPT-2, 其参数数量比 GPT 多出一个数量级以上。每个模型的学习率都经过手动调整, 以在 WebText 的 5% 留存样本上达到最佳困惑度。所有模型仍对 WebText 存在欠拟合, 并且随着训练时间的增加, 留存样本的困惑度至今仍在改善。

3.1. 语言建模

作为实现零样本任务迁移的第一步, 我们希望了解 WebText 语言模型在其训练的主要任务——语言建模上的零样本领域迁移表现。由于我们的模型在字节级别运行, 不需要有损的预处理或分词, 因此可以在任何语言模型基准上对其进行评估。语言建模数据集的结果通常以某个数值来报告, 该数值是每个标准预测单元 (通常是字符、字节或单词) 的平均负对数概率的缩放或指数形式。我们通过计算 WebText 语言模型对数据集的对数概率, 再除以标准单元的数量, 来评估相同的数值。对于其中许多数据集, WebText 语言模型将在显著分布外进行测试, 需要预测经过严格标准化的文本、分词伪影 (如断开的标点和缩写)、打乱的句子, 甚至字符串

	LAMBADA (PPL)	LAMBADA (ACC)	CBT-CN (ACC)	CBT-NE (ACC)	WikiText2 (PPL)	PTB (PPL)	enwik8 (BPB)	text8 (BPC)	WikiText103 (PPL)	1BW (PPL)
SOTA	99.8	59.23	85.7	82.3	39.14	46.54	0.99	1.08	18.3	21.8
117M	35.13	45.99	87.65	83.4	29.41	65.85	1.16	1.17	37.50	75.20
345M	15.60	55.48	92.35	87.1	22.76	47.33	1.01	1.06	26.37	55.72
762M	10.87	60.12	93.45	88.0	19.93	40.31	0.97	1.02	22.05	44.575
1542M	8.63	63.24	93.30	89.05	18.34	35.76	0.93	0.98	17.48	42.16

表 3. 多个数据集上的零样本结果。这些结果均未经过任何训练或微调。PTB 和 WikiText-2 的结果来自 (Gong 等人, 2018)。CBT 的结果来自 (Bajgar 等人, 2016)。LAMBADA 的准确率结果来自 (Hoang 等人, 2018)，LAMBADA 的困惑度结果来自 (Grave 等人, 2016)。其他结果来自 (Dai 等人, 2019)。

<UNK>在 WebText 中极为罕见——在 400 亿字节中仅出现 26 次。我们在表 3 中报告了主要结果，使用了可逆的去分词器，这些去分词器尽可能多地消除了这些分词 / 预处理伪影。由于这些去分词器是可逆的，我们仍然可以计算数据集的对数概率，并且它们可以被视为一种简单的领域自适应形式。我们观察到，使用这些去分词器后，GPT-2 的困惑度降低了 2.5 到 5。

WebText 语言模型在不同领域和数据集间的迁移效果良好，在零样本设置下，8 个数据集中有 7 个的性能达到了当前最佳水平。在小型数据集（如 Penn Treebank 和 WikiText-2，这些数据集仅有 100 万到 200 万的训练标记）上，我们观察到了显著的性能提升。在用于衡量长程依赖的数据集（如 LAMBADA (Paperno 等人, 2016) 和儿童书籍测试 (Hill 等人, 2015)）上，也有显著的性能提升。然而，我们的模型在 One Billion Word Benchmark (Chelba 等人, 2013) 上的表现仍明显逊于之前的研究成果。这可能是由于该数据集既是最大的数据集，又经过了一些极具破坏性的预处理——1BW 的句子级打乱操作消除了所有的长程结构。

3.2. 儿童书籍测试




图 2. 儿童书籍测试的表现与模型容量的函数关系。人类表现数据来自 Bajgar 等人 (2016 年)，而非原始论文中低得多的估计值。

儿童书籍测试 (CBT) (Hill 等人, 2015 年) 旨在考察语言模型在不同类别词语上的表现：命名实体、名词、动词和介词。该测试没有将困惑度作为评估指标，而是通过自动构建的完形填空测试来报告准确率，任务是从 10 个可能的选项中预测被省略词语的正确答案。遵循原始论文中介绍的语言模型方法，我们根据语言模型计算每个选项的概率以及以该选项为条件的句子其余部分的概率，并预测概率最高的那个选项。如图 2 所示，随着模型规模的增大，性能稳步提升，并且在该测试中大幅缩小了与人类表现的差距。数据重叠分析显示，CBT 测试集中的一本名为拉迪亚德·吉卜林所著的《丛林之书》出现在 WebText 中，因此我们报告的是验证集上的结果，该验证集没有明显的重叠。GPT-2 在普通名词上达到了 93.3% 的最新最佳结果，在命名实体上达到了 89.1%。我们应用了解码器来去除 CBT 中 PTB 风格的分词痕迹。

3.3. 数字

LAMBADA 数据集 (Paperno 等人, 2016) 用于测试系统对文本中长距离依赖关系的建模能力。该任务要求预测句子的最后一个词，而要成功预测这个词，人类至少需要 50 个标记的上下文。GPT-2 将当前最优结果的困惑度从 99.8 (Grave 等人, 2016) 提升至 8.6，并将语言模型在该测试中的准确率从 19%

(Dehghani 等人, 2018) 提高到 52.66%。对 GPT-2 的错误进行分析后发现，其大多数预测虽然是句子的合理延续，但并非有效的结尾词。这表明该语言模型没有利用“这个词必须是句子的最后一个词”这一额外的有用约束。通过添加停用词过滤器来近似实现这一约束，准确率进一步提升至 63.24%，使该任务的整体当前最优结果提高了 4%。此前的当前最优结果 (Hoang 等人, 2018) 采用了一种不同的限制性预测设置，即模型的输出仅被限制为上下文中出现过的词。而对于 GPT-2 而言，这种限制是有害而非有益的。

由于 19% 的答案与语境不符。我们使用了未经预处理的数据集版本。

3.4. 威诺格拉德模式挑战赛




图 3. 模型容量与 Winograd 模式挑战赛表现的关系。

Winograd 模式挑战 (Levesque 等人, 2012) 的构建旨在通过衡量系统解决文本歧义的能力来评估其常识推理能力。最近, Trinh 和 Le (2018) 展示了使用语言模型在该挑战上取得的显著进展, 他们通过更高的概率来预测歧义的解决方式。我们遵循他们的问题设定, 并在图 3 中用完全评分和部分评分两种技术可视化了我们模型的性能。GPT-2 将最先进的准确率提高了 7%, 达到 70.70%。该数据集规模相当小, 仅包含 273 个示例, 因此我们建议阅读 Trichelair 等人 (2018) 的研究以更好地理解这一结果。

3.5. 阅读理解

对话问答数据集 (CoQA) Reddy 等人 (2018) 包含来自 7 个不同领域的文档, 这些文档与提问者和回答者之间关于该文档的自然语言对话配对。CoQA 测试阅读理解能力, 以及模型回答依赖对话历史的问题 (如 “为什么?”) 的能力。

当以文档、相关对话历史和最终标记 A 为条件时, GPT-2 的贪婪解码在开发集上达到了 55 的 F1 分数。这达到或超过了 4 个基线系统中 3 个的性能, 且没有使用这些基线系统所训练的 127,000 多个手动收集的问答对。有监督的最先进技术是一个基于 BERT 的系统 (Devlin 等人, 2019)。

	R-1	R-2	R-L	R-AVG
Bottom-Up Sum	41.22	18.68	38.34	32.75
Lede-3	40.38	17.66	36.62	31.55
Seq2Seq + Attn	31.33	11.81	28.83	23.99
GPT-2 TL;DR:	29.34	8.27	26.58	21.40
Random-3	28.78	8.63	25.52	20.98
GPT-2 no hint	21.58	4.03	19.47	15.03

表 4. 基于 CNN 和每日邮报数据集, 通过 ROUGE F1 指标衡量的摘要性能。Bottom-Up Sum 是 (Gehrmann 等人, 2018) 提出的最先进模型。

2018), 已接近人类在 89 F1 中的表现。尽管 GPT-2 在没有任何监督训练的情况下取得这样的表现令人欣喜, 但对其答案和错误的一些分析表明, GPT-2 经常使用基于简单检索的启发式方法, 例如在回答 “谁” 的问题时, 会从文档中选取一个名字作为答案。

3.6. 摘要生成

我们在 CNN 和每日邮报数据集 (Nallapati 等人, 2016) 上测试了 GPT-2 的摘要生成能力。为了引导其产生摘要行为, 我们在文章后添加了文本

“TL;DR:”, 并使用 $k=2$ 进行 100 到 k 的随机采样 (Fan 等人, 2018), 这种方法相比贪心解码能减少重复, 并鼓励生成更具抽象性的摘要。我们将这 100 个标记中生成的前 3 个句子作为摘要。虽然从质量上看, 生成的内容类似于摘要 (如表 14 所示), 但它们往往聚焦于文章中的近期内容, 或者会混淆具体细节, 比如一起车祸涉及多少辆车, 或者某个标志是在帽子上还是衬衫上。在常用的 ROUGE 1、2、L 指标上, 生成的摘要性能仅开始接近经典的神经基线模型, 且仅勉强超过从文章中随机选取 3 个句子的表现。当移除任务提示时, GPT-2 在综合指标上的性能下降了 6.4 分, 这表明可以通过自然语言在语言模型中激发特定任务的行为。

3.7. 翻译

我们测试了 GPT-2 是否已经开始学习如何在不同语言之间进行翻译。为了帮助它推断出这是期望完成的任务, 我们给这个语言模型提供了格式为 “英语句子 = 法语句子” 的示例对作为上下文, 然后在给出 “英语句子 =” 的最终提示后, 使用贪心解码从模型中采样, 并将生成的第一个句子作为翻译结果。在 WMT-14 英法测试集上, GPT-2 的 BLEU 值为 5, 这略逊于先前在无监督单词翻译研究中通过双语词典进行的逐词替换。

Question	Generated Answer	Correct	Probability
Who wrote the book the origin of species?	Charles Darwin	✓	83.4%
Who is the founder of the ubuntu project?	Mark Shuttleworth	✓	82.0%
Who is the quarterback for the green bay packers?	Aaron Rodgers	✓	81.1%
Panda is a national animal of which country?	China	✓	76.8%
Who came up with the theory of relativity?	Albert Einstein	✓	76.4%
When was the first star wars film released?	1977	✓	71.4%
What is the most common blood type in sweden?	A	✗	70.6%
Who is regarded as the founder of psychoanalysis?	Sigmund Freud	✓	69.3%
Who took the first steps on the moon in 1969?	Neil Armstrong	✓	66.8%
Who is the largest supermarket chain in the uk?	Tesco	✓	65.3%
What is the meaning of shalom in english?	peace	✓	64.0%
Who was the author of the art of war?	Sun Tzu	✓	59.6%
Largest state in the us by land mass?	California	✗	59.2%
Green algae is an example of which type of reproduction?	parthenogenesis	✗	56.5%
Vikram samvat calender is official in which country?	India	✓	55.6%
Who is mostly responsible for writing the declaration of independence?	Thomas Jefferson	✓	53.3%
What us state forms the western boundary of montana?	Montana	✗	52.3%
Who plays ser davos in game of thrones?	Peter Dinklage	✗	52.1%
Who appoints the chair of the federal reserve system?	Janet Yellen	✗	51.5%
State the process that divides one nucleus into two genetically identical nuclei?	mitosis	✓	50.7%
Who won the most mvp awards in the nba?	Michael Jordan	✗	50.2%
What river is associated with the city of rome?	the Tiber	✓	48.6%
Who is the first president to be impeached?	Andrew Johnson	✓	48.3%
Who is the head of the department of homeland security 2017?	John Kelly	✓	47.0%
What is the name given to the common currency to the european union?	Euro	✓	46.8%
What was the emperor name in star wars?	Palpatine	✓	46.5%
Do you have to have a gun permit to shoot at a range?	No	✓	46.4%
Who proposed evolution in 1859 as the basis of biological development?	Charles Darwin	✓	45.7%
Nuclear power plant that blew up in russia?	Chernobyl	✓	45.7%
Who played john connor in the original terminator?	Arnold Schwarzenegger	✗	45.2%

表 5. GPT-2 在自然问题开发集上生成的 30 个最自信的答案，按 GPT-2 的概率排序。根据第 4 节所述的程序，这些问题均未出现在 WebText 中。

(Conneau 等人, 2017b)。在 WMT-14 法语 - 英语测试集上, GPT-2 能够利用其非常强大的英语语言模型表现出显著更好的性能, 达到 11.5 BLEU。这优于 (Artetxe 等人, 2017) 和 (Lample 等人, 2017) 的几个无监督机器翻译基线, 但仍远低于当前最佳无监督机器翻译方法 (Artetxe 等人, 2019) 的 33.5 BLEU。这项任务的表现让我们感到惊讶, 因为我们在过滤步骤中故意从 WebText 中移除了非英语网页。为了证实这一点, 我们在 WebText 上运行了一个字节级语言检测器 2, 结果只检测到 10MB 的法语数据, 这比先前无监督机器翻译研究中常见的单语法语语料库大约小 500 倍。

3.8. 问答

一种测试语言模型中包含哪些信息的潜在方法是评估其生成事实类问题正确答案的频率。以前在所有信息都存储在参数中的神经系统 (如《神经对话模型》(Vinyals 和 Le, 2015)) 中展示这种行为时, 由于缺乏高质量的评估数据集, 只报告了定性结果。最近推出的自然问题数据集 (Kwiatkowski 等人,

2019) 是一个很有前景的资源, 可用于更定量地测试这一点。与翻译类似, 语言模型的上下文会植入示例问答对, 这有助于模型推断数据集的简短回答风格。在使用 SQUAD 等阅读理解数据集常用的精确匹配指标进行评估时, GPT-2 回答正确的问题占 4.1%。3 作为对比, 最小的模型在准确率上未能超过 1.0%, 这一准确率来自一个极其简单的基线 —— 该基线返回每种问题类型 (谁、什么、在哪里等) 最常见的答案。GPT-2 正确回答的问题数量是其 5.3 倍, 这表明到目前为止, 模型容量一直是神经系统在这类任务中表现不佳的一个主要因素。GPT-2 为其生成的答案所赋予的概率校准良好, 在它最有把握的 1% 的问题上, GPT-2 的准确率为 63.1%。表 5 展示了 GPT-2 在开发集问题上生成的 30 个最有把握的答案。GPT-2 的性能仍然远远落后于将信息检索与抽取式文档问答相结合的开放域问答系统, 后者的准确率在 30% 到 50% 之间 (Alberti 等人, 2019)。

亚历克以前认为自己擅长随机的 trivia 知识, 在与 GPT-2 相同的环境中接受测试时, 他在 100 个随机抽取的例子中答对了 17 个。实际上他只答对了 14 个, 但他本应该答对另外那 3 个的。

	PTB	WikiText-2	enwik8	text8	Wikitext-103	1BW
Dataset train	2.67%	0.66%	7.50%	2.34%	9.09%	13.19%
WebText train	0.88%	1.63%	6.31%	3.94%	2.42%	3.75%

表 6. 测试集 8 元语法与训练集重叠的百分比。

泛化与记忆

计算机视觉领域的近期研究表明，常见的图像数据集包含数量不容忽视的近重复图像。例如，CIFAR-10 的训练图像和测试图像之间有 3.3% 的重叠 (Barz & Denzler, 2019)。这会导致机器学习系统的泛化性能被过度高估。随着数据集规模的增大，这一问题出现的可能性也越来越大，这表明 WebText 可能也存在类似现象。因此，分析测试数据中有多少也出现在训练数据中是很重要的。

为了研究这一点，我们创建了包含 WebText 训练集标记的 8 元语法的布隆过滤器。为了提高召回率，字符串被规范化为仅包含小写字母数字单词，并使用单个空格作为分隔符。构建的布隆过滤器的误报率上限为

1.0%，如图 2 所示。我们进一步验证了较低的假阳性

率。我们通过生成 100 万个字符串进一步验证了较低的假阳性率，而这些字符串中没有一个被过滤器识别出来。

这些布隆过滤器使我们能够根据给定的数据集，计算该数据集中同时出现在 WebText 训练集中的 8 元语法的百分比。表 6 展示了常见语言模型基准测试集的这种重叠分析。常见语言模型数据集的测试集与 WebText 训练集的重叠率在 1%-6% 之间，平均重叠率为 3.2%。有点令人惊讶的是，许多数据集与其自身的训练分割部分有更大的重叠，平均重叠率为 5.9%。

我们的方法以优化召回率为目标，虽然对重叠部分的人工检查发现了许多常见短语，但也存在许多因数据重复导致的较长匹配。这并非 WebText 独有的问题。例如，我们发现 WikiText-103 的测试集中有一篇文章也出现在训练数据集中。由于测试集仅包含 60 篇文章，因此重叠率至少为 1.6%。4 更令人担忧的是，根据我们的流程，1BW 与其自身训练集的重叠率接近 13.2%。

在 Winograd 模式挑战赛中，我们发现只有 10 个模式与 WebText 训练集存在任何 8 元语法重叠。其中，2 个是虚假匹配。在剩下的 8 个中，只有 1 个模式出现在任何语境中，这些语境

额外重叠的很大一部分原因是编辑们在多个具有共同主题的文章中重复使用了一些段落，例如朝鲜战争中的各种战役。

泄露了答案。

在 CoQA 中，新闻领域约 15% 的文档已包含在 WebText 中，模型在这些文档上的 F1 分数大约高出 3 分。CoQA 的开发集指标报告了在 5 个不同领域的平均表现，我们发现由于各领域间的重叠，F1 分数有约 0.5-1.0 分的提升。不过，WebText 中并不包含实际的训练问题或答案，因为 CoQA 是在 WebText 的链接截止日期之后发布的。

在 LAMBADA 数据集上，平均重叠率为 1.2%。GPT-2 在重叠率超过 15% 的示例上，困惑度要低约 2。当排除所有存在任何重叠的示例后重新计算指标，困惑度从 8.6 变为 8.7，准确率从 63.2% 降至 62.9%。整体结果的这一微小变化可能是因为每 200 个示例中只有 1 个存在显著重叠。

总体而言，我们的分析表明，WebText 训练数据与特定评估数据集之间的数据重叠对报告结果有微小但持续的益处。然而，正如表 6 所强调的，对于大多数数据集，我们并未发现其重叠程度明显大于标准训练集和测试集之间已存在的重叠。

理解并量化高度相似的文本如何影响性能是一个重要的研究问题。更好的去重技术（如可扩展的模糊匹配）也有助于更好地回答这些问题。目前，我们建议在创建新的自然语言处理数据集的训练集和测试集拆分时，使用基于 n 元语法重叠的去重方法作为重要的验证步骤和合理性检查。

另一种判断 WebText 语言模型的性能是否归因于记忆的潜在方法是检查它们在自身预留数据集上的表现。如图 4 所示，WebText 的训练集和测试集上的性能相似，并且随着模型规模的增大而共同提升。这表明，即使是 GPT-2 在很多方面仍然对 WebText 存在欠拟合。

GPT-2 也能够撰写关于会说话的独角兽被发现的新闻文章。表 13 中提供了一个例子。

相关工作

这项工作的很大一部分是衡量在更大数据集上训练的大型语言模型的性能。这




图 4. 基于 WebText 训练的语言模型的性能随模型大小的变化。

这与 Jozefowicz 等人 (2016 年) 的研究相似, 他们在 10 亿词基准数据集上对基于循环神经网络 (RNN) 的语言模型进行了扩展。Bajgar 等人 (2016 年) 之前也通过从古腾堡计划中创建一个多得多的训练数据集来补充标准训练数据集, 从而改进了在儿童书籍测试 (Children's Book Test) 上的结果。Hestness 等人 (2017 年) 深入分析了各种深度学习模型的性能如何随着模型容量和数据集大小的变化而变化。我们的实验虽然在不同任务中噪声大得多, 但表明目标的子任务也存在类似趋势, 并且这种趋势延续到了 10 亿以上参数的范围。

生成模型中一些有趣的习得功能此前已有记载, 例如循环神经网络语言模型中的单元会执行行宽跟踪以及引号 / 注释检测 (Karpathy 等人, 2015 年)。对我们的研究更具启发意义的是 Liu 等人 (2018 年) 的发现: 一个经过训练用于生成维基百科文章的模型, 还学会了在不同语言之间翻译名称。

先前的研究已经探索了筛选和构建大型网页文本语料库的替代方法, 例如 iWeb 语料库 (Davies, 2018)。

在语言任务的预训练方法方面, 已有大量研究。除了引言中提到的那些, GloVe (Pennington 等人, 2014) 将词向量表示学习扩展到了整个 Common Crawl 语料库。一项在文本深度表示学习方面具有影响力的早期研究是 Skip-thought 向量 (Kiros 等人, 2015)。McCann 等人 (2017) 探索了源自机器翻译模型的表示的应用, 而 Howard 与 Ruder (2018)

改进了 (Dai 和 Le, 2015) 提出的基于循环神经网络 (RNN) 的微调方法。(Conneau 等人, 2017a) 研究了自然语言推理模型所学习到的表示的迁移性能, 而 (Subramanian 等人, 2018) 则探索了大规模多任务训练

(Ramachandran 等人, 2016) 证明, seq2seq 模型通过使用预训练语言模型作为编码器和解码器进行初始化而获益。最近的研究表明, 在针对诸如闲聊对话和基于对话的问答系统等复杂生成任务进行微调时, 语言模型预训练也很有帮助 (Wolf 等人, 2019)

(Dinan 等人, 2018)。

讨论

许多研究致力于学习 (Hill 等人, 2016)、理解 (Levy 和 Goldberg, 2014) 以及批判性评估 (Wieting 和 Kiela, 2019) 有监督和无监督预训练方法的表征。我们的研究表明, 无监督任务学习是另一个值得探索的有前景的研究领域。这些发现可能有助于解释预训练技术在下游自然语言处理任务中广泛成功的原因, 因为我们证明, 在极限情况下, 其中一种预训练技术开始直接学习执行任务, 而无需有监督的调整或修改。

在阅读理解方面, GPT-2 在零样本设置下的表现与有监督基线相当。然而, 在摘要等其他任务上, 尽管它在质量上能够完成任务, 但根据定量指标, 其表现仍处于初级水平。虽然作为一项研究成果具有一定的启示意义, 但就实际应用而言, GPT-2 的零样本表现仍远未达到可用程度。

我们研究了 WebText 语言模型在许多经典自然语言处理任务上的零样本表现, 但仍有许多其他任务可以进行评估。毫无疑问, 在许多实际任务中, GPT-2 的表现仍然不比随机猜测好。即使是在我们评估过的常见任务上, 如问答和翻译, 语言模型也只有在具备足够能力时, 才能开始超越简单的基准模型。

虽然零样本性能为 GPT-2 在多项任务上的潜在性能确立了基准, 但通过微调能达到何种上限尚不明确。在某些任务中, GPT-2 的完全抽象输出与基于抽取式指针网络 (Vinyals 等人, 2015) 的输出有显著差异, 而后者目前在许多问答和阅读理解数据集上处于最先进水平。鉴于 GPT 微调此前的成功, 我们计划在 decaNLP 和 GLUE 等基准上研究微调, 尤其是因为目前尚不清楚额外的 (内容) ……

GPT-2 的训练数据和容量足以克服 BERT 所展现的单向表征的低效性 (Devlin 等人, 2018)。

结论

当大型语言模型在足够大且多样化的数据集上进行训练时, 它能够在许多领域和数据集上表现出色。GPT-2 在 8 个测试的语言建模数据集中, 有 7 个实现了零样本的最先进性能。该模型在零样本设置下能够完成的任务多样性表明, 经过训练以最大化足够多样化文本语料库可能性的高容量模型, 开始学习如何以令人惊讶的方式执行任务。

无需明确监督就能完成大量任务。5

致谢

感谢所有在 WebText 中撰写文本、分享链接和为内容点赞的人。数百万民众参与了 GPT-2 训练数据的创建。同时也感谢所有为我们提供训练基础设施支持的谷歌员工, 包括扎克·斯通、JS·里尔、乔纳森·休、拉塞尔·鲍尔、程有龙、诺姆·沙泽尔、所罗门·布洛斯、迈克尔·班菲尔德、阿曼·古普塔、丹尼尔·索恩以及其他许多人。最后, 感谢为论文草稿提供反馈的人士: 雅各布·斯坦哈特、山姆·鲍曼、杰弗里·欧文和麦迪逊·梅。

参考文献

Al-Rfou, R., Choe, D., Constant, N., Guo, M. 和 Jones, L. 基于更深层自注意力的字符级语言建模。arXiv 预印本 arXiv:1808.04444. 2018.

阿尔贝蒂 (C.)、李 (K.) 和柯林斯 (M.)。自然问题的 bert 基准。arXiv 预印本 arXiv:1901.08634, 2019.

Alcorn, M. A., Li, Q., Gong, Z., Wang, C., Mai, L., Ku, W.-S., 以及 Nguyen, A. 摆个姿势 (即可): 神经网络很容易被熟悉物体的奇特姿势欺骗。arXiv 预印本 arXiv:1811.11553. 2018.

Amodei, D., Ananthanarayanan, S., Anubhai, R., Bai, J., Battenberg, E., Case, C., Casper, J., Catanzaro, B., Cheng, Q., Chen, G. 等人。《深度语音 2: 英语和普通话的端到端语音识别》。见《国际机器学习会议》, 第 172-182 页。2016 年。

Artetxe, M., Labaka, G., Agirre, E. 和 Cho, K. 无监督神经机器翻译。arXiv 预印本 arXiv:1710.11041, 2017.

Artetxe, M., Labaka, G. 和 Agirre, E. 一种有效的无监督机器翻译方法。arXiv 预印本 arXiv:1902.01313, 2019.

用于下载和使用小型模型的初步代码可在 <https://github.com/openai/gpt-2> 获取。

Ba, J. L., Kiros, J. R., 和 Hinton, G. E. 层归一化。arXiv 预印本 arXiv:1607.06450. 2016.

Bajgar, O., Kadlec, R. 和 Kleindienst, J. 拥抱数据丰富性: 用于阅读理解的书测试数据集。arXiv 预印本 arXiv:1610.00956. 2016.

Barz, B. 和 Denzler, J. 我们在测试数据上训练吗? 清除 CIFAR 中的近重复数据。arXiv 预印本 arXiv:1902.00423, 2019.

Bengio, Y., Ducharme, R., Vincent, P., 和 Jauvin, C. 一种神经概率语言模型。《机器学习研究期刊》, 3 (2 月): 1127-1155. 2003.

鲍曼 (S. R.)、帕夫利克 (E.)、格雷夫 (E.)、范杜梅 (B.)、王 (A.)、胡拉 (J.)、夏 (P.)、帕帕加里 (R.)、麦科伊 (R. T.)、帕特尔 (R.) 等。《寻找埃尔莫的朋友们: 超越语言建模的句子级预训练》。arXiv 预印本 arXiv:1812.10860, 2018.

Caruana, R. 多任务学习。《机器学习》, 28 (1): 41-75, 1997.

Chelba, C., Mikolov, T., Schuster, M., Ge, Q., Brants, T., Koehn, P. 和 Robinson, T. 用于衡量统计语言建模进展的十亿词基准。arXiv 预印本 arXiv:1312.3005. 2013.

Collobert, R., Weston, J., Bottou, L., Karlen, M., Kavukcuoglu, K. 和 Kuksa, P. 几乎从零开始的自然语言处理。《机器学习研究期刊》, 12 (8 月): 2493-2537, 2011.

Conneau, A., Kiela, D., Schwenk, H., Barrault, L. 和 Bordes, A. 基于自然语言推理数据的通用句子表示监督学习。arXiv 预印本 arXiv:1705.02364, 2017a.

Conneau, A., Lample, G., Ranzato, M., Denoyer, L. 和 Jégou, H. 无平行语料的单词翻译。arXiv 预印本 arXiv:1710.04087. 2017b.

戴安·M·戴 (Dai, A. M.) 和奎因·V·乐 (Le, Q. V.)。半监督序列学习。见《神经信息处理系统进展》, 第 3079-3087 页。2015 年。

戴子航、杨子江、杨毅、W. W. 科恩、J. 卡博内尔、Q. V. 乐和 R. 萨拉赫丁诺夫。Transformer-xl: 超越固定长度上下文的注意力语言模型。arXiv 预印本 arXiv:1901.02860, 2019.

戴 140 亿词的 iweb 语料库。
<https://corpus.bvu.edu/iWeb/>. 2018 年。

Dehghani, M., Gouws, S., Vinyals, O., Uszkoreit, J., 以及 Kaiser, L. 通用 Transformer。arXiv 预印本 arXiv:1807.03819. 2018.

德夫林 (J.)、张 (M.-W.)、李 (K.) 和托图诺娃 (K.)。Bert: 用于语言理解的深度双向 Transformer 预训练。arXiv 预印本 arXiv:1810.04805. 2018.

Dinan, E., Roller, S., Shuster, K., Fan, A., Auli, M. 和 Weston, J. 《维基百科巫师: 知识驱动的对话智能体》。arXiv 预印本 arXiv:1811.01241. 2018.

范安 (音译)、刘易斯 (音译) 和多芬 (音译)。《分层神经故事生成》。arXiv 预印本 arXiv:1805.04833, 2018 年。

芬恩 (C.)、阿比尔 (P.) 和莱文 (S.)。《与模型无关的元学习：深度网络的快速适应》。arXiv 预印本 arXiv:1703.03400, 2017 年。

格尔曼 (S.)、邓 (Y.) 和拉什 (A. M.)。自底向上的抽象式摘要。arXiv 预印本 arXiv:1808.10792, 2018。

吉利克 (D.)、布伦克 (C.)、维尼雅尔斯 (O.) 和萨布拉马尼亚 (A.)。基于字节的多语言处理。arXiv 预印本 arXiv:1512.00103, 2015。

龚晨、何丹、谭晓、秦涛、王亮、刘铁岩。Frage: 与频率无关的词表示。《神经信息处理系统进展》，第 1341-1352 页, 2018 年。

Grave, E., Joulin, A. 和 Usunier, N. 利用连续缓存改进神经网络语言模型。arXiv 预印本 arXiv:1612.04426, 2016。

何凯明、张祥雨、任少卿、孙剑。深度残差网络中的恒等映射。见《欧洲计算机视觉会议论文集》，第 630-645 页。施普林格出版社, 2016 年。

Hestness, J., Narang, S., Ardalani, N., Diamos, G., Jun, H., Kianinejad, H., Patwary, M., Ali, M., Yang, Y. 和 Zhou, Y. 深度学习的缩放具有可预测性, 这是经验所得。arXiv 预印本 arXiv:1712.00409, 2017。

希尔 (F.)、博尔德斯 (A.)、乔普拉 (S.) 和韦斯顿 (J.)。《Goldilocks 原则: 利用显性记忆表征阅读儿童书籍》。arXiv 预印本 arXiv:1511.02301, 2015。

希尔 (F.)、赵 (K.) 和科尔霍宁 (A.)。从未标注数据中学习句子的分布式表示。arXiv 预印本 arXiv:1602.03483, 2016。

Hoang, L., Wiseman, S. 和 Rush, A. M. 实体追踪改进完形填空式阅读理解。arXiv 预印本 arXiv:1810.02891, 2018。

Howard, J. 和 Ruder, S. 用于文本分类的通用语言模型微调。见《第 56 届计算语言学协会年会论文集 (第一卷: 长论文)》, 第 1 卷, 第 328-339 页, 2018 年。

杰莱内克 (F.) 和默瑟 (R. L.)。基于稀疏数据的马尔可夫源参数插值估计。见《模式识别实践研讨会论文集》, 荷兰阿姆斯特丹, 北荷兰出版社, 1980 年 5 月。

贾锐和梁培。用于评估阅读理解系统的对抗性示例。arXiv 预印本 arXiv:1707.07328, 2017 年。

Jozefowicz, R., Vinyals, O., Schuster, M., Shazeer, N. 和 Wu, Y. 探索语言建模的极限。arXiv 预印本 arXiv:1602.02410, 2016。

Kaiser, L., Gomez, A. N., Shazeer, N., Vaswani, A., Parmar, N., Jones, L., 以及 Uszkoreit, J. 一个模型学习万物。arXiv 预印本 arXiv:1706.05137, 2017。

卡帕西 (A.)、约翰逊 (J.) 和费菲 (L.)。《循环网络的可视化与理解》。arXiv 预印本 arXiv:1506.02078, 2015 年。

柯克帕特里克 (J.)、帕斯坎努 (R.)、拉比诺维茨 (N.)、维内斯 (J.)、德雅尔丹 (G.)、鲁苏 (A. A.)、米兰 (K.)、全 (J.)、拉马略 (T.)、格拉布斯卡 - 巴温斯卡 (A.) 等。克服神经网络中的灾难性遗忘。《美国国家科学院院刊》, 第 201611835 页, 2017 年。

Kiros, R., Zhu, Y., Salakhutdinov, R. R., Zemel, R., Urtasun, R., Torralba, A. 以及 Fidler, S. 跳读思维向量。见《神经信息处理系统进展》, 第 3294-3302 页, 2015 年。

Krizhevsky, A., Sutskever, I. 和 Hinton, G. E. 基于深度卷积神经网络的 ImageNet 图像分类。见《神经信息处理系统进展》, 第 1097-1105 页, 2012 年。

Kwiatkowski, T., Palomaki, J., Rhinehart, O., Collins, M., Parikh, A., Alberti, C., Epstein, D., Polosukhin, I., Kelcey, M., Devlin, J. 等人。自然问题: 问答研究的基准。2019 年。

莱克、B.M., 厄尔曼、T.D., 特南鲍姆、J.B. 和格什曼、S.J.《构建能像人类一样学习和思考的机器》。《行为与脑科学》, 40 卷, 2017 年。

Lample, G., Conneau, A., Denoyer, L. 和 Ranzato, M. 仅使用单语语料库的无监督机器翻译。arXiv 预印本 arXiv:1711.00043, 2017。

莱韦斯克 (H.)、戴维斯 (E.) 和摩根斯特恩 (L.)。《威诺格拉德模式挑战赛》。发表于《第十三届知识表示与推理原理国际会议》, 2012 年。

Levy, O. 和 Goldberg, Y. 神经词嵌入作为隐式矩阵分解。见《神经信息处理系统进展》, 第 2177-2185 页, 2014 年。

刘, P. J., 萨利赫, M., 波特, E., 古德里奇, B., 塞帕西, R., 凯泽, L. 和沙泽尔, N. 通过总结长序列生成维基百科。arXiv 预印本 arXiv:1801.10108, 2018。

麦凯恩 (B.)、布拉德伯里 (J.)、熊 (C.) 和索歇尔 (R.)。《在翻译中学习: 语境化词向量》。收录于《神经信息处理系统进展》, 第 6204-6205 页, 2017 年。

麦肯 (B.)、凯斯卡 (N. S.)、熊 (C.) 和索切尔 (R.)。《自然语言十项全能: 作为问答的多任务学习》。arXiv 预印本 arXiv:1806.08730, 2018 年。

Merity, S., Xiong, C., Bradbury, J. 和 Socher, R. 指针哨兵混合模型。arXiv 预印本 arXiv:1609.07843, 2016。

Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S. 和 Dean, J. 词和短语的分布式表示及其组合性。见《神经信息处理系统进展》, 第 3111-3119 页, 2013 年。

Nallapati, R., Zhou, B., Gulcehre, C., Xiang, B., 等。基于序列到序列循环神经网络及其他模型的抽象文本摘要。arXiv 预印本 arXiv:1602.06023, 2016。

帕佩尔诺 (D.)、克鲁谢夫斯基 (G.)、拉扎里杜 (A.)、范 (Q., N.)、贝尔纳迪 (R.)、佩泽勒 (S.)、巴罗尼 (M.)、博莱达 (G.) 和费尔南德斯 (R.)。《LAMBADA 数据集: 需要广泛语篇语境的单词预测》。arXiv 预印本 arXiv:1606.06031, 2016 年。

Pennington, J., Socher, R. 和 Manning, C. glove: 用于词表示的全局向量。见《2014 年自然语言处理经验方法会议论文集》(EMNLP), 第 1532-1543 页, 2014 年。

彼得斯 (M. E.) 和勒科克 (D.)。《使用多样化特征集进行内容提取》。收录于《第 22 届国际万维网大会论文集》，第 89-90 页。美国计算机协会 (ACM)，2013 年。

彼得斯 (Peters, M. E.)、诺依曼 (Neumann, M.)、伊耶尔 (Iyyer, M.)、加德纳 (Gardner, M.)、克拉克 (Clark, C.)、李 (Lee, K.) 和泽特勒莫耶 (Zettlemoyer, L.)。深度语境化词表示。arXiv 预印本 arXiv:1802.05365, 2018。

拉德福德 (A.)、约泽福维奇 (R.) 和萨茨克韦弗 (I.)。《学习生成评论并发现情感》。arXiv 预印本 arXiv:1704.01444, 2017 年。

拉德福德 (A.)、纳拉辛汉 (K.)、萨利曼斯 (T.) 和萨茨克韦弗 (I.)。通过生成式预训练提升语言理解能力。2018 年。

拉马钱德兰 (P.)、刘 (P. J.) 和勒 (Q. V.)。用于序列到序列学习的无监督预训练。arXiv 预印本 arXiv:1611.02682, 2016 年。

Recht, B.、Roelofs, R.、Schmidt, L. 和 Shankar, V. CIFAR-10 分类器能泛化到 CIFAR-10 吗? arXiv 预印本 arXiv:1806.00451, 2018。

雷迪 (S.)、陈 (D.) 和曼宁 (C. D.)。Coqa: 一项对话式问答挑战。arXiv 预印本 arXiv:1808.07042, 2018。

施瓦茨 (R.)、萨普 (M.)、康斯塔斯 (I.)、齐勒斯 (L.)、崔 (Y.) 和史密斯 (N. A.)。《故事补全任务: 华盛顿大学自然语言处理系统》。发表于《第二届词汇、句子和语篇层面语义模型链接研讨会论文集》，第 52-55 页, 2017 年。

See, A.、Liu, P. J. 和 Manning, C. D. 言简意赅: 基于指针生成网络的文本摘要。arXiv 预印本 arXiv:1704.04368, 2017。

森里奇 (R.)、哈多 (B.) 和伯奇 (A.)。基于子词单元的稀有词神经机器翻译。arXiv 预印本 arXiv:1508.07909, 2015。

Subramanian, S.、Trischler, A.、Bengio, Y. 和 Pal, C. J. 2018 年, 通过大规模多任务学习学习通用分布式句子表示。arXiv 预印本 arXiv:1804.00079。

Sutskever, I.、Vinyals, O. 以及 Le, Q. V. 基于神经网络的序列到序列学习。见《神经信息处理系统进展》，第 3104-3112 页, 2014 年。

萨茨克韦弗 (I.)、约泽福维奇 (R.)、格雷戈尔 (K.)、雷曾德 (D.)、利利克拉普 (T.) 和维尼尔斯 (O.)。迈向有原则的无监督学习。arXiv 预印本 arXiv:1511.06440, 2015 年。

Trichelair, P.、Emami, A.、Cheung, J. C. K.、Trischler, A.、Suleman, K. 以及 Diaz, F. 关于自然语言理解中常识推理的评估。arXiv 预印本 arXiv:1811.01778, 2018。

Trinh, T. H. 和 Le, Q. V. 一种简单的常识推理方法。arXiv 预印本 arXiv:1806.02847, 2018。

Vaswani, A.、Shazeer, N.、Parmar, N.、Uszkoreit, J.、Jones, L.、Gomez, A. N.、Kaiser, Ł. 以及 Polosukhin, I. 注意力就是一切。见《神经信息处理系统进展》，第 5998-6008 页, 2017 年。

Vinyals, O. 和 Le, Q. 一种神经对话模型。arXiv 预印本 arXiv:1506.05869, 2015。

Vinyals, O.、Fortunato, M. 和 Jaitly, N. 指针网络。见《神经信息处理系统进展》，第 2692-2700 页, 2015 年。

王 (A.)、辛格 (A.)、迈克尔 (J.)、希尔 (F.)、利维 (O.) 和鲍曼 (S. R.)。GLUE: 一个用于自然语言理解的多任务基准和分析平台。arXiv 预印本 arXiv:1804.07461, 2018。

韦斯顿, J. E. 基于对话的语言学习。见《神经信息处理系统进展》，第 829-837 页, 2016 年。

Wieting, J. 和 Kiela, D. 无需训练: 探索用于句子分类的随机编码器。arXiv 预印本 arXiv:1901.10444, 2019。

沃尔夫 (T.)、桑 (V.)、肖蒙德 (J.) 和德朗格 (C.)。Transfertransfo: 一种基于神经网络的对话智能体的迁移学习方法。arXiv 预印本 arXiv:1901.08149, 2019。

Yogatama, D.、d'Áutume, C. d. M.、Connor, J.、Kocisky, T.、Chrzanowski, M.、Kong, L.、Lazaridou, A.、Ling, W.、Yu, L.、Dyer, C. 等人。《学习和评估一般语言智能》。arXiv 预印本 arXiv:1901.11373, 2019。

附录 A：样本

8.1. 模型容量

为了补充图 4 中所示的更大规模语言模型在 WebText 上的困惑度提升，表 7 至表 11 展示了最小的 WebText 语言模型与 GPT-2 在随机选取的未见过的 WebText 测试集文章上的并排补全结果。

8.2. 文本记忆

我们观察到 GPT-2 在较长字符串上存在一些记忆行为，这些字符串在数据集中多次重复出现，例如著名的引语或演讲。例如，当以《葛底斯堡演说》的前一句半为条件（该内容在 WebText 中约出现 40 次）时，GPT-2 的 argmax 解码能还原出这篇演说。即使在不截断的情况下进行采样，我们发现模型会先复制这篇演说一段时间，然后才偏离，但风格仍保持相似。它通常会在 100-200 个标记内发生偏离，一旦偏离，就会表现出越来越大的多样性。

为了量化精确记忆在样本中出现的频率，我们基于 WebText 测试集文章生成了 GPT-2 的样本，并将 GPT-2 生成内容的重叠率与真实补全内容的重叠率进行了比较。这项分析的结果如下，表明 GPT-2 重复训练集中文本的频率低于留存文章的基准率。




图 5. WebText 测试集和样本（以 WebText 测试集为条件，采用 $k=40$ 的 top-k 截断随机采样）与 WebText 训练集的 8 元语法重叠百分比的累积分布函数（CDF）。大多数样本的重叠率低于 1%，其中超过 30% 的样本没有重叠，而测试集的中位数重叠率为 2.6%。

8.3. 多样性

表 12 展示了对同一随机 WebText 测试集上下文的多个补全结果，体现了在标准采样设置下补全内容的多样性。

8.4. 鲁棒性

表 13 展示了前面提到的会说话的独角兽新闻文章。我们发现该模型能够处理分布外的语境，但这些样本的质量通常较低。

语培 (WebText 测试)

搭配 1: 经典款

这套搭配是我买这双鞋时想到的第一套穿搭。它就像是杰克·格兰瑟姆那套穿搭的夏季版本；事实上，我的鞋子颜色和他的耐克竞速者系列很接近！我没有穿厚重的哈里斯粗花呢夹克和牛仔衬衫，而是穿了一件棉质双排扣夹克和一件亚麻衬衫。这两种面料（这种颜色的）在夏天是绝对必备的，因为它们既可以搭配深色裤子，也可以搭配浅色裤子！正如你所见，它们和深色牛仔裤以及这双鞋搭配得非常好。这是一套仿男装风格 / 学院风的穿搭。

总的来说，这是一套非常休闲的服装，所以我搭配了运动鞋。我不喜欢穿全套羊毛西装配运动鞋（就像《GQ》杂志上经常出现的那样），但我确实愿意尝试休闲风格的搭配，比如这套棉质双排扣西装。在打造休闲男装搭配时，用运动鞋来搭配，休闲面料是关键。我甚至建议可以用这类运动鞋搭配卡其色斜纹棉布西装或白色亚麻西装。只是一定要打不打领带，或者搭配 T 恤或马球衫；穿运动鞋再打领带就有点太过了。

Small model completion	GPT-2 completion
. Outfit 2: High End This outfit was just in the eye of the storm. It's a hybrid of what ASICS does with streetwear (like J. Crew) and what J. Crew does with casual pieces that are a bit more traditional. Again, as I mentioned before, it's a low budget item and they can be very expensive. These will definitely be an issue if you're trying to work as a casual sneakermaker, and that's OK but don't hesitate if you want to try the lower price versions of their outfits! This version features a very low cut-cut neckline (which is not a bad thing), slightly longer legs, and a pair of long legs to keep things nice. My preferred color of color these items are blue-gray (which is my first colors, as they are a light white), or black (which is my favorite of my designs). As always, my pick of colors from this store have nothing to do with that other than the design. For a high end, I would recommend this to everyone! Outfit 3: High Light This was a "high light" look while I had a chance to get some color. I think the color is based on	for me! Outfit 2: Casual Jacket I know that some people might be opposed to wearing sneakers in a turtleneck, but I wanted to be true to myself, so I went with a slim fitting turtleneck in a color more similar to my favorite color of the day. Overall, it's a classic turtleneck, with nothing too flashy. I did swap my shoes for these ASICS Tiger Killshots and I wish I hadn't did that. The shoe itself is very comfortable, however, I found that wearing them in these sneakers made my feet look a bit larger. I'd wear them with denim, chinos, whatever, but would never recommend wearing them alone. There are just too many variables involved. Outfit 3: Dress This is the final outfit I wore the ASICS Tiger Killshots. This version of the ASICS is a much more modern and streamlined version. The shoe has the most modern and minimal design that I can think of! With a lot of black, these sneakers look very cool. They'll definitely be very comfortable for summer. To me, wearing them with a suit is the easiest way to have a good pair of sneaker shoes. That's pretty much it! If

表 7. 随机的未见过的上下文（顶部），以及来自最小模型（左侧）和最大模型（右侧）的非精选补全内容。上下文为 768 个 token，显示了大约 256 个 token 的段落。补全内容为 256 个 token，并完整显示。生成过程使用了带有 $k = 40$ 的 top-k 随机采样。

语培 (WebText 测试)

西班牙一些最壮丽的历史景点可追溯至穆斯林统治时期，包括科尔多瓦的大清真寺（即梅斯基塔）、同样位于科尔多瓦的麦地那·阿扎哈拉——这座曾名为“扎赫拉城”的安达卢斯宫殿如今虽已成废墟，但仍可供参观；还有格拉纳达的阿尔罕布拉宫，这是一座保存完好的宏伟宫殿。此外，在西班牙穆斯林时代建造的两座犹太会堂至今仍屹立不倒，分别是托莱多的圣玛丽亚·拉·布兰卡犹太会堂和位于老城区的科尔多瓦犹太会堂。

收复失地运动与帝国时代 [编辑]

小型模型补全

穆斯林西班牙时代与世界其他地区截然不同，有着相当悠久的历史。公元前 9 世纪下半叶，西班牙帝国存在之时，到公元 1150 年，它已相当缓慢地转变为一个小型的世俗化帝国，处于一个更为繁荣和多元的状态。公元 1050 年，那不勒斯皇帝（其特点至少部分在于一系列从该地区西北海岸到西海岸的战争和入侵，例如，多瑙河从直布罗陀一直延伸到西班牙南部，但同一天就被罗马军队摧毁）获得了那不勒斯皇帝的称号。在过去几十年里，他为恢复和维持这个帝国做出了巨大贡献，这是对西方的首次贡献。他的继任者是费迪南德，他于 1148 年从教皇宝座上夺取了权力，而第一位帝国继任者是瑞典国王阿尔弗雷德二世。该帝国再次成为欧洲大陆为数不多的独立国家之一，尽管在此期间其领土上的人口不超过 2 亿，但人们对皇帝有很多话要说。从 1720 年起，穆斯林占西班牙人口的一半。

GPT-2 补全

1092 年和 1095 年的“收复失地运动”（字面意思为“回归祖国”）见证了伊比利亚半岛上卡斯蒂利亚和阿拉贡联合王国的建立，一个穆斯林王朝在此存续。这是欧洲最后一次将穆斯林统治视为“本土的”，也是基督教煽动和组织的冲突在欧洲最后一次显现。

穆斯林摩尔人在西班牙的统治，尤其是在非穆斯林群体中，常被称为“格拉纳达征服”，而西班牙有时也被称为“格拉纳达的西班牙”。穆斯林统治的最后几年之后，是西班牙的收复失地运动。1189 年 3 月，费迪南德九世在普瓦捷战役中获胜，1187 年萨拉丁征服耶路撒冷，此后穆斯林被驱逐或被迫离开伊比利亚半岛。

当摩尔人向北撤退时，西班牙的收复失地运动时期宣告结束。然而，直到收复失地运动在 1229 年至 1492 年期间重新开展，摩尔人的统治才被基督教统治完全取代。

西班牙最后一个穆斯林国家格拉纳达被

表 8. 随机的未见过的语境（上），以及来自最小模型（左）和最大模型（右）的非精心挑选的补全内容。语境为 768 个令牌，显示的段落大约相当于 256 个令牌。补全内容为 256 个令牌，并完整显示。生成时使用了带有 $k=40$ 的 top-k 随机采样。

Context (WebText test)	
Pinky The pink ghost's AI is designed to "feel" opposite of the red ghost's behavior. Pinky actually attempts to get out in front of Pac-Man. This is accomplished by setting the target 4 tiles ahead of Pac-Man's current location in the direction that Pac-Man is travelling. One exception to this is when Pac-Man is traveling up. Due to an overflow bug in the code, the calculation includes a left offset equal to the expected up offset. The use of Pac-Man's expected position allows the player to exploit the navigation code for Pinky. This was most often seen in situations where Pac-Man and Pinky are in close proximity to each other. For example, if they were headed toward one another, once they are less than 4 tiles apart, the target tile is now behind Pinky. If he encounters an intersection while in this configuration, he will attempt to double-back (by turning) in order to reach the target tile. Player's would often perform what was referred to as a "head fake" by changing directions rapidly just as Pinky was approaching an intersection. By displacing the target tile just as Pinky	
Small model completion was coming to the left, they would get the "correct" direction. If the location is actually farther from what Pac-Man was at, the player's will not respond to the ghost's movement, and the ghost will instead return to the player's current location. This is because Pac-Man does not move by turning. The ghost will have to go to another location of some kind to return where he began, and this is achieved in many ways. It will often simply leave the location, as for example if Pac-Man did jump off a cliff, he would return to the spot where he was before vanishing into space. There is a good number of possibilities these ghost paths may be possible, but the most obvious ones are if the player wants to avoid getting caught up in the game, with a goal as easy as keeping Pac-Man in the game for 1/3 as long as he was. Chasing In Pac-Man's case, this would be similar to how Pac-Man can "catch up" in a fight. A ghost could chase through enemies. This is useful for many reasons, both for Pac-Man and his AI. Unlike most Ghost games, this ghost simply travels in the direction from	GPT-2 completion was about to cross the intersection, Pac-Man would be able to dodge the ghosts' projectiles and return to the safe location of the safe house. Buster The yellow ghost's AI is specifically designed to try to avoid Pac-Man from leaving the safe house. The player must press the SPACE bar to reveal the safe house's doors, then go into them to find the yellow ghost hiding in the next room. The player must also note that the ghost will not attempt to exit the safe house if it sees Pac-Man already there. In fact, the ghost will not attempt an exit in the first place unless they're already in the safe house. These two behaviors are based on the fact that the player does not always attempt to reach the safe house before Pac-Man (or Blinky). The player must also beware of this glitch if a ghost (or another player) is already in the safe house and attempting to get out as soon as Pac-Man or Blinky is gone. At this point, the ghost will attempt to exit the safe house in a similar manner as it is in "Chase" mode. Pac-Man There are some ghosts that follow Pac-Man. These ghosts are

表 9. 随机未见过的上下文（顶部），以及来自最小模型（左侧）和最大模型（右侧）的非精心挑选的补全内容。上下文为 768 个令牌，显示了约 256 个令牌的段落。补全内容为 256 个令牌，并完整显示。生成时使用了带有 $k = 40$ 的 top-k 随机采样。

Context (WebText test)	
Corporal Michael P. Goeldin was an unskilled laborer from Ireland when he enlisted in Company A in November 1860. Goldein survived the war. Corporal Patrick O’Neal, also from Ireland, first enlisted in 1854 and served with Company L, 3d U.S. Artillery, in Oregon. He returned to the East Coast and enlisted in the company in 1860. O’Neal served until 1874, when he was named superintendent of the National Cemetery at Willets Point, New York. Corporal Benjamin Browne was a shoemaker from Orange County, New York. In August 1862, he enlisted in the newly formed 124th New York Volunteers, and was one of sixty-one men who transferred into Company A that October. Browne reenlisted in the company in February 1864 while it was camped at Brandy Station. He returned to civilian life after completing his enlistment in 1867. On 10 June, Artificer William Collins was promoted to corporal, probably to fill a combat leadership void for the crossing of the James River. Collins’s service record does not reflect the qualities he demonstrated to earn this promotion, but he had obviously overcome some serious problems. Born in Sacketts Harbor, New York, Collins enlisted in the company in December 1853 at the age of twenty-two, and reenlisted in December 1858. Just a month before the war began in April 1861, Collins went “over the hill” and was not caught until three years later. Returned to the company on 22 March 1864, he was tried	
Small model completion	GPT-2 completion
on military charges and was discharged from the U.S. Military. He returned to the company, and was assigned to Division of Internal Affairs during the Civil War. As an engineer, Collins also had training in engineering from his native New York. After graduate studies in the Union College of Engineering, he was employed in the United States Army for two years at the same time. There he worked under Captain Daniel Pfeiffer and was promoted to colonel in May 1870, three years after Captain Pfeiffer’s enlistment. Collins returned home to England after completing his first year in the First Division to serve the next two years in the Army Corps of Engineers, and by his second year, he began to experience his service duty.; —endoftext— MOSCOW, July 5 (Reuters) - U.K.-based Russian state media and government sources and experts say Moscow has sought to downplay the “military buildup” of the Syrian opposition while maintaining support for President Donald Trump’s plan to build a wall along the U.S.-Mexico border, calling it a “military coup”. U.S.-led Syria war veteran and Syria envoy Michael Flynn (R), right, gestures with U.S.-based Syrian political analyst Ahmet Koryat, with	in June of that year. Sentenced to be shot for desertion, he remained on active duty. Captain James J. Dall was born in Virginia in 1829 during the Revolution and joined his father in the Army in 1836. He served with the 2d Virginia Infantry until 1845, when he went to the Western Reserve Regiment; and, on his discharge, he reenlisted with Company I, 25th New York Volunteers (which in 1845 numbered about 4,500 men). One of his brothers, James, served with his company in the same capacity in the same brigade. While the regiment remained in Connecticut through 1846, Captain Dall served with Company I at various times before his discharge. A veteran of the Mexican War, he had served two years on the staff of Brigadier General John J. Sullivan at San Antonio. During the Peninsula Campaign of 1863, he commanded a company of twenty-three and was in charge of the battery of fifty-four heavy mortars and the gunboat Pinta of the Battery, a gunboat and several other boats. Captain Dall was on active duty with Company I in the fall of 1865. Two years later, he was promoted to second lieutenant. Captain John A. O’

表 10. 随机未见上下文（顶部），以及来自最小模型（左侧）和最大模型（右侧）的非精选补全内容。上下文为 768 个 token，显示了约 256 个 token 的段落。补全内容为 256 个 token，并完整显示。生成过程使用了带有 $k = 40$ 的 top-k 随机采样。

Context (WebText test)	
Xmonad, Xresources, and Fonts Xresources can be an absolute pain (they were for me). So, this a bit of help: First of all, the way that fonts are generally handled in Xmonad is through XFT . Xft is the X FreeType Interface library and is a library that handles the actual rendering of fonts in Xmonad/urxvt (Xresources specifies a bunch of resources to things that launch under the X window manager. Settings for individual programs are specified in Xresources like so: Urxvt.background:background settins here). Anyway, fonts are set using this syntax in Xresources : urxvt*font:xft:your font name goes here:size=the size of the font goes here,xft:fall-back font 1 goes here So, thats the most basic part of fonts in urxvt specified via Xresources. Fixing /.ssh/ Permissions in Cygwin In Cygwin on Windows I found that I could not set the permissions of my /.ssh/ folder to be 0600, as is required for ssh to allow you to use keys. The symptom I had was that I no matter what I did, it always modified the owner and the group	
Small model completion was set to /.ssh/ , which was the way things were. This could not be fixed completely. I found I could make that much more workable with just typing the username with your mouse then trying to set permissions to be "0600" for the group, which is what my system is now configured to do. However, as of Cygwin 7 on Linux I have found that doing so is now "unnecessary" for my system! I also installed a package called chroot. It does that by allowing you to install/upgrade to your system directory. So, as of Windows 8 and up, installing that can require chroot, so I tried and tried and found that it wasn't so bad when installing the package on Linux and then uninstalling it. As of my last write-up on Cygwin, the script just does its job (the sudo commands do the rest), if you try it you will have to log the change. If that wasn't confusing enough, this is what I tried and just went back to my /.ssh/ directory and the chroot script. I found I was finally running out of permissions (because i forgot to create a symlink to ssh from the file system and	GPT-2 completion , making these files read-only. I tried just starting ssh and using a program like passwd which modifies the owner/group to 0644 permissions, but it didn't work. It was annoying but not nearly as bad as it could be, just annoying to have to fiddle with permissions. So I decided to do this as the reverse: For each .ssh folder in your Cygwin directory, set the permission of each file and directory to 2644. Then start ssh with: ssh-add /.ssh/ The first time you connect, your permissions of the /.ssh folder that you just had in Cygwin will be set to 0600. Then every time you connect again, your permissions will change to 0644. Makefile for Xresources as used in /.xsessionrc These are made in my .xsessionrc : .xprofile: .xsession-errors: color="" For example: .xprofile: color=blue As the colors are stored in a separate file, the color in your /.xsession-errors will look like cyan instead of blue. This is mostly because, as of now, only the color is assigned to your

表 11. 随机的未见过的上下文（顶部），以及来自最小模型（左侧）和最大模型（右侧）的非精心挑选的补全内容。上下文为 768 个令牌，显示的段落约为 256 个令牌。补全内容为 256 个令牌，并完整显示。生成时使用了带有 $k = 40$ 的 top-k 随机采样。

Context (WebText test)		
Aaron loves mint chocolate cake, but he requires that it be paired with mini chocolate chips, so I threw some of those in between the layers. I also had a few Peppermint Jo Jos on hand so I crushed them up and threw some of those in along with some crushed meringue cookies because, why not? It's a total smorgasbord of minty chocolate chippy cookie crunchy goodness. I didn't measure how much of each topping I used, but after I tasted the finished product, I wish I had added more. You can add anything you want- crushed candy canes, peppermint bark, etc. And don't be afraid to use a heavy hand. Texture = good. If you don't have 7-inch cake pans, you can get 3 shorter 8-inch layers out of this		
GPT-2 Completion 1 recipe. I made the longer version, then used the pan for a layer of buttercream frosting and stuck 1/3 of it into the fridge for a frosting topper. Just make sure you have all of this frosting prepared earlier than you make this cake and you won't have to wait on it as your egg whites sit on the bottom of your mixing bowl. You want the egg whites whipped to stiff peaks? Then put your cake dish over a pot of simmering water and heat it up until it's just barely warm. It doesn't take more than 3-5 minutes; just enough to get it started	GPT-2 Completion 2 recipe. If you do, and you know how to make that cake, then your life will never be the same. I have two very simple rules when it comes to cookie crumbs or chocolate chips. 1) When I buy raw sugar, I do not use it until it's cooled down and has at least half a teaspoon of sugar on it. That's my rule. And 2) If I have a recipe that calls for something and I want to use it in a recipe, I do not substitute it with something else on-line. Like this. I found this really cute card with cute little kittens on	GPT-2 Completion 3 recipe, which will likely yield about the same amount of cake. Chocolate Buttermilk Cake Print Chunks of chocolate cake, coated in buttermilk and topped with crunchy chopped chocolate, drizzled with chocolate sauce. Simple but a nice change from chocolate cake! Author: Momma Made Ingredients For the chocolate buttermilk cake 1 1/2 cup unsalted butter , room temperature 1 1/2 cup granulated sugar 3 large eggs plus 1 egg yolk For the chocolate glaze 1/3 cup cocoa powder 1 3/4 cups powdered sugar 6 ounces semis
GPT-2 Completion 4 recipe. Meringue Cookies 1 3/4 cup butter, softened 1 cup sugar 1 egg yolk 3 T. heavy cream 3 1/2-4 cups flour pinch of salt Peppermint-Jojo Topping 1 1/4 cups powdered sugar 1 cup chopped pecans 1/2 cup finely chopped mint leaves 1/2 cup chopped fresh mint (about 1/2 sheet) 1 tsp. peppermint extract 1/4 tsp. sea salt pinch of sea	GPT-2 Completion 5 recipe. My 2 failures at Christmas morning were not due to poor frosting skills. That was another success story. The cake was beautifully moist, and well, just a beautiful cake. It's got very little air in it or moisture, but all the chocolate and mint was perfectly blended together. One thing that made me cringe a bit was that all those ingredients-egg yolks, sugar, melted butter, chocolate chips, melted chocolate, and mint- had to be mixed right into the cake batter, which is super time-consuming. A friend suggested that if I put the batter in a separate bowl, I	GPT-2 Completion 6 recipe, which will give you about 6-9 servings of delicious chocolate cake. To prevent your layers from sticking together, I used my 8-inch round tart pan, lined it with parchment paper, then cut up 4 7-inch round cakes from it and sandwiched the layers between them (this also worked well for the 1-layer chocolate cake as well). When you're ready to bake this cake, remove the parchment paper, preheat oven to 350 degrees and bake for about 30 – 40 minutes, until the top is golden and a tester comes out clean. Chocolate Buttermilk Layer Cake with Peppermint Jo

表 12. 从相同语境（来自 WebText 测试）生成的 GPT-2 非精选补全内容。语境为 384 个标记（显示为截断形式），生成内容为 128 个标记。生成过程使用了带有 $k = 40$ 的 top-k 随机采样。

背景（人工撰写）：一项令人震惊的发现中，科学家在安第斯山脉一个偏远且此前未被探索的山谷里发现了一群独角兽。更让研究人员惊讶的是，这些独角兽能说一口流利的英语。

GPT-2：这位科学家根据它们独特的角，将这个种群命名为“奥维德独角兽”。这种长有四只角的银白色独角兽此前不为科学界所知。

如今，将近两个世纪之后，引发这一奇特现象的谜团终于被解开了。

拉巴斯大学的进化生物学家豪尔赫·佩雷斯博士和几位同伴在安第斯山脉探险时，发现了一个小山谷，那里没有其他动物或人类。佩雷斯注意到，这个山谷里似乎有一个天然喷泉，周围是两座岩石山峰和银色的积雪。

佩雷斯和其他人随后进一步深入山谷。“当我们到达一座山峰的顶端时，水看起来是蓝色的。上面还有一些水晶。”佩雷斯说。

佩雷斯和他的朋友们看到独角兽群时感到十分惊讶。从空中就能看到这些生物，无需移动太多就能看清它们——它们近在咫尺，近到能摸到它们的角。

在研究这些奇特的生物时，科学家们发现它们也能说一些相当标准的英语。佩雷斯表示：“例如，我们可以发现它们有一种共同的‘语言’，有点像某种方言或辩证用语。”

佩雷斯博士认为，独角兽可能起源于阿根廷。人们认为，这些动物是在人类抵达南美洲的这些地区之前就生活在那里的那个失落种族的后裔。

虽然它们的起源仍不明确，但一些人认为，或许这些生物是在人类文明出现之前的某个时期，由人类与独角兽相遇而产生的。佩雷斯表示：“在南美洲，这类事件似乎相当常见。”

然而，佩雷斯还指出，要确切知道独角兽是否真的是一个消失的外星种族的后代，唯一的方法可能就是通过 DNA。这位科学家表示：“但它们似乎能很好地用英语交流，我认为这是进化的标志，或者至少是社会组织发生变化的标志。”

表 13. GPT-2 在分布外语境下的条件生成。使用 $k = 40$ 生成的 10 个样本精选

Article: Prehistoric man sketched an incredible array of prehistoric beasts on the rough limestone walls of a cave in modern day France 36,000 years ago. Now, with the help of cutting-edge technology, those works of art in the Chauvet-Pont-d’Arc Cave have been reproduced to create the biggest replica cave in the world. The manmade cavern named the Caverne du Pont-d’Arc has been built a few miles from the original site in Vallon-Pont-D’arc in Southern France and contains 1,000 painstakingly-reproduced drawings as well as around 450 bones and other features... Cavemen and women sketched an incredible array of prehistoric beasts on the rough limestone walls of a cave 36,000 years ago and now a replica has been created (pictured) ...	
GPT-2: The original site in Vallon-Pont-D’arc in Southern France is a Unesco World Heritage site and is the oldest known and the best preserved cave decorated by man. The replica cave was built a few miles from the original site in Vallon-Pont-D’Arc in Southern France. The cave contains images of 14 different species of animals including woolly rhinoceros, mammoths, and big cats.	Reference: Cave mimics famous Caverne du Pont-d’Arc in France, the oldest cave decorated by man and the best preserved. The replica contains all 1,000 paintings which include 425 such as a woolly rhinoceros and mammoths. Minute details were copied using 3D modelling and anamorphic techniques, often used to shoot widescreen images. The modern cave also includes replica paw prints of bears, bones and details preserved in the original cave.
Article: ‘If you can find my submarine, it’s yours,’ Russian oil billionaire Roman Abramovich once said. And it seems the oligarch and Chelsea FC owner, whose submarine is just one of the extras that came with his £300million superyacht Eclipse (perfect for getting to shore undetected), is not the only wealthy businessman splashing out on underwater exploration. Dubbed Earth’s real ‘final frontier’, the oceans are still so little-explored that billionaires are queuing up to buy vessels that give them a glimpse of the dramatic seascapes and incredible wildlife of the world’s oceans. So if you have a spare few million in the bank and want some holiday snaps and Instagram posts that will really trump everyone else, you may want to snap up one of these... Whale of a time: The OrcaSub takes you 2000 feet beneath the surface in two pressurised Perspex viewing domes for optimum exploration ...	
GPT-2: The U-Boat Worx submarine can dive to 984 feet (300 metres) and is capable of diving to the bottom of the ocean. It can be used for diving, snorkelling and even snorkel diving. The submarine is also equipped with a snorkelling platform.	Reference: Feel like a James Bond villain with the most advanced submerged ocean vehicles. Some convert from a yacht into a submarine, and others detached off for a speedy exploration. Oliver’s Travels offers a Mile Low package on its submarine, complete with chef and butler for £175,000 a night.
Article: Amina Ali Qassim is sitting with her youngest grandchild on her lap, wiping away tears with her headscarf. Only a few months old, this is the baby girl whose ears she desperately tried to cover the night the aerial bombardment started. She lay awake, she says, in a village mosque on the Yemeni island of Birim, counting explosions as the baby cried. It could have been worse though. They could have still been in their house when the first missile landed. “Our neighbor shouted to my husband ‘you have to leave, they’re coming.’ And we just ran. As soon as we left the house, the first missile fell right by it and then a second on it. It burned everything to the ground,” Qassim tells us ...	
GPT-2: Yemen is in the middle of a civil war. Saudi Arabia is leading the coalition bombing campaign. It’s been bombing Yemen for more than two months now.	Reference: Amina Ali Qassim’s family sought shelter in a mosque before fleeing Yemen. Thousands like them are boarding boats to sail to Djibouti. Saudi Arabia has been pounding Yemen in a bid to defeat Houthi rebels.

表 14. GPT-2 生成的摘要与 CNN 和每日邮报数据集测试集上的参考摘要。

English reference This re-release, titled The Next Day Extra, was presented in the form of three disks: the original album, unpublished studio sessions and remixes, plus a DVD containing the four clips that have already been unveiled.	GPT-2 French translation Les nouvelles re-releases, tout en premier disc, nécessaire de l'album, un studio session et remixes, plus une DVD de l'écran de quelques clips qui ont été déjà échappés.
French reference Un homme expliquait que le fonctionnement de la hernia fonctionnelle qu'il avait reconnu avant de faire, le fonctionnement de la hernia fonctionnelle que j'ai réussi, j'ai réussi.	GPT-2 English translation This release, originally released on three discs: the original album, sessions studio inédites and remixes, a DVD containing the four clips that were released on the previous day.
English reference One man explained that the free hernia surgery he'd received will allow him to work again.	GPT-2 French translation Un homme expliquait que le fonctionnement de la hernia fonctionnelle qu'il avait reconnu avant de faire, le fonctionnement de la hernia fonctionnelle que j'ai réussi, j'ai réussi.
French reference Un homme a expliqué que l'opération gratuite qu'il avait subie pour soigner une hernie lui permettrait de travailler à nouveau.	GPT-2 English translation A man told me that the operation gratuity he had been promised would not allow him to travel.
English reference Speaking to an open government conference in London via video link, Mr Kerry said: "There is no question that the President and I and others in government have actually learned of some things that had been happening on an automatic pilot because the ability has been there, going back to World War Two and to the very difficult years of the Cold War, and then, of course, 9/11."	GPT-2 French translation Le premier conference de l'édition internationale en ligne sur la vide, le ministre de l'Édition internationale a été vide, lui dit : "Il n'y a qu'une question que le président et moi et tous les autres personnes d'une administration qui a été évident par la fois, par la part de la guerre, par la part de la guer
French reference S'exprimant lors d'une conférence intergouvernementale à Londres par liaison vidéo, M. Kerry a déclaré: "Il est indéniable que le Président, moi-même et d'autres membres du gouvernement avons pris connaissance de certaines choses en mode pilote automatique parce que nous en avons la possibilité, dès la Seconde guerre mondiale et jusqu'aux années difficiles de la Guerre froide, puis bien sûr le 11 septembre."	GPT-2 English translation In a conférence between the United States and London, Secretary of State John Kerry said: "It is undeniable that the President, myself and others of the government have been aware of certain certain choices that have been made in the past in order to be able to do certain things in a more automated way."

表 15. 由 GPT-2 生成的英语到法语及法语到英语的翻译。

语境（段落及先前的问答对）
所在语境：

2008 年夏季奥运会火炬接力于 2008 年 3 月 24 日至 8 月 8 日举行，时间在 2008 年夏季奥运会之前，主题为“同一个世界，同一个梦想”。2007 年 4 月 26 日，火炬接力计划在中国北京公布。这项被组织者称为“和谐之旅”的接力活动历时 129 天，火炬传递距离达 13.7 万公里（8.5 万英里），是自 1936 年夏季奥运会前开始这一传统以来，奥运火炬接力距离最长的一次。

3 月 24 日，奥运火炬在希腊奥林匹亚的奥运会发源地点燃后，传递至雅典的泛雅典体育场，随后前往北京，并于 3 月 31 日抵达。从北京开始，火炬沿着一条途经六大洲的路线传递。火炬经过了丝绸之路沿线的城市，象征着中国与世界其他地区之间古老的联系。火炬传递还包括从中国一侧将圣火带上位于尼泊尔和中国西藏边境的珠穆朗玛峰峰顶，该区域为此次活动专门封闭。

问：主题是什么

A：“同一个世界，同一个梦想”。

问：这场接力的长度是多少？

答：137,000 公里

问：它比之前的更大吗？

A：不

问：这场接力从哪里开始的？

A：希腊。奥林匹亚

问：那个地方有什么值得注意的吗？

奥运会的发源地

问：之后他们去了哪里？

雅典

问：这场传递持续了多少天？

129

问：他们参观了任何著名的地标吗？

帕纳辛奈科体育场

问：他们爬过什么山吗？

A：

喜马拉雅，珠穆朗玛峰

Turker 的回答，未知、是、是、是

表 16. 精选的 CoQA 补全。

语境（段落及先前的问答对）

汤姆走到哪儿都跟着 54 岁的秘书凯瑟琳·格林。他在她工作的办公室里四处走动，还和她一起去购物。“大多数人似乎并不介意汤姆，”觉得他很棒的凯瑟琳说。“他是我的第四个孩子，”她说道。她或许真的把他当成儿子，并且像对待儿子那样对待他。他四处走动，自己买食物、支付医药费和税款，但实际上汤姆是一条狗。

凯瑟琳和汤姆住在瑞典，在这个国家，每个人都应该按照政府制定的规则过着有秩序的生活，政府也为其人民提供高水平的福利。这种福利水平是需要花钱的。

瑞典人所有东西都要缴税，所以他们对于养狗也要多缴税这件事并不感到惊讶。有些人每年为养狗权缴纳的税款高达 500 瑞典克朗，这些税款由政府用于狗狗医院，有时也用于生病狗狗的医疗。然而，大多数这类治疗费用昂贵，因此主人常常决定为他们的狗购买健康保险，甚至人寿保险。

在瑞典，狗主人必须为他们的狗造成的任何损害买单。瑞典养犬俱乐部的一位官员解释了这意味着什么：如果你的狗跑到马路上被一辆路过的汽车撞到，作为主人，你必须赔偿汽车所受的任何损失，即使你的狗在事故中已经死亡。

问：凯瑟琳多大了？

54

问：她住在哪里？

瑞典

标准答案：斯德哥尔摩

十瓦其机器人回答：瑞典、瑞典、在瑞典、瑞典

表 17. 精选的 CoQA 补全。