

# 更多关注注意力： 通过注意力迁移提升卷积神经网络的性能

Sergiy Zagoruyko, Nikos Komodakis

巴黎东部大学巴黎桥理工学院, 法国巴黎

{sergey.zagoruyko, nikos.komodakis}@enpc.fr

## 摘要

注意力在人类的视觉体验中起着关键作用。此外，最近有研究表明，在将人工神经网络应用于计算机视觉和自然语言处理等领域的各种任务时，注意力也能发挥重要作用。在这项研究中，我们表明，通过为卷积神经网络恰当定义注意力，我们实际上可以利用这类信息，通过迫使学生卷积神经网络模仿强大的教师网络的注意力图，来显著提升其性能。为此，我们提出了几种新颖的注意力迁移方法，这些方法在各种数据集和卷积神经网络架构上都展现出了持续的性能提升。我们实验所用的代码和模型可在<https://github.com/szagoruyko/attention-transfer>获取。

## 1 引言

作为人类，我们需要集中注意力才能充分感知周围环境。因此，注意力是我们视觉体验的关键方面，并且与感知密切相关——我们需要保持注意力来构建具有细节和连贯性的视觉表征。

近年来，随着人工神经网络在计算机视觉和自然语言处理等领域日益普及，人工注意力机制也开始得到发展。人工注意力能让系统“关注”某个对象，从而更细致地对其进行研究。与心理学中所使用的注意力类似，它也成为理解神经网络背后机制的一种研究工具。

其中一个广为流传的假设是，存在非注意性和注意性的感知过程。非注意性过程有助于从整体上观察一个场景并收集高层次信息，这些信息与其他思维过程相结合时，能帮助我们控制注意过程，并将注意力引导到场景的特定部分。这意味着，拥有不同知识、不同目标，因而采用不同注意策略的观察者，实际上可能对同一个场景产生不同的感知。这就引出了本文的主题：人工视觉系统内部的注意力存在怎样的差异？我们能否利用注意力信息来提升卷积神经网络的性能？更具体地说，一个教师网络能否通过向另一个学生网络提供其关注点信息（即其注意力集中的位置）来提升后者的性能？

为了研究这些问题，首先需要恰当地明确如何针对给定的卷积神经网络来定义注意力。为此，我们在此将注意力视为一组空间映射，这些映射本质上试图编码网络在做出输出决策（例如对图像进行分类）时最关注的输入空间区域。此外，这些映射可以针对网络的各个层来定义，以便它们能够捕获低级、中级和高级的表征信息。更具体地说，在这项工作中，我们定义了两种类型的空间注意力映射：基于激活的和基于梯度的。我们探究了这两种注意力映射在不同数据集和架构上的变化，并表明它们实际上包含有价值的信息。




图 1: (a) 一张输入图像以及一个对应的卷积网络空间注意力图，该图展示了网络为了对给定图像进行分类而关注的区域。显然，这类图一定包含关于该网络的价值信息。我们在本文中提出的问题如下：我们能否利用这类知识来改进 CNN 模型的训练？(b) 注意力迁移的示意图：学生 CNN 在训练时，不仅要做出良好的预测，还要使其空间注意力图与已训练好的教师 CNN 的空间注意力图相似。

这可显著提升各类卷积神经网络架构（不同类型且针对不同任务训练的架构）的性能。为此，我们提出了几种新颖的方法，将注意力从强大的教师网络转移到较小的学生网络，以提升后者的性能（图 1）。

综上所述，本研究的贡献如下：

- 我们提出将注意力作为一种从一个网络向另一个网络传递知识的机制
- 我们提出同时使用基于激活和基于梯度的空间注意力图
- 我们通过实验表明，我们的方法在多种数据集和深度网络架构（包括残差网络和非残差网络）上都有显著改进
- 我们发现，基于激活的注意力迁移比全激活迁移能带来更好的改进，并且可以与知识蒸馏相结合

本文其余部分的结构如下：我们首先在第 2 节描述相关工作，在第 3 节解释我们基于激活和基于梯度的注意力迁移方法，然后在第 4 节展示这两种方法的实验结果。我们在第 5 节对本文进行总结。

## 2 相关工作

基于注意力的跟踪早期研究（Larochelle 和 Hinton, 2010; Denil 等人, 2012）受到了人类注意力机制理论（Rensink, 2000）的启发，并通过受限玻尔兹曼机开展相关工作。近年来，该研究被应用于基于循环神经网络的神经机器翻译中，例如 Bahdanau 等人（2014）的研究，同时也被用于其他多项自然语言处理相关任务。此外，它还被应用于计算机视觉相关任务，如图像 captioning（Xu 等人, 2015）、视觉问答（Yang 等人, 2015），以及弱监督目标定位（Oquab 等人, 2015）和分类（Mnih 等人, 2014）等，这里仅列举几个典型例子。在所有这些任务中，注意力机制都被证明是有用的。

在深度卷积神经网络中可视化注意力图是一个开放性问题。最简单的基于梯度的方法是计算网络输出相对于输入的雅可比矩阵（这会导致注意力可视化不一定具有类别区分性），例如 Simonyan 等人（2014 年）的研究。Zeiler 和 Fergus（2014 年）提出了另一种方法，该方法包括附加一个名为“反卷积网络”的网络，该网络与原始网络共享权重，并用于将特定特征投影到图像平面上。也有许多方法被提出来改进基于梯度的注意力，例如引导反向传播（Springenberg 等人, 2015 年），即在计算相对于前一层输出的梯度时，在 ReLU 层中加入变化。通过引导反向传播获得的注意力图也不具有类别区分性。在现有方法中

在可视化注意力方面，我们还应提及 Zhou 等人（2016 年）提出的类激活图，其原理是移除顶部的平均池化层，并将线性分类层转换为卷积层，从而为每个类别生成注意力图。Selvaraju 等人（2016 年）提出的 Grad-CAM 方法结合了引导反向传播和类激活图，为具有类别区分性的注意力图增添了图像级细节。

神经网络的知识蒸馏由 Hinton 等人（2015 年）、Bucila 等人（2006 年）开创，这是一种迁移学习方法，旨在通过借鉴强大的教师网络的知识来改进学生网络的训练。尽管在某些特殊情况下，有研究表明浅层网络能够在不损失精度的前提下逼近深层网络（Lei 和 Caruana, 2014 年），但后来与知识蒸馏相关的研究大多基于深层网络总能学习到更好表示的假设。例如，FitNets（Romero 等人，2014 年）尝试利用参数更多的浅层网络来学习一个瘦长的深层网络。高速公路网络（Srivastava 等人，2015 年）以及后来的残差网络（He 等人，2015 年）的引入，使得训练精度更高的极深架构成为可能，并且这些网络的通用性在大量不同数据集上得到了实验验证。尽管残差网络的主要设计动机是增加深度，但 Zagoruyko 和 Komodakis（2016 年）后来的研究表明，超过一定深度后，性能的提升主要来自网络容量的增加，即参数数量的增多（例如，研究显示，一个仅有 16 层的更宽的深度残差网络，只要其参数数量与极瘦长的 1000 层网络相当，就能学习到同等甚至更好的表示）。

基于上述事实，并且由于较浅的深度网络比更宽的网络并行性更差，我们认为需要重新审视知识迁移，并采取与 FitNets 相反的方法——我们尝试学习深度更浅的学生网络。我们用于迁移的注意力图与上述基于梯度和基于激活的图都相似，它们起到类似于 FitNets 中“提示”的作用，尽管我们没有引入新的权重。

### 3 注意力迁移

在本节中，我们将阐述用于定义卷积神经网络空间注意力图的方法，以及在每种情况下如何将注意力信息从教师网络传递给学生网络。

#### 3.1 基于激活的注意力迁移

让我们考虑一个 CNN 层及其对应的激活张量  $A \in R^{C \times H \times W}$ ，它由  $C$  个特征平面组成，空间维度为  $H \times W$ 。基于激活的映射函数  $F$ （针对该层）将上述 3D 张量  $A$  作为输入，并输出一个空间注意力图，即一个在空间维度上定义的扁平化 2D 张量，或者

$$F: R^{C \times H \times W} \rightarrow R^{H \times W}.$$

。

为了定义这样一种空间注意力映射函数，本节中我们做出的隐含假设是，隐藏神经元激活的绝对值（当网络对给定输入进行评估时产生）可以用作该神经元相对于特定输入重要性的指标。因此，通过考虑张量  $A$  元素的绝对值，我们可以通过计算这些值在通道维度上的统计量来构建空间注意力图（见图 3）。更具体地说，在本研究中，我们将考虑以下基于激活的空间注意力图：

$$\text{绝对值之和: } F_{sum}(A) = \sum_{c=1}^C |A_c|$$

$$\cdot \text{绝对值的总和的 } p \text{ 次幂 (其中 } n > 1) : F_{psum}(A) = \sum_{c=1}^C |A_c|^p$$

$$\cdot \text{绝对值的最大值的 } p \text{ 次幂 (其中 } n > 1) : F_{pmax}(A) = \max_{c=1}^C |A_c|^p$$

其中  $A_c = A(:, :, c)$ （使用 Matlab 符号），并且  $\max$ 、幂和绝对值运算都是按元素进行的（例如， $|A_c|^p$  等价于 Matlab 符号中的  $\text{abs}(A_c) . \wedge p$ ）。




图 2: 在为面部识别训练的网络的不同层级上, 绝对值注意力图  $F_{sum}$  的总和。中层注意力图在眼睛、鼻子和嘴唇周围具有更高的激活水平, 高层激活则对应整张脸。

我们对多个数据集上不同网络的激活情况进行了可视化, 包括 ImageNet 分类与定位、COCO 目标检测、人脸识别以及细粒度识别。我们主要关注没有顶部密集线性层的现代架构, 例如 Network-In-Network、ResNet 和 Inception, 这些架构具有精简的卷积结构。我们还研究了相同架构、宽度和深度但用不同框架训练的网络, 这些网络在性能上存在显著差异。我们发现, 上述隐藏层激活的统计数据不仅与图像层面上预测对象存在空间相关性, 而且在精度更高的网络中, 这些相关性往往更强; 此外, 性能更强的网络会在性能较弱的网络没有关注的地方出现注意力峰值 (例如, 见图 4)。而且, 网络中不同层的注意力图会聚焦于不同的部分。在第一层, 神经元在低级梯度点处的激活水平较高; 在中间层, 其在眼睛或车轮等最具判别性的区域激活水平更高; 而在顶层, 其激活情况则反映了完整的对象。例如, Parkhi 等人 (2015) 用于人脸识别训练的网络, 其中间层注意力图在眼睛、鼻子和嘴唇周围的激活度更高, 而顶层激活则对应完整的人脸 (图 2)。

关于上面定义的不同注意力映射函数, 它们可能具有略微不同的特性。例如:

- 与  $F_{sum}(A)$  相比, 空间图  $F_{sum}^p(A)$  (其中  $n > 1$  对与具有最高激活度的神经元相对应的空间位置赋予了更大的权重, 即对最具判别性的部分赋予了更大的权重 ( $p$  值越大, 对那些具有最高激活度的部分的关注度就越高))。
- 此外, 在所有对应相同空间位置的神经元激活中,  $F_{max}^p(A)$  只会考虑其中一个来为该空间位置分配权重 (这与  $F_{sum}^p(A)$  不同, 后者会倾向于那些带有多个高激活神经元的空间位置)。

为了进一步说明这些函数的差异, 我们可视化了三个在分类性能上存在显著差异的网络的注意力图: Network-In-Network (top-1 验证准确率为 62%)、ResNet34 (top-1 验证准确率为 73%) 和 ResNet-101 (top-1 验证准确率为 77.3%)。在每个网络中, 我们选取了最后的下采样前激活图, 图 4 左侧为中层激活图, 右侧为顶部平均池化前的激活图。顶层图较为模糊, 因为它们的原始空间分辨率为  $7 \times 7$ 。显然, 大多数判别性区域具有更高的激活水平, 例如狼的面部, 并且随着参数  $p$  (用作指数) 的增大, 形状细节会逐渐消失。

在注意力迁移中, 给定教师网络的空间注意力图 (使用上述任何一种注意力映射函数计算得出), 目标是训练一个学生网络, 使其不仅能做出正确的预测, 还能拥有与教师网络相似的注意力图。通常, 可以在多个层计算的注意力图上设置迁移损失。例如, 在 ResNet 架构中, 根据教师网络和学生网络的深度, 可以考虑以下两种情况:

- 相同深度: 可能在每个残差块后设置注意力转移层




图 3: 特征维度上的注意力映射。




图 4: 各种 ImageNet 网络的激活注意力图: Network-In-Network (62% 的 top-1 验证准确率)、ResNet-34 (73% 的 top-1 验证准确率)、ResNet-101 (77.3% 的 top-1 验证准确率)。左半部分: 中层激活, 右半部分: 顶层 softmax 前激活




图 5: 当两个网络均为残差网络且教师网络更深时, 师生注意力迁移的示意图。

- 不同深度: 对每组残差块的输出激活进行注意力转移

类似的情况也适用于其他架构 (例如 NIN, 在这种情况下, 一个组指的是由  $3 \times 3$ 、 $1 \times 1$ 、 $1 \times 1$  卷积组成的块)。在图 5 中, 我们提供了残差网络架构不同深度情况的示意图。

不失一般性, 我们假设迁移损失被置于相同空间分辨率的学生和教师注意力图之间, 但如果需要, 可以对注意力图进行插值以匹配它们的形状。令  $S$ 、 $T$  和  $w_S$ 、 $w_T$  分别表示学生、教师及其权重, 令  $L(W, x)$  表示标准交叉熵损失。另令  $I$  表示我们希望迁移注意力图的所有师生激活层对的索引。那么我们可以定义如下总损失:

$$\mathcal{L}_{AT} = \mathcal{L}(W_S, x) + \frac{\beta}{2} \sum_{j \in I} \frac{\|Q_S^j - Q_T^j\|_p}{\|Q_S^j\|_p + \|Q_T^j\|_p},$$

其中  $Q_S^j = \text{vec}(F(A_S^j))$  和  $Q_T^j = \text{vec}(F(A_T^j))$  分别是矢量化形式的第  $j$  对学生和教师注意力图,  $p$  指的是范数类型 (在实验中我们使用  $p = 2$ )。可以看出, 在注意力迁移过程中, 我们使用了  $l_2$  归一化的注意力图, 即将每个矢量化的注意力图  $Q$  替换为  $\frac{Q}{\|Q\|_p}$  (也可以使用  $l_1$  归一化)。它

值得强调的是，注意力图的标准化对于学生训练的成功至关重要。

注意力转移也可以与知识蒸馏相结合 (Hinton 等人, 2015)，在这种情况下，只需在上述损失中加入一个额外项（对应于教师和学生标签的软化分布之间的交叉熵）。结合使用时，注意力转移几乎不会增加计算成本，因为教师的注意力图可以在正向传播过程中轻松计算，这也是蒸馏所需的。

### 3.2 基于梯度的注意力迁移

在这种情况下，我们将注意力定义为相对于输入的梯度，这可以被视为输入敏感性图 (Simonyan 等人, 2014 年)，即输入空间位置处的注意力编码了输出预测相对于该输入位置变化的敏感程度（例如，如果一个像素的微小变化会对网络输出产生较大影响，那么可以合理地认为网络正在“关注”该像素）。我们将教师和学生相对于输入的损失梯度定义为：

$$x_{T,i} = -\frac{\partial \mathcal{L}(W_T, x)}{\partial x_i}, \quad x_{S,i} = -\frac{\partial \mathcal{L}(W_S, x)}{\partial x_i}$$

那么，如果我们希望学生的梯度注意力与教师的注意力相似，我们可以最小化它们之间的距离（这里我们使用  $l_2$  距离，但也可以采用其他距离）：

$$-$$

已知  $W_T$  和  $x$ ，要求得所需的关于  $w_S$  的导数：

$$-\frac{\partial}{\partial w_S} \mathcal{L}(W_S, x) = -\frac{\partial}{\partial w_S} \mathcal{L}(W_S, x) + \beta (I_S - I_T) \frac{\partial^2}{\partial w_S \partial x} \mathcal{L}(W_S, x)$$

因此，要进行更新，我们首先需要进行前向和反向传播以获得  $J_S$  和  $J_T$ ，计算第二个误差

在这种情况下，涉及二阶混合偏导数计算  $\frac{\partial^2}{\partial w_S \partial x}$

上述计算类似于 Drucker 和 LeCun (1992) 提出的双重反向传播技术（其中，相对于输入的梯度的  $l_2$  范数被用作正则化项）。此外，即使对于具有复杂图结构的现代架构，在支持自动微分的框架中也能高效实现这一计算。除去前向传播，第二次反向传播的成本与第一次大致相同。

我们还提议在梯度注意力图上实施水平翻转不变性。为此，我们将水平翻转的图像和原始图像一同传播，进行反向传播，然后将梯度注意力图翻转回来。接着，我们在得到的注意力和输出上添加  $l_2$  损失，并进行第二次反向传播：

$$\mathcal{L}_{sym}(W, x) = \mathcal{L}(W, x) + \frac{\beta}{2} \left( \frac{\partial}{\partial w_S} \mathcal{L}(W, x) - \text{flip} \left( \frac{\partial}{\partial w_S} \mathcal{L}(W, \text{flip}(x)) \right) \right)^2,$$

其中， $\text{flip}(x)$  表示翻转算子。这与 Cohen & 以及 Cohen 和 Welling (2016) 提出的群等变卷积神经网络

需要注意的是，在这项工作中，我们只考虑了相对于输入层的梯度，但一般来说，人们可能会提出相对于网络更高层的注意力转移和对称性约束。

## 4 实验部分

在接下来的部分中，我们将探讨在各种图像分类数据集上的注意力迁移。我们将本节分为两部分，第一部分包含在 CIFAR 上基于激活的注意力迁移和基于梯度的注意力迁移实验，第二部分则是基于激活



我们在更大的数据集上进行了实验。对于基于激活的注意力迁移，我们使用了 Network-In-Network (Lin 等人, 2013) 和基于 ResNet 的架构 (包括最近提出的宽残差网络 (WRN) Zagoruyko 和 Komodakis, 2016)，因为与 AlexNet 或 VGG 相比，它们性能最佳，在参数数量方面设立了很强的基准，并且已在涉及小型和大型数据集的各类论文中得到研究。在 Scenes、CUB 和 ImageNet 数据集上，我们使用 ResNet-18 和 ResNet-34 进行了实验。至于基于梯度的注意力，由于需要复杂的自动微分，我们将实验限制在无批量归一化的 Network-In-Network 和 CIFAR 数据集上。

#### 4.1 CIFAR 实验

我们从 CIFAR 数据集开始，该数据集包含  $32 \times 32$  的小图像，在对顶部激活进行下采样后，分辨率甚至更小，因此注意力迁移的空间不大。有趣的是，即使在这种不利的设置下，我们发现注意力迁移似乎能带来合理的收益，在所有情况下都能提供一致的改进。我们使用水平翻转和随机裁剪的数据增强方法，并且所有网络都采用批标准化。我们发现 ZCA 白化对验证准确率有负面影响，因此舍弃了它，转而采用更简单的均值标准差归一化。我们将 ResNet 迁移的知识蒸馏 (KD) 温度提高到 4，并使用  $\alpha = 0.9$  (有关这些参数的解释，请参见 Hinton 等人 (2015) 的研究)。

##### 4.1.1 基于激活的注意力迁移

使用  $r^2$  注意力图进行的注意力迁移结果，针对 CIFAR-10 上的各种网络，可在表 1 中找到。我们对教师网络 / 学生网络具有相同深度 (WRN-16-2/WRN16-1) 以及不同深度 (WRN-40-1/WRN-16-1、WRN-40-2/WRN-16-2) 的情况进行了实验。在所有组合中，注意力迁移 (AT) 都显示出显著的改进，当它与知识蒸馏 (AT+KD) 结合时，改进效果更高。

| student        | teacher        | student | AT   | F-ActT | KD   | AT+KD | teacher |
|----------------|----------------|---------|------|--------|------|-------|---------|
| NIN-thin, 0.2M | NIN-wide, 1M   | 9.38    | 8.93 | 9.05   | 8.55 | 8.33  | 7.28    |
| WRN-16-1, 0.2M | WRN-16-2, 0.7M | 8.77    | 7.93 | 8.51   | 7.41 | 7.51  | 6.31    |
| WRN-16-1, 0.2M | WRN-40-1, 0.6M | 8.77    | 8.25 | 8.62   | 8.39 | 8.01  | 6.58    |
| WRN-16-2, 0.7M | WRN-40-2, 2.2M | 6.31    | 5.85 | 6.24   | 6.08 | 5.71  | 5.23    |

表 1: 不同架构在 CIFAR-10 上的基于激活的注意力迁移 (AT)。误差计算为 5 次不同种子运行的中值。F-ActT 指完整激活迁移 (见第 4.1.2 节)

为了验证在 WRN 迁移中每组至少有一个基于激活的注意力迁移损失是否重要，我们分别在组 1、组 2 和组 3 中训练了三个网络，每个网络仅使用一个迁移损失，并与使用所有三个损失训练的网络进行了比较。相应的结果为 8.11、7.96、7.97 (针对单独的损失) 和 7.93 (针对组合损失，使用 WRN16-2/WRN-16-1 作为教师 / 学生对)。每个损失都提供了一定程度的额外注意力迁移。

我们还分别以 WRN-16-1 和 WRN16-2 作为学生网络和教师网络，探究了哪些注意力映射函数的效果往往最佳 (表 2)。有趣的是，基于求和的函数效果非常相似，且优于基于最大值的函数。为简单起见，从现在开始，我们将使用平方注意力映射函数  $r^2$  的和。至于公式 2 中的参数  $\beta$ ，它通常在 0.1 左右变化，我们将其设置为  $10^3$  除以每一层注意力图中的元素数量和批量大小。在将 AT 与 KD 结合的情况下，我们在训练过程中对其进行衰减，以简化对迁移样本的学习。

##### 4.1.2 基于激活的注意力转移与完整激活转移

为了验证从完整激活张量传输信息是否比从注意力图传输更有利，我们使用 FitNets 风格的提示进行了实验——直接对完整激活使用  $l_2$  损失，通过  $1 \times 1$  卷积层来匹配张量形状，结果发现相比基准学生模型的改进微乎其微 (见表 1 中的 F-ActT 列)。对于宽度相同但深度不同的网络，我们尝试直接回归到激活值，不使用  $1 \times 1$  卷积。在传输损失之前，我们还使用了  $l_2$  归一化，并在训练过程中衰减公式 2 中的  $\beta$ ，因为这些操作能带来更好的性能。我们发现，注意力图传输以及完整激活传输都能极大地加快收敛速度，但注意力图传输的效果要好得多。

其最终精度提升优于全激活迁移（见图 7 (b)，附录）。有趣的是，注意力图所携带的信息对于迁移而言，比全激活更为重要。

表 2: 不同注意力映射函数下 WRN16-2/WRN-16-1 教师 / 学生对的测试误差。报告的是 5 次运

表 3: 各种基于梯度的注意力方法在 CIFAR-10 上的性能。基线是一个具有 0.2M 参数的精简 NIN 网络（仅在水平翻转的增强数据上训练，且不使用批量归一化）， $\min-l_2$ 指的是使用输入的梯度的 $l_2$ 范数作为正则化项，对称范数指的是在梯度注意力图上使用翻转不变性（参见公式 6），AT 指注意力迁移，KD 指知识蒸馏（AT 和 KD 均使

#### 4.1.3 基于梯度的注意力迁移

为简单起见，我们在这些实验中使用了精简的 Network-In-Network 模型，没有采用带有批量归一化的随机裁剪数据增强，只使用了水平翻转增强。我们还只使用确定性算法和固定种子的采样，因此报告的数据来自单次运行的实验。我们发现，在这种设置下，网络已经难以拟合训练数据，因此即使是基线实验也关闭了权重衰减。未来，我们计划探索用于师生对的基于梯度的注意力机制，以利用批量归一化，因为目前尚不清楚在基于梯度的注意力迁移所需的第二次反向传播步骤中，批量归一化应该如何表现（例如，它是否应该对批量归一化参数有贡献，或者是否需要使用固定参数进行单独的前向传播）。我们探索了以下设计。

最小化关于输入的梯度的 $l_2$ 范数，即 Drucker 和 LeCun (1992) 提出的双重反向传播方法；

梯度注意力图的对称范数（参见公式 6）；

当学生 - 教师共享梯度的注意力迁移；

共享学生 - 教师激活的注意力迁移

各种方法的结果如表 3 所示。有趣的是，仅仅最小化梯度的 $l_2$ 范数就已经能取得相当不错的效果。此外，对称范数是性能最佳的注意力范数之一，我们计划在未来的其他数据集上也对其进行研究。我们还观察到，与基于激活的注意力迁移类似，使用基于梯度的注意力迁移能够提升性能。我们还在相同的训练条件下用基于激活的注意力迁移（AT）训练了一个网络，该网络在所有方法中取得了最佳性能。需要注意的是，没有批归一化的学生网络 NIN 的架构与教师网络略有不同，它在池化层之前没有 ReLU 激活函数，这使得在没有批归一化时性能更好，而有批归一化时性能更差。因此，为了通过基于激活的注意力迁移获得最佳性能，我们必须训练一个新的教师网络，该网络带有批归一化且在池化

## 4.2 大型输入图像网络

在本节中，我们在输入图像尺寸为  $224 \times 224$  的 ImageNet 网络上对隐藏激活注意力迁移进行了实验。据推测，由于注意力图的空间分辨率更高，注意力在这类网络中更为重要。



表 4: 在 Scenes 和 CIFR 数据集上使用注意力迁移误差进行微调

#### 4.2.1 迁移学习

为了探究注意力迁移在微调中的作用,我们选择了两个数据集:Wah 等人 (2011) 提出的 Caltech-UCSD Birds-200-2011 细粒度分类数据集 (CUB), 以及 Quattoni 和 Torralba (2009) 提出的 MIT 室内场景分类数据集 (Scenes), 这两个数据集都包含约 5000 张训练图像。我们采用了在 ImageNet 上预训练的 ResNet-18 和 ResNet-34, 并在这两个数据集上进行微调。在 CUB 数据集上,我们对边界框进行裁剪,将其中一个维度调整为 256, 然后进行随机裁剪。微调时固定批归一化层,冻结第一组残差块。之后,我们将微调后的 ResNet-34 网络作为在 ImageNet 上预训练的 ResNet-18 的教师模型,在最后两组上使用  $F_{s,m}^2$  注意力损失。在这两种情况下,注意力迁移都带来了显著的性能提升,缩小了 ResNet-18 和 ResNet-34 在准确率上的差距。在 Scenes 数据集上,注意力迁移 (AT) 的效果

#### IMAGENET4.2.2

为了在 ImageNet 上展示基于激活的注意力迁移,我们采用 ResNet-18 作为学生模型,ResNet-34 作

最后我们使用  $F_{s,m}^2$  注意力损失,我们也没有时间

我们没有调整任何超参数,而是保留了微调实验中的超参数。尽管如此,带有注意力迁移的 ResNet-18 在验证集上的 top-1 准确率提高了 1.1%, top-5 准确率提高了 0.8% (附录中的表 5 和图 7 (a))。我们未能在 ImageNet 上通过知识蒸馏 (KD) 获得积极结果。使用 ResNet-18-ResNet-34 作为学生-教师网络时,在与 CIFAR 上相同的超参数设置下,实际上会阻碍收敛。有研究表明,如果教师网络和学生网络的架构/深度不同,知识蒸馏很难发挥作用 (我们在 CIFAR 上也观察到了同样的现象),因此我们尝试在注意力迁移中使用相同的架构和深度。在这种情况下,在 CIFAR 上,注意力迁移 (AT) 和知识蒸馏都能很好地发挥作用,改善收敛效果和最终精度,但在 ImageNet 上,知识蒸馏的收敛速度明显较慢 (由于计算资源不足,我们没有训练到最后)。此外,我们在文献中也没有发现

## 5 结论

我们提出了几种将注意力从一个网络转移到另一个网络的方法,并在多个图像识别数据集上展示了实验结果。观察注意力转移在空间信息更为重要的情况下 (例如目标检测或弱监督定位) 如何发挥作用将很有趣,这也是我们计划在未来探索的内容。

总的来说,我们认为我们这些有趣的发现将有助于进一步推进知识蒸馏领域的发展,并加深对卷积神

## 参考文献

德米特里·巴赫达诺夫、京贤赵与约书亚·本吉奥。《通过联合学习对齐与翻译实现神经机器翻译》。CoRR, 编号 abs/1409.0473, 2014 年。网址 <http://arxiv.org/abs/1409.0473>。

克里斯蒂安·布西拉、里奇·卡鲁阿纳和亚历山德鲁·尼古列斯库-米齐尔。模型压缩。收录于《知

塔科·S. 科恩和马克斯·韦林。群等变卷积网络。abs/1602.07576, 2016。URL <https://arxiv.org/abs/1602.07576>

米莎·德尼尔、洛里斯·巴扎尼、雨果·拉罗谢尔和南多·德·弗雷塔斯。利用深度架构学习图像跟

H. 德鲁克和 Y. 勒丘恩。利用双重反向传播提高泛化性能。《IEEE 神经网络汇刊》, 3 (6) : 991-

何恺明、张祥雨、任少卿和孙剑。用于图像识别的深度残差学习。CoRR, abs/1512.03385, 2015。

杰弗里·E·辛顿、奥里奥尔·文尼亚斯和杰夫·迪恩。《提炼神经网络中的知识》。2015 年。

雨果·拉罗谢尔和杰弗里·E. 辛顿。利用三阶玻尔兹曼机学习组合中央凹瞥见。收录于 J. D. 拉弗蒂、C. K. I. 威廉姆斯、J. 肖韦 - 泰勒、R. S. 泽梅尔和 A. 库洛塔 (编), 《神经信息处理系统进展 27》, 第 2204-2212 页。柯兰出版社, 2014 年。

圭兴·巴·雪和甲森·卡鲁阿纳。深度网络真的重要得多吗? 发表于《神经信息处理系统 27》, 第 1312-1320 页。2014 年。

弗拉基米尔·米尼赫、尼古拉斯·赫斯、亚历克斯·格雷夫斯和科拉伊·卡武克库奥卢。视觉注意力的循环模型。收录于扎法尔·加哈拉尼、马克斯·韦林、科琳娜·科特斯、尼尔·D. 劳伦斯和凯伦·Q. 魏因贝格 (编), 《神经信息处理系统进展 27》, 第 2204-2212 页。柯兰出版社, 2014 年。

M. 奥夸布、L. 博图、I. 拉普捷夫 and J. 西维奇。目标定位是免费的吗? 基于卷积神经网络的弱监督学习。发表于《IEEE 计算机视觉与模式识别会议论文集》, 2015 年。

O. M. 帕克希、A. 韦达尔迪和 A. 齐瑟曼。《深度人脸识别》。发表于《英国机器视觉会议》, 2015 年。

A. 本托恩和 A. 托拉多。空中场景识别。发表于《计算机视觉与模式识别》, 2014 年。

阿诺德·A. 伦辛吉。场景的动态表征。收录于《视觉认知》, 第 17-42 页。2000 年。

Adriana Romero、Nicolas Ballas、Samira Ebrahimi Kahou、Antoine Chassang、Carlo Gatta 和 Yoshua Bengio。FitNets: 瘦深网络的提示。技术报告 arXiv 报告 1412.6550, arXiv, 2014 年。

兰普拉萨思·R. 塞尔瓦拉朱、阿比舍克·达斯、拉马克里希纳·韦丹塔姆、德维·帕里赫和德鲁夫·巴特拉。Grad-cam: 你为什么这么说? 通过基于梯度的定位从深度网络获得视觉解释。2016 年。

卡伦·西蒙尼扬、安德里亚·韦达利和安德鲁·齐瑟曼。《深入卷积网络: 可视化图像分类模型和显

J. T. 斯普林伯格、A. 多索维茨基、T. 布罗克斯和 M. 里德米勒。《追求简洁: 全卷积网络》。发表于 arXiv:1412.6806, 亦收录于 2015 年国际学习表征会议 (ICLR) 研讨会环节, 2015 年。网址: <https://arxiv.org/abs/1412.6806>

鲁佩什·库马尔·斯里瓦斯塔瓦、克劳斯·格雷夫和于尔根·施密德胡贝尔。高速公路网络。

C. Wah、S. Branson、P. Welinder、P. Perona 和 S. Belongie。《加州理工学院 - 加州大学圣地亚哥分校视觉中心: 视觉中心》。加州理工学院视觉中心, 2014 年。

Kelvin Xu、Jimmy Ba、Ryan Kiros、Kyunghyun Cho、Aaron C. Courville、Ruslan Salakhutdinov、Richard S. Zemel 和 Yoshua Bengio。展示、关注与描述: 基于视觉注意力的神经图像 caption 生成。CoRR, abs/1502.03044, 2015。URL <https://arxiv.org/abs/1502.03044>

作为会议论文发表于 ICIR 2017

杨自超、何晓冬、高剑锋、邓力和亚历山大·J·斯莫拉。用于图像问答的堆叠注意力网络。CoRR, abs/1511.02274, 2015。URL <http://arxiv.org/abs/1511.02274>。

谢尔盖·扎戈鲁伊科和尼科斯·科普法基斯。零残差网络。发表于《英国机器视觉学会

马修·蔡勒和罗布·弗格斯。卷积网络的可视化与理解。发表于《欧洲计算机视觉会议》，2014 年。

周博磊、阿迪蒂亚·科斯拉、阿加塔·拉佩德里扎、奥德·奥利瓦和安东尼奥·托拉尔巴。《学习用

A 附录

A.1 图和表




图 6: 不同场景网络的顶级激活注意力图: 原始预训练 ResNet-18 (ResNet-18-ImageNet)、在场景上训练的 ResNet-18 (ResNet-18-scenes)、使用注意力转移训练的 ResNet-18 (ResNet-18-scenes-AT, 以 ResNet-34 作为教师模型)、在场景上训练的



(a) ImageNet 上 ResNet-18 与 ResNet-34 之间的注意力迁移。实线代表 top-5 验证误差, 虚线代表 top-5 训练误差。分别在最后两个残差块组的输出上使用了两种注意力迁移损失, 未使用知识蒸馏 (KD) 损失。

图 7

表 5: ImageNet 上的注意力迁移验证误差 (单裁剪)。迁移损失在第 60/100 个轮次添加。

## A.2 实现细节

这些实验是在 Torch 机器学习框架中进行的。双向传播可以在支持自动微分的现代框架中实现, 例如 Torch、Theano、Tensorflow。在 ImageNet 实验中, 我们使用了 fb.resnet.torch 代码, 并在教师模型和学生模型中均采用 2 块 Titan X 显卡进行数据并行处理, 以加快训练速度。我们实验所用的代码和