

从更强的教师模型中进行知识蒸馏

黄涛^{1,2} 游珊^{1*} 王飞³ 钱晨¹ 徐畅²

¹ 商汤科技研究院 ² 悉尼大学工程学院计算机科学系 ³ 中国科学技术大学

摘要

与现有的知识蒸馏方法不同，现有方法侧重于基准设置，其中教师模型和训练策略并不像最先进的方法那样强大且具有竞争力，本文提出了一种名为 DIST 的方法，用于从更强的教师模型中更好地进行蒸馏。我们通过实验发现，学生模型与更强的教师模型之间的预测差异可能会相当严重。因此，在 KL 散度中实现预测的精确匹配会干扰训练，导致现有方法表现不佳。在本文中，我们表明，只需保留教师模型和学生模型的预测之间的关系就足够了，并提出了一种基于相关性的损失函数，以明确地从教师模型中捕捉类间的内在关系。此外，考虑到不同实例与每个类别的语义相似度不同，我们还将这种关系匹配扩展到类内层面。我们的方法简单且实用，大量实验表明，它能很好地适应各种架构、模型大小和训练策略，并且在图像分类、目标检测和语义分割任务上始终能达到最先进的性能。代码可在以下地址获取：https://github.com/hunto/DIST_KD。

1 引言

自动特征工程的出现推动深度神经网络在众多计算机视觉任务中取得了显著成功，例如图像分类 [17, 19, 38, 48, 53]、目标检测 [2, 23] 和语义分割 [5, 54]。在追求更好性能的过程中，当前的深度学习模型通常变得更深、更宽 [13, 45]。然而，由于计算和内存资源的限制，这类庞大的模型在实际部署中较为不便。为了使一个高效模型能拥有与那些更大模型相媲美的性能，知识蒸馏 (KD) [16] 被提出，其通过在训练过程中蒸馏更大模型（教师模型）的知识来提升高效模型（学生模型）的性能。

知识蒸馏的核心在于如何构建知识并将其从教师模型传递给学生模型。最直观且有效的方法是通过 KL 散度来匹配教师模型和学生模型的概率预测（响应）分数 [16]。通过这种方式，学生模型在训练过程中能获得更具信息量的信号指导，因此有望比独立训练时取得更优的性能。除了这种常规的预测匹配方法外，其他研究 [11, 14, 34, 41] 还对中间表示中的知识进行了探索，以进一步提升蒸馏性能，但这通常会导致额外的训练成本。例如，OFD [14] 提出通过多个中间层来蒸馏信息，但需要额外的卷积操作进行特征对齐；CRD [41] 引入了对比损失来传递成对关系，但它需要为 ImageNet 图像的所有 128 维特征建立一个记忆库，并且会产生额外 2.6 亿次的浮点运算量。

* 通讯作者：单优 voushan@sensetime.com。




图 1: 在 ImageNet 上, 知识蒸馏 (KD) 与我们提出的 DIST 方法在不同教师模型上的对比。(a) 使用基线策略, 在不同模型大小的教师模型上训练 ResNet-18 学生模型。(b) 使用不同策略, 在 ResNet-50 教师模型上训练 ResNet-18 学生模型。

最近, 已有一些研究 [8, 29, 39] 着手解决当学生模型与教师模型规模存在显著差异时, 学生网络学习效果不佳的问题。例如, TAKD [29] 提出通过引入一个中等规模的额外教学辅助模型来减小教师与学生之间的差异; DGKD [39] 则通过密集整合所有辅助模型以指导学生, 进一步改进了 TAKD。然而, 增大模型规模只是获得更强教师模型的一种常用方法。目前对于能得到更强教师模型的训练策略及其对知识蒸馏 (KD) 的影响, 尚缺乏深入分析。最重要的是, 我们更需要一种足够通用的解决方案, 以应对由更强教师模型带来的知识蒸馏难题, 而不是费力地分别处理不同类型的更强教师模型 (无论是更大规模的模型还是采用更强训练策略的模型)。

为了理解是什么造就了更强的教师模型以及它们对知识蒸馏 (KD) 的影响, 我们系统地研究了设计和训练深度神经网络的主流策略, 并发现:

- 除了增大模型规模, 还可以通过先进的训练策略 (例如标签平滑和数据增强) 来获得更强的教师模型 [51]。然而, 如图 1 所示, 在教师模型更强的情况下, 学生模型在常规知识蒸馏 (KD) 中的性能可能会下降, 甚至比不使用知识蒸馏从头开始训练的效果还要差。
- 当我们将师生模型的训练策略调整为更强的策略时, 师生模型之间的差异往往会变得相当大 (见图 2)。在这种情况下, 通过 KL 散度精确恢复预测结果可能具有挑战性, 并会导致普通知识蒸馏 (KD) 的失败。保持师生模型预测结果之间的关系是充分且有效的。在将知识从教师模型传递给学生模型时, 我们真正关心的是保留教师模型的偏好 (预测结果的相对排序), 而不是精确恢复绝对值。师生模型预测结果之间的相关性有助于放宽 KL 散度的精确匹配要求, 并提炼内在关系。

因此, 在本文中, 我们利用皮尔逊相关系数 [33] 作为一种新的匹配方式来替代 KL 散度。此外, 除了预测向量中的类间关系 (见图 3), 基于不同实例与每个类别的相似度存在差异这一直觉, 我们还提出蒸馏类内关系以进一步提升性能, 具体如图 3 所示。具体而言, 对于每个类别, 我们收集一批中所有实例对该类别的对应预测概率, 然后将这种关系从教师模型迁移到学生模型。我们提出的方法 (称为 DIST) 极其简单、高效且实用, 仅需几行代码即可实现 (见附录 A.1), 并且训练成本几乎与普通知识蒸馏 (KD) 相同。因此, 学生模型无需再承担匹配强大教师模型精确输出的负担, 而只需在适当引导下蒸馏那些真正具有信息价值的关系。

我们在基准数据集上进行了大量实验, 以验证我们在各种任务 (包括图像分类、目标检测和语义分割) 上的有效性。实验结果表明, 我们的 DIST 显著优于普通知识蒸馏 (KD) 以及那些精心设计的最先进的 KD 方法。例如, 在 ImageNet 上使用相同的基线设置时, 我们的 DIST




图 2: 在 ImageNet 验证集上, 采用不同策略单独训练的模型其预测结果存在差异。例如, R18B1 代表使用策略 B1 训练的 ResNet-18。训练策略 B1 和 B2 的详细信息参见表 1。

在 ResNet-18 上达到了 72.07% 的最高准确率。借助更强的策略, 我们的方法在最新的 Transformer 模型 Swin-T 上取得了 82.3% 的准确率, 相比知识蒸馏 (KD) 提升了 1%。

2 重新审视知识蒸馏的预测匹配

在传统的知识蒸馏 [16] 中, 知识通过最小化教师模型和学生模型的预测分数之间的差异, 从预训练的教师模型转移到学生模型。

形式上, 对于学生网络和教师网络的 logits $Z^{(s)} \in \mathbb{R}^{B \times C}$ 和 $Z^{(t)} \in \mathbb{R}^{B \times C}$, 其中

B 和 C 分别表示批次大小和类别数量, 标准知识蒸馏损失 [16] 表示为

$$\mathcal{L}_{KD} := \frac{\tau^2}{B} \sum_{i=1}^B KL(Y_{i,:}^{(t)}, Y_{i,:}^{(s)}) = \frac{\tau^2}{B} \sum_{i=1}^B \sum_{j=1}^C Y_{i,j}^{(t)} \log \left(\frac{Y_{i,j}^{(t)}}{Y_{i,j}^{(s)}} \right),$$

其中 KL 指的是 Kullback-Leibler 散度,

$$Y_i^{(s)} = \text{softmax}(Z_i^{(s)}/\tau), Y_i^{(t)} = \text{softmax}(Z_i^{(t)}/\tau),$$

是概率预测向量, τ 是控制 logits 平滑度的温度因子。

除了公式 (1) 中教师的软目标外, 知识蒸馏 (KD) [16] 指出, 结合真实标签训练学生模型是有益的, 整体训练损失由原始分类损失 $\mathcal{L}_{CE}$ 和知识蒸馏损失 $\mathcal{L}_{KD}$ 组成,

$$\mathcal{L} = \alpha \mathcal{L}_{CE} + \beta \mathcal{L}_{KD}$$

组成,

(3) 其中 $\mathcal{L}_{CE}$ 通常是学生网络的预测与真实标签之间的交叉熵损失, α 和 β 是用于平衡这些损失的因子。

2.1 与更强教师模型的灾难性差异

如第 1 节所示, 教师模型对知识蒸馏 (KD) 的影响尚未得到充分研究, 尤其是当预训练教师模型的性能变得更强时, 例如模型规模更大, 或者使用更先进且具有竞争力的策略进行训练, 如标签平滑、mix-up [51]、自动数据增强 [9] 等。关于这一点, 如图 2 所示, 我们使用策略 B1 和策略 B2 分别独立训练 ResNet-18 和 ResNet-50, 得到 4 个训练好的模型

(R18B1、R18B2、R50B1 和 R50B2, 其准确率分别为 69.76%、73.4%、76.13% 和 78.5%), 然后使用 KL 散度 ($\tau=1$ 和 $\tau=4$) 对预测概率 Y 的差异进行比较。我们有以下观察结果:

使用 B2 进行训练比使用 B1 获得更高的准确率, 例如, 在 ResNet-18 上, B2 的准确率为 73.4%, 而 B1 为 69.8%。




图 3: 我们的 DIST 和现有 KD 方法之间的差异。传统的 KD 点明智地匹配学生 ($(s \in \mathbb{R}^5)$) 教师 ($t \in \mathbb{R}^5$) 的输出; 实例关系方法在特征层上运行, 分别测量学生和教师实例之间的内部相关性 (corr.), 然后将教师的相关性转移到学生身上。我们的 DIST 建议保持学生和教师之间的类间和类内关系。类间关系: 教师和学生每个实例上预测的概率分布之间的相关性。类内关系: 每个类上所有实例概率的相关性。

- 与 ResNet-50 相比, 采用更强策略时, ResNet-18 的输出变化不大。这表明表征能力限制了学生模型的性能, 并且随着两者差异的增大, 学生模型要精确匹配教师模型的输出往往会变得相当困难。
- 当教师模型和学生模型采用更强的策略进行训练时, 两者之间的差异会更大。这表明, 当我们采用更强的训练策略进行知识蒸馏时, 知识蒸馏损失与分类损失之间的一致会更严重, 从而干扰学生模型的训练。

因此, 由于学生和教师之间的差异可能相当大, 使用 KL 散度进行精确匹配 (即只有当教师和学生的输出完全相同时, 损失才能达到最小值) 似乎过于雄心勃勃且要求过高。由于对于更强的教师来说, 精确匹配可能是不利的, 我们的想法是开发一种宽松的方式来匹配教师和学生的预测。

3 DIST: 从更强的教师模型中蒸馏

3.1 带关系的宽松匹配

预测分数表明了教师模型对所有类别的置信度 (或偏好)。为了让教师模型和学生模型的预测实现宽松匹配, 我们开始思考对于教师模型的输出, 我们真正关心的是什么。实际上, 在推理过程中, 我们并不在意精确的概率值, 只关注它们之间的关系, 即教师模型预测结果的相对排序。

通过这种方式, 对于某些具有 $\mathbb{R}^C \times \mathbb{R}^C \rightarrow \mathbb{R}^+$ 的指标 $d(\cdot, \cdot)$ 而言, 如果对于式 (1) 的 KL 散度中任意两个预测向量 $y_1^{(s)}$ 和 $y_2^{(t)}$ 存在 $a = b$, 那么就可以得出 $d(a, b) = 0$ 的精确匹配。作为一种宽松匹配, 我们可以引入具有 $\mathbb{R}^C \rightarrow \mathbb{R}^C$ 的额外映射 $\phi(\cdot)$ 和 $\psi(\cdot)$, 以便

$$d(\phi(a), \psi(b)) = d(a, b), \forall a, b \quad (4)$$

因此, $d(a, b) = 0$ 并不一定要求 a 和 b 完全相同。尽管如此, 由于我们关注 a 或 b 内部的关系, 映射 ϕ 和 ψ 应该是保序的, 且不影响预测向量的语义信息和推理结果。

在这方面，对于保序映射，一个简单而有效的选择是正线性变换，即

$$d(m_1 a + n_1, m_2 b + n_2) = d(a, b). \quad (5)$$

其中 m_1 、 m_2 、 n_1 和 n_2 是常数，且满足 $m_1 \times m_2 > 0$ 。因此，这种匹配在预测的尺度和偏移分别发生变化时可能具有不变性。实际上，为了满足式 (5) 的性质，我们可以采用广泛使用的皮尔逊距离作为度量，即

$$d_n(u, v) := 1 - \rho_n(u, v). \quad (6)$$

$\rho_n(u, v)$ 是两个随机变量 u 和 v 之间的皮尔逊相关系数，

$$\rho_p(u, v) := \frac{\text{Cov}(u, v)}{\text{Std}(u)\text{Std}(v)} = \frac{\sqrt{\frac{\sum_{i=1}^C (u_i - \bar{u})(v_i - \bar{v})}{C-1}}}{\sqrt{\frac{\sum_{i=1}^C (u_i - \bar{u})^2}{C-1}} \sqrt{\frac{\sum_{i=1}^C (v_i - \bar{v})^2}{C-1}}}$$

其中 $\text{Cov}(u, v)$ 是 u 和 v 的协方差， $\bar{u}$ 和 $\text{Std}(u)$ 分别表示 u 的均值和标准差。

通过这种方式，我们可以将这种关系定义为相关性。更具体地说，原始的普通知识蒸馏 (KD) [16] 中的精确匹配可以被放宽，转而通过最大化线性相关性来保留教师模型和学生模型在每个样本的概率分布上的关系，我们将其称为类间关系。形式上，对于每对预测向量 $Y_i^{(s)}$ 和 $Y_i^{(t)}$ ，类间关系损失可以表示为

$$\mathcal{L}_{inter} := \frac{1}{B} \sum_{i=1}^B d_n(Y_i^{(s)}, Y_i^{(t)}).$$

。

一些保序映射或度量也可用于如式 (4) 所示的松弛匹配，例如第 4.5 节中通过实验研究的余弦相似度；其他更先进和精细的选择可留作未来的工作。

3.2 利用类内关系实现更好的蒸馏

除了类间关系（即我们在每个实例中传递多个类别的关系）之外，每个类别中多个实例的预测分数也具有信息价值且十分有用。这些分数表明了多个实例与某一类别之间的相似度。例如，假设我们有三张图片，分别包含“猫”“狗”和“飞机”，它们在“猫”这一类别上有三个预测分数，记为 ϵ 、 f 和 g 。通常情况下，“猫”的图片在“猫”这一类别上的分数应该最高，而“飞机”的图片分数应该最低，因为它无生命的物体。这种“ $\epsilon > f > g$ ”的关系也可以传递给教师模型。此外，即使对于同一类别的图片，语义相似度的内在类内差异实际上也具有信息价值。这表明了来自教师模型的先验知识，即哪一个在该类别中更可靠。

因此，我们也鼓励提取这种内部关系以获得更好的性能。实际上，定义预测矩阵 $Y^{(s)}$ 和 $Y^{(t)}$ ，其中每行分别为 $Y_i^{(s)}$ 和 $Y_i^{(t)}$ ，那么上述的相互关系就是按行最大化相关性（见图 3）。相比之下，对于内部关系，相应的损失函数则是按列最大化相关性，即

$$\mathcal{L}_{intra} := \frac{1}{C} \sum_{i=1}^C d_n(Y_i^{(s)}, Y_i^{(t)}).$$

因此，整体训练损失 $\mathcal{L}_{tot}$ 可以由分类损失、类间知识蒸馏损失和类内知识蒸馏损失构成，即

$$\mathcal{L}_{tot} = \alpha \mathcal{L}_{cls} + \beta \mathcal{L}_{inter} + \gamma \mathcal{L}_{intra}. \quad (10)$$

其中 α 、 β 和 γ 是用于平衡这些损失的因子。通过这种方式，借助关系损失，我们在一定程度上赋予了学生网络自适应匹配教师网络输出的自由度，从而在很大程度上提升了蒸馏性能。

表 1: 图像分类任务的训练策略。BS: 批量大小; LR: 学习率; WD: 权重衰减; CL: 标签平滑; EMA: 模型指数移动平均; DA: 随机增强 [9]; DE: 随机擦除; CT: 颜色抖动。

Strategy	Dataset	Epochs	Total BS	Initial LR	Optimizer	WD	LS	EMA	LR scheduler	Data augmentation
A1	CIFAR-100	240	64	0.05	SGD	5×10^{-4}	-	-	$\times 0.1$ at 150,180,210 epochs	crop + flip
B1	ImageNet	100	256	0.1	SGD	1×10^{-4}	-	-	$\times 0.1$ every 30 epochs	crop + flip
B2	ImageNet	450	768	0.048	RMSProp	1×10^{-5}	0.1	0.9999	$\times 0.97$ every 2.4 epochs	{B1} + RA + RE
B3	ImageNet	300	1024	5e-4	AdamW	5×10^{-2}	0.1	-	cosine	{B2} + CJ + Mixup + CutMix

表 2: ImageNet 上基准设置的评估结果。我们使用 Torchvision [28] 发布的 ResNet-34 和 ResNet-50 作为教师网络, 并遵循标准训练策略 (B1)。

学生 (教师) 教师 学生 KD [16] OFD [14] CRD [41] SRRL [47] Review [7]

ResNet-18 (ResNet-34)

Top-1 71.73 73.31 69.76 70.66 71.08 71.17 71.61 72.07

Top-5 91.42 89.08 89.88 90.07 90.13 90.60 90.51 90.42

MobileNet (ResNet-50)

Top-1 76.16 70.13 70.68 71.25 71.37 72.49 72.56 73.24

Top-5 92.86 89.49 90.30 90.34 90.41 90.92 91.00 91.12

4 实验

4.1 实验设置

训练策略。图像分类任务的训练策略总结于表 1 中。CIFAR-100: 为了进行公平比较, 我们采用与 CRD [41] 相同的训练策略 (表 1 中记为 A1) 和预训练模型。ImageNet: B1: 为了与以往的知识蒸馏 (KD) 方法进行比较, 我们使用与 CRD [41] 相同的简单训练策略来训练基线模型。B2: 为了验证 KD 方法在现代训练策略上的有效性, 我们借鉴 EfficientNet [40] 的思路, 设计了训练策略 B2, 与 B1 相比, 该策略能显著提升性能。B3: 策略 B3 用于训练 Swin-Transformers [27], 包含更强的数据增强和正则化手段。

损失权重。在 CIFAR-100 和 ImageNet 上, 我们在公式 (10) 中设置了 $\alpha = 1$ 、 $\beta = 2$ 和 $\gamma = 2$ 。在目标检测和语义分割任务中, 这三个因子均等于 1。对于知识蒸馏 (KD) [16], 我们在公式 (3) 中设置了 $\alpha = 0.9$ 、 $\beta = 1$, 并使用默认温度 $\tau = 4$ 。具体而言, 在 CIFAR-100 上我们选择了更大的温度 $\tau = 4$, 而非在 ImageNet 上使用的 $\tau = 1$, 因为 CIFAR-100 容易过拟合, 且学习到的概率分布较为陡峭。

4.2 图像分类

ImageNet 上的基线结果。我们首先使用基线设置将我们的方法与先前的工作进行比较。如表 2 所示, 我们的 DIST 显著优于先前的知识蒸馏 (KD) 方法。请注意, 我们的方法仅在模型的输出上执行, 计算成本与 KD [16] 相似。尽管如此, 与那些精心设计的方法相比, 它甚至能取得更好的性能。例如, CRD [41] 需要为 ImageNet 图像的所有 128 维特征保留一个内存库, 并产生额外 2.6 亿次浮点运算的计算成本; SRRL [47] 和 Review [7] 需要额外的卷积来进行特征对齐。DIST 的实现可在附录 A.1 中找到, 与这些方法相比相当简单。

从更强的教师模型中蒸馏知识。由于更强的教师模型来自更大的模型规模和更优的策略, 我们首先进行实验, 在采用基准策略 B1 的不同规模 (模型大小) 的 ResNet 上, 将我们的 DIST 与普通知识蒸馏 (KD) 进行比较。如表 3 所示, 当教师模型变得更大时, ResNet-18 学生模型的表现甚至比使用中等规模的 ResNet-50 教师模型时更差。然而, 我们的 DIST 随着教师模型规模的增大呈现上升趋势, 并且与 KD 相比, 其改进也变得更加显著, 这表明我们的 DIST 能更好地处理学生模型与更大规模教师模型之间的巨大差异。

从更强大的训练策略中提取知识。最近, 借助复杂的训练策略和强大的数据增强技术, 模型在 ImageNet 上的性能得到了显著提升。

表 3: 不同教师规模下 ResNet-18 和 ResNet-34 在 ImageNet 上的性能表现。

Student	Teacher	Top-1 ACC (%)			
		student	teacher	KD	DIST
ResNet-18	ResNet-34	69.76	73.31	71.21	72.07 (+0.86)
	ResNet-50		76.13	71.35	72.12 (+0.77)
	ResNet-101		77.37	71.09	72.08 (+0.99)
	ResNet-152		78.31	71.12	72.24 (+1.12)
ResNet-34	ResNet-50	73.31	76.13	74.73	75.06 (+0.33)
	ResNet-101		77.37	74.89	75.36 (+0.47)
	ResNet-152		78.31	74.87	75.42 (+0.55)

表 4: 使用强策略在 ImageNet 上训练的学生模型性能。Swin-T 采用表 1 中的策略 B3 进行训练，其他模型采用 B2 进行训练。†: 由 [44] 训练。‡: 在 ImageNet-22K 上预训练。

Teacher	Student	Top-1 ACC (%)					
		teacher	student	KD [16]	RKD [30]	SRRL [47]	DIST
ResNet-50†	ResNet-18	80.1	73.4	72.6	72.9	71.2	74.5
	ResNet-34		76.8	77.2	76.6	76.7	77.8
	MobileNetV2		73.6	71.7	73.1	69.2	74.4
	EfficientNet-B0		78.0	77.4	77.5	77.3	78.6
Swin-L‡	ResNet-50	86.3	78.5	80.0	78.9	78.6	80.2
	Swin-T		81.3	81.5	81.2	81.5	82.3

(例如，TIMM [44] 在 ResNet-50 上达到 80.4% 的准确率，而基线策略 B1 仅获得 76.1%)。然而，大多数知识蒸馏 (KD) 方法仍然在简单的训练设置下进行实验。关于这些 KD 方法是否适用于先进策略，相关研究很少。因此，我们在先进的训练策略下进行实验，并将我们的方法与基础 KD、基于实例关系的 RKD [30] 以及 SRRL [47] 进行比较。

我们首先使用强大的策略训练传统 CNN，同时采用文献 [44] 中训练的高性能 ResNet-50 (准确率 80.1%) 作为教师模型。如表 4 所示，无论是在相似架构 (ResNet-18、ResNet-34) 还是异构架构 (MobileNetV2、EfficientNet-B0) 上，我们的 DIST 都能取得最佳性能。值得注意的是，RKD 和 SRRL 的表现可能不如从头训练，尤其是当学生模型较小 (ResNet-18 和 MobileNet) 或师生模型架构差异较大 (ResNet-50 和 Swin-L) 时。这可能是因为它们侧重于中间特征，与预测结果相比，学生模型恢复教师模型的特征更具挑战性。

此外，我们在最新的最先进模型 Swin-Transformer [27] 上进行了实验。结果表明，我们的 DIST 方法即使在更强的模型和策略上也能带来性能提升。例如，在使用 Swin-L 作为教师模型时，我们的方法分别将 ResNet-50 和 Swin-T 的性能提升了 1.7% 和 1.0%。

CIFAR-100。表 5 中 CIFAR-100 数据集上的结果表明，通过对预测的 logits 进行蒸馏，我们的方法甚至优于那些精心设计的特征蒸馏方法。

4.3 目标检测

我们进一步研究了 DIST 在下游任务中的有效性。我们在 MS COCO 目标检测数据集 [25] 上进行了实验，并简单地将我们的 DIST 用作对最终类别预测的额外监督。遵循 [37,52]，我们采用相同的标准训练策略，对于使用 ResNet-50 骨干网络的两阶段 Faster R-CNN [23] 学生模型，使用带有 ResNeXt-101 骨干网络的 Cascade Mask R-CNN [2] 作为教师模型；而对于使用 ResNet-50 骨干网络的单阶段 RetinaNet [24]，则使用带有 ResNeXt-101 骨干网络的 RetinaNet 作为教师模型。

如表 6 所示，我们的 DIST 在 COCO 验证集上取得了具有竞争力的结果。为了进行比较，我们在与 DIST 相同的设置下训练了 vanilla KD，结果表明，仅通过替换损失函数，我们的 DIST 就显著优于 vanilla KD。此外，通过结合

表 5: CIFAR-100 数据集上的评估结果。上方和下方的模型分别表示教师模型和学生模型。

Method	Same architecture style			Different architecture style		
	WRN-40-2 WRN-40-1	ResNet-56 ResNet-20	ResNet-32x4 ResNet-8x4	ResNet-50 MobileNetV2	ResNet-32x4 ShuffleNetV1	ResNet-32x4 ShuffleNetV2
Teacher	75.61	72.34	79.42	79.34	79.42	79.42
Student	71.98	69.06	72.50	64.6	70.5	71.82
<i>Feature-based methods</i>						
FitNet [35]	72.24±0.24	69.21±0.36	73.50±0.28	63.16±0.47	73.59±0.15	73.54±0.22
VID [1]	73.30±0.13	70.38±0.14	73.09±0.21	67.57±0.28	73.38±0.09	73.40±0.17
RKD [30]	72.22±0.20	69.61±0.06	71.90±0.11	64.43±0.42	72.28±0.39	73.21±0.28
PKT [31]	73.45±0.19	70.34±0.04	73.64±0.18	66.52±0.33	74.10±0.25	74.69±0.34
CRD [41]	74.14±0.22	71.16±0.17	75.51±0.18	69.11±0.28	75.11±0.32	75.65±0.10
<i>Logits-based methods</i>						
KD [16]	73.54±0.20	70.66±0.24	73.33±0.25	67.35±0.32	74.07±0.19	74.45±0.27
DIST	74.73±0.24	71.75±0.30	76.31±0.19	68.66±0.23	76.34±0.18	77.35±0.25

与 DIST 相同。学生。*: 我们使用 $\tau = 1$ 和其他设置实现了知识蒸馏 (KD)。表 6: COCO 验证集上的结果。表 7: Cityscapes 验证集上的结果。所有模型均在 ImageNet 上进行预训练。

Method	AP	AP ₅₀	AP ₇₅	AP _S	AP _M	AP _L
<i>Two-stage detectors</i>						
T: Cascade Mask RCNN-X101	45.6	64.1	49.7	26.2	49.6	60.0
S: Faster RCNN-R50	38.4	59.0	42.0	21.5	42.1	50.3
KD [16]*	39.7	61.2	43.0	23.2	43.3	51.7
FKD [52]	41.5	62.2	45.1	23.5	45.0	55.3
CWD [37]	41.7	62.0	45.5	23.3	45.5	55.5
DIST	40.4	61.7	43.8	23.9	44.6	52.6
DIST + mimic	41.8	62.4	45.6	23.4	46.1	55.0
<i>One-stage detectors</i>						
T: RetinaNet-X101	41.0	60.9	44.0	23.9	45.2	54.0
S: RetinaNet-R50	37.4	56.7	39.6	20.0	40.7	49.7
KD [16]*	37.2	56.5	39.3	20.4	40.4	49.5
FKD [52]	39.6	58.8	42.1	22.7	43.3	52.5
CWD [37]	40.8	60.4	43.4	22.7	44.5	55.3
DIST	39.8	59.5	42.5	22.0	43.7	53.0
DIST + mimic	40.1	59.4	43.0	23.2	44.0	53.6

Method	mIoU (%)
T: DeepLabV3-R101	78.07
S: DeepLabV3-R18	74.21
SKD [26]	75.42
IFVD [43]	75.59
CWD [37]	75.55
CIRKD [46]	76.38
DIST	77.10
S: PSPNet-R18	72.55
SKD [26]	73.29
IFVD [43]	73.71
CWD [37]	74.36
CIRKD [46]	74.73
DIST	76.31

结合模拟的 DIST 通过最小化教师和学生的 FPN 特征之间的均方误差，甚至可以超越专为目标检测设计的最先进知识蒸馏方法

4.4 语义分割

我们还在语义分割这一具有挑战性的密集预测任务上进行了实验。遵循 [37, 43, 46]，我们在 Cityscapes 数据集上使用 ResNet-18 骨干网络训练了 DeepLabV3 [6] 和 PSPNet [54]，并将我们的 DIST 应用于分类头的预测中，所使用的教师模型是带有 ResNet101 骨干网络的 DeepLabV3。如表 7 所示，仅在类别预测的监督下，我们的 DIST 在语义分割任务上就能显著优于现有的知识蒸馏方法。例如，在 PSPNet-R18 上，我们的 DIST 比最近的最先进方法 CIRKD [46] 高出 1.58%，这证明了我们在此建模方面的有效性。

4.5 消融研究

类间相关性和类内相关性的影响。本文提出了两种类型的关系：类间关系和类内关系。为了验证每种关系的有效性，我们进行了实验，分别利用这些关系对学生模型进行训练。表 8 的结果证实，类间关系和类内关系均能优于普通的知识蒸馏（KD）；此外，将它们结合起来可以进一步提升性能。

表 8: ImageNet 上类间和类内关系的消融实验。学生模型和教师模型分别为 ResNet-18 和 ResNet-34。

Method	Inter	Intra	ACC (%)
KD	-	-	71.21
DIST (KL div.)	✗	✓	70.61
DIST (KL div.)	✓	✓	71.62
DIST	✓	✗	71.63
DIST	✗	✓	71.55
DIST	✓	✓	72.07

类内关系在普通知识蒸馏（KD）中的作用。为了研究类内关系在普通 KD 中的有效性，我们通过实验训练了使用 KL 散度作为关系度量的 DIST，记为 DIST（KL 散度）³。如表 8 中的结果所示，在普通 KD 中加入类内关系也能提升性能（从 71.21% 提升至 71.62%）。然而，当仅使用类内关系训练学生模型时，使用 KL 散度的提升效果不如使用皮尔逊相关系数显著（70.61% 对比 71.55%），这是因为类内分布的均值和方差可能存在差异。

仅使用 KD 损失训练学生的效果。仅用 KD 损失训练学生能更好地体现蒸馏能力和监督信号的信息丰富度。如表 9 所示，当仅使用 KD 损失训练学生时，我们的 DIST 显著优于普通 KD。在不使用真实标签的情况下，它甚至能超过独立训练的准确率，这表明我们的 DIST 在蒸馏那些真正有益的关系方面是有效的。

表 9: 在 ImageNet 上有无分类损失的训练知识蒸馏（KD）对比。学生模型和教师模型分别为 ResNet-18 和 ResNet-34。未使用知识蒸馏（KD）的 ResNet-18 的原始准确率为 69.76%。

Method	w/ cls. loss	w/o cls. loss
KD	71.21	68.12
DIST	72.07	70.65

更多消融研究可参阅 A.3 节

5 结论

本文提出了一种名为 DIST 的新知识蒸馏（KD）方法，旨在更好地从更强的教师模型中进行蒸馏。我们通过实验研究了学生模型与更强的教师模型之间存在的显著差异问题，并提出了一种基于关系的损失函数，以在线性意义上放宽 KL 散度的精确匹配要求。我们的 DIST 方法简单且能有效处理强教师模型。大量实验表明，该方法在各种基准任务中均表现出优越性。例如，DIST 甚至优于专为目标检测和语义分割设计的最先进的知识蒸馏方法。

致谢

本研究部分得到澳大利亚研究委员会（项目编号 DP210101859）和悉尼大学研究加速器（SOAR）奖的支持。

³具体而言，vanilla KD 与仅包含类间关系的 DIST（KL 散度）相同。

参考文献

- [1] S. Ahn, S. X. Hu, A. Damianou, N. D. Lawrence 和 Z. Dai. 用于知识迁移的变分信息蒸馏。见《IEEE/CVF 计算机视觉与模式识别会议论文集》，第 9163-9171 页，2019 年。8
- [2] 蔡宗泽 (Z. Cai) 和纳斯西门托·瓦斯康塞洛斯 (N. Vasconcelos)。《级联 R-CNN：高质量目标检测与实例分割》。《IEEE 模式分析与机器智能汇刊》，第 1-1 页，2019 年。1。7
- [3] K. Chandrasegaran, N.-T. Tran, Y. ZHAO 和 N. man Cheung. 平滑还是不平滑？论标签平滑与知识蒸馏的兼容性。2022。14
- [4] 陈 H.、王 Y.、徐 C.、徐 C.、陶 D.。通过特征嵌入学习学生网络。《IEEE 神经网络与学习系统汇刊》，32 (1): 25-35。2020。13
- [5] 陈立聪、G. 帕潘德里欧、F. 施罗夫和 H. 亚当。重新思考用于语义图像分割的空洞卷积。arXiv 预印本 arXiv:1706.05587。2017。1
- [6] 陈立聪、朱毅、乔治·帕潘德里欧、弗雷德里克·施罗夫和霍萨姆·亚当。基于带孔可分离卷积的编码器-解码器用于语义图像分割。《欧洲计算机视觉会议论文集》(ECCV)，第 801-818 页，2018 年。8
- [7] 陈鹏、刘思、赵华、贾佳。通过知识回顾提炼知识。《IEEE/CVF 计算机视觉与模式识别会议论文集》，第 5008-5017 页，2021 年。6
- [8] J. H. Cho 和 B. Hariharan. 论知识蒸馏的有效性。见《IEEE/CVF 国际计算机视觉会议论文集》，第 1794-1802 页，2019 年。2
- [9] E. D. Cubuk, B. Zoph, J. Shlens 和 Q. V. Le. RandAugment: 具有缩减搜索空间的实用自动化数据增强。见《IEEE/CVF 计算机视觉与模式识别会议研讨会论文集》，第 702-703 页，2020 年。3、6
- [10] Y. Dodge. 《简明统计学百科全书》。施普林格科学与商业媒体出版社。2008 年。13
- [11] 杜思远、游思远、李翔、吴健、王飞、钱晨和张聪。求同存异：梯度空间中的自适应集成知识蒸馏。《神经信息处理系统进展》，33:12345-12355，2020。1
- [12] 苟俊、于斌、S. J. 梅班克、陶大程。知识蒸馏：综述。《国际计算机视觉期刊》，129 (6) : 1789-1819。2021。
- [13] 何恺明、张晓峰、任少卿、孙剑。用于图像识别的深度残差学习。《IEEE 计算机视觉与模式识别会议论文集》，第 770-778 页，2016 年。1
- [14] B. Heo, J. Kim, S. Yun, H. Park, N. Kwak 和 J. Y. Choi. 特征蒸馏的全面改进。见《IEEE/CVF 国际计算机视觉会议论文集》，第 1921-1930 页，2019 年。1、6
- [15] 许炳 (B. Heo)、李明 (M. Lee)、尹思 (S. Yun)、崔在元 (J. Y. Choi)。通过蒸馏隐藏神经元形成的激活边界实现知识迁移。《AAAI 人工智能大会论文集》，第 33 卷，第 3779-3787 页，2019 年。
- [16] G. Hinton, O. Vinyals 和 J. Dean. 提炼神经网络中的知识。arxiv 预印本 arxiv: 1503.02531.2015。1.3.5.6.7.8.14
- [17] A. G. Howard, M. 朱, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto 和 H. Adam. 移动网络：用于移动视觉应用的高效卷积神经网络。arxiv 预印本 arxiv: 1704.04861, 2017。1
- [18] 黄涛、李志、陆华、单阳、杨森、冯燕、王峰、游思、徐聪。关系替代损失学习。见《国际学习表征会议》，2022 年。
- [19] T. Huang, S. You, B. Zhang, Y. Du, F. Wang, C. Qian 和 C. Xu. Dyrep: 利用动态重参数化进行引导训练。arXiv 预印本 arXiv:2203.12868。2022。1
- [20] M. G. Kendall. 一种新的等级相关度量。《生物计量学》，30 (1/2): 81-93，1938。13
- [21] J. Kim, S. Park 和 N. Kwak. 释义复杂网络：通过因子转移实现网络压缩。arXiv 预印本 arXiv:1802.04977，2018。
- [22] 孔思 (S. Kong)、郭涛 (T. Guo)、游思 (S. You)、徐超 (C. Xu)。《利用少量数据学习学生网络》。发表于《AAAI 人工智能大会论文集》，第 34 卷，第 4469-4476 页，2020 年。
- [23] 林同炎 (T.-Y. Lin)、P. 多拉尔 (P. Dollár)、R. 格施克 (R. Girshick)、何恺明 (K. He)、B. 哈里哈兰 (B. Hariharan) 和 S. 贝隆吉 (S. Belongie)。用于目标检测的特征金字塔网络。《IEEE 计算机视觉与模式识别会议论文集》，第 2117-2125 页，2017 年。1。7
- [24] 林同炎、P. 戈亚尔、R. 格施克、K. 贺和 P. 多拉。用于密集目标检测的焦点损失。《IEEE 国际计算机视觉会议论文集》，第 2980-2988 页，2017 年。7

- [25] 林同炎 (T.-Y. Lin)、迈尔 (M. Maire)、贝朗吉 (S. Belongie)、海斯 (J. Hays)、佩罗纳 (P. Perona)、拉马南 (D. Ramanan)、多拉 (P. Dollár) 和齐特尼克 (C. L. Zitnick)。《微软 COCO: 上下文中的常见物体》。见《欧洲计算机和视觉会议论文集》, 第 740-755 页。施普林格出版社, 2014 年。7
- [26] 刘 Y、舒 C、王 J、沈 C。用于密集预测的结构化知识蒸馏。《IEEE 模式分析与机器学习汇刊》, 2020 年。8
- [27] 刘 Z、林 Y、曹 Y、胡 H、魏 Y、张 Z、林 S、郭 B. Swin Transformer: 使用移位窗口的分层视觉 Transformer。arXiv 预印本 arXiv:2103.14030。2021。3。6。7
- [28] S. 马塞尔和 Y. 罗德里格斯。Torchvision: Torch 的机器视觉包。见《第 18 届 ACM 国际多媒体会议论文集》, 第 1485-1488 页。2010 年。6
- [29] S. I. Mirzadeh、M. Farajtabar、A. Li、N. Levine、A. Matsukawa 和 H. Ghasemzadeh。通过教师助手改进知识蒸馏。《AAAI 人工智能大会论文集》, 第 34 卷, 第 5191-5198 页, 2020 年。2
- [30] W. Park、D. Kim、Y. Lu 和 M. Cho。关系知识蒸馏。见《IEEE/CVF 计算机视觉与模式识别会议论文集》, 第 3967-3976 页。2019 年。7。8。13。14
- [31] N. 帕萨利斯、M. 泽勒皮和 A. 泰法斯。用于轻量级深度表示学习的概率知识迁移。《IEEE 神经网络与学习系统汇刊》, 32 (5): 2030-2039。2020。8
- [32] A. 帕斯克、S. 格罗斯、F. 马萨、A. 勒雷尔、J. 布拉德伯里、G. 钱南、T. 基林、Z. 林、N. 吉梅申、L. 安蒂加。PyTorch: 一种命令行风格的高性能深度学习库。《神经信息处理系统进展》, 32:8026-8037, 2019。13
- [33] K. 皮尔逊。VII. 对进化论的数学贡献——III. 回归、遗传与随机交配。《伦敦皇家学会哲学汇刊·A 辑》(收录数学或物理学论文), 187: 253-318, 1896。2
- [34] 彭博、金鑫、刘军、李丹、吴燕、刘阳、周思、张哲。知识蒸馏的相关性一致性。《IEEE/CVF 国际计算机视觉会议论文集》, 第 5007-5016 页, 2019 年。1、13
- [35] A. 罗梅罗、N. 巴拉斯、S. E. 卡胡、A. 沙桑、C. 加塔和 Y. 本吉奥。Fitnets: 瘦深网络的提示。arXiv 预印本 arXiv:1412.6550。2014。8
- [36] 沈 Z、刘 Z、徐 D、陈 Z、郑 K.-T. 和萨维德斯 M。标签平滑真的与知识蒸馏不兼容吗: 一项实证研究。见《国际学习表征会议》, 2020 年。14
- [37] 舒晨、刘艳、高杰、闫哲、沈超。用于密集预测的通道级知识蒸馏。《IEEE/CVF 国际计算机视觉会议论文集》, 第 5311-5320 页。2021 年。7。8
- [38] K. Simonyan 和 A. Zisserman。用于大规模图像识别的非常深的卷积网络。arXiv 预印本 arXiv:1409.1556, 2014。1
- [39] W. Son、J. Na、J. Choi 和 W. Hwang。《使用多个教师助手的密集引导知识蒸馏》。发表于《IEEE/CVF 国际计算机视觉会议论文集》, 第 9395-9404 页, 2021 年。2
- [40] M. Tan 和 Q. Le。Efficientnet: 重新思考卷积神经网络的模型缩放。见《国际机器学习会议》, 第 6105-6114 页。PMLR。2019 年。6
- [41] Y. Tian、D. Krishnan 和 P. Isola。对比表示蒸馏。见《国际学习表征会议》, 2019 年。1、6、8、14
- [42] F. Tung 和 G. Mori。保相似度知识蒸馏。见《IEEE/CVF 国际计算机视觉会议论文集》, 第 1365-1374 页。2019 年
- [43] 王宇、周伟、蒋涛、白旭、徐阳。用于语义分割的类内特征变异蒸馏。见《欧洲计算机视觉会议论文集》, 第 346-362 页。施普林格出版社, 2020 年。8
- [44] R. Wightman、H. Touvron 和 H. Jégou。《Resnet 强势回归: timm 中一种改进的训练流程》。arXiv 预印本 arXiv:2110.00476。2021。7
- [45] 谢思远 (S. Xie)、罗斯·吉尔希克 (R. Girshick)、皮奥特·多拉尔 (P. Dollár)、涂智 (Z. Tu) 和何恺明 (K. He)。深度神经网络的聚合残差变换。《IEEE 计算机视觉与模式识别会议论文集》, 第 1492-1500 页。2017 年。1
- [46] 杨晨、周航、安子 (音译)、蒋晓 (音译)、徐阳 (音译) 和张强 (音译)。用于语义分割的跨图像关系知识蒸馏。arXiv 预印本 arXiv:2204.06986。2022。8
- [47] 杨·J、马丁内斯·B、布拉特·A 和齐米罗普洛斯·G。基于 softmax 回归表示学习的知识蒸馏。见《国际学习表征会议论文集》, 2020 年。6、7、14
- [48] 游思 (S. You)、黄天 (T. Huang)、杨明 (M. Yang)、王峰 (F. Wang)、钱晨 (C. Qian) 和张聪 (C. Zhang)。《GreedyNAS: 基于贪婪超网络的快速一次性神经网络架构搜索》。发表于《IEEE/CVF 计算机视觉与模式识别会议论文集》, 第 1999-2008 页。2020 年。1

- [49] S. You, C. Xu, C. Xu 和 D. Tao. 从多个教师网络中学习。见《第 23 届 ACM SIGKDD 国际知识发现与数据挖掘会议论文集》，第 1285–1294 页，2017 年。
- [50] S. Zagoruyko 和 N. Komodakis. 更多关注注意力：通过注意力迁移提升卷积神经网络的性能。arXiv 预印本 arXiv:1612.03928. 2016.
- [51] 张 H、西塞 M、多芬 Y. N.、洛佩斯 - 帕斯 D. mixup: 超越经验风险最小化。见《国际学习表征会议》，2018 年。2. 3
- [52] 张磊和马凯。基于特征的知识蒸馏改进目标检测：迈向精确高效的检测器。《国际学习表征会议》，2020 年。7. 8
- [53] 张 X、周 X、林 M、孙 J. Shufflenet: 一种适用于移动设备的高效卷积神经网络。《IEEE 计算机视觉与模式识别会议论文集》，第 6848–6856 页，2018 年。1
- [54] 赵 H、石 J、齐 X、王 X、贾 J. 金字塔场景解析网络。《IEEE 计算机视觉与模式识别会议论文集》，第 2881–2890 页，2017 年。1、8

检查表

1. 对于所有作者.....

(a) 摘要和引言中提出的主要观点是否准确反映了论文的贡献和范围？[是]

(b) 你是否描述了工作的局限性？[是] 见附录

(c) 您是否讨论了您的工作可能带来的任何负面社会影响？[是] 见附录。

(d) 您是否已阅读伦理审查指南并确保您的论文符合这些指南？[是]

2. 如果你包含理论结果.....

(a) 你是否陈述了所有理论结果的完整假设集？[不适用]

(b) 你是否包含了所有理论结果的完整证明？[不适用]

3. 如果你进行了实验

(a) 您是否包含了重现主要实验结果所需的代码、数据和说明（无论是在补充材料中还是作为 URL）？[是] 论文中提供了训练细节。训练代码和日志已发布在 GitHub 上：<https://github.com/hunto/DIST-KD>.

(b) 您是否指定了所有训练细节（例如，数据分割、超参数及其选择方式）？[是]

(c) 你是否报告了误差线（例如，关于多次运行实验后随机种子的误差线）？[是] 报告了 CIFAR-100 的标准差

(d) 您是否包含了计算的总用量以及所使用的资源类型（例如，GPU 类型、内部集群或云服务提供商）？[是]

4. 如果你正在使用现有资产（例如代码、数据、模型）或整理 / 发布新资产.....

(a) 如果你的研究工作使用了现有资源，你是否引用了创作者？[是]

(b) 你是否提及了资产的许可？[是]

(c) 您是否在补充材料中或以 URL 形式包含了任何新资产？[是] 包含了代码和训练日志。

(d) 您是否讨论过是否以及如何从您正在使用 / 整理其数据的人那里获得同意？[不适用]

(e) 您是否讨论过您正在使用 / 整理的数据是否包含个人身份信息或攻击性内容？[不适用]

5. 如果你使用了任何测试人员或志愿者进行了研究

(a) 您是否包含了给参与者的完整指示文本以及适用的截图？[不适用]

(b) 您是否描述了任何潜在的参与者风险，并在适用情况下提供了机构审查委员会 (IRB) 批准的链接？[不适用]

(c) 您是否包含了支付给参与者的估计时薪以及用于参与者报酬的总金额？[不适用]

A 附录 14. 因子迁移 (FT) (

A.1 DIST 的实现 B. DIST 的实现

本节展示了 DIST 的实现代码，如图 4 所示。仅利用学生模型和教师模型的输出 logits，我们的 DIST 采用了相当简单的输入和计算，并且易于实现。本节展示了 DIST 的实现代码，如图 5 所示。仅利用学生模型和教师模型的输出 logits，我们的 DIST 采用了相当简单的输入和计算，并且易于实现。

```
import torch.nn as nn

def cosine_similarity(a, b, eps=1e-8):
    return (a * b).sum(1) / (a.norm(dim=1) * b.norm(dim=1) + eps)

def pearson_correlation(a, b, eps=1e-8):
    return cosine_similarity(a - a.mean(1).unsqueeze(1), b - b.mean(1).unsqueeze(1), eps)

def inter_class_relation(y_s, y_t):
    return 1 - pearson_correlation(y_s, y_t).mean()

def intra_class_relation(y_s, y_t):
    return inter_class_relation(y_s.transpose(0, 1), y_t.transpose(0, 1))

class DIST(nn.Module):
    def __init__(self, beta, gamma):
        super(DIST, self).__init__()
        self.beta = beta
        self.gamma = gamma

    def forward(self, z_s, z_t):
        y_s = z_s.softmax(dim=1)
        y_t = z_t.softmax(dim=1)
        inter_loss = inter_class_relation(y_s, y_t)
        intra_loss = intra_class_relation(y_s, y_t)
        kd_loss = self.beta * inter_loss + self.gamma * intra_loss
        return kd_loss
```

图 5: DIST 的 PyTorch (Paszke 等人, 2019) 实现。图 4: DIST 的 PyTorch [32] 实现

A.2 相关工作

存在一些知识蒸馏 (KD) 方法 [4, 30, 34]，它们将样本之间的关系从教师模型迁移到学生模型 (见图 3 进行说明)。这些方法的目的是从教师模型中学习样本之间的相似关系，例如，同类样本的语义空间应该相近，而不同类样本之间的距离应该更大。为了蒸馏这种样本关系，CCKD [34] 提出成对地衡量每个样本之间的相关性，然后最小化教师模型和学生模型之间相关分数的差异；RKD [30] 通过每对样本之间的距离和角度来构建样本关系；文献 4 引入了一种局部保持损失，将教师模型的样本关系嵌入到学生模型中。

然而，在本文中，我们聚焦于概率预测而非中间特征，并从一个新的角度利用这种关系来放宽并替代几乎所有知识蒸馏方法中的 KL 散度，这有助于我们获得更好的性能，尤其是当学生模型在更强的教师模型指导下进行训练时。此外，与以往单独衡量教师模型和学生模型实例之间关系的研究不同，我们同时提出了类间关系和类内关系，以更好地从教师模型中进行知识蒸馏。

A.3 更多消融实验

教师与学生之间的相关性。为了验证我们基于相关性的损失函数的有效性，我们测量了教师模型和学生模型之间的相关性，其中学生模型通过普通分类损失、知识蒸馏 (KD) 以及我们提出的 DIST 方法进行训练。我们选择常用的皮尔逊相关系数、斯皮尔曼相关系数 [10] 和肯德尔 tau 等级相关系数 [20] 作为相关性指标。如图 5 所示，与基线方法相比，我们的 DIST 方法获得了更高的类间和类内相关性。

在 DIST 中使用余弦相似度。在我们的方法中，关系匹配可以是任何具有式 (4) 相同形式的函数。我们在 DIST 中简单采用了常用的皮尔逊相关系数作为关系度量。在此，我们通过实验来研究余弦相似度在我们方法中的有效性。

余弦相似度和皮尔逊相关系数都能评估教师与学生之间的关系。与余弦相似度的尺度不变性相比，皮尔逊相关系数具有一种




图 5: ResNet-18 学生模型与 ResNet-34 教师模型之间的相关性。我们使用 B1 策略在 ImageNet 上对此方法进行了训练。

表 10: DIST 中余弦相似度和皮尔逊相关系数的消融实验。我们在 ImageNet 上训练学生网络 ResNet-18 和教师网络 ResNet-34，分别使用或不使用标签平滑 (LS)。

Method	w/o LS	w/ LS
Teacher	73.31	73.78
KD ($\tau = 4$)	71.21	70.71
KD ($\tau = 1$)	71.49	71.37
DIST (cosine)	71.79	71.63
DIST (Pearson)	72.07	72.18

通过先对向量进行中心化处理（参见公式 (7)），可以获得额外的平移不变性，并且它对分布变化可能更具鲁棒性。我们进行了实验，在我们的 DIST 中比较这两种指标，并在有或没有标签平滑的情况下训练模型。由于最近的研究 [3, 36] 指出，高温下的知识蒸馏 (KD) 与标签平滑不兼容，我们还使用 KD 训练了模型 ($\tau = 1$)。如表 10 所示，与知识蒸馏和使用余弦相似度的 DIST 相比，采用皮尔逊相关系数的 DIST 获得了更高的准确率，特别是当教师模型和学生模型都使用标签平滑训练时（这会使预测的概率分布发生偏移）。因此，具有尺度和平移不变性的皮尔逊相关系数可能是衡量 DIST 中关系的更好指标。

A.4 训练速度比较

我们将我们的 DIST 与普通知识蒸馏 (KD) [16]、关系知识蒸馏 (RKD) [30]、对比表示蒸馏 (CRD) [41] 和自监督表示学习 (SRRL) [47] 的训练速度进行了比较，结果汇总于表 11。我们的 DIST 几乎拥有与普通 KD 相同的最高训练速度，优于其他基于特征的知识蒸馏方法。

表 11: 使用策略 B1 在 ImageNet 上用 ResNet-34 教师模型训练 ResNet-18 学生模型的平均训练速度（批次 / 秒）。该速度是在 8 块 NVIDIA V100 GPU 上基于我们的实现进行测试的。

KD	RKD	SRRL	CRD	DIST
[16]	[30]	[47]	[41]	
14.28	11.11	12.98	8.33	14.19

A.5 匹配函数的图景

正如我们在正文中所讨论的，在知识蒸馏 (KD) 中，KL 散度和均方误差 (MSE) 等匹配函数被用于使学生模型和教师模型的输出相匹配。在 DIST 中，我们建议通过关系匹配函数（即皮尔逊距离）来放宽知识蒸馏中的匹配约束。在此，我们将 KL 散度、MSE、余弦距离和皮尔逊距离的分布情况进行可视化，以更好地展示我们在放宽约束方面的有效性。如图 6 和图 7 所示，我们随机生成一个二维向量作为学生模型和教师模型的输出对数，然后调整教师模型中的第一个元素，并目

学生的 logits (即 $z_1^{(s)}$ 和 $z_1^{(t)}$) 独立存在并修复剩余元素, 以绘制关于 $z_1^{(s)}$ 和 $z_1^{(t)}$ 的损失或梯度景观。具体来说, 当 $z_1^{(s)} = z_1^{(t)}$ 时, 学生的 logits 和

教师是完全相同的, 这些函数的损失值应该为零。当我们改变 logits 的值时, 曲线展示了损失值如何随之变化, *i.e.*, 即损失对分布偏移的敏感性。图 7 中的梯度分布表明, 我们的 DIST 中的 PCC 在非最优区域且有更陡峭的梯度曲线, 并且在最优区域拥有最大的面积。这表明我们的 DIST 能够通过更广泛的 $z_1^{(t)}$ 和 $z_1^{(s)}$ 快速优化, 因此它将会与任务损失的空余更小




图 6: 损失曲面的可视化。(a) 均方误差。(b) KL 散度。(c) 余弦距离。(d) 皮尔逊距离。

A.6 讨论

局限性。DIST 能够在分类、目标检测和语义分割等多种任务中持续改进多类分类效果。然而, 它在二分类任务上的效果较差, 因为该任务仅包含两个类别, 类间关系中的信息有限。

社会影响。研究所提出方法的有效性将消耗大量计算资源。这些工作可能会导致碳排放增加, 进而引发环境问题。然而, 所提出的知识蒸馏方法能够提升轻量级紧凑型模型的性能, 在生产中用轻量模型替代重型模型可以节省更多能源消耗, 因此有必要充分验证 DIST 的有效性。




图 7: 梯度景观可视化。