

FITNETS: 瘦深网络的提示

Adriana Romero¹, Nicolas Ballas², Samira Ebrahimi Kahou³, Antoine Chassano², Carlo Catta⁴ 和 Yoshua Bengio²¹ 西班牙巴塞罗那, 巴塞罗那大学。 ² 加拿大魁北克省蒙特利尔, 蒙特利尔大学。 [†] CIFAR 资深研究员。 ³ 加拿大魁北克省蒙特利尔, 蒙特利尔综合理工学院。 ⁴ 西班牙贝拉特拉, 计算机视觉中心。

摘要

虽然深度往往能提升网络性能, 但也会使基于梯度的训练变得更加困难, 因为更深的网络往往具有更强的非线性。最近提出的知识蒸馏方法旨在获得小型且执行快速的模型, 研究表明, 学生网络可以模仿更大的教师网络或网络集成的软输出。在本文中, 我们扩展了这一理念, 不仅利用教师网络的输出, 还将其学习到的中间表示作为提示, 来训练比教师网络更深、更精简的学生网络, 以改进训练过程并提升学生网络的最终性能。由于学生网络的中间隐藏层通常比教师网络的中间隐藏层小, 因此引入了额外的参数, 用于将学生网络的隐藏层映射到对教师网络隐藏层的预测。这使得我们能够训练出泛化能力更好或运行速度更快的更深层学生网络, 而这种权衡由所选的学生网络容量控制。例如, 在 CIFAR-10 数据集上, 一个参数数量减少近 10.4 倍的深度学生网络, 其性能超过了更大的、最先进的教师网络。

1 引言

深度网络最近在计算机视觉任务(如图像分类和目标检测)中展现出了最先进的性能(Simonyan & Zisserman, 2014; Szegedy 等人, 2014)。然而, 性能顶尖的系统通常涉及非常宽且深的网络, 包含大量参数。此类宽而深的模型一旦训练完成, 一个主要缺点是在推理时会导致系统耗时极长, 因为它们需要执行大量的乘法运算。此外, 大量的参数使得这些模型对内存的需求很高。由于这些原因, 性能顶尖的宽深网络并不适合有内存或时间限制的应用场景。

文献中已有多项尝试致力于解决模型压缩问题, 以减轻推理时的计算负担。在 Bucila 等人(2006)的研究中, 作者提出训练一个神经网络来模仿复杂且庞大的集成模型的输出。该方法利用集成模型对未标记数据进行标记, 并使用经集成模型标记的数据来训练神经网络, 从而模仿集成模型所学到的函数, 同时达到相近的准确率。这一理念在 Ba 和 Caruana(2014)的研究中得到了最新应用, 他们将深层宽网络压缩为更浅但更宽的网络, 其中压缩后的模型通过使用深层网络(或深层网络集成)标记的数据来模仿复杂模型所学到的函数。更近一些, 知识蒸馏(KD)(Hinton 和 Dean, 2014)被引入作为一种模型压缩框架, 它通过遵循师生范式来简化深层网络的训练——在这种范式中, 学生会根据教师输出的软化版本受到惩罚。该框架将深层网络集成(教师)压缩为深度相近的学生网络。为此, 学生网络在训练时既要预测教师网络的输出, 也要预测真实的分类标签。所有先前与卷积神经网络相关的研究都侧重于将一个教师网络或网络集成压缩为宽度和深度相近的网络, 或者压缩为更浅更宽的网络, 而没有利用深度这一特性。

深度是表示学习的一个基本方面，因为它有助于特征的复用，并能在更高层产生更抽象且具有不变性的表示 (Bengio 等人, 2013)。深度的重要性已得到验证：(1) 从理论上讲，对于某些函数族，深度表示的表达能力比浅层表示呈指数级增强 (Montufar 等人, 2014)；(2) 从经验上讲，ImageNet 竞赛中表现顶尖的两个模型分别采用了具有 19 层和 22 层的深度卷积网络 (Simonyan 与 Zisserman, 2014; Szegedy 等人, 2014)。

然而，训练深度架构已被证明具有挑战性 (Larochelle 等人, 2007; Erhan 等人, 2009)，因为它们由连续的非线性组成，因此会产生高度非凸且非线性的函数。人们已投入大量精力来缓解这一优化问题。一方面，预训练策略，无论是无监督的 (Hinton 等人, 2006; Bengio 等人, 2007) 还是有监督的 (Bengio 等人, 2007)，都以贪婪的逐层方式训练网络参数，以便将网络参数初始化在一个潜在的良好吸引域中。各层会根据中间目标依次进行训练。同样，半监督嵌入 (Weston 等人, 2008) 为中间层提供指导，以帮助学习极深的网络。基于这一思路，(Cho 等人, 2012) 在纯无监督场景下，通过每隔一层借用另一个模型的激活值，来缓解深度玻尔兹曼机 (DBM) 的优化问题。最近，(Chen-Yu 等人, 2014; Szegedy 等人, 2014; Gulcehre 与 Bengio, 2013) 表明，为深度架构的中间层添加监督有助于深度网络的训练。这种监督是通过在中间隐藏层顶部堆叠一个带有 softmax 层的有监督多层感知机 (MLP) 来实现的，以确保它们相对于标签具有判别性。另外，课程学习策略 (CL) (Bengio, 2009) 通过修改训练分布来解决优化问题，使得学习网络能够逐渐接收相对于已学概念而言难度适当且不断增加的样本。因此，课程学习类似于一种延续方法，它加快了训练过程的收敛速度，并能在高度非凸的代价函数中找到潜在更优的局部最小值。

在本文中，我们旨在利用深度来解决网络压缩问题。我们提出了一种新颖的方法来训练轻薄且深层的网络，称为 FitNets，以压缩宽而较浅（但仍然是深层）的网络。该方法源于最近提出的知识蒸馏 (KD) (Hinton & Dean, 2014)，并对这一理念进行了扩展，以支持更轻薄、更深层的学生模型。我们从教师网络的隐藏层引入中间层提示，来指导学生网络的训练过程，即我们希望学生网络 (FitNet) 学习一种能够预测教师网络中间表示的中间表示。这些提示使得训练更轻薄、更深层的网络成为可能。结果证实，更深层的模型能让我们实现更好的泛化，而使这些模型更轻薄则有助于显著减轻计算负担。我们在 MNIST、CIFAR-10、CIFAR-100、SVHN 和 AFLW 基准数据集上验证了所提出的方法，结果表明，我们的方法在参数数量和乘法运算量显著减少的情况下，性能达到或超过了教师网络。

2 方法

在本节中，我们详细介绍了用于从更浅更宽的网络训练 FitNets 的师生框架。首先，我们回顾了最近提出的知识蒸馏 (KD)。其次，我们重点介绍了所提出的提示算法，该算法在整个训练过程中为 FitNet 提供指导。最后，我们阐述了 FitNet 如何以分阶段的方式进行训练。

2.1 知识蒸馏综述

为了获得更快的推理速度，我们探索了最近提出的压缩框架 (Hinton & Dean, 2014)，该框架从一组更宽网络（即教师网络）的软化输出中训练出一个学生网络。其理念是让学生网络不仅能捕捉真实标签所提供的信息，还能捕捉教师网络所学到的更精细的结构。该框架可总结如下。

设 T 为一个教师网络，其输出 softmax 为 $p_T = \text{softmax}(a_T)$ ，其中对于某个示例， a_T 是教师 softmax 前激活的向量。当教师模型是单个网络时， a_T 表示输出层的加权和，而如果教师模型是集成的结果，则 p_T 或 a_T 通过对不同网络的输出进行平均得到（分别对应算术平均或几何平均）。设 S 为一个具有参数的学生网络

m_e 和输出概率 $p_S = \text{softmax}(a_S)$ ，其中 a_e 是学生的 softmax 前输出。学生网络将接受训练，使其输出 p_S 与教师的输出 p_T 以及真实标签 y_{true} 相似。由于 p_T 可能非常接近样本真实标签的独热码表示，因此引入了一种松弛方法 $\tau > 1$ 来软化来自教师网络输出的信号，从而在训练过程中提供更多信息¹。当将学生网络的输出 (p_S) 与教师的软化输出 (p_{τ}) 进行比较时，会应用相同的松弛方法：

$$p_{\tau} = \text{softmax}(a_T^{\tau}), p_{\tau} = \text{softmax}(a_S^{\tau}). (1)$$

然后训练学生网络以优化以下损失函数：

$$\mathcal{L}_{KD}(W_S) = \mathcal{H}(y_{true}, p_S) + \lambda \mathcal{H}(p_{\tau}, p_S). (2)$$

其中， $\mathcal{H}$ 表示交叉熵， λ 是一个可调节参数，用于平衡这两个交叉熵。请注意，式 (2) 中的第一项对应于（学生）网络输出与标签之间的传统交叉熵，而第二项则促使学生网络从教师网络的软化输出中学习。

据我们所知，知识蒸馏 (KD) 的设计初衷是让学生网络模仿深度相近的教师网络结构。我们发现，即使学生网络的结构稍深，知识蒸馏框架也能取得令人鼓舞的结果，但当我们增加学生网络的深度时，知识蒸馏训练仍然会面临深度网络优化的难题（参见第 4.1 节）。

2.2 基于提示的训练

为了助力深度 FitNet（比其教师网络更深）的训练，我们引入了来自教师网络的提示。提示被定义为教师网络隐藏层的输出，其作用是指导学生网络的学习过程。相应地，我们会从 FitNet 中选择一个隐藏层，即被指导层，让其向教师网络的提示层学习。我们希望被指导层能够预测提示层的输出。需要注意的是，提示的存在是一种正则化形式，因此，必须合理选择提示层与被指导层这一组合，以避免学生网络出现过度正则化的情况。被指导层设置得越深，网络所拥有的灵活性就越低，FitNet 也就越有可能受到过度正则化的影响。在我们的研究中，我们选择教师网络的中间层作为提示层。同样地，我们选择学生网络的中间层作为被指导层。

鉴于教师网络通常比 FitNet 更宽，所选的提示层可能比被引导层有更多的输出。因此，我们在被引导层添加了一个回归器，其输出与提示层的大小相匹配。然后，我们通过最小化以下损失函数来训练从第一层到被引导层的 FitNet 参数以及回归器参数：

$$\mathcal{L}_{HT}(W_{Guided}, W_m) = \frac{1}{2} \|u_h(x; W_{Hint}) - r(u_m(x; W_{Guided}); W_m)\|^2. (3)$$

其中， u_h 和 u_m 是教师 / 学生的深度嵌套函数，分别达到其各自的提示层 / 被引导层，参数为 W_{Hint} 和 W_{Guided} ， r 是被引导层顶部的回归器函数，参数为 W_m 。注意， u_h 和 r 的输出必须具有可比性，i.e.、 u_h 和 r 必须是相同的非线性函数。

然而，在引导层和提示层为卷积层的情况下，使用全连接回归器会显著增加参数数量和内存消耗。令 $N_{h1} \times N_{h2}$ 和 O_h 分别为教师提示的空间大小和通道数。同样，令 $N_{s1} \times N_{s2}$ 和 O_s 为 FitNet 引导层的空间大小和通道数。全连接回归器权重矩阵中的参数数量为

$N_{h1} \times N_{h2} \times O_h \times N_{s1} \times N_{s2} \times O_s$ 。为了缓解这一限制，我们改用卷积回归器。卷积回归器的设计使其考虑的输入图像空间区域与教师提示大致相同。因此，回归器的输出具有与教师提示相同的空间大小。给定空间大小为 $N_{h1} \times N_{h2}$ 的教师提示，回归器接收 Fitnet 引导层的输出。

例如，正如 Hinton 和 Dean (2014) 所主张的，借助软化的输出，除了提供与概率最高的类别相关的信息外，还能提供更多关于输入与其他类别的相对相似性的信息。




图 1: 使用提示训练学生网络。

大小为 $N_{L-1} \times N_{L-2}$ 的层, 并调整其核形状 $L_1 \times L_2$, 使得 $N_{L-1} - L_2 + 1 = N_{L-2}$, 其中 $i \in 1 \dots 2$ 。卷积回归器权重矩阵中的参数数量为 $L_1 \times L_2 \times O_L \times O_{L-1}$, 其中 $L_1 \times L_2$ 显著低于 $N_{L-1} \times N_{L-2} \times N_{L-1} \times N_{L-2}$ 。

2.3 FITNET 阶段式训练

我们按照学生 / 教师范式, 以分阶段的方式训练 FitNet。图 1 总结了训练流程。从一个训练好的教师网络和一个随机初始化的 FitNet 开始 (图 1 (a)), 我们在 FitNet 引导层的顶部添加一个由 m_r 参数化的回归器, 并训练 FitNet 中直至引导层的参数 $W_{Guided}^{1:g}$, 以最小化公式 (3) (见图 1 (b))。最后, 基于预训练的参数, 我们训练整个 FitNet m_s 的参数, 以最小化公式 (2) (见图 1 (c))。算法 1 详细说明了 FitNet 的训练过程。

算法 1 FitNet 阶段式训练

该算法接收的输入包括: 教师模型的已训练参数 W_T 、FitNet 的随机初始化参数 m_s , 以及分别对应提示层和引导层的两个索引 h 和 g 。令 W_{Hint} 为教师模型直至提示层 h 的参数。令 W_{Guided} 为 FitNet 直至引导层 g 的参数。令 W_r 为回归器的参数。第一阶段是基于教师模型提示层的预测误差, 对学生网络直至引导层进行预训练 (第 4 行)。第二阶段是对整个网络进行知识蒸馏训练 (第 6 行)。

Input:	W_S, W_T, g, h
Output:	W_S^*
1:	$W_{Hint} \leftarrow \{W_T^1, \dots, W_T^h\}$
2:	$W_{Guided} \leftarrow \{W_S^1, \dots, W_S^g\}$
3:	Initialize W_r to small random values
4:	$W_{Guided}^* \leftarrow \argmin_{W_{Guided}} \mathcal{L}_{HT}(W_{Guided}, W_r)$
5:	$\{W_S^1, \dots, W_S^g\} \leftarrow \{W_{Guided}^{*1}, \dots, W_{Guided}^{*g}\}$
6:	$W_S^* \leftarrow \argmin_{W_S} \mathcal{L}_{KD}(W_S)$

2.4 与课程学习的关系

在本节中, 我们认为我们基于提示的知识蒸馏 (KD) 训练可以被视为课程学习 (Curriculum Learning) 的一种特定形式 (Bengio, 2009)。课程学习通过适当地选择学习者所接触的一系列训练分布 (从简单示例到更复杂的示例), 已被证明能够加快训练收敛速度, 并有可能提高模型的泛化能力。课程学习的一项扩展研究 (Gulcehre 和 Bengio, 2013) 还表明, 通过在训练过程中对中间层使用引导提示, 能够显著简化训练过程。然而, Bengio (2009) 使用手工定义的启发式方法来衡量序列中示例的“简单性”, 而 Gulcehre 和 Bengio (2013) 的引导提示则需要一些关于最终任务的先验知识。这两种课程学习策略都倾向于针对特定问题。

我们的方法通过使用教师模型来缓解这一问题。实际上, 教师模型学习到的中间表示被用作提示, 以指导 FitNet 的优化过程。此外, 教师模型的置信度通过教师交叉熵提供了一种衡量样本“简单性”的方法。

式 (2) 中的这一项确保高教师置信度的样本比低教师置信度的样本具有更强的影响：后者对应的概率更接近均匀分布，对学生模型参数的推动作用更小。换句话说，教师会根据自身的置信度对训练样本进行惩罚。需要注意的是，式 (2) 中的参数 λ 控制着教师交叉熵的权重，进而控制着每个样本的重要性。为了促进对更复杂样本（教师置信度较低的样本）的学习，我们在训练过程中通过线性衰减逐步降低 λ 。该课程学习过程可以分为两个阶段：首先通过提示 / 引导层迁移学习中间概念，然后联合训练整个学生网络，同时降低 λ ，这使得较简单的样本（教师对其非常有把握的样本）在初始阶段能产生更强的影响，但随着 λ 的衰减，其重要性会逐渐降低。因此，本文提出的基于提示的训练是一种通用的课程学习方法，其中关于当前任务的先验信息纯粹是从教师模型中推导出来的。

Algorithm	# params	Accuracy
<i>Compression</i>		
FitNet	~2.5M	91.61%
Teacher	~9M	90.18%
Mimic single	~54M	84.6%
Mimic single	~70M	84.9%
Mimic ensemble	~70M	85.8%
<i>State-of-the-art methods</i>		
Maxout		90.65%
Network in Network		91.2%
Deeply-Supervised Networks		91.78%
Deeply-Supervised Networks (19)		88.2%

表 1: CIFAR-10 上的准确率

Algorithm	# params	Accuracy
<i>Compression</i>		
FitNet	~2.5M	64.96%
Teacher	~9M	63.54%
<i>State-of-the-art methods</i>		
Maxout		61.43%
Network in Network		64.32%
Deeply-Supervised Networks		65.43%

表 2: CIFAR-100 上的准确率

3 基准数据集上的结果

在本节中，我们展示了在多个基准数据集上的结果²。所有网络的架构以及训练细节均在补充材料中给出。

3.1 CIFAR-10 和 CIFAR-100

CIFAR-10 和 CIFAR-100 数据集 (Krizhevsky 和 Hinton, 2009) 分别由属于 10 个和 100 个不同类别的 32×32 像素 RGB 图像组成。它们都包含 50K 训练图像和 10K 测试图像。CIFAR-10 每个类别有 1000 个样本，而 CIFAR-100 每个类别有 100 个样本。与 Goodfellow 等人 (2013b) 一样，我们对数据集进行了归一化以实现对比度归一化，并应用了 ZCA 白化。

CIFAR-10: 为了验证我们的方法，我们训练了一个由 maxout 卷积层构成的教师网络，如 Goodfellow 等人 (2013b) 所报道的那样，并设计了一个拥有 17 个 maxout 卷积层的 FitNet，其后是一个 maxout 全连接层和一个顶层 softmax 层，参数数量约为教师网络的 1/3。学生网络的第 11 层被训练以模仿教师网络的第 2 层。与 Goodfellow 等人 (2013b)、Chen-Yu 等人 (2014) 的做法相同，我们在训练过程中通过随机翻转对数据进行增强。表 1 总结了所获得的结果。我们的学生模型性能优于教师模型，同时所需参数明显更少，这表明深度对于获得更好的表征至关重要。与网络压缩方法相比，我们的算法取得了优异的结果；例如，学生网络达到了 91.61% 的准确率，显著高于 Ba 和 Caruana (2014) 的最佳结果 85.8%，同时所需参数约少 28 倍。与最先进的方法相比，我们的算法与最佳性能相当。

有人可能会认为，选择用宽教师网络的隐藏状态来提示内层网络是合理的。一个简单直接的替代方案是用期望输出对它们进行提示。这可以通过几种不同的方式来实现：(1) 分阶段训练，其中第一阶段根据分类目标优化网络的前半部分，第二阶段根据分类目标优化整个网络。

² 用于复现实验的代码已公开: <https://github.com/adri-romsors/FitNets>

目标。在这种情况下，阶段 1 将网络参数设置在一个良好的局部最小值处，但这种初始化似乎并没有充分帮助阶段 2，导致阶段 2 无法学习。为了进一步辅助瘦长深层学生网络的训练，我们可以在不同的隐藏层添加带有期望输出的额外提示。然而，正如（Bengio 等人，2007）所观察到的，在有监督预训练的情况下，被引导层可能会丢弃输入中的一些因素，而这些因素需要经过更多的层和非线性处理后才能被用于预测类别。（2）采用知识蒸馏（KD）的分阶段训练，其中阶段 1 针对分类目标优化网络的前半部分，阶段 2 则根据公式（2）优化整个网络。与前一种情况类似，阶段 1 将网络参数设置在一个良好的局部最小值处，但这种初始化似乎也没有充分帮助阶段 2，导致阶段 2 学习失败。（3）针对被引导层的有监督提示和输出层的分类目标之和，对两个阶段进行联合优化。我们进行了这项实验，使用 RMSprop（Tieleman 和 Hinton，2012）尝试了不同的初始化和学习率，但未能找到任何能使网络学习的组合。需要注意的是，我们可以通过像深度监督网络（DSN）那样在每个层添加提示并进行联合优化来简化训练。因此，我们构建了上述 19 层架构，并通过 DSN 对其进行训练，取得了 88.2% 的测试性能，这明显低于通过 FitNets 基于提示的训练所获得的性能（91.61%）。这一结果表明，在中间层使用与分类相关的极具判别性的提示可能过于激进；而使用更平滑的提示（例如来自教师网络的引导）则能提供更好的泛化能力。（4）针对被引导层的有监督提示和输出层的公式（2）之和，对两个阶段进行联合优化。在网络的中间层添加有监督提示并没有简化这种瘦长深层网络的训练，网络仍无法学习。

CIFAR-100：为了验证我们的方法，我们按照 Goodfellow 等人（2013b）的报道，训练了一个包含 maxout 卷积层的教师网络，并使用了与 CIFAR-10 中相同的 FitNet 架构。与 Chen-Yu 等人（2014）的做法一样，我们在训练过程中通过随机翻转对数据进行了增强。表 2 总结了所获得的结果。与之前的情况相同，我们的 FitNet 性能优于教师模型，将参数数量减少了三分之二，并且与最先进的方法相比，FitNet 的性能接近最先进水平。

3.2 SVHN

SVHN 数据集（Netzer 等人，2011 年）由谷歌街景收集的 32×32 彩色门牌号图像组成。训练集中有 73257 张图像，测试集中有 26032 张图像，还有 531131 个难度较低的样本。我们遵循 Goodfellow 等人（2013b）的评估流程，并将他们的 maxout 网络用作教师模型。我们训练了一个 13 层的 FitNet，它由 11 个 maxout 卷积层、一个全连接层和一个 softmax 层组成。

Algorithm	# params	Misclass
<i>Compression</i>		
FitNet	~1.5M	2.42%
Teacher	~4.9M	2.38%
<i>State-of-the-art methods</i>		
Maxout		2.47%
Network in Network		2.35%
Deeply-Supervised Networks		1.92%

表 3: SVHN 误差

Algorithm	# params	Misclass
<i>Compression</i>		
Teacher	~361K	0.55%
Standard backprop	~30K	1.9%
KD	~30K	0.65%
FitNet	~30K	0.51%
<i>State-of-the-art methods</i>		
Maxout		0.45%
Network in Network		0.47%
Deeply-Supervised Networks		0.39%

表 4: MNIST 误差

表 3 显示，尽管我们的 FitNet 仅使用了教师模型 32% 的容量，但其准确率与教师模型相当。我们的 FitNet 在性能上可与其他最先进的方法相媲美，例如 Maxout 和 Network in Network。

3.3 MNIST

为了对训练过程进行合理性检验，我们在 MNIST 数据集（LeCun 等人，1998）上评估了所提出的方法。MNIST 是一个手写数字（0 到 9）数据集，由 28×28 像素的灰度图像组成，包含 60K 张训练图像和 10K 张测试图像。我们按照 Goodfellow 等人（2013b）的报道，训练了一个由 maxout 卷积层构成的教师网络，并设计了一个

FitNet 的深度是教师网络的两倍，参数约为教师网络的 8%。学生网络的第 4 层经过训练，以模仿教师网络的第 2 层。

表 4 报告了所获得的结果。为了验证使用提示的影响，我们使用以下三种方式训练了 FitNet 架构：

(1) 标准反向传播（针对分类标签）、(2) 知识蒸馏 (KD) 或 (3) 基于提示的训练 (HT)。当从 softmax 层使用标准反向传播训练 FitNet 时，这种深而窄的架构实现了 1.9% 的错误分类率。使用知识蒸馏时，同一网络的错误分类率达到 0.65%，这证实了教师网络的潜力；而添加提示后，错误率进一步降至 0.51%。此外，学生网络的表现略优于教师网络，同时所需参数减少了 12 倍。

3.4 美国劳联

AFLW (Koestinger 等人, 2011) 是一个真实世界的人脸数据库，包含 25K 张带标注的图像。为了在人脸识别场景中评估所提出的框架，我们通过调整图像标注区域的大小以适配 16×16 像素的补丁来提取正样本。同样地，我们从 ImageNet (Russakovsky 等人, 2014) 数据集中提取了 25K 个不含人脸的 16×16 像素补丁作为负样本。我们使用 90% 的提取补丁来训练网络。

在本实验中，我们旨在另一种架构上评估该方法。为此，我们训练了一个包含 3 个 ReLU 卷积层和 1 个 sigmoid 输出层的教师网络。我们设计了第一个 FitNet (FitNet 1)，其乘法运算量比教师网络少 15 倍；第二个 FitNet (FitNet 2) 的乘法运算量比教师网络少 2.5 倍。两个 FitNet 均包含 7 个 ReLU 卷积层和 1 个 sigmoid 输出层。

教师网络在验证集上的错误分类率为 4.21%。我们通过知识蒸馏 (KD) 和提示训练 (HT) 两种方式对 FitNets 进行了训练。一方面，使用 KD 训练 FitNet 1 时，错误分类率为 4.58%；使用 HT 训练时，错误分类率为 2.55%。另一方面，使用 KD 训练 FitNet 2 时，错误分类率为 1.95%；使用 HT 训练时，错误分类率为 1.85%。这些结果表明，该方法可扩展到不同类型的架构，并凸显了使用提示的优势，尤其是在处理更精简的架构时。

4 实证结果分析

我们通过比较使用标准反向传播（关于标签的交叉熵）、知识蒸馏 (KD) 或基于提示的训练 (HT) 训练的各种网络，实证研究了我们的方法的优势。实验在 CIFAR-10 数据集上进行 (Krizhevsky 和 Hinton, 2009)。

在固定计算预算下，我们对深度不断增加的网络进行了比较。每个网络由连续的 3×3 卷积核大小的卷积层组成，随后是 maxout 非线性激活函数和非重叠的 2×2 最大池化。最后的最大池化会对所有剩余的空间维度取最大值，得到 1×1 的向量表示。我们仅改变不同网络之间的深度和每个卷积的通道数，也就是说，为了符合给定的计算预算，随着网络深度的增加，每个卷积层的通道数会减少。

4.1 辅助深度网络的训练

在本节中，我们研究了 HT 的影响。我们考虑了两种计算预算，分别约为 3000 万和 1.07 亿次运算，这与图像前向传播所需的乘法运算量相对应。对于每种计算预算，我们训练的网络由 3、5、7 和 9 个卷积层组成，其后是一个全连接层和一个 softmax 层。我们比较了它们在使用标准反向传播、KD 和 HT 训练时的性能。图 2 报告了在 CIFAR-10 上的测试结果，该测试使用验证集进行早停，即我们没有在训练集加验证集上重新训练模型。

由于深度较深且容量较小，FitNets 难以训练。如图 2 (a) 所示，使用标准反向传播，我们无法训练具有超过 5 层、3000 万次乘法运算的网络。而使用知识蒸馏 (KD) 时，我们成功训练出了多达 7 层的网络。在训练目标中加入知识蒸馏的教师交叉熵（公式 (2)）会更重视较简单的样本，即教师网络有信心的样本，这可能会使训练成本更平滑 (Bengio, 2009)。尽管知识蒸馏在优化方面有一些优势，但值得注意的是，知识蒸馏训练仍然存在




图 2: 标准反向传播、知识蒸馏和基于提示的训练在 CIFAR-10 上的比较。

Network	# layers	# params	# mult	Acc	Speed-up	Compression rate
Teacher	5	~9M	~725M	90.18%	1	1
FitNet 1	11	~250K	~30M	89.01%	13.36	36
FitNet 2	11	~862K	~108M	91.06%	4.64	10.44
FitNet 3	13	~1.6M	~392M	91.10%	1.37	5.62
FitNet 4	19	~2.5M	~382M	91.61%	1.52	3.60

表 5: CIFAR-10 上的精度 / 速度权衡。

随着深度的增加, 7 层网络达到了其极限。HT 有助于缓解这些优化问题, 并且能够训练具有 3000 万次乘法运算的 13 层网络。HT 和 KD 之间的唯一区别在于参数空间中的起点: 要么是随机的, 要么是通过教师的提示获得的。一方面, 在高度非线性函数 (如非常深的网络) 中, 局部最小值尤其是鞍点的大量存在, 凸显了随机在参数空间中找到良好起点的难度 (Dauphin 等人, 2014)。另一方面, 图 2 (a) 中的结果表明, HT 可以引导学生在参数空间中找到更好的初始位置, 从该位置我们可以通过随机梯度下降来最小化成本。因此, HT 从优化的角度带来了益处。当我们固定网络容量和层数时, 使用 HT 训练的网络往往比其他训练方法产生更好的测试性能。例如, 在图 2 (b) 中, 使用提示训练的 7 层网络在测试集上的性能比不使用任何提示的模型提高了 0.7% (准确率从 89.45% 提高到 90.1%)。正如 Erhan 等人 (2009) 所指出的, 预训练策略可以起到正则化器的作用。这些结果表明, HT 是比 KD 更强的正则化器, 因为它能在测试集上带来更好的泛化性能。最后, 图 2 强调, 在固定计算预算的情况下, 深层模型比浅层模型具有更好的性能。实际上, 考虑使用提示训练的网络, 对于 1.07 亿次乘法运算, 11 层网络比 5 层网络的绝对性能提升了 4.11%; 对于 3000 万次乘法运算, 提升了 3.4%。因此, 实验验证了我们的假设: 在固定计算量的情况下, 我们可以利用模型的深度来实现更快的计算和更好的泛化。

总之, 本实验表明: (1) 与标准反向传播和知识蒸馏 (KD) 相比, 使用 HT 能够训练更深的模型; (2) 在容量固定的情况下, 更深的模型比更浅的模型表现更好。

4.2 模型性能与效率之间的权衡

为了评估 FitNets 的效率, 我们测量了它们在 GPU 上处理 CIFAR-10 测试样本所需的总推理时间以及参数压缩情况。表 5 报告了各种 FitNets 相对于教师模型的加速比和压缩率, 以及它们的层数、容量和精度。在本实验中, 为了与教师模型进行公平比较, 我们按照 Goodfellow 等人 (2013b) 的方法, 在训练集和验证集上重新训练了我们的 FitNets。

FitNet 1 是我们最小的网络，其容量比教师网络低 36 倍，速度却比教师网络快一个数量级，且性能仅略有下降，降幅为 1.3%。FitNet 2 的容量略有提升，性能比教师网络高出 0.9%，同时速度仍快 4.64 倍，优势显著。通过进一步增加 FitNets 3 和 4 的网络容量与深度，我们将性能提升幅度提高到了 1.6%，且速度仍快于教师网络。尽管压缩率带来了速度与精度之间的权衡，但 FitNets 往往速度明显更快，即便在容量较低的情况下，也能达到或超过教师网络的性能。

一些研究工作，如矩阵分解 (Jaderberg 等人, 2014; Denton 等人, 2014)，致力于加快深度网络卷积层的运算速度，但代价是会略微降低其性能。这类方法与 FitNets 具有互补性，可用于进一步加快 FitNet 卷积层的速度。

其他与量化方案相关的研究 (Chen 等人, 2010; Jégou 等人, 2011; Gong 等人, 2014) 旨在降低存储需求。与 FitNets 不同，这类方法在压缩网络参数时，性能只会出现轻微下降。借助深度，FitNets 即使将参数数量减少 10 倍，其性能也能优于教师网络。不过，我们认为量化方法与 FitNets 也是互补的，可用于进一步降低存储需求。比较教师网络的滤波器与 FitNet 的滤波器之间存在多少冗余，以及由此确定 FitNets 的滤波器在不出现显著性能下降的情况下可被压缩多少，这将是一件有趣的事。该分析不在本文的研究范围内，留待未来工作中进行。

5 结论

我们提出了一个新颖的框架，通过引入教师网络隐藏层的中间级提示来指导学生网络的训练过程，将宽而浅的网络压缩为窄而深的网络。我们能够利用这些提示来训练参数更少的极深学生模型，这些模型的泛化能力可能优于教师网络，且 / 或运行速度更快。我们提供的实证证据表明，用教师网络的隐藏状态提示窄而深网络的内层，比用分类目标提示它们的泛化效果更好。我们在基准数据集上的实验强调，低容量的深度网络能够提取出与参数多达其 10 倍的网络相当甚至更优的特征表示。这种基于提示的训练表明，应投入更多精力探索新的训练策略，以充分利用深度网络的能力。

致谢

我们感谢 Theano (Bastien 等人, 2012) 和 Pylearn2 (Goodfellow 等人, 2013a) 的开发者，以及加拿大计算中心 (Compute Canada) 和魁北克计算中心 (Calcul Québec) 提供的计算资源。本研究得到了加拿大科学与工程研究委员会 (NSERC)、加拿大高级研究所 (CIFAR)、加拿大研究主席计划、TIN2013-41751 项目、2014-SGR-221 资助以及西班牙经济与竞争力部 (MINECO) TIN2012-38187-C03 资助的部分支持。

参考文献

- Ba, J. 和 Caruana, R. 深度网络真的需要很深吗？发表于《神经信息处理系统进展》，第 2654-2662 页，2014 年。
- 巴斯蒂安 (F.)、兰布林 (P.)、帕斯坎努 (R.)、伯格斯特拉 (J.)、古德费洛 (I.)、伯杰龙 (A.)、布沙尔 (N.)、沃德 - 法利 (D.) 和 Bengio (Y.)。Theano: 新功能与速度改进。深度学习与无监督特征学习研讨会，神经信息处理系统大会。2012 年。
- Bengio, Y. 为人工智能学习深度架构。《机器学习基础与趋势》。2009 年。
- Bengio, Y., Lamblin, P., Popovici, D., 和 Larochelle, H. 深度网络的贪婪逐层训练。收录于《神经信息处理系统进展》。第 153-160 页。2007 年。
- Bengio, Y., Courville, A., 和 Vincent, P. 表示学习：综述与新视角。《IEEE 模式分析与机器智能汇刊》，2013 年。
- Bucila, C., Caruana, R. 和 Niculescu-Mizil, A. 模型压缩。见《KDD》，第 535-541 页，2006 年。
- 陈永健、关涛、王程。基于残差矢量量化的近似最近邻搜索。《传感器》，10 (12):11259-11273，2010。

- 陈宇, L., 赛宁, X., 帕特里克, G., 郑友, Z. 和朱文, T. 深度监督网络. CoRR, abs/1409.5185, 2014.
- Cho, Kyunghyun, Raiko, Tapani, Ilin, Alexander 和 Karhunen, Juha. 深度玻尔兹曼机的两阶段预训练算法。见《神经信息处理系统大会深度学习与无监督特征学习研讨会论文集》。2012 年。
- 多芬 (Y.), 帕斯坎努 (R.), 古尔切雷 (C.), 赵 (K.), 冈古利 (S.) 和 Bengio (Y.). 《识别并解决高维非凸优化中的鞍点问题》。收录于《神经信息处理系统进展》。2014 年。
- Denton, Emily L, Zaremba, Wojciech, Bruna, Joan, LeCun, Yann 和 Fergus, Rob. 《利用卷积网络中的线性结构进行高效评估》。发表于《神经信息处理系统进展》。第 1269-1277 页。2014 年。
- Erhan, D., Manzagol, P.A., Bengio, Y., Bengio, S. 和 Vincent, P. 深度架构训练的难点及无监督预训练的影响。见《AISTATS》。第 153-160 页。2009 年。
- 龚云超, 刘柳, 杨敏和卢博米尔·布尔杰夫。使用矢量量化压缩深度卷积网络。CoRR, abs/1412.6115, 2014.
- 古德费洛, I. J., 沃德 - 法利, D., 兰布林, P., 杜穆兰, V., 米尔扎, M., 帕斯坎努, R., 伯格斯特拉, J., 巴斯蒂安, F. 和本吉奥, Y.。Pvlearn2: 一个机器学习研究库。arXiv 预印本 arXiv:1308.4214. 2013a。
- 古德费洛 (I.J.), 沃德 - 法利 (D.), 米尔扎 (M.), 库维尔 (A.) 和 Bengio (Y.). Maxout 网络。发表于《国际机器学习会议论文集》。2013b。
- Gulcehre, C. 与 Bengio, Y. 知识至关重要: 先验信息对优化的重要性。发表于《国际学习表征会议》(ICLR), 2013 年。
- 辛顿 (G. E.), 奥辛德罗 (S.) 和 Teh (Y.-W.). 深度信念网络的快速学习算法。《神经计算》, 18 (7): 1527–1554, 2006。
- 辛顿 (G.), 维尼尔斯 (O.) 和迪恩 (J.). 《提炼神经网络中的知识》。收录于《深度学习与表征学习研讨会论文集》。神经信息处理系统大会。2014 年。
- Jaderberg, M., Vedaldi, A. 和 Zisserman, A. 利用低秩扩展加速卷积神经网络。发表于《英国机器视觉会议论文集》。2014 年。
- Jégou, Hervé, Douze, Matthijs 和 Schmid, Cordelia. 用于最近邻搜索的乘积量化。《IEEE 模式分析与机器智能汇刊》。33 (1):117–128. 2011。
- Koestinger, M., Wohlhart, P., Roth, P.M. 和 Bischof, H. 野外环境中的带注释面部标志点: 一个用于面部标志点定位的大规模真实世界数据库。收录于《第一届 IEEE 面部图像分析技术基准测试国际研讨会论文集》, 2011 年。
- 克里热夫斯基 (A.) 和辛顿 (G.). 《从微小图像中学习多层特征》。硕士论文, 多伦多大学计算机科学系, 2009 年。
- 拉罗谢尔 (H.), 埃尔汉 (D.), 库维尔 (A.), 伯格斯特拉 (J.) 和本吉奥 (Y.). 《深度架构在多变异因素问题上的实证评估》。发表于《国际机器学习会议论文集》, 第 473-480 页, 2007 年。
- LeCun, Y., Bottou, L., Bengio, Y. 和 Haffner, P. 基于梯度的学习在文档识别中的应用。《IEEE 汇刊》, 86 (11):2278–2324. 1998 年 11 月。
- 蒙图法尔 (G.F.), 帕斯坎努 (R.), 赵 (K.) 和 Bengio (Y.). 关于深度神经网络的线性区域数量。收录于《神经信息处理系统进展》。2014 年。
- Netzer, Y., Wang, T., Coates, A., Bissacco, A., Wu, B., 和 Ng, A. 利用无监督特征学习读取自然图像中的数字。发表于《神经信息处理系统大会 (NIPS) 深度学习与无监督特征学习研讨会》。2011 年。
- Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Huang, Z., Karpathy, A., Khosla, A., Bernstein, M., Berg, A. C. 以及 Fei-Fei, L.。ImageNet 大规模视觉识别挑战赛。2014 年。
- Simonyan, K. 和 Zisserman, A. 用于大规模图像识别的非常深的卷积网络。CoRR, abs/1409.1556, 2014.
- Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., D.A., Erhan, D., Vanhoucke, V., 以及 Rabinovich, A. 利用卷积进行更深层次的研究。CoRR. abs/1409.4842. 2014.
- Tieleman, T. 和 Hinton, G. 第 6.5 讲 —— RmsProp: 用梯度近期幅度的移动平均值对梯度进行除法运算。COURSERA: 机器学习神经网络。2012 年。
- Weston, J., Ratle, F., 和 Collobert, R. 基于半监督嵌入的深度学习。发表于《国际机器学习会议论文集》, 2008 年。

补充材料：网络架构和训练流程

在补充材料中，我们描述了整篇论文中使用的所有网络架构和超参数。

A.1 CIFAR-10/CIFAR-100

在本节中，我们将描述教师网络和 FitNet 架构，以及在 CIFAR-10/CIFAR-100 实验中使用的超参数。

A.1.1 教师网络

我们使用了 Goodfellow 等人 (2013b) 中报道的 CIFAR-10/CIFAR-100 maxout 卷积网络作为教师模型。这两个教师模型具有相同的架构，分别由 3 个卷积隐藏层组成，单元数为 96-192-192。每个卷积层之后是 maxout 非线性激活函数（包含 2 个线性部分）和一个最大池化算子，其窗口大小分别为 4x4、4x4 和 2x2 像素。所有最大池化单元的重叠区域为 2x2 像素。第三个卷积层之后是一个包含 500 个单元的全连接 maxout 层（包含 5 个线性部分）和一个顶层 softmax 层。CIFAR-10/CIFAR-100 教师模型采用随机梯度下降和动量法进行训练。更多细节请参考 Goodfellow 等人 (2013b)。

A.1.2 拟合网络

在此，我们将介绍第 3 节和第 4 节中使用的 FitNet 架构。每个 FitNet 由连续的零填充卷积层（核大小为 3×3 ）组成，其后是具有两个线性分段的 maxout 非线性激活函数。部分卷积层之后会进行非重叠的 2×2 最大池化操作；每个网络总共有 3 个最大池化单元。最后一个最大池化会对所有剩余的空间维度取最大值，得到 1×1 的向量表示。与 CIFAR10/100 教师模型一样，最后一个卷积层之后会连接一个全连接层和一个 softmax 层。

表 6 描述了图 2 中深度实验所使用的架构。表 7 描述了表 5 中效率 - 性能权衡实验的架构。表 1、表 2 和表 3 中报告的结果对应于 FitNet 4 架构。

所有 FitNet 参数均在 $U(-0.005, 0.005)$ 范围内随机初始化。我们使用带有 RMSProp (Tieleman 和 Hinton, 2012) 的随机梯度下降来训练 FitNets，初始学习率为 0.005，小批量大小为 128。式 (2) 中的参数 λ 初始化为 4，并在 500 个 epoch 内线性衰减至 $\lambda = 1$ 。松弛项 τ 设置为 3。

在 CIFAR-10 数据集上，我们将训练集划分为 40K 个训练样本和 10K 个验证样本。我们通过最小化公式 (3) 来训练第一阶段，并在验证误差连续 100 个 epoch 未得到改善后停止训练，最多训练 500 个 epoch。之后，我们使用 RMSprop 优化器，通过最小化公式 (2) 来训练第二阶段，采用与第一阶段相同的停止标准和超参数。我们根据上述停止标准选择最佳的 epoch 数量，并在整个 50K 训练样本（训练集 + 验证集）上重新训练 FitNet。

在 CIFAR-100 上，我们使用随机梯度下降结合 RMSprop 直接在整个训练集上进行训练，采用与 CIFAR-10 的 FitNets 相同的超参数，且训练轮数由 CIFAR-10 的停止准则确定。

A.2 MNIST

在本节中，我们将描述教师网络和 FitNet 架构，以及在 MNIST 实验中使用的超参数。

我们按照 Goodfellow 等人 (2013b) 的报道，训练了一个由 maxout 卷积层构成的教师网络。该教师网络架构包含三个卷积 maxout 隐藏层（每个层有 2 个线性分段），分别有 48、48 和 24 个单元，随后是 4x4、4x4 和 2x2 像素的空间最大池化，其中

5 Layer	7 Layer	9 Layer	11 Layer
conv 3x3x64 (3x3x128) pool 2x2	conv 3x3x16 (3x3x32) conv 3x3x32 (3x3x64) pool 2x2	conv 3x3x16 (3x3x32) conv 3x3x32 (3x3x32) pool 2x2	conv 3x3x16 (3x3x16) conv 3x3x16 (3x3x32) conv 3x3x16 (3x3x32) pool 2x2
conv 3x3x64 (3x3x128) pool 2x2	conv 3x3x32 (3x3x80) conv 3x3x64 (3x3x80) pool 2x2	conv 3x3x32 (3x3x64) conv 3x3x32 (3x3x80) conv 3x3x32 (3x3x80) pool 2x2	conv 3x3x32 (3x3x48) conv 3x3x32 (3x3x64) conv 3x3x32 (3x3x80) pool 2x2
conv 3x3x64 (3x3x128) pool 8x8	conv 3x3x64 (3x3x128) pool 8x8	conv 3x3x48 (3x3x96) conv 3x3x64 (3x3x128) pool 8x8	conv 3x3x48 (3x3x96) conv 3x3x48 (3x3x96) conv 3x3x64 (3x3x128) pool 8x8
fc softmax	fc softmax	fc softmax	fc softmax
hint: 2 $\leftarrow$ 2	hint: 4 $\leftarrow$ 2	hint: 5 $\leftarrow$ 2	hint: 7 $\leftarrow$ 2

表 6: 计算预算为 3000 万 (或 1.07 亿) 次乘法运算的 Fitnet 架构: conv $s_m \times s_n \times c$ 是核大小为 $s_m \times s_n$ 、输出通道数为 c 的卷积; pool $s_m \times s_n$ 是大小为 $s_m \times s_n$ 的非重叠池化; fc 代表全连接。提示: FitNet - 教师分别指定了用于基于提示训练的提示层和引导层。

FitNet 1	FitNet 2	FitNet 3	FitNet 4
conv 3x3x16 conv 3x3x16 conv 3x3x16 pool 2x2	conv 3x3x16 conv 3x3x32 conv 3x3x32 pool 2x2	conv 3x3x32 conv 3x3x48 conv 3x3x64 conv 3x3x64 pool 2x2	conv 3x3x32 conv 3x3x32 conv 3x3x32 conv 3x3x48 conv 3x3x48 pool 2x2
conv 3x3x32 conv 3x3x32 conv 3x3x32 pool 2x2	conv 3x3x48 conv 3x3x64 conv 3x3x80 pool 2x2	conv 3x3x80 conv 3x3x80 conv 3x3x80 conv 3x3x80 pool 2x2	conv 3x3x80 conv 3x3x80 conv 3x3x80 conv 3x3x80 conv 3x3x80 conv 3x3x80 pool 2x2
conv 3x3x48 conv 3x3x48 conv 3x3x64 pool 8x8	conv 3x3x96 conv 3x3x96 conv 3x3x128 pool 8x8	conv 3x3x128 conv 3x3x128 conv 3x3x128 pool 8x8	conv 3x3x128 conv 3x3x128 conv 3x3x128 conv 3x3x128 conv 3x3x128 conv 3x3x128 pool 8x8
fc softmax	fc softmax	fc softmax	fc softmax
hint: 6 $\leftarrow$ 2	hint: 6 $\leftarrow$ 2	hint: 8 $\leftarrow$ 2	hint: 11 $\leftarrow$ 2

表 7: 性能 - 效率适配网络架构。

2x2 像素的重叠。第三个隐藏层之后是一个全连接的 softmax 层。与 Goodfellow 等人 (2013b) 的做法一样，我们在第二个卷积层添加了零填充。

我们设计的 FitNet 深度是教师网络的两倍，参数数量约为教师网络的 8%。学生网络架构包含 6 个 maxout 卷积隐藏层（每个层有 2 个线性部分），分别有 16、16、16、16、12、12 个单元。最大池化仅每间隔一层应用一次，池化区域分别为 4x4、4x4、2x2 像素，重叠部分为 2x2 像素。第 6 个卷积隐藏层之后是一个全连接的 softmax 层。

教师网络的训练方式如 Goodfellow 等人 (2013b) 所述。FitNet 的训练采用了第 2 节中描述的分阶段方式。我们将训练集分为包含 50K 样本的训练集和包含 10K 样本的验证集。

所有网络参数均在 $U(-0.005, 0.005)$ 范围内随机初始化。在第一阶段，通过随机梯度下降最小化式 (3)，训练 FitNet 的第 4 层以模仿教师网络的第 2 层。我们使用 128 个样本的小批量大小，并将学习率固定为 0.0005。我们将 λ 初始化为 4，并在最初的 150 个 epoch 内对其进行衰减，直到其达到 1。训练根据以下标准停止：在 100 个 epoch 内验证误差没有改善，且最多进行 500 个 epoch。我们使用相同的小批量大小、学习率和停止标准来训练第二阶段。松弛项 τ 设置为 3。

A.3 SVHN

在本节中，我们将介绍教师网络和 FitNet 架构，以及在 SVHN 实验中使用的超参数。

我们使用了 Goodfellow 等人 (2013b) 所描述的 SVHN maxout 卷积网络作为教师模型。该网络由 3 个分别包含 64、128 和 128 个单元的卷积隐藏层组成，随后是一个包含 400 个单元的全连接 maxout 层和一个顶层 softmax 层。教师模型的训练过程遵循 Goodfellow 等人 (2013b) 的方法。

我们使用了表 7 中概述的 FitNet 4 架构，在 $U(-0.005, 0.005)$ 范围内随机初始化网络参数，并采用与 CIFAR-10 中相同的超参数进行训练。在这种情况下，我们使用了与 CIFAR-10 中相同的早停策略，但没有在整个训练集（训练集 + 验证集）上重新训练 FitNet。两个阶段使用了相同的超参数。

A.4 AFLW

在本节中，我们将介绍教师网络和 FitNet 架构，以及在 AFLW 实验中使用的超参数。

我们训练了一个教师网络，该网络包含 3 个 ReLU 卷积层，分别有 128、512 和 512 个单元，其后是一个 sigmoid 层。在第一个卷积层之后进行了大小为 2×2 的非重叠最大池化操作。我们为每个层分别使用了 3-2-5 的感受野。

我们设计了两个包含 7 个 ReLU 卷积层的 FitNet。FitNet 1 的各层分别有 16、32、32、32、32、32、32 个单元，其后是一个 sigmoid 层。FitNet 2 的各层分别有 32、64、64、64、64、64、64 个单元，其后同样是一个 sigmoid 层。在这两种情况下，我们都使用了 3×3 的感受野，并且由于图像分辨率非常小，没有进行任何最大池化操作。

两个 FitNet 的所有网络参数均在 $U(-0.05, 0.05)$ 范围内随机初始化。两个 FitNet 均按照第 2 节中描述的分阶段方式进行训练。我们使用 90% 的数据用于训练。在第一阶段，通过随机梯度下降最小化公式 (3)，训练 FitNet 的第 5 层以模仿教师网络的第 3 层。我们采用 128 个样本的小批量大小，初始学习率设为 0.001，并在最初的 100 个 epochs 内将其衰减至 0.01。我们还使用了动量法，初始动量设为 0.1，并在第 100 个 epoch 时饱和至 0.9。我们在 500 个 epochs 后选取最佳验证值。第二阶段的训练采用了相同的小批量大小、学习率和停止准则。松弛项 τ 设为 3。