

源论文链接：[Attention and feature transfer based knowledge distillation | Scientific Reports](#)

这不是一篇很厉害的文章。

预知识

一、AT

1. 核心定义

AT（文献 30）是首个将注意力图迁移引入知识蒸馏（KD）的经典模型，通过强制学生网络模仿教师的类激活图（CAM），让学生学习“教师在分类时关注的关键区域”。其核心逻辑是：注意力图（推理过程）的迁移能提升学生对“有效信息”的聚焦能力。

2. 技术实现

- CAM 生成：

AT 基于 CNN 的全连接层权重，将其投影回最后一层卷积特征图，生成反映“类别判别区域”的 CAM。公式为：

$$CAM_j(x, y) = \sum_{i=1}^C W_i^j A_i(x, y)$$

其中， W_i^j 是全连接层第 j 类对第 i 通道的权重， A_i 是卷积特征图。CAM 通过像素值高低表示“该区域对类别 j 的重要性”。

- 注意力迁移：

教师将 CAM 作为“注意力图”传递给学生，学生通过最小化“师生 CAM 的 MSE 损失”，学习教师的关注模式。AT 的损失函数为：

$$L_{AT} = \sum_k \frac{1}{C_k H_k W_k} \left\| \frac{\text{Norm}(CAM_{teacher}^k)}{\|\text{Norm}(CAM_{teacher}^k)\|_2} - \frac{\text{Norm}(CAM_{student}^k)}{\|\text{Norm}(CAM_{student}^k)\|_2} \right\|_2^2$$

3. 贡献与局限

- 贡献：首次证明“迁移推理过程（注意力）”的有效性，为注意力基 KD 奠定基础；在 CIFAR-100 上，AT 使学生（VGG8）准确率达 71.43%（相同师生架构，表 5）。
- 局限：仅迁移最后一层的 CAM，忽略中间层的连续推理过程；未对 CAM 进行二值化等优化，注意力图的“关键区域”不够突出。

二、CAT-KD

1. 核心创新

CAT-KD (文献 19, CVPR 2023) 是当时注意力基 KD 的先进方法, 针对 AT 的局限提出两点改进:

- **卷积替代 CAM:**
通过 1×1 卷积生成更精细化的注意力 (非单纯 CAM), 并通过**二值化操作** (0/1 掩码) 突出教师关注的核心区域, 避免学生学习到模糊的弱相关区域。
- **中间层连续迁移:**
将 CAM 的生成推广到 CNN 的**所有中间层** (不仅最后一层), 强制学生模仿教师在不同推理阶段的注意力分布, 捕捉“从局部到全局”的持续关注逻辑。

2. 技术细节 (基于文档实验部分)

- **二值化 CAM:**
对教师中间层的预激活特征 (Pre-Feature) 生成 CAM 后, 通过阈值二值化 (如 0.5), 仅保留教师“最关注的区域” (白色), 过滤无关背景 (黑色), 提升注意力图的针对性。
- **自适应损失权重:**
在 CIFAR-100 实验中, CAT-KD 通过调整“注意力损失权重 β ” (如 1~50), 平衡 CE 损失与注意力损失, 避免单一损失主导训练。

3. 性能表现

- 在 CIFAR-100 上, 当教师为 ResNet32x4、学生为同架构时, CAT-KD 学生准确率达 76.91%, 优于 AT 的 73.44% (表 5);
- 当师生架构不同 (如教师 ResNet32x4 $\rightarrow$ 学生 ShuffleNetV1), CAT-KD 准确率 78.26%, 仅略低于 AFT-KD 的 78.39% (表 4), 证明其竞争力。

AFD




Figure 1. Illustration of AFT-KD. To align the teacher and student network, we divide it into N stages of reasoning. The value of N varies in different teacher-student structures. For example, N equals 3 in the experiment in section "Exploration of AFB".




Figure 2. Illustration of AFB generation method.

人们总在蒸馏的路上越来越严格。

从一开始的标签蒸馏，到特征图蒸馏。到本论文之中认为仅仅是外化内容的蒸馏不能满足学到推理过程的需求，要求把这个推理的过程一起引导学生学习，但是这个推理过程物理意义上存在于教师模型的参数逻辑之中，不能外化。所以只能另辟蹊径，寻找简单的代替品。然而，这些不严谨的逻辑，也给了我对于本文章不太好的印象。

推理过程和结果

强调了，模型在传统KD（AT+KD）之中，直接学习特征图是学习老师推理之后的结果，那现在要学习老师推理的过程。

推理的过程认为可以体现在 $PreF$ 之中

$$F = ReL(PreF)$$

所以推理过程的信息集中在这个preF之中

利用这个preF，在经过上图二的步骤，最后与preF相加，就是推理过程和推理结果的融合了。

$$CAM = Binary(Conv1 * 1(PreF))$$

$$AF = CAM + ReL(PreF)$$

动态权重

$$L = \alpha L_{cls} + \beta L_{AF}$$

$$rC = LC/LC$$

$$rAF = LAF/LAF$$

$$\alpha = rC / \frac{rC + rAF}{2}$$

$$\beta = rAF / \frac{rC + rAF}{2}$$

- L 表示训练第一个epoch得到的损失值
- r 是一个衰减比率

核心思想是，要是这个衰减比例越小，就代表训练的越好，需要的权重就动态调整的越小。

缺点

现有的蒸馏严重依赖与模型的相似性，也就是存在契合的几个层用来AFD，否则只能是简单的认为对齐。

更加严重的是，有时候还会用到插值法或者 $1 * 1$ 卷积来消除两边特征图的差距，这样有损性能。

不同架构的网络没办法实现蒸馏/效果很差。