

思考

get

- 全局和实例

question

- PCC的梯度不好计算，对于所有样本求和太繁杂了（解决，根据批次计算）
- PCC的相关性真的拟合的很好吗，没有精确值，看起来不像是一个很好的损失函数。并且只能适用于分类
- 有时候教师模型做出模糊判断是被场景误导，并且这只适用于分类。如果在全局上使用，可能会误导模型，这可能适用于**图像分割**之后的检测。
- 如果当个样本拟合效果很好，何必要在全局再做一次


前言

KD是knowledge Distill知识蒸馏，DIST是本文提出的观点


B1，B2是一种训练策略

Table 1: Training strategies on image classification tasks. *BS*: batch size; *LR*: learning rate; *WD*: weight decay; *LS*: label smoothing; *EMA*: model exponential moving average; *RA*: RandAugment [9]; *RE*: random erasing; *CJ*: color jitter.

Strategy	Dataset	Epochs	Total BS	Initial LR	Optimizer	WD	LS	EMA	LR scheduler	Data augmentation
A1	CIFAR-100	240	64	0.05	SGD	5×10^{-4}	-	-	$\times 0.1$ at 150,180,210 epochs	crop + flip
B1	ImageNet	100	256	0.1	SGD	1×10^{-4}	-	-	$\times 0.1$ every 30 epochs	crop + flip
B2	ImageNet	450	768	0.048	RMSProp	1×10^{-5}	0.1	0.9999	$\times 0.97$ every 2.4 epochs	{B1} + RA + RE
B3	ImageNet	300	1024	5e-4	AdamW	5×10^{-2}	0.1	-	cosine	{B2} + CJ + Mixup + CutMix



(a) Stronger model sizes



(b) Stronger strategies


Figure 1: Comparisons of KD and our proposed DIST on ImageNet with different teachers. (a) The ResNet-18 students are trained using baseline strategy with different model sizes of the teacher. (b) The ResNet-18 students are trained using different strategies with ResNet-50 teachers.

- **挑战一**：当教师模型越来越强大（大尺寸或先进训练策略如标签平滑、数据增强），KD出现了无法跟上学习的现象，表现为准确率下降
- **挑战二**：当训练策略优化，教师模型得到了更好的结果，kd却出现了比不kd更坏的结果

核心观点：

蒸馏的核心是保留教师模型输出的结果的相对关系，而不是绝对的准确值（直接学习准确值 seems way too overambitious and demanding），我们需要改进KL散度（放宽限制），使得学生更好的学习相对关系。

创新



输出概率

- 两者都进行温度处理，实验中温度取4

$$y^{(t)} = \text{softmax}\left(\frac{y^{(t)}}{t}\right)$$

$$y^{(s)} = \text{softmax}\left(\frac{y^{(s)}}{t}\right)$$

PCC

PCC是皮尔逊相关系数 (Pearson Correlation Coefficient, PCC)

是衡量 类间关系损失的指标。“类间关系”指单个实例对所有类别的概率排序关系（例如：教师模型认为“实例 1 属于类 A 的概率 > 类 B > 类 C”，学生模型需保留这种排序，而非精确匹配概率值）

PCC 本质是“归一化后的协方差”，能反映两个变量的线性相关程度（取值范围 $[-1, 1]$ ），越接近 1 说明关系越一致；若直接用 PCC 作为“匹配指标”，则损失可定义为“1 - PCC”（即皮尔逊距

离)，损失越小表示师生关系越一致。

有点类似于我们的**线性相关系数**（实际上就是），一堆离散数据根据公式判断是否线性相关，分子那一块能够根据面积来模拟推导，要是线性相关，面积相加减会变得很大，要是出现一些不和谐的点，就会导致面积变小或者变成负数。从而得到是否线性相关

在线性相关函数之中， $r=1$ 表示随着 x 增大， y 增大的线性相关性最强， $r=-1$ 表示随着 x 增大， y 减小。 $r=0$ 表示 x 增大， y 可能减小可能增大。

那么我们根据这个思想，推广一下，如果我们将学生模型输入作为 x ，教师模型输入作为 y ，那么我们想要他们的排序相同，也就是 x 增大， y 应该随之增大，这样就构成了顺序关系

给出公式，针对一个样本 i ，**基于一个批次**

$$r_i = \frac{Cov(x^{(s)}, y^{(t)})}{Std(x^{(t)})Std(y^{(s)})}$$
$$r_i = \frac{\sum_{j=1}^C (x_{i,j}^{(s)} - \bar{x}_i^{(s)})(y_{i,j}^{(t)} - \bar{y}_i^{(t)})}{\sum_{j=1}^C (x_{i,j}^{(s)} - \bar{x}_i^{(s)})^2 \cdot \sum_{j=1}^C (y_{i,j}^{(t)} - \bar{y}_i^{(t)})^2}$$

这个 r_i 描述了教师和学生两者的线性相关性，我们需要确保它能够接近最大值，根据梯度优化的原理，损失值应该设定为

$$L_{inter} = \frac{1}{2} \cdot \sum_{i=1}^N (1 - r_i)$$

intra

统计针对于单个类别的所有预测（教师和学生），输出针对于一个类别的唯一向量，该向量能够根据全局数据统计“看到”这个类别的时候，最有可能和什么类别混淆。

简单来说，就是根据全局输出，对于每一个类别输出一个向量，例如类别A的向量，记录了(类别A > 类别C > 类别D)，这个向量能够代表这个类别

值得注意的是，这是**基于一个批次统计的**

损失函数， C 表示类别

$$L_{intra} = \frac{1}{C} \sum_{j=1}^C (1 - p_j)$$

所以说，在全局上修正了学生模型和教师模型预测的结果偏差

损失函数

$$L = \alpha L_{cls} + \beta L_{inter} + L_{intra}$$