

一般来说，后面的训练不需要冻结前面的权重

- 特征图的训练使用MSE损失函数
- 要是特征不匹配，需要多加一个层使得特征匹配，是否会损失性能不知道，但是解决了教师模型和学生模型必然存在的模型不同大小的问题

实现注意事项

1. 需要在输出层使用相同的激活函数
2. 注意在中间层使用特征对齐，越靠后学生网络的灵活性和可变性越低
3. 需要对于输出的特征图进行归一化，保证方差和平均值一致，以免数值大的参数层主导了梯度下降

cifar10数据集

```
classes = ('plane', 'car', 'bird', 'cat', 'deer', 'dog', 'frog', 'horse',  
           'ship', 'truck')
```

试验


验证在引导的时候，多加的一个矩阵是否会影响到模型的性能，当验证集的准确率相差超过0.8%时，认为有差距。

两个试验，需要保证的前提是，

1. 使用同样的教师模型，使用同样的层引导
2. 必要时改变学生模型，在相同的位置进行特征引导
3. 两种基线模型的表现要一致

教师网络训练结果

train/teacher_loss



Run ↑

Value

Step


Relative

0.1731

19,500

16.96 min

train/teacher_epoch_loss



Run ↑

Value


Step

Relative

0.2225


50

16.76 min



基线网络训练结果

train/baseline_loss



Run ↑

Value

Step


Relative

0.2841

43,000

13.58 min

train/baseline_epoch_loss



Run ↑

Value


Step

Relative

0.3365


60

13.41 min




学生网络蒸馏效果

只进行蒸馏，不进行特征引导



train/distill_epoch_loss



Run ↑

Value

Step


Relative

0.8514

50

20.2 min

train/distill_acc



Run ↑

Value

Step


Relative

83.5938

19,500

20.44 min

train/distill_epoch_acc



Run ↑

Value

Step


Relative

87.386

50

20.2 min



- 蒸馏分类损失







试验一

前后分布训练,


- stage one : 引导层前面的网络进行fitnet训练
- stage two : 固定引导层以及前面的网络, 进行后续网络的单独训练









- 蒸馏各个损失记录






试验二

- stage one : 在引导层以及之前做训练
- stage two : 将stage one当作预训练来看, 在预训练的基础上再次进行训练, 观察否能够得到更好的效果



train/distill_loss




Run ↑

Value

Step

Relative

train/distill_epoch_loss




Run ↑


Value


Step

Relative





- 蒸馏的各个损失记录






测试结果






• stage one



• stage two



试验总结

模型	教师	基线	学生（蒸…	学生（实验…	学生（实验…
损失	0.222	0.339	0.85	1.38	0.73

模型	教师	基线	学生（蒸…	学生（实验…	学生（实验…
训练准确率	92.7%	88.42%	87.38%	81.24%	88.4%
验证准确率	87.09%	83.99%	84.05%	80.64%	86.36%
fit损失	-	-	-	0.23	0.23
软损失	-	-	1.05	0.97	0.40
硬损失	-	-	1.96	2.66	1.49
参数量	1.35M	306k~0.3M	306K~0.3M	306k~0.3M	306k~0.3M

教师&基线比较

- 损失：两者使用了不同的学习率，学习率比较大的基线模型在收敛速度上较快；但是教师网络最终的损失比较小，这是在意料之内的，因为教师模型的表示能力比基线模型更强；两者在收敛之后稳定性都很好。
- 准确率：教师模型，基线模型在训练集上的准确率分别达到了**92.6%**和**88.5%**，可以看出，两者的差距比较明显，提升了绝对4%，两者都没有出现过拟合现象
- 测试：两者在测试集上最佳准确率分别是**87%**和**84%**，**教师模型的表示能力高于基线模型**。在正常训练时，教师模型在epoch25时大概达到收敛，基线模型在15时达到收敛。

总结：教师模型能力强于基线模型，在更少的训练epoch之中达到了更好的效果，准确率有不小的差距。

试验一&二比较

- fit损失：两次试验在stage one没有区别，损失都在0.23左右，表现不错，在2000×100步，也就是epoch6的时候都趋向于收敛。
- distill损失：损失分别为**1.3**和**0.7**，差距较大。在epoch程度损失函数较为平稳，但是从微观来看，实验一在不同的步骤损失浮动比较大。实验二在试验后期趋向于平稳。实验一收敛比较快。
两者在hard和soft损失上表现差距很大，实验二明显优于实验一
- 准确率：**81%**和**88%**，差距很大
- 测试集：**80.6%**和**86.3%**，差距很大

总结：实验二的效果显著优于实验一，我归结为以下要点

1. 冻结了前面的层之后，模型只需要调整后面的部分参数，所以试验一收敛比较快。这可以认为在已有输出的后面接上一个**分类头**，只需要调整分类头的部分参数。模型比较小，收敛比

较快。但是，前面的层都接也就意味着，前面输出的特征图就是**一定程度上的原始图片**，这个微笑的模型要处理这个图片，是很艰难的。

2. 试验一在stage one之后，不一定能够保证引导层前面的参数学习教师模型的效果很优秀，**少参数经过学习之后不一定能够正确/完整替代多参数的表达效果**。考虑到两次试验都收敛到同一个损失，我们有理由相信这两次的训练都到达了最佳的效果。但是这个最佳效果在后续的实验一蒸馏之中并没有带来很好的效果。
3. **冻结参数影响了模型的调整能力**。冻结参数扼杀了根据正确标签纠正的机会。相反，解冻参数能够让模型在当前的模型之中，将引导层的输出调整向更适合小参数模型的方向。


基线&学生&实验二比较

- 损失：学生和基线没有比较的必要，两者性质不同/实验二损失低于学生模型
- 准确率：两者都达到了88.4%的准确率，这一点惊人的相似
- 测试：**84% 和 86.3%**，fitnet模型有所提升。基于相同准确率考量，第二个模型的泛化效果更好

总结：

1. 基线和实验二在训练集上的正确率相等，但是实验二的泛化能力更好，一个观点就是**教师引导学生走向了正确方向**，一个观点是**蒸馏本身加强了模型的泛化能力**。但是学生和实验二表明，两者都发挥了作用。两者叠加效果更加。
2. **教师模型带领学生模型走向正确的方向**。虽然我们提到了，实验一之中少参数不能很好学习多参数的结论，但是它引导模型从局部最小值中走出，走向接近于教师的正确方向，因此，实验二训练之后相较于基线模型能够收敛向一个更好的结果。

分类结果分析



- dog 和 cat 两者错误最多
- student相较于teacher在一些方面有所提升。