

前言

我们倾向于将模型学习到的知识和其参数对应起来，这使得我们很难理解如何在保持相同知识的情况下，改变模型的形式。

文章之中提出，学习的知识最后体现在能够**正确从输入映射到输出**。知识还可以体现在这些映射结果之中，也就是模型可能还会为错误的标签赋予一定的数值，这之中包含了模型对于知识的理解，还可以说，是该**模型泛化能力**的体现。

- 注：泛化能力描述了模型在学习训练集的数据之后，理解数据并且运用到新知识的能力。

知识蒸馏

给出经典公式

$$\text{SoftMax}(x_i, T) = \frac{\exp(x_i/T)}{\sum_{x \in X} \exp(x/T)}$$

- 数学理解：T的增大，会把x拉回到一个小范围，由于导数的递增属性，使得他们的差距被缩小，起到了放大错误样本的功能。

在计算损失函数的时候，利用了硬标签和软标签，既要学习正确的样本，又要兼顾知识蒸馏。

在计算梯度的时候，x由于温度附带上了 $1/t^2$ 的梯度，因此在计算损失函数时要乘回去 T^2

交叉熵函数

详情请见 [熵](#) 一章节

- 教师模型生成的软标签为 $(p = [p_1, p_2, \dots, p_N])$ (N为类别数， (p_i) 是教师对第i类的软概率，由教师 $\text{logit}(v_i)$ 通过T下的 softmax 生成: $p_i = \frac{\exp(v_i/T)}{\sum_j \exp(v_j/T)}$;
- 学生模型预测的软概率为 $q = [q_1, q_2, \dots, q_N]$ (由学生 $\text{logit}(z_i)$ 通过相同T下的 softmax 生成);

则软目标交叉熵损失为：

$$L_{\text{soft}} = - \sum_{i=1}^N p_i \cdot \log(q_i)$$


- 在最后，软目标的损失函数比重要设计的远大于硬标签
则**最终蒸馏损失**为：

$$L_{\text{distill}} = (1 - \alpha) \cdot T^2 \cdot L_{\text{soft}} + \alpha \cdot L_{\text{hard}}$$


实验


试验结果1——自定义模型

教师





- 最高准确率达









基线






学生







验证集





试验结果2——ResNet模型

教师

- 损失





- 准确率 —— 在训练集上达到了94.5以上，非常亮眼




基线

- 损失，在2以上，相较于teacher逊色许多，不过训练时不稳定，震荡程度大






- 准确率——震荡十分明显，可能是由于lr高





对于epoch的训练集准确率到达了92.5的水平，也是稍微逊色




学生

- 损失（两张图标签颠倒了）
震荡程度很小，但是损失值比较大




- 分类损失


硬标签的损失十分的高，他和正确标签之间存在一些距离（一部分来源于软标签的T值）




软标签的震荡十分大，也是保持在0.3之上，值也很大



- 准确率——准确率十分高，在baseline的92.5和教师模型的94.5之间，达到了93




小模型震荡的比较严重




验证集

来看看泛化的表现


- teacher——在epoch30最佳模型达到了93.67%的准确率，在跳出了局部最小值后十分平稳



- baseline——在epoch33最佳模型达到了92.29%的准确率，训练不平稳，比教师模型差了1.5%



- student——在epoch33和epoch47都达到了93.05%左右的正确率，收敛后基本平稳，相较于基线模型，有接近0.8%的提升。



结果分析


1. 模型的表现

模型	参数量	训练集Accuracy	测试集Accuracy
teacher (ResNet)	1351.1K ~ 1.35M	95.59%	93.67%
baseline (简单卷积)	175K ~ 1.75M	92.50%	92.29%
student (同baseline)	175K ~ 1.75M	93.09%	93.05%

在模型架构和参数量相等的条件下

- **训练速度**：蒸馏模型比空白模型收敛更快
- **训练稳定性**：在损失函数方面，蒸馏模型不稳定；然而在体现模型真实表现的验证集上，却蒸馏模型更稳定
- **准确性/泛化能力**：在拟合训练集时，蒸馏模型获得更好效果，搞了绝对0.5%，并且在泛化能力上，蒸馏模型也更加强大，接近教师模型的表现

2. 模型出错分析



观察teacher和baseline模型，两者出奇的一致，分布很相同。

学生模型在蒸馏之后，对于类别6明显出错有所减少。

相较于baseline，student模型出错的概率情况比较平均。